

統計section1～10

- 統計section1～10
 - 1 事象と確率
 - 1.1 ベイズの定理
 - 1.1.1 何が嬉しいのか：恒等式の書き換えが持つ「因果の逆転」の魔力
 - 1.1.2 結論：何が凄すぎるのか？
 - 2 確率分布と母関数
 - 2.1 繰り返しの法則
 - 何これ：神の視点の平均を「条件ごとの平均の平均」で求める
 - 何が嬉しいのか？
 - 2.2 確率母関数
 - 何これ：確率分布を「多項式の係数」として閉じ込めた圧縮ファイル（ZIP）
 - 何が嬉しいのか？：面倒な「和の計算」が「微分の作業」に大化けする
 - 2.3 モーメント母関数
 - 何これ：確率分布の情報を「マクローリン展開の係数」として保存する汎用ZIPファイル
 - 何が嬉しいのか？：分布の「指紋」であり、微分の威力がさらに上がる
 - 3 分布の特性値
 - 3.1 変動係数
 - 何これ：スケール（単位や大きさ）が全く違うもの同士の「相対的なブレ」を公平に比べる指標
 - 何が嬉しいのか？
 - 3.2 歪度（わいど / Skewness）
 - 何これ：分布が「どっちに尻尾（裾）を引いているか」を表す非対称性の指標
 - 覚え方のコツ
 - 3.3 尖度（せんど / Kurtosis）
 - 何これ：正規分布と比べて「極端な外れ値が出やすいか（ファットテールか）」を測る指標
 - 何が嬉しいのか？
 - 3.4 共分散
 - 何これ：2つの変数が「どれくらい連動して動くか」を表す相互作用（クロスターム）
 - 何が嬉しいのか？
 - 3.5 相関係数
 - 何これ：共分散を「単位を持たないキレイなスケール（-1から1）」に規格化したもの
 - 3.6 偏相関関係（偏相関係数）
 - 何これ：共通の「黒幕」の影響を差し引いた、純粋な1対1の関係性
 - 公式の覚え方
 - 3.7 様々な平均
 - 何これ：データの「性質」に合わせて、適切な「平らにならす方法」を使い分けるツール
 - 3.7.1 加重平均（Weighted Average）
 - 3.7.2 幾何平均（Geometric Mean）
 - 3.7.3 調和平均（Harmonic Mean）
 - 3.8 行列表現
 - 確率変数ベクトルと平均ベクトル
 - 分散共分散行列（理論値）
 - 標本分散共分散行列（データから計算）
 - 相関行列
 - 何これ：多次元の「ゆらぎの形状」を記述する慣性テンソル
 - 何が嬉しいのか？：線形代数を使って「データの固有状態」を抽出できる
 - 4 変数変換
 - 4.1 $Y = g(X)$ の変換
 - 何これ：確率という「粉」の総量（面積=1）を保つための「連続の式（質量保存則）」
 - 何が嬉しいのか？
 - 4.2 $Z = X + Y$ の変換
 - 何これ：波の「畳み込み（コンボリューション）」
 - 何が嬉しいのか？
 - 4.3 Box-Cox変換

- 何これ：歪んだ世界を「正規分布（ユークリッド空間）」に無理やり平坦化する魔法のレンズ
 - 何が嬉しいのか？
- 5 離散型分布
 - 5.1 離散一様分布
 - 何これ：すべての選択肢が完全に平等な、もっともピュアな「サイコロ」の分布
 - 5.2 ベルヌーイ分布
 - 何これ：すべての離散型分布の「原子」（1回きりの丁半バクチ）
 - 何が嬉しいのか？
 - 5.3 二項分布
 - 何これ：ベルヌーイ分布の「コピペ&足し算」
 - 何が嬉しいのか？（再生性の意味）
 - 5.4 超幾何分布
 - 何これ：くじを「戻さない（非復元）」せいで、引くたびに確率が変化するリアルな二項分布
 - 何が嬉しいのか？
 - 5.5 Poisson（ポアソン）分布
 - 何これ：無限回クジを引けるが、当たる確率がほぼゼロの世界（レア事象の分布）
 - 何が嬉しいのか？
 - 5.6 幾何分布
 - 何これ：「SSRが出るまでガチャを引き続ける」ときの、爆死回数の分布
 - 5.7 負の二項分布
 - 何これ：幾何分布の「コピペ&足し算」（目的のアイテムを r 個集めるまでの道のり）
 - 5.8 多項分布
 - 何これ：コイン（2面）の世界から、サイコロ（多面）の世界への拡張
- 6 連続型分布と標本分布
 - 6.1 連続一様分布
 - 何これ：どこを切っても「金太郎飴」のような、完全に平坦な確率の海
 - 6.2 正規分布
 - 何これ：統計学における「絶対王者」。自然界のノイズが行き着く究極の姿
 - 6.3 指数分布
 - 何これ：「いつ起きるか分からない突発イベント」を待ち続ける時間の分布
 - 6.4 ガンマ分布
 - 何これ：指数分布の「コピペ&足し算」（目的のイベントが a 回起こるまでの待ち時間）
 - 6.5 ベータ分布
 - 何これ：「確率」そのものの確率分布（コインの歪み具合を推理する）
 - 6.6 対数正規分布
 - 何これ：「掛け算」で増えていく現象（乗法過程）がたどり着く姿
 - 6.7 多変量正規分布
 - 何これ：多次元空間に浮かぶ、傾いた「ラグビーボール型の雲」
 - 6.8 混合正規分布
 - 何これ：異なる背景を持つ集団がごちゃ混ぜになった、ふたつの「山」を持つ分布
 - 6.8.1 パラメータ推定（EMアルゴリズム）
 - 何が嬉しいのか？：「卵が先か鶏が先か」を交互に解く機械学習の超絶テクニック
 - 6.9 カイ二乗分布
 - 何これ：ランダムな矢印（ベクトル）の「長さの2乗」の分布
 - 6.9.1 非心カイ二乗分布
 - 何これ：「的の中心（原点）」から狙いがズレているときの散らばりの分布
 - 6.10 t 分布
 - 何これ：データ数が少なくて「真のばらつき」が分からないときの、実戦向けの正規分布
- 7 極限定理、漸近理論
 - 7.1 概収束（条件：最強）
 - 何これ：「絶対に、例外なく、最後にはピッタリ一致する」という究極の収束
 - 7.2 平均2乗収束（条件：最強クラス）
 - 7.3 確率収束（条件：中）
 - 何これ：「誤差が ϵ 以上になる確率が、どんどん消滅していく」収束
 - 7.4 分布収束（条件：最弱）
 - 何これ：「中身は違っても、外見（グラフの形）は最終的に同じになる」収束
 - 7.4 大数の弱法則（※番号は元のまま）
 - 何これ：サンプルを無限に集めれば、標本平均は必ず「真の平均」にたどり着くという安心感
 - 7.5 中心極限定理

- 何これ：どんなに変な分布でも、大量に足し合わせると「正規分布」になる宇宙の法則
- 7.6 連続修正
 - 何これ：カクカクの階段（離散）を、なめらかな坂道（連続）で測るときの「隙間埋め」
- 7.7 連続写像定理
 - 7.7.1 例
 - 何これ：極限の世界でも「連続関数」ならそのまま適用していいというチート能力
- 7.8 スルツキーの補題
 - 何これ：ふわふわ揺れる「分布」と、ガッチリ固まった「定数」は自由に計算してヨシ
- 7.9 デルタ法
 - 7.9.1 例
 - 何これ：複雑な関数の分散を知りたいとき、微分（接線）を使って無理やり正規分布に近似するハック
- 8 統計的推定の基礎
 - 8.1 統計的推定
 - 何これ：鍋の「味見」でスープ全体の塩加減を当てるゲーム
 - 8.2 順序統計量
 - 何これ：テストの点数を「背の順」に並び替えること
 - 8.3 モーメント法
 - 何これ：「影の形」から「実体のサイズ」を逆算する推理法
 - 8.4 最尤法
 - 何これ：「この結果が起きたってことは、元々の設定はこうだったと考えるのが一番自然だよね！」という逆転の発想
 - 8.5 漸近正規性
 - 何これ：データが増えれば、最尤推定量は「真の値」を中心に美しい正規分布を描く
 - 8.6 バイアス・バリエンス分解
 - 何これ：推定の「ヘタクソさ」は、「狙いのズレ（バイアス）」と「腕のブレ（バリエンス）」の足し算である
 - 8.7 不偏推定量
 - 何これ：「何回も繰り返せば、平均的にはちゃんと真の値（的のド真ん中）に一致する」という優れた計算式
 - 8.8 ジャックナイフ推定量
 - 何これ：わざとデータを1個ずつ仲間外れにして、推定の「クセ」をあぶり出して打ち消す職人技
 - 8.9 一様最小分散不偏推定量（UMVUE）
 - 何これ：偏りがなく（不偏）、かつ一番ブレない（最小分散）、「最強のダーツプレイヤー」
 - 8.10 クラメール・ラオの不等式
 - 8.10.1 漸近有効推定量
 - 8.10.2 有効推定量
 - 何これ：「どんなに頑張っても、この限界線より精度を良くすることは物理的に不可能だよ」という絶望と希望の不等式
 - 8.11 十分統計量
 - 何これ：元のデータが1万個あっても、この「要約された値」さえ知っていれば情報ロスはゼロ！という究極のデータ圧縮
- 9 区間推定
 - 何これ：「点」ではなく「網」でターゲットを捕まえる技術
 - 9.1 母平均の推定（母分散が既知）
 - 何これ：理想的なボーナスタイム（基本形）
 - 9.2 母平均の推定（母分散が未知、小標本）
 - 何これ：「分からないこと」が多いから、少し広めに網を張る（ t 分布の出番）
 - 9.3 母平均の推定（母分散未知、大標本）の場合
 - 何これ：データが大量にあれば、代用品(U)でも正規分布(1.96)を使ってヨシ！という力技
 - 9.4 母分散の推定（母平均が未知）の場合
 - 何これ：平均ではなく「バラつきのブレ幅」を推定する
 - 9.5 母比率の推定（大標本）の場合
 - 何これ：テレビでよく見る「内閣支持率」のカラクリ
 - 9.6 分散の比の区間推定
 - 何これ：「機械Aと機械B、どちらが安定してる？」を比べるための割り算
 - 9.7 多項分布の差の信頼区間
- 10 検定の基礎と検定法の導出
 - 何これ：統計学における「刑事裁判」
 - 10.1 検出力とサンプルサイズ
 - 何これ：「犯人を見つけ出す能力」と「手がかりのデカさ」
 - 10.2 生産者危険
 - 何これ：【冤罪（えんざい） / 誤報】（あわてんぼうのエラー）
 - 10.3 消費者危険
 - 何これ：【見逃し / 隠蔽】（ぼんやりさんのエラー）

1 事象と確率

1.1 ベイズの定理

$$\begin{aligned} p(A|B) &= \frac{p(B|A)p(A)}{p(B)} \\ &= \frac{p(B|A)p(A)}{p(B|A)p(A) + p(B|A^c)p(A^c)} \end{aligned}$$

1.1.1 何が嬉しいのか：恒等式の書き換えが持つ「因果の逆転」の魔力

数式単体を見れば、条件付き確率の定義から導かれる単なる「当たり前の恒等式」に過ぎません。数式としての難易度も非常に単純です。

しかし、この定理がデータサイエンスや統計学において「革命」と呼ばれるほど特別視される理由は、**左辺と右辺の文字に、実務上とんでもなく都合の良い意味（役割）を割り当てたから**です。

通常、確率は**「原因（理論・パラメータ）→ 結果（データ）」の順方向で考えます。しかし、現実の科学やデータ分析で私たちが直面するのは常にその逆、「結果（データ）→ 原因（理論・パラメータ）」という逆方向の推論です。ベイズの定理は、この逆問題を解くための唯一のツールとなります。

記号の A と B を、以下のように書き換えてみます。

- $A \rightarrow \theta$ （私たちが本当に知りたい **未知のパラメータ、理論、仮説**）
- $B \rightarrow D$ （手元にある **既知の実験データ、観測結果**）

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$

各項にこの意味を割り当てると、この数式の真の嬉しさが見えてきます。

- $p(\theta)$ 【事前分布】
データを得る前の、その理論やパラメータに対する「事前の確信度（仮説）」。
- $p(D|\theta)$ 【尤度（ゆうど）】
理論 θ が正しいと仮定したとき、そのデータ D が観測される確率。順方向の確率であるため、数理モデルやシミュレーションから**直接計算が可能**。
- $p(\theta|D)$ 【事後分布】
実験データ D を目撃した後に、理論 θ が正しいと言える「修正された確信度」。私たちが本当に知りたい**データから原因を逆算する**という究極の目的そのもの。

1.1.2 結論：何が凄すぎるのか？

1. **逆問題を順問題に変える：**
「データ D から未知のパラメータ θ を直接当てる（逆問題）」のは一般に超難問ですが、ベイズの定理を使えば、簡単に計算できる「パラメータ θ のときにどんなデータが出るか（順問題 = 尤度）」の掛け算にすり替えることができます。
2. **自動的な学習（アップデート）システム：**
データ D が新しく得られるたびに、左辺の「事後分布」を次のステップの「事前分布」に代入して再計算することで、理論をどんどん洗練（学習）させていくサイクルを数式1行で表現しています。

数式自体の当たり前さと、用途の強力さ（逆問題を解くチート性）のギャップこそが、ベイズの定理の最大の価値です。

2 確率分布と母関数

2.1 繰り返しの法則

$$E[E[X|Y]] = E[X]$$

何これ：神の視点の平均を「条件ごとの平均の平均」で求める

物理の言葉で言えば、これは**「全配置にわたるアンサンブル平均を、部分系ごとに粗視化（Coarse-graining）して二段階で計算する手続き」**です。「全確率の公式」の期待値バージョンに過ぎません。

数式の内側から順に解釈すると、意味がはっきり分かります。

- $E[X|Y]$ 【内側の期待値】：条件付き期待値
「変数 Y の値が固定された」という条件下での、 X の平均値です。これは Y の値によって変化するため、 Y の関数になります。
- $E[\cdot]$ 【外側の期待値】： Y についての平均
内側で計算した「条件ごとの平均」に対して、さらに「その条件が発生する確率」の重みをつけて、すべての Y にわたって平均をとります。

Tip

💡 具体例：東大生の平均身長を求める

全校生徒を全員一列に並べて平均身長 ($E[X]$) を直接計算するのは大変です。

そこで、まずは学部 (Y) ごとに平均身長を計算します。これが内側の $E[X|Y]$ です (理学部の平均、工学部の平均...)。

次に、その「各学部の平均身長」を、各学部の人数比率で重み付けして足し合わせます。これが外側の $E[\cdot]$ です。結果として、全体の平均身長 $E[X]$ と完全に一致します。

何が嬉しいのか？

全体の平均 $E[X]$ を直接計算するのが難しいとき、**「まず特定の条件 Y でグループ分けして、そのグループ内の平均 (内側) を出し、最後にそれをグループの構成比で足し合わせる (外側)」**という二段階のステップを踏めば、複雑な同時確率分布を扱わずに済むため、計算が劇的に楽になります。ベイズ統計などでも頻出する変形テクニックです。

2.2 確率母関数

離散型確率変数 X の確率関数を $p(X)$ とすると、1 に十分に近いすべての s に対して、次の級数が収束するときの $G_X(s)$ のこと

$$G_X(s) = E[s^X] = \sum_{k=0}^{\infty} s^k p(k)$$

何これ：確率分布を「多項式の係数」として閉じ込めた圧縮ファイル (ZIP)

物理でいう分配関数 (Partition Function) の離散版です。あるいは、信号処理や数学での「Z変換」や「テイラー展開」そのものです。

数式の意味をそのままバラしてみると、ただの形式的な多項式 (べき級数) であることが分かります。

$$G_X(s) = p(0)s^0 + p(1)s^1 + p(2)s^2 + p(3)s^3 + \dots$$

ここで導入されている文字 s は、ただの「引数 (ダミーの変数)」であり、実用的な意味は何もありません。重要なのは、 s^k の前にくっついている係数が、「 $X = k$ になる確率 $p(k)$ 」そのものになっているという点です。つまり、バラバラに存在していた確率のリストを、多項式という「1つの関数の箱」にパッキング (ZIP圧縮) したものが確率母関数です。

Note

📦 例え話：仕切り付きの収納ボックス

確率 $p(0), p(1), p(2) \dots$ をそのまま足してしまうと、全部混ざってただの「1」になってしまいます (全確率の和は1だから)。

そこで、 $s^0, s^1, s^2 \dots$ という**「絶対に混ざらない仕切り (タグ)」**をそれぞれにくっつけてから足し合わせることで、各々の確率の値を独立したまま1つの関数 $G_X(s)$ の中に安全に保管しているイメージです。

何が嬉しいのか？：面倒な「和の計算」が「微分の作業」に大化けする

Important

🔥 ここがチート！微分すると中身が飛び出してくる

確率母関数 $G_X(s)$ を s で1回微分してから $s = 1$ を代入すると、魔法のように期待値 $E[X]$ が出てきます。

$$G'_X(s) = p(1) + 2p(2)s + 3p(3)s^2 + \dots$$

$s = 1$ を代入：

$$G'_X(1) = \sum k p(k) = E[X]$$

1. 微分するだけで期待値や分散が手に入る：

離散確率の面倒な無限級数の和の計算が、「関数を微分して1を代入するだけ」の機械的作業に一変します（2回微分すれば分散もすぐ作れます）。

2. 確率変数の足し算（和の分布）が「掛け算」になる：

独立な2つの確率変数 X と Y の和 $X + Y$ の確率分布を真面目に計算しようとすると、面倒な畳み込み（コンボリューション）が必要になります。しかし、母関数の世界では $G_{X+Y}(s) = G_X(s)G_Y(s)$ となり、**「母関数同士の掛け算」**にするだけで計算が完了します。分配関数で独立な系の全分配関数が各系の積になると全く同じ原理です。

2.3 モーメント母関数

0に十分に近いすべての t に対して、次の期待値が存在するときの $M_X(t)$ のこと

$$M_X(t) = G_X(e^t) = E[e^{tX}] = \sum_{k=0}^{\infty} e^{tk} p(k)$$

何これ：確率分布の情報を「マクローリン展開の係数」として保存する汎用ZIPファイル

先ほどの「確率母関数（2.2）」の進化版です。物理や工学でいうところのラプラス変換（あるいは統計力学の分配関数 $Z(\beta)$ において $\beta = -t$ と置いたもの）と全く同じ操作をしています。

確率母関数は s^X を使いましたが、こちらは e^{tX} を使います。なぜわざわざネイピア数 e を使うのか？それは、 e^{tX} をマクローリン展開（テイラー展開）すると、以下のように綺麗な多項式にバラけるからです。

$$e^{tX} = 1 + tX + \frac{t^2}{2!}X^2 + \frac{t^3}{3!}X^3 + \dots$$

この両辺の期待値（平均）をとると、こうなります。

$$M_X(t) = E[e^{tX}] = 1 + tE[X] + \frac{t^2}{2!}E[X^2] + \frac{t^3}{3!}E[X^3] + \dots$$

つまり、 t のべき乗の係数として、 X のすべての「モーメント $(E[X], E[X^2], E[X^3] \dots)$ 」が規則正しく格納されている状態になります。

Note

確率母関数との違い

確率母関数 $G_X(s)$ は基本的に「離散型（サイコロの目など）」にしか使えないという弱点がありました。しかし、モーメント母関数 $M_X(t)$ は総和 $\sum$ を積分 $\int$ に変えることで「連続型（身長や温度など）」の分布にも使える完全上位互換の汎用圧縮ファイルになります。

何が嬉しいのか？：分布の「指紋」であり、微分の威力がさらに上がる

Important

ここがチート！微分して「0」を入れるとモーメントが飛び出す

確率母関数では微分して「1」を入れましたが、モーメント母関数の場合は微分して $t = 0$ を代入します。

$M_X(t)$ を t で1回微分して $t = 0$ を入れると、期待値 $E[X]$ が出ます。

2回微分して $t = 0$ を入れると、2次のモーメント $E[X^2]$ が出ます。これを使えば、面倒な積分の計算をせずとも分散 $V(X) = E[X^2] - (E[X])^2$ が一瞬で計算できます。

1. どんな分布でも機械的な微分で平均と分散が出せる：

正規分布、ポアソン分布、ガンマ分布など、どんなに複雑な確率密度関数でも、一度 $M_X(t)$ さえ求めてしまえば、あとは「微分して0を入れる」という脳死の作業だけで平均や分散が手に入ります。

2. 和の分布が「掛け算」になる（確率母関数と同じ）：

独立な確率変数 X と Y の和のモーメント母関数は、それぞれの母関数の積 $M_{X+Y}(t) = M_X(t)M_Y(t)$ になります。

3. 分布の「指紋」として使える（一意性）：

「モーメント母関数が完全に一致するなら、元の確率分布も絶対に同じである」という強力な定理があります。準1級の第7章で出てくる「中心極限定理（たくさんの変数を足すと正規分布に近づく定理）」なども、真正面から確率を計算するのではなく、この「モーメント母関数の形が正規分布のそれに近づいていくか」を確認することで証明されます。

3 分布の特性値

3.1 変動係数

非負の確率変数 X のばらつきが期待値に対してどれくらいかを示す指標

$$\frac{\sqrt{V(X)}}{E[X]}$$

何これ：スケール（単位や大きさ）が全く違うもの同士の「相対的なブレ」を公平に比べる指標

物理や工学でいうところの「相対誤差」や、「 S/N 比（シグナル・ノイズ比）の逆数」に相当するものです。分子の $\sqrt{V(X)}$ は標準偏差（ばらつきの絶対量）を表します。



Tip

🔦 例え話：アリの測定誤差とゾウの測定誤差

「アリの体長（平均 1cm）」と「ゾウの体長（平均 300cm）」を測ったとき、どちらも標準偏差（ばらつき）が 0.5cm だったとします。ばらつきの「絶対量」は同じですが、アリにとっての 0.5cm は致命的な大誤差（元のサイズの半分）なのに対し、ゾウにとっての 0.5cm は誤差の範囲（ほとんど無視できる）ですよね。つまり、標準偏差をそのまま比べるのは不公平なのです。だから、**標準偏差を期待値（平均サイズ）で割り算**することで、「平均値の何倍くらいブレるのか」という相対的な指標に直しています。

何が嬉しいのか？

「単位が違うもの（例：体重と身長）」や「平均値のスケールが桁違いのもの（例：大企業の年収のばらつきと、ベンチャー企業の年収のばらつき）」を、同じ土俵で比較できるようになります。

3.2 歪度（わいど / Skewness）

確率変数 X の期待値を μ 、分散を σ^2 とするとき、次のように X を標準化した確率変数の 3 乗の期待値。

$$\frac{E[(x - \mu)^3]}{\sigma^3}$$

分布が、右に長い裾を持つときには正の値、左に長い裾を持つときには負の値をとりやすく、左右対称ならば 0 になります。

何これ：分布が「どっちに尻尾（裾）を引いているか」を表す非対称性の指標

物理の言葉で言えば、**「重心（平均 μ ）まわりの 3 次のモーメント」**です。



Note

📐 物理的解釈：なぜ「3乗」するのか？

分散は $(x - \mu)^2$ と「2乗」するため、平均より大きくても小さくても、必ずプラスの値になってしまい「左右のどっちにブレたか」の情報が消滅してしまいます。しかし、「3乗」であればマイナスの符号がそのまま残ります。

- 平均よりバカでかい値（右側の外れ値）があると、プラスの方向に大きく引っ張られる → **歪度は正（右裾が長い）**
- 平均よりめっちゃくちゃ小さい値（左側の外れ値）があると、マイナスの方向に大きく引っ張られる → **歪度は負（左裾が長い）**

覚え方のコツ

「右に長い裾＝右に歪んでいる」という言葉のニュアンスに引っ張られないでください。試験では**「グラフの裾（しっぽ）が伸びている方向が、歪度の符号（プラスかマイナスか）になる」**と直感的に覚えておくと迷いません。年収の分布など、少数の大金持ちが平均を押し上げているデータは「右裾が長い（歪度 > 0 ）」になります。

3.3 尖度（せんど / Kurtosis）

確率変数 X の期待値を μ 、分散を σ^2 とするとき、次のように X を標準化した確率変数の 4 乗の期待値。

$$\frac{E[(x - \mu)^4]}{\sigma^4}$$

確率密度関数のグラフに山が1つあり、その山が尖っているほど尖度は大きな値をとる傾向があります。この期待値を正規分布で計算すると3になるので、上の式から3をひいた値が正か負かによって分布の形状を正規分布と比べることがあります。

何これ：正規分布と比べて「極端な外れ値が出やすいか（ファットテールか）」を測る指標

物理の言葉で言えば、**「重心まわりの4次のモーメント」**です。

🔥 Important

🔥 ここがポイント：なぜ「4乗」するのか？（外れ値への超絶ペナルティ）

$(x - \mu)^4$ という式は、平均 μ の近くでは非常に小さな値になりますが、平均から少しでも離れると、4乗の効果で爆発的に巨大な値になります。

つまり、尖度という指標は「中心付近の山の形」よりも、**「平均から遥か遠く離れた外れ値（尻尾の先っぽ）がどれくらい存在するか」**に強烈に反応するセンサーなのです。

何が嬉しいのか？

「尖度」という名前のせいで「山の頂上が尖っているかどうか」の指標だと誤解されがちですが、本質は**「裾の重さ（極端なリスクの起こりやすさ）」**の評価です。

- 尖度が大きい（正規分布の「3」より大きい）：

正規分布よりも「平均から遠く離れた極端な外れ値」が頻発する分布です（これをファットテールと呼びます）。確率の総和は1なので、裾に確率を奪われた分を取り返すために、結果として「中心の山が高く尖る」ことになります。金融商品の暴落リスクの評価などで非常に重要視されます。

- 「-3」をする理由：

統計学の王様である「正規分布」の尖度を計算するとピッタリ「3」になります。そこで、正規分布を基準の「0」として扱うために、公式の最後に「-3」をして調整する流儀（超過尖度と呼びます）がよく使われます。

3.4 共分散

$$\begin{aligned} Cov[X, Y] &= E[XY] - E[X]E[Y] \\ Cov[aX + b, cY + d] &= acCov[X, Y] \\ V[X \pm Y] &= V[X] + V[Y] \pm 2Cov[X, Y] \end{aligned}$$

何これ：2つの変数が「どれくらい連動して動くか」を表す相互作用（クロスターム）

物理の言葉で言えば、**2つの物理量の「内積」や「結合エネルギー」**に相当する概念です。 X が平均より大きいとき、 Y も平均より大きければプラス、小さければマイナスになります。

🔥 Tip

💡 公式の物理的解釈

- $Cov[X, Y] = E[XY] - E[X]E[Y]$

これは定義式 $E[(X - E[X])(Y - E[Y])]$ を展開したものです。力学における「平行軸の定理」のように、実際の計算を劇的に楽にするための実用公式として使われます。

- $V[X \pm Y] = V[X] + V[Y] \pm 2Cov[X, Y]$

これ、物理の**波の干渉**や、**ベクトルの長さの2乗公式 ($|\vec{A} \pm \vec{B}|^2 = |\vec{A}|^2 + |\vec{B}|^2 \pm 2\vec{A} \cdot \vec{B}$) **と全く同じ形をしていますよね。2つの変数を足したときの全体のばらつき（分散）は、ただ足し算するだけではなく、2つが連動する成分（干渉項＝共分散）を考慮しなければならない、ということです。

何が嬉しいのか？

複数の変数が組み合わさった複雑なシステムの分散を計算する際の、基本的な構成要素（ビルディングブロック）になります。

3.5 相関係数

(※ご提示いただいた数式は分母が $V[Y]$ になっていますが、正しくは全体にルートがかかる $\sqrt{V[X]V[Y]}$ 、または $\sqrt{V[X]}\sqrt{V[Y]}$ ですね。ここでは修正して解説します！)

$$\rho[X,Y] = \frac{Cov[X,Y]}{\sqrt{V[X]}\sqrt{V[Y]}}$$

何これ：共分散を「単位を持たないキレイなスケール (-1から1)」に規格化したもの

共分散の弱点は「値の大きさ自体には意味がない(単位に依存してしまう)」ことです。そこで、共分散をそれぞれの標準偏差 ($\sqrt{V}$) で割り算することで、**「スケールに依存しない純粋な運動の強さ」**を抽出しています。

Note

物理的・幾何学的解釈：データ空間における「なす角」

データ点を多次元空間のベクトル $\vec{X}$ と $\vec{Y}$ とみなしたとき、この数式は**「内積を、それぞれのベクトルの長さで割っている」**ことになります。

つまり、相関係数 ρ とは「2つのベクトルのなす角 θ の $\cos \theta$ 」そのものです。

- $\rho = 1$ ($\cos \theta = 1$) : 全く同じ方向を向いている (完全な正の相関)
- $\rho = 0$ ($\cos \theta = 0$) : 直交している (無相関)
- $\rho = -1$ ($\cos \theta = -1$) : 真逆を向いている (完全な負の相関)

3.6 偏相関関係 (偏相関係数)

Z が、 X と Y の両方に相関があるとき、 X と Y の間に直接的な相関がなくても Z を介して相関が発生します (擬似相関)。偏相関係数は、 Z の影響を除いた場合の X と Y の相関係数で、次の式で計算できます。

$$\rho[X,Y|Z] = \frac{\rho[X,Y] - \rho[X,Z]\rho[Y,Z]}{\sqrt{(1 - \rho[X,Z]^2)(1 - \rho[Y,Z]^2)}}$$

何これ：共通の「黒幕」の影響を差し引いた、純粋な1対1の関係性

物理で言えば、「背景場 (バックグラウンド)」や「外部からの共通の駆動力」の影響をプロジェクション (射影) して取り除き、系どうしの真の相互作用だけを見る操作です。

Important

例え話：アイスクリームと水難事故 (擬似相関の古典的例)

- X : アイスクリームの売上
- Y : 水難事故の件数

この2つを計算すると、強い正の相関 ($\rho[X,Y] > 0$) が出ます。「アイスが売れるほど、人が溺れる」という謎の結論です。しかし、ここには**「気温 (Z)」という黒幕**があります。気温が高いからアイスが売れるし、気温が高いから海に行って溺れる人が増えるだけです。

先ほどの数式を使って「気温 (Z)」の影響を数学的に排除すると、 $\rho[X,Y|Z]$ はほぼ 0 になります。これが偏相関係数の威力です。

公式の覚え方

式自体は複雑に見えますが、分子の形 $\rho[X,Y] - \rho[X,Z]\rho[Y,Z]$ に注目してください。「 X と Y の表面上の相関」から、「 Z を経由した相関ルート ($X \rightarrow Z \rightarrow Y$)」を引き算しているだけです。グラフィカルモデル (第25章) や重回帰分析 (第16章) で非常に重要な役割を果たします。

3.7 様々な平均

$$\begin{cases} \frac{\sum_i w_i x_i}{\sum_i w_i} & \text{(加重平均)} \\ \sqrt[n]{\prod_i x_i} & \text{(幾何平均)} \\ \left(\frac{1}{n} \sum_i \frac{1}{x_i}\right)^{-1} & \text{(調和平均)} \end{cases}$$

※幾何平均の数式（ルートの書き方など）は、一般的な数学の表記 $\sqrt[n]{\prod}$ に少し修正しています。

何これ：データの「性質」に合わせて、適切な「平らにならす方法」を使い分けるツール

私たちが普段「平均」と呼んでいるのは「算術平均（全部足して個数で割る）」ですが、データが持っている物理的な意味によっては、算術平均を使うと**論理が破綻する**ケースがあります。それぞれ「どういう状況で使うべきか」という明確な役割があります。

3.7.1 加重平均（Weighted Average）

物理の言葉で言えば、完全に**重心（Center of Mass）**の計算です。

- **何をしているか：**すべてのデータが平等ではなく、それぞれのデータに「重み（重要度や質量） w_i 」がついている場合の平均です（ただし $\sum w_i = 1$ と規格化されている前提です）。
- **何が嬉しいのか：**
物理で「複数の質点系の重心位置」を求めるとき、単に座標を足して個数で割るのではなく、質量の大きな点の座標を強く反映させますよね。それと全く同じです。
 - 例：テストの平均点を出すとき、100点満点の数学と、50点満点の小テストを「1対1」で足して割るのは不公平です。配点（重み）を考慮して平均化する際に使います。

3.7.2 幾何平均（Geometric Mean）

物理の言葉で言えば、**「 n 次元空間の超直方体を、同じ体積を持つ超立方体に変換したときの1辺の長さ」**です。

Note

物理的・幾何学的解釈

$x_1, x_2, \dots, x_n$ を全部掛け合わせる ($\prod x_i$) ということは、各データを「辺の長さ」とした n 次元直方体の「体積」を求めていることになります。

その体積に対して n 乗根 ($\sqrt[n]{\cdot}$) をとるということは、「もし全ての辺が同じ長さだったとしたら、その長さはいくらか？」と計算し直している（直方体を正方形に均している）わけです。

- **いつ使うべきか：足し算ではなく「掛け算」で増えていくデータ**
 - 例：投資の利回りや、バクテリアの増殖率など「前年比 x 倍」といった**比率・成長率**の平均を出したいとき。
 - なぜ算術平均ではダメなのか：1年目に株価が2倍（2.0）、2年目に半分（0.5）になったとします。最終的な資産は元通り（ $2.0 \times 0.5 = 1.0$ ）なので、平均成長率は「1.0 倍」であるべきです。しかし算術平均をすると $(2.0 + 0.5)/2 = 1.25$ 倍となり、謎の利益が出たことになってしまい論理が破綻します。幾何平均なら $\sqrt{2.0 \times 0.5} = 1.0$ と正しく計算できます。

3.7.3 調和平均（Harmonic Mean）

物理の言葉で言えば、**「並列回路の合成抵抗」**そのものです。

Tip

例え話：行きと帰りの「平均速度」

行きは時速 60km (x_1)、帰りは時速 40km (x_2) で同じ道のりを往復しました。平均時速は？

算術平均で $(60 + 40)/2 = 50$ km と答えると**不正解**です。なぜなら、遅い時速 40km で走っている時間の方が長いので、全体の平均速度は 50 より遅くなるはずだからです。

これを調和平均で計算すると $\left(\frac{1/60 + 1/40}{2}\right)^{-1} = 48$ km となり、正しい平均時速が求まります。

- **いつ使うべきか：「～あたり」といった単位（速度、密度、効率など）の平均**
距離（分子）が固定されていて、速度（分母）が変わるようなデータの平均をとるとき、速度をそのまま足し算することは物理的に意味を持ちません。一度「逆数（＝一定距離を進むのにかかる時間）」にひっくり返してから算術平均をとり、最後にもう一度逆数に戻して速度の単位に復元する。これが調和平均の正体です。

3.8 行列表現

確率変数ベクトルと平均ベクトル

- 確率変数ベクトル：複数の確率変数 $x_1, \dots, x_p$ を縦に並べて1つのベクトルにまとめたものです。

$$x = (x_1, \dots, x_p)^T$$

- 平均ベクトル（期待値ベクトル）：それぞれの期待値を並べたベクトルです。物理でいう**「多粒子系の重心座標」**に相当します。

$$E[x] = (E[x_1], \dots, E[x_p])^T$$

- 線形変換の性質： A を $r \times p$ の定数行列、 b を r 次元の定数ベクトルとしたとき、期待値の線形性から以下が成り立ちます。

$$E[Ax + b] = AE[x] + b$$

分散共分散行列（理論値）

p 次元確率変数ベクトル x に対して、各成分のばらつきと相互の関係を記述する $p \times p$ の行列です。半正定値対称行列となります。

$$\Sigma = V[x] = E[(x - E[x])(x - E[x])^T]$$

- 線形変換の性質： $V[Ax + b] = AV[x]A^T$ となり、行列 A が両側から挟まる形になります（テンソルの座標変換公式 $g'_{\mu\nu} = \frac{\partial x^\alpha}{\partial x'^\mu} \frac{\partial x^\beta}{\partial x'^\nu} g_{\alpha\beta}$ と同形式です）。

標本分散共分散行列（データから計算）

p 変数のサイズ n の実標本データに対して、不偏分散・不偏共分散を成分に持つ行列 $S = (S_{ij})$ です。

Important

不偏分散共分散の定義式

i 番目の変数と j 番目の変数の共分散成分 S_{ij} は以下の式で計算されます。

$$S_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)$$

ここで x_{ki} は「 k 番目のサンプルの i 番目の変数の値」を表します。分母が $n-1$ になっているのは、自由度を調整して「偏り」をなくするため（不偏性）です。

相関行列

各成分を相関係数 $\rho[x_i, x_j]$ とした行列です。対角成分は全て 1 になります。

- 標本相関行列：実データから計算された相関係数を成分に持つ行列です。

何これ：多次元の「ゆらぎの形状」を記述する慣性テンソル

物理系の方にとって、分散共分散行列は力学における**「慣性テンソル（Inertia Tensor）」**そのものです。

Note

物理的・幾何学的解釈

対角成分は「各軸方向のモーメント（分散）」、非対角成分は「軸間の歪み（共分散）」を表します。

データが多次元空間に作る「雲（楕円体）」の形状を完全に記述しており、**非対角成分がゼロでない = データの主軸が座標軸に対して傾いている**ことを意味します。

何が嬉しいのか？：線形代数を使って「データの固有状態」を抽出できる

確率変数をベクトルや行列で記述することで、第22章以降の「多変量解析」において、固有値問題などの線形代数の手法がそのまま炸裂します。

Tip

🔥 ここがチート！主成分分析（PCA）の正体

分散共分散行列 S は「対称行列」なので、必ず直交行列を使って対角化できます。

これを物理に翻訳すると、**「慣性主軸を求める（対角化する）」ことで、データ間の相関を消し去り、最も情報のゆらぎが大きい方向（主成分）を特定する**という作業になります。

剛体の回転において、最も回転させやすい（またはにくい）軸を探すのと、数学的に全く同じ操作でデータの特徴抽出ができるのです。

4 変数変換

4.1 $Y = g(X)$ の変換

$f_X(x) \mapsto f_Y(y)$ が目標

$$\begin{aligned} f_Y(y) &= f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \\ &= f_X(g^{-1}(y)) \left| \frac{1}{g'(g^{-1}(y))} \right| \end{aligned}$$

何これ：確率という「粉」の総量（面積=1）を保つための「連続の式（質量保存則）」

物理の流体力学などで出てくる**「連続の式（ $\rho_1 V_1 = \rho_2 V_2$ ）」**と全く同じ考え方です。

Note

📐 物理的解釈：なぜ絶対値の微分（ヤコビアン）が掛かっているのか？

確率密度関数 $f(x)$ は、単なる「値」ではなく「密度（濃さ）」です。

もし変数変換 $Y = 2X$ を行ったらとします。これは空間を「2倍に引き伸ばす」操作です。空間が2倍に広がったのに、粉（確率）の濃さがそのままだったら、全確率の合計が2倍に増えて宇宙が崩壊してしまいます。

だから、空間を引き伸ばした分だけ、密度は薄めないとはいけません。この**「空間の伸び縮み率（体積変化率）」を補正する係数が、右辺にくっついている微分の絶対値（ヤコビアン）の正体**です。

何が嬉しいのか？

手元にあるデータ X に、何かしらの関数 g を噛ませて Y という新しい指標を作ったとき（例：半径 X の分布から、面積 $Y = \pi X^2$ の分布を知りたいとき）、その新しい指標 Y がどんな確率分布に従うかを、元の分布 f_X から正確に逆算して求めることができます。

4.2 $Z = X + Y$ の変換

$Z = X + Y$, $T = Y$ の変換を考えると、 $f_X(x)f_Y(y) \mapsto f_Z(z)$ が目標なので、

$$\left| \begin{array}{cc} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial t} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial t} \end{array} \right| f_Z(z) dz dt = f_X(x) f_Y(y) dx dy$$

なので、

$$\begin{aligned} f_Z(z) &= f_X(x) f_Y(y) \\ &= \int_{-\infty}^{\infty} f_X(z-t) f_Y(t) dt \end{aligned}$$

(※補足：チートシートの2行目 $f_Z(z) = f_X(x)f_Y(y)$ は、厳密には同時確率密度関数 $f_{Z,T}(z,t) = f_X(z-t)f_Y(t) \times |J|$ のことです。そこから邪魔な変数 T を積分して消去（周辺化）した結果が3行目になります。)

何これ：波の「畳み込み（コンボリューション）」

物理や信号処理で頻出する**「畳み込み積分」**そのものです。

Tip

💡 直感的なイメージ：サイコロを2つ振って「和が z 」になる確率

例えば「2つのサイコロの目の和が5になる確率」を求めるとき、どう計算しますか？

「(1,4), (2,3), (3,2), (4,1)」のパターンを全部足しますよね。

これを連続関数でやっているのが上の積分式です。

- t ：1つ目の変数（サイコロの目）
- $z - t$ ：和を z にするために、2つ目の変数が**「絶対に取らなければならない値」**

つまり、 z という結果を作るための「すべての組み合わせの確率の掛け算」を、直線 $x + y = z$ に沿ってダーツと積分して足し合わせているだけです。

何が嬉しいのか？

独立な2つのノイズ源（例：測定器の熱雑音 X と、環境の電磁ノイズ Y ）が同時に乗ってきたとき、最終的に観測されるノイズ Z がどんな分布の形になるのかを計算できます。

4.3 Box-Cox変換

非対称であるなど、正規分布からずれている非負のデータ x を正規分布に近づける次の変換のこと。

$$x \mapsto \begin{cases} \frac{x^\lambda - 1}{\lambda} & (\text{for } \lambda \neq 0) \\ \log(x) & (\text{for } \lambda = 0) \end{cases}$$

λ の値を変化させることでべき乗変換や対数変換など、様々な変換が可能であり、その中で変換後のデータが正規分布に近づくものを選択します。

何これ：歪んだ世界を「正規分布（ユークリッド空間）」に無理やり平坦化する魔法のレンズ

物理で言えば、**「現象のスケール（次元）に合わせて、観測する目盛りをリニアから対数などに切り替える作業の自動化」**です。

Important

🔥 ここが美しい！なぜ $\lambda = 0$ で突然 $\log$ が出てくるのか？

数式をパッと見ると、「 λ が0以外の時はべき乗なのに、なんで $\lambda = 0$ のときだけ突然 $\log$ （対数）になるの？ 繋がりがなくない？」と不思議に思いませんか？

実はこれ、上の式 $\frac{x^\lambda - 1}{\lambda}$ において、 $\lambda \rightarrow 0$ の極限をとり、ロピタルの定理（分母と分子を λ で微分）を適用すると、見事に $\log(x)$ に一致するのです。

つまり、この2つの式は全く別物ではなく、1つの滑らかな数式の「連続した家族」になっています。

何が嬉しいのか？

統計学や機械学習の手法（t検定、回帰分析など）は、基本的に**「データが正規分布（左右対称の綺麗なベルカーブ）に従っていること」**を前提として作られています。

しかし、現実のデータ（年収、待ち時間、地震のエネルギーなど）は右に裾を引いた歪んだ分布ばかりです。

Box-Cox変換は、パラメータ λ のツマミをグリグリと回すだけで、

- $\lambda = 1$ （何もしない）
- $\lambda = 0.5$ （ルートをとり）
- $\lambda = 0$ （対数をとる：地震のマグニチュードや音のデシベルと同じ）
- $\lambda = -1$ （逆数をとる：速度を「ペース」に変換するようなもの）

というあらゆる変換をシームレスに試し、一番データが正規分布に近くなる「最適なツマミの位置（入）」をコンピュータに見つけさせることができる、超強力な前処理ツールです。

5 離散型分布

5.1 離散一様分布

$$p(X = x_i) = \frac{1}{n} \quad (\text{for } i \in \{1, 2, \dots, n\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = \frac{n+1}{2} \\ V[X] = \frac{n^2-1}{12} \\ G(s) = E[s^X] = \frac{s(1-s^n)}{n(1-s)} \end{cases}$$

何これ：すべての選択肢が完全に平等な、もっともピュアな「サイコロ」の分布

物理の言葉で言えば、すべての状態が等確率で発現する**「ミクロカノニカルアンサンブル（等確率の原理）」**そのものです。偏りが一切ない、完全に公平な状態を表します。

 Note

 特性値の数学的トリック

- **平均 $\frac{n+1}{2}$** ：1から n までの数字を綺麗に並べたときの、ど真ん中の重心位置です。
- **分散の分母にある「12」という謎の数字**：これは綺麗な連続空間の一様分布の分散 $\frac{(b-a)^2}{12}$ につながる重要な数字です。自然数の2乗の和の公式 $\sum k^2 = \frac{1}{6}n(n+1)(2n+1)$ を展開して整理していく過程で、この「12」が必然的に浮かび上がってきます。
- **確率母関数 $G(s)$** ：数式を展開すると $\frac{1}{n}(s^1 + s^2 + \dots + s^n)$ となります。これは初項 $\frac{s}{n}$ 、公比 s 、項数 n の**等比数列の和の公式**そのものです。

5.2 ベルヌーイ分布

コイン投げのように、結果が2通り（一方を成功、他方を失敗と呼ぶ）の試行をベルヌーイ試行と言い、ベルヌーイ試行を1回行ったときの成功回数がしたがう確率分布。ベルヌーイ試行の成功確率を p として、ベルヌーイ分布を $Bin(1, p)$ と表します。

$$p(X = x) = p^x(1-p)^{1-x} \quad (\text{for } x \in \{0, 1\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = p \\ V[X] = p(1-p) \\ G(s) = E[s^X] = ps + 1 - p \end{cases}$$

何これ：すべての離散型分布の「原子」（1回きりの丁半バクチ）

物理の量子力学でいう**「スピン1/2の系（アップかダウンか）」や、情報理論の「1ビット（0か1か）」**に相当する、これ以上分解できない最小単位の分布です。

 Tip

 **数式のハック：なぜ $p^x(1-p)^{1-x}$ なんて回りくどい書き方をするのか？**

プログラミングにおける「if文（条件分岐）」を、数式1行でスマートに表現するためのチートテクニックです。

- **成功（ $x = 1$ ）のとき**： $p^1 \times (1-p)^0 = p$ となり、成功確率だけが残る。
- **失敗（ $x = 0$ ）のとき**： $p^0 \times (1-p)^1 = 1-p$ となり、失敗確率だけが残る。

x に0か1を代入するだけで、自動的に確率が切り替わるシステムになっています。

何が嬉しいのか？

一見単純ですが、分散 $V[X] = p(1-p)$ の性質が非常に面白いです。この値は $p = 0.5$ （五分五分）のときに最大値 0.25 になります。確率が $p = 0.9$ （ほぼ成功する）や $p = 0.1$ （ほぼ失敗する）のように偏っているときは、「結果が予想しやすい」ため、ばらつき（物理でいうエントロピー）は小さくなります。完全に予測不可能でカオスなときほど、分散が最大になるという直感と一致します。

5.3 二項分布

成功確率 p の独立なベルヌーイ試行を n 回行ったときの成功回数がしたがう確率分布で、 $Bin(n, p)$ と表します。確率関数は次の通りです。

$$p(X = x) = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \quad (\text{for } x \in \{0, 1, \dots, n\})$$

この時、以下のようになっている

$$\begin{cases} E[X] = np \\ V[X] = np(1-p) \\ G(s) = E[s^X] = (ps + 1 - p)^n \end{cases}$$

二項分布には再生性があり、 $X_1 \sim Bin(n_1, p)$, $X_2 \sim Bin(n_2, p)$ が独立であるとき、 $X_1 + X_2 \sim Bin(n_1 + n_2, p)$ が成り立ちます。

何これ：ベルヌーイ分布の「コピペ&足し算」

先ほどのベルヌーイ分布を、独立に n 回繰り返して全部足し合わせたものです。

Important

🔥 ここがチート！特性値はすべて「 n 倍」するだけ

独立な確率変数を足し算するとき、**「平均も分散も、そのまま足し算していい」**という強力な性質（2.1や3.4の応用）がありました。そのため、1回あたりの平均が p 、分散が $p(1-p)$ なら、 n 回合わせた二項分布の平均は np 、分散は $np(1-p)$ と、ただの n 倍で一瞬で導出できます。

確率母関数 $G(s)$ も、「和の分布は母関数の積」というルール通り、ベルヌーイの式 $(ps + 1 - p)$ を単純に n 乗するだけで完成します。

何が嬉しいのか？（再生性の意味）

「再生性」とは、**「同じ確率のガチャなら、別々に引いて後から合算しても、最初からまとめて引いても同じ分布になる」**という性質です。「午前中に10回ガチャを引く（ $Bin(10, p)$ ）」のと「午後に20回ガチャを引く（ $Bin(20, p)$ ）」のを合計したデータは、完全に「1日に30回ガチャを引く（ $Bin(30, p)$ ）」という1つの二項分布として綺麗にマージして扱えます。

5.4 超幾何分布

N 本のくじの中に M 本の当たりがあり、 n 本のくじを非復元抽出するとき、ひいた当たりの本数がしたがう確率分布で、 $HG(N, M, n)$ と表します。

$$p(X = x) = \frac{{M \choose x} {N-M \choose n-x}}{{N \choose n}} \quad (\text{for } x \in [\max\{0, n - (N - M)\}, \min\{n, M\}])$$

この時、以下のようになっている

$$\begin{cases} E[X] = \frac{nM}{N} \\ V[X] = \frac{nM}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1} \end{cases}$$

n と M/N を一定にしたまま、 $N \rightarrow \infty$ とすると、二項分布 $Bin(n, M/N)$ に収束します。

何これ：くじを「戻さない（非復元）」せいで、引くたびに確率が変化するリアルな二項分布

二項分布との決定的な違いは、**「引いたくじを箱に戻さない」という点です。1人目が当たりを引くと、2人目の当たる確率は下がります。つまり、試行同士が独立ではなく、お互いに影響を与え合う（相関がある）**状態の分布です。

Important

🔥 ここに注目！分散の後ろにくっついている不気味な係数の正体

超幾何分布の平均は $\frac{nM}{N}$ であり、これは当たり確率を $p = \frac{M}{N}$ とおけば、二項分布の平均 np と全く同じです。

しかし、分散の式をよく見ると、二項分布の分散 $np(1-p)$ の後ろに、 $\frac{N-n}{N-1}$ という見慣れない係数が掛け算されています。これを統計学では**「有限母集団修正」**と呼びます。この係数が、非復元抽出の「お互いに影響し合う性質」を完璧に制御しています。

- もし $n = 1$ （1回しか引かない）なら：

$\frac{N-1}{N-1} = 1$ となり、二項分布の分散と完全に一致します（1回だけなら戻すも戻さないもないため）。

- もし $n = N$ （箱の中身をすべて引ききる）なら：

分子が $N - N = 0$ になるため、**分散（ばらつき）はゼロになります**。当たり前ですよ。箱の中身を全部引いたら、手元にある当たりの本数は「絶対に M 本」であり、一切のゆらぎが発生しないからです。

何が嬉しいのか？

もし箱の中にある総くじ数 N が無限に大きい ($N \rightarrow \infty$) とすると、この有限母集団修正の項は $\lim_{N \rightarrow \infty} \frac{N-n}{N-1} = 1$ となり、消滅します。つまり、「琵琶湖の水からコップ1杯の水をすくい取る」ような巨大な対象（無限母集団）からデータをサンプリングするときは、いちいち戻さなくても、計算が簡単な二項分布（復元抽出）として扱って良いという強力な保証（近似）を与えてくれます。

5.5 Poisson（ポアソン）分布

$\lambda > 0$ を平均発生率とすると、特定の時間（空間）内に事象が x 回発生する確率のモデル化に用いられる確率分布で、 $Po(\lambda)$ と表します。

$$p(X = x) = \frac{\lambda^x e^{-\lambda}}{x!} \quad (\text{for } x \in \{0, 1, 2, \dots\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = \lambda \\ V[X] = \lambda \\ G(s) = E[s^X] = e^{(s-1)\lambda} \end{cases}$$

ポアソン分布には再生性があり、 $X_1 \sim Po(\lambda_1)$, $X_2 \sim Po(\lambda_2)$ が独立であるとき、 $X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$ が成り立ちます。

二項分布 $Bin(n, p)$ で、 $np = \lambda$, $n \rightarrow \infty$ とすると、 $Po(\lambda)$ に分布収束します。（少数の法則）

何これ：無限回クジを引けるが、当たる確率がほぼゼロの世界（レア事象の分布）

物理で言えば、**「放射性物質の崩壊」や「単位面積に降り注ぐ雨粒の数」**などを記述する分布です。

Note

📌 直感的なイメージ：二項分布の極限

「少数の法則」とあるように、ポアソン分布は二項分布の親戚です。

例えば、「1年（365日）で交通事故に遭う回数」を考えます。これは $n = 365$ 、 $p = (\text{1日の事故発生率})$ の二項分布です。

さらに細かく「1時間単位」「1秒単位」と区切っていくと、 n は無限大 (∞) に近づき、 p は限りなくゼロ (0) に近づきます。しかし、1年間の「平均事故回数 ($np = \lambda$)」は一定です。

このように、**「いつ起きるか全く予測できないが、平均すると一定期間に λ 回起きる」**という現象を見事に数式化したのがポアソン分布です。

何が嬉しいのか？

二項分布の計算には「試行回数 n 」と「確率 p 」の2つの情報が必要ですが、ポアソン分布は**「平均発生回数 λ 」というたった1つのパラメータだけで完全に形が決まる**という超お手軽仕様になっています。しかも「**平均=分散= λ** 」となるため、計算が劇的に楽になります。

5.6 幾何分布

独立な成功確率 p のベルヌーイ試行をくり返すとき、はじめての成功が起きるまでの失敗の回数 X がしたがう分布で、 $Geo(p)$ と表します。

$$p(X = x) = p(1-p)^x \quad (\text{for } x \in \{0, 1, 2, \dots\})$$

この時、以下のようになっている

$$\begin{cases} E[X] = \frac{1-p}{p} \\ V[X] = \frac{1-p}{p^2} \\ G(s) = E[s^X] = \frac{p}{1-(1-p)s} \end{cases}$$

幾何分布については、どんな0以上の整数 m, n に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$p(X \geq m + n | X \geq m) = p(X \geq n)$$

[Image of geometric distribution mass function]

何これ：「SSRが出るまでガチャを引き続ける」ときの、爆死回数の分布

「いつか必ず成功するけど、それまでに何回失敗するかな？」をモデル化したものです。

 Important

 ここがポイント：残酷な「無記憶性 (Memoryless Property)」

無記憶性の数式を言葉に翻訳すると、こうなります。

「すでに m 回連続でガチャを外している ($X \geq m$) という条件下で、さらに追加で n 回外す確率は、最初から n 回外す確率と全く同じである」

つまり、「これまで99回外したから、そろそろ当たるだろう」という人間の期待を数学は冷酷に打ち砕きます。サイコロやガチャは過去の失敗を一切記憶していません。いついかなる時も、確率は常にリセットされて一定なのです（連続型分布における「指数分布」も全く同じ性質を持ちます）。

5.7 負の二項分布

成功確率 p のベルヌーイ試行をくり返すとき、 r 回目の成功が起きるまでの失敗の回数がしたがう分布で、 $NB(r, p)$ と表します。 $r = 1$ のときには幾何分布に一致します。

$$p(X = x) = {}_{r+x-1}C_x p^r (1-p)^x \quad (x \in \{0, 1, 2, \dots\})$$

この時、以下のようになっている

(※ご提示の分散の式は分子に p が余分に入っていたので、 $r(1-p)/p^2$ にそと修正しておきますね！)

$$\begin{cases} E[X] = \frac{r(1-p)}{p} \\ V[X] = \frac{r(1-p)}{p^2} \\ G(s) = E[s^X] = \left(\frac{p}{1-(1-p)s} \right)^r \end{cases}$$

負の二項分布には**再生性**がある

何これ：幾何分布の「コピペ&足し算」（目的のアイテムを r 個集めるまでの道のり）

幾何分布が「1回成功するまで」なら、負の二項分布は「 r 回成功するまで」の分布です。

 Tip

 特性値のチート導出

「 r 回成功するまでの失敗回数」は、「1回成功するまでの失敗回数（幾何分布）」を r 回独立に繰り返して足し合わせたものと全く同じです。だから、**平均も、分散も、幾何分布の公式を単純に「 r 倍」するだけで完成します**。確率母関数 $G(s)$ も、幾何分布の母関数を「 r 乗」するだけです。再生性（同じ分布同士を足すと、パラメータが足される性質）があるのもこのためです。

5.8 多項分布

ベルヌーイ試行は結果が2通りですが、より一般的に結果が k 通りで、それぞれが起こる確率が $p_1, p_2, \dots, p_k$ ($p_1 + p_2 + \dots + p_k = 1$) で一定の場合を多項試行と呼ぶことにします。独立な多項試行を n 回行ったとき、 k 通りの結果が起きる回数がしたがう確率分布が多項分布で、 $M(n; p_1, p_2, \dots, p_k)$ と表します。 $k = 2$ のときには二項分布に一致します。

$$p(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k} \quad (\text{for } x_1 + \dots + x_k = n)$$

$(X_1, \dots, X_k) \sim M(n; p_1, \dots, p_k)$ のとき、 $X_i \sim \text{Bin}(n, p_i)$ であり、 X_i と X_j ($i \neq j$) の共分散と相関係数は次の通りです。
(※相関係数もルートが分母にまで掛かる形に整理して修正しています！)

$$\begin{cases} \text{Cov}(X_i, X_j) = -np_i p_j \\ \rho(X_i, X_j) = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}} \end{cases}$$

何これ：コイン（2面）の世界から、サイコロ（多面）の世界への拡張

二項分布を「他次元ベクトル」に拡張したものです。「アンケートでA党、B党、C党にそれぞれ何票入るか」といったデータを扱うときの基本になります。

Note

物理的解釈：なぜ共分散と相関係数が「マイナス」になるのか？

共分散の式にマイナスがついているのが最大のポイントです。

多項分布は「全体の試行回数 n が固定されている（保存則がある）」という制約の中で動いています。

つまり、**「項目 i の回数（例：サイコロの1の目）がたくさん出た」ということは、必然的に「他の項目 j の回数（例：サイコロの2の目）はその分だけ減る」**というゼロサムゲームになっているのです。誰かが得をすれば誰かが損をするため、変数同士の関係（相関）は必ずマイナスになります。

6 連続型分布と標本分布

6.1 連続一様分布

区間 $[a, b]$ で一定の確率密度をもつ確率分布で、 $a < b$ として、 $U(a, b)$ と表します。

$$f(x) = \begin{cases} 0 & (x \notin [a, b]) \\ \frac{1}{b-a} & (x \in [a, b]) \end{cases}$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{a+b}{2} \\ V[X] = \frac{(b-a)^2}{12} \\ M(t) = E[e^{tX}] = \frac{e^{bt} - e^{at}}{(b-a)t} \end{cases}$$

何これ：どこを切っても「金太郎飴」のような、完全に平坦な確率の海

離散一様分布（サイコロ）の連続空間バージョンです。ルーレットの針が止まる角度（0 から 360 度）のように、どの値も全く同じ確率で出現する状態を表します。

Note

物理的・幾何学的解釈

- 分散の「12」という数字：前章の離散一様分布でも登場しましたが、連続空間の場合、分散は積分 $\int x^2 dx = \frac{1}{3}x^3$ から計算されます。この積分の「3」と、幅を計算する際の操作などが組み合わさり、必然的に分母に「12」が現れます。慣性モーメントの計算で、棒の重心周りの回転の式が $\frac{1}{12}ML^2$ になるのと同じ数学的構造です！

6.2 正規分布

偶然誤差に見られるように、平均 μ を中心とする対称な確率分布で、 $\sigma > 0$ として、 $N(\mu, \sigma^2)$ と表します。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

特に、 $\mu = 0, \sigma^2 = 1$ の場合を**標準正規分布**と言います。

この時次が成り立つ。

$$\begin{cases} E[X] = \mu \\ V[X] = \sigma^2 \\ M(t) = E[e^{tX}] = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right) \end{cases}$$

正規分布には再生性があり、 $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$ が独立であるとき、 $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ が成り立ちます。より一般的に、 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$ も成り立ちます。

[Image of normal distribution curve with standard deviations]

何これ：統計学における「絶対王者」。自然界のノイズが行き着く究極の姿

物理系の方にとっては**「マクスウェル＝ボルツマン分布」の速度成分や、量子力学の「ガウス波束（基底状態の波動関数）」**そのものです。

🔥 Important

🔥 何が嬉しいのか？：中心極限定理の主役

コイン投げだろうが、サイコロだろうが、ポアソン分布だろうが、**「独立な確率変数を大量に足し合わせると、元の分布の形に関係なく、最終的に必ずこの正規分布の形になる」**という宇宙の法則（中心極限定理）があります。

ランダムウォーク（ブラウン運動）を無限に繰り返した粒子の存在確率も正規分布になりますし、熱雑音も正規分布です。「細かい無数の要因が足し合わさってできた結果」はすべてコレに従うため、統計学の基準として圧倒的に多用されます。

6.3 指数分布

機械が故障するまでの時間などを表すのにも使われる確率分布で、 $\lambda > 0$ として、 $Exp(\lambda)$ と表します。

$$f(x) = \lambda e^{-\lambda x}$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{1}{\lambda} \\ V[X] = \frac{1}{\lambda^2} \\ M(t) = E[e^{tX}] = \frac{\lambda}{\lambda - t} \end{cases}$$

指数分布については、どんな正の数 a, b に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$p(X \geq a + b | X \geq a) = p(X \geq b)$$

何これ：「いつ起きるか分からない突発イベント」を待ち続ける時間の分布

前章の「幾何分布（ガチャが当たるまでの回数）」の連続時間バージョンです。物理では**「放射性同位体が崩壊するまでの時間」**の分布と全く同じ式です（半減期の計算でおなじみですね）。

🔥 Tip

💡 ポアソン分布との密接な関係

ポアソン分布と指数分布は表裏一体です。

- **ポアソン分布**：1時間に平均 λ 台のバスが来る確率。
- **指数分布**：そのバスが「次に来るまでの待ち時間（間隔）」の確率。

ここにも**無記憶性**があります。「もう30分も待ってるんだから、そろそろ来るだろう」という人間の期待は通用しません。いまこの瞬間からさらに b 分待つ確率は、最初から b 分待つ確率と同じです。放射性原子が「俺はもう1億年崩壊せずに我慢したから、そろそろ崩壊しようかな」と思わないのと同じです。

6.4 ガンマ分布

$x > 0$ で定義される確率分布で、 $a > 0, b > 0$ として、 $Ga(a, b)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}} \quad (x \geq 0)$$

a を**形状母数**、 b を**尺度母数**と言い、上の式の $\Gamma(a)$ はガンマ関数です。 $a = 1$ のときには、指数分布 $Exp(1/b)$ に一致します。この時次が成り立つ。

$$\begin{cases} E[X] = ab \\ V[X] = ab^2 \\ M(t) = E[e^{tX}] = (1 - bt)^{-a} \end{cases}$$

ガンマ分布には再生性があり、 $X_1 \sim Ga(a_1, b)$ 、 $X_2 \sim Ga(a_2, b)$ が独立であるとき、 $X_1 + X_2 \sim Ga(a_1 + a_2, b)$ が成り立ちます。

何これ：指数分布の「コピペ&足し算」（目的のイベントが a 回起こるまでの待ち時間）

幾何分布に対する「負の二項分布」の関係と同じです。指数分布が「1回目」のイベントが起きるまでの時間なら、ガンマ分布は「 a 回目」のイベントが起きるまでの時間の分布です。

📌 Note

📌 数式のハック

- 形状母数 a が整数の場合、ガンマ分布は**「互いに独立な a 個の指数分布 $Exp(1/b)$ を足し合わせたもの（アーラン分布）」**になります。
- だから、平均は単純に指数分布の平均 b （※ $\lambda = 1/b$ の場合）を a 倍した ab になり、分散も a 倍の ab^2 になります。再生性があるのも、単なる「足し算の拡張」だからです。

6.5 ベータ分布

$0 < x < 1$ で定義される確率分布で、 $a > 0, b > 0$ として、 $Be(a, b)$ と表します。

$$f(x) = \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} \quad (0 \leq x \leq 1)$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{a}{a+b} \\ V[X] = \frac{ab}{(a+b)^2(a+b+1)} \end{cases}$$

何これ：「確率」そのものの確率分布（コインの歪み具合を推理する）

X の範囲が $[0, 1]$ （つまり 0% から 100%）に限定されているのが最大の特徴です。これは**「確率（ p ）がどんな値を取りそうか」を表現するための分布**です。

Tip

💡 何が嬉しいのか？：ベイズ統計の親友（共役事前分布）

未知のコインを投げて「表が $a - 1$ 回、裏が $b - 1$ 回」出たとき、「このコインの本当の『表が出る確率 X 』はどれくらいだろうか？」と推理（ベイズ推定）した結果が、そのままベータ分布の形になります。

式の中に $x^{a-1}(1-x)^{b-1}$ とあるように、これは二項分布の $p^x(1-p)^{n-x}$ の p を主役（変数）にすり替えたものです。

6.6 対数正規分布

$Y \sim N(\mu, \sigma^2)$ のとき、 $X = e^Y$ がしたがう確率分布で、 $\Lambda(\mu, \sigma^2)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2x}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right) \quad (\text{for } x \geq 0)$$

この時次が成り立つ。

$$\begin{cases} E[X] = \exp\left(\mu + \frac{1}{2}\sigma^2\right) \\ V[X] = \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1) \end{cases}$$

何これ：「掛け算」で増えていく現象（乗法過程）がたどり着く姿

正規分布が「細かい要因の足し算」で生まれるなら、対数正規分布は「細かい要因の掛け算」で生まれます。

Important

🔥 物理的・現実的解釈

- なぜ対数をとるのか？： $\log X = Y$ ですから、「掛け算（ $X = A \times B \times C \dots$ ）」の世界を対数によって「足し算（ $\log X = \log A + \log B + \log C \dots$ ）」の世界に変換しています。足し算の世界（ Y ）なら、中心極限定理が発動して正規分布 $N(\mu, \sigma^2)$ になりますよね。それを元の世界（ X ）に戻したのが対数正規分布です。
- 実例：株価の変動、年収の分布、岩石を砕いたときの破片の大きさ（砕くたびに体積が「何分の一」になるという掛け算）など、右に長く裾を引く非対称なデータの多くがこの分布に従います。

6.7 多変量正規分布

$\mathbf{x} = (x_1, \dots, x_k)^T$ 、その平均ベクトルを $\boldsymbol{\mu} = (\mu_1, \dots, \mu_k)^T$ 、分散共分散行列を Σ とする k 変量正規分布を $N(\boldsymbol{\mu}, \Sigma)$ と表します。同時確率密度関数は次の通りです。

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

2変量の場合には次のように表せます。

$$f(\mathbf{x}) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left[-\frac{1}{2}(x_1 - \mu_1 \quad x_2 - \mu_2)\Sigma^{-1}\begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}\right]$$

また、 X_1 と X_2 の相関係数を ρ として、 $(X_1, X_2)^T$ が次の2変量正規分布にしたがうとき、 $X_1 \sim N(\mu_1, \sigma_1^2)$ 、 $X_2 \sim N(\mu_2, \sigma_2^2)$ が成り立ちます。

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left[\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right]$$

このとき、 $aX_1 + bX_2$ は次の正規分布にしたがいます。

$$aX_1 + bX_2 \sim N[a\mu_1 + b\mu_2, a^2\sigma_1^2 + 2ab\rho\sigma_1\sigma_2 + b^2\sigma_2^2]$$

$X_1 = x_1$ が与えられたときの X_2 の条件付き分布は次の期待値、分散をもつ正規分布です。

$$E[X_2 | X_1 = x_1] = \mu_2 + \frac{\rho\sigma_1\sigma_2}{\sigma_1^2}(x_1 - \mu_1)$$

$$V[X_2 | X_1 = x_1] = \sigma_2^2(1 - \rho^2)$$

何これ：多次元空間に浮かぶ、傾いた「ラグビーボール型の雲」

1次元のベルカーブ（山）を、多次元空間に拡張したものです。上から等高線を見ると、データは綺麗な楕円の形に広がっています。

Note

幾何学的解釈と予測への応用

- **行列の正体**：指数関数の中身にある $(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ は、幾何学的には**「マハラノビス距離の2乗」**を表しています。分散が大きく傾いている方向を自動的に補正し、公平に距離を測る「計量テンソル」の役割を果たします。
- **何が嬉しいのか？**：条件付き期待値の式は、まさに X_1 から X_2 を当てる**「回帰直線」**の式です。条件付き分散 $V[X_2 | X_1 = x_1] = \sigma_2^2(1 - \rho^2)$ を見ると、相関 ρ がある情報を知ること、予測のブレが元の分散より確実に小さく（鋭く）なることがわかります。

6.8 混合正規分布

複数の正規分布を合成してできる確率分布。例えば、 $N(0, 1)$ の確率密度関数を $\phi_1(x)$ ， $N(4, 1)$ の確率密度関数を $\phi_2(x)$ として、 $f(x) = 0.3\phi_1(x) + 0.7\phi_2(x)$ は2成分混合正規分布の確率密度関数である。これが一般にすると以下のようになる。

$$f(x) = \sum_{j=1}^k \pi_j \phi_j(x) \quad \left(\text{where } \sum_{j=1}^k \pi_j = 1 \right)$$

【例題】大学入試における合格確率

ある大学の入試では60点以上の得点が合格である。

受験者のうち、文系と理系の生徒の割合は 2 : 1 であり、それぞれの得点分布は以下に従うとする。

- 文系の得点： $N(55, 6^2)$
- 理系の得点： $N(65, 8^2)$

ランダムに選んだ1人の受験生の得点を X 、標準正規分布の確率密度関数を $\phi(x)$ としたとき、その受験生が合格（ $X \geq 60$ ）である確率は次のように求められる。

$$P(X \geq 60) = \frac{2}{3}P\left(Z \geq \frac{60 - 55}{6}\right) + \frac{1}{3}P\left(Z \geq \frac{60 - 65}{8}\right)$$

何これ：異なる背景を持つ集団がごちゃ混ぜになった、ふたつの「山」を持つ分布

これまでの確率分布は山が1つ（単峰性）でしたが、現実の世界は「文系と理系」「男性と女性」のように、**性質の違う複数のグループが混ざり合っ**て、**山が2つ以上できている**ことがよくあります。これを数学的に表現したのが混合正規分布です。

6.8.1 パラメータ推定（EMアルゴリズム）

手元にある観測データ $x_1, x_2, \dots, x_n$ から、混合分布を構成する各分布のパラメータ（平均・分散・混合比）を推定する。

ここでは2成分混合正規分布の確率密度関数を以下のように定義する。

$$f(x) = \pi\phi_1(x) + (1 - \pi)\phi_2(x)$$

パラメータ $\theta = (\mu_1, \sigma_1^2, \mu_2, \sigma_2^2, \pi)$ が未知のとき、**EMアルゴリズム**を用いて次の手順で推定を行う。

① 初期値の設定

パラメータの初期値 $\theta^{(0)}$ を決定する。

② 【Eステップ】負担率の計算

現在のパラメータ $\theta^{(k)}$ を用いて、各観測値 x_i がグループ1 (ϕ_1) から得られた確率（負担率 γ_i ）を求める。

$$\gamma_i^{(k+1)} = \frac{\pi^{(k)} \phi_1(x_i | \mu_1^{(k)}, \sigma_1^{2(k)})}{\pi^{(k)} \phi_1(x_i | \mu_1^{(k)}, \sigma_1^{2(k)}) + (1 - \pi^{(k)}) \phi_2(x_i | \mu_2^{(k)}, \sigma_2^{2(k)})}$$

③【Mステップ】パラメータの更新

②で求めた $\gamma_i^{(k+1)}$ を各データがグループ1に属する重みとして扱い、パラメータの $k+1$ 回目の更新値を次の式で求める。

$$\begin{aligned}\mu_1^{(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} x_i}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\ \sigma_1^{2(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} (x_i - \mu_1^{(k+1)})^2}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\ \pi^{(k+1)} &= \frac{1}{n} \sum_{i=1}^n \gamma_i^{(k+1)}\end{aligned}$$

(※ グループ2のパラメータ μ_2, σ_2^2 についても、重みを $(1 - \gamma_i^{(k+1)})$ に置き換えて同様に更新する)

④ 収束判定

パラメータの更新による変化量が十分に小さくなるまで、②（Eステップ）と③（Mステップ）を収束するまで繰り返す。

何が嬉しいのか？：「卵が先か鶏が先か」を交互に解く機械学習の超絶テクニック

データにラベル（「この点は文系」「これは理系」）がなくても、「文系の山」と「理系の山」を自動で分離するためのアルゴリズムです。

- **Eステップ**：いま仮置きしている山から見て、各データが「どっちの山から生まれたっぽさ」があるかを確率（負担率）で割り振る。
- **Mステップ**：その割り振られた確率を「重み」として使い、各山の位置（平均・分散）を計算し直す。
これを繰り返すと、水と油が自然に分離するようにコンピュータが隠れたグループの境界線を見つけ出してくれます。

6.9 カイ二乗分布

n を自然数として、 $Ga(n/2, 2)$ を自由度 n のカイ二乗分布と言って、 $\chi^2(n)$ と表します。

1. $Z \sim N(0, 1)$ のとき、 $Z^2 \sim \chi^2(1)$ であり、 Z_i がそれぞれ独立であるならば、 $\sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ です。
2. ガンマ分布の再生性から、 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$ で、 X と Y が独立ならば、 $X + Y \sim \chi^2(m + n)$ です。
3. $X \sim \chi^2(n)$ のとき、 $E[X] = n$, $V[X] = 2n$ です。モーメント母関数はガンマ分布のモーメント母関数から導けるので略。

何これ：ランダムな矢印（ベクトル）の「長さの2乗」の分布

物理の熱力学において、**「空間を飛び回る気体分子の運動エネルギーの分布」**そのものです。



Tip

💡 物理的・幾何学的イメージ

各座標軸方向の速度 Z_1, Z_2, Z_3 がそれぞれ独立な標準正規分布に従っているとき、原点からの「距離の2乗」は $Z_1^2 + Z_2^2 + Z_3^2$ になります。これが**自由度3のカイ二乗分布**です。自由度 n は「独立に動ける次元の数」であり、次元が増えれば増えるほど、距離の2乗の平均値も n に比例して大きくなります。

6.9.1 非心カイ二乗分布

Z_i が独立に標準正規分布に従い、 $\lambda = \sum_{i=1}^n \mu_i^2 \geq 0$ のとき、 $\sum_{i=1}^n (Z_i + \mu_i)^2 \sim \chi^2(n, \lambda)$ であり、この分布を**非心カイ二乗分布**と言います。
これも再生性があり、 $X_i \sim \chi^2(n_i, \lambda_i)$ のとき、以下のように書ける。

$$\sum_{i=1}^n X_i \sim \chi^2\left(\sum_{i=1}^n n_i, \sum_{i=1}^n \lambda_i\right)$$

何これ：「的の中心（原点）」から狙いがズレているときの散らばりの分布

最初から中心が μ_i だけズレている（偏りがある）状態での、原点からの距離の2乗を測定しています。物理で言えば、全体として一定の速度（風）で移動している容器の中の、分子の運動エネルギー分布を測るようなものです。

6.10 t分布

$Z \sim N(0, 1)$, $Y \sim \chi^2(n)$ で Z と Y が独立のとき、次の T がしたがう確率分布を自由度 n のt分布と言って、 $t(n)$ と表します。

$$T \equiv \frac{Z}{\sqrt{Y/n}} \sim t(n)$$

$t(1)$ はコーシー分布に一致し、 $n \rightarrow \infty$ で $t(n)$ は標準正規分布に分布収束します。また、 $X \sim t(n)$ ならば、 $n > 1$ のとき $E[X] = 0$ で、 $n > 2$ のとき $V[X] = n/(n-2)$ です。

上の T の式で、 $Z \sim N(\lambda, 1)$ のとき、 T がしたがう確率分布を自由度 n 、非心度 λ の非心 t 分布と言います。

何これ：データ数が少なくて「真のばらつき」が分からないときの、実戦向けの正規分布

形は標準正規分布にそっくりですが、正規分布よりも**「裾が厚い（両端の確率が高い）」**のが特徴です。

🔥 Important

🔥 数式の構造を見破る：なぜ裾が厚くなるのか？

分子 Z はデータのズレを表しますが、分母 $\sqrt{Y/n}$ は「手元の少ないデータから見積もった、ばらつきの不確かさ」を表します。データ数が少ないと、分母のばらつき見積もり自体がまたま小さくなってしまいう「ゆらぎ」が発生します。分母がランダムに変動するせいで、定数で割る時よりも**「確率的にとんでもない大外れの値」が出やすくなります**。これが分布の裾が厚くなる理由です。データが増えれば分母のゆらぎは消え、完璧な標準正規分布に収束します。

7 極限定理、漸近理論

確率変数列 X_i の4つの収束は、条件の強さで変わってきます。

🔥 Important

🔥 訂正：収束の「強さ」のヒエラルキーについて

元のテキストでは概収束が「条件弱」、分布収束が「条件強」となっていましたが、実は**全くの逆**です！統計学における収束の強さは、以下の順番（上が最強）になります。

1. **概収束（最強） / 平均2乗収束（最強クラス）**：確率変数の「実体」そのものが、ズレなく完全に一致していく状態。
2. **確率収束（中）**：上記が成り立つなら必ずこれも成り立つ。実体がズレる確率が0に近づく。
3. **分布収束（最弱）**：上記が成り立つなら必ずこれも成り立つ。中身の実体が違ってても、「見た目のヒストグラム（分布の形）」さえ一致すれば許される一番ゆるい条件。

以下の見出しでは、この正しい強弱関係に基づいてカッコ内を修正しています。

7.1 概収束（条件：最強）

$$P(\lim_{n \rightarrow \infty} X_n = Y) = 1$$

これが成り立つのが概収束であり、例えば**大数の強法則**がある。

何これ：「絶対に、例外なく、最後にはピッタリ一致する」という究極の収束

サイコロを無限回振ったとき、平均が3.5からズレる世界線（確率）は「0%」である、という非常に強い主張です。

7.2 平均2乗収束（条件：最強クラス）

$$\lim_{n \rightarrow \infty} E[(X_n - Y)^2] = 0$$

これが成り立つのが平均2乗収束である。

7.3 確率収束（条件：中）

$$\forall \epsilon \in \mathbb{R}_{>0} \text{ s.t. } \lim_{n \rightarrow \infty} P(|X_n - Y| > \epsilon) = 0$$

このとき、「 $X_n \rightarrow_p Y$ 」と表す。

何これ：「誤差が ϵ 以上になる確率が、どんどん消滅していく」収束

完全に一致するかは約束できないけれど、「ほんの少しでも外れる確率」はデータが増えるにつれてゼロに近づいていくよ、という状態です。**大数の弱法則**は、実はこの「確率収束」に該当します。

7.4 分布収束（条件：最弱）

$$\lim_{n \rightarrow \infty} F_n(x) = G(x)$$

これが成り立つのが、分布収束といい、「 $X_n \rightarrow_d Y$ 」と表す。

何これ：「中身は違っても、外見（グラフの形）は最終的に同じになる」収束

例えば、「サイコロの出目の合計」と「コンピュータが作った乱数」は全く別の現象（実体）ですが、データが無限にあれば「どちらも同じ正規分布のベルカーブを描く」ようになります。これが分布収束です。

7.4 大数の弱法則（※番号は元のまま）

X_i が平均 μ 、分散有限の同一の分布に独立に従うとき、その標本平均は μ に**確率収束**（平均2乗収束を根拠として証明されることが多い）します。

何これ：サンプルを無限に集めれば、標本平均は必ず「真の平均」にたどり着くという安心感

「視聴率調査」や「世論調査」が成り立つ根本的な理由です。一部のデータ（標本）の平均値であっても、サンプルサイズ n を大きくしていけば、必ず神様だけが知っている本当の平均 μ に一致します。

7.5 中心極限定理

X_i が平均 μ 、分散 σ^2 の同一の分布に従うとき、その標本平均については次の**分布収束**が成り立つ。


$$\sqrt{n}(\bar{X}_n - \mu) \rightarrow_d N(0, \sigma^2)$$

何これ：どんなに変な分布でも、大量に足し合わせると「正規分布」になる宇宙の法則

元データが「いびつな形（一様分布、ポアソン分布、指数分布など）」であっても、「それらの平均（標本平均）」の分布は、データ数 n さえ大きければ美しい正規分布（ベルカーブ）に落ち着くという、統計学において最も神がかった定理です。

7.6 連続修正

離散分布を**中心極限定理**によって正規分布で近似するとき、区間幅を0.5だけずらして近似の精度を上げる方法。例えば、 $X \sim \text{Bin}(n, p)$, $Y \sim N(np, np(1-p))$ として、 $P(a \leq X \leq b)$ は $P(a - 0.5 \leq Y \leq b + 0.5)$ でよく近似できます。次の図で、黄色いアミかけ部分 ($8.5 \leq Y \leq 11.5$) と二項分布の $P(9 \leq X \leq 11)$ を比べてみてください。



何これ：カクカクの階段（離散）を、なめらかな坂道（連続）で測るときの「隙間埋め」

二項分布（棒グラフ）は「幅が1」の長方形の集まりですが、正規分布（線）には幅がありません。そのため、「9から11まで」を連続な世界で計算するときは、棒グラフの左端（8.5）から右端（11.5）までを含めてあげないと面積が足りなくなってしまう、という微調整テクニックです。

7.7 連続写像定理

$X_n \rightarrow_d X$ で関数 h が連続である時、 $h(X_n) \rightarrow_d h(X)$ が成り立つ。

7.7.1 例

X_i が平均 μ 、分散 σ^2 の同一の分布に独立に従うとき、その標本平均について、中心極限定理によって以下の**分布収束**が成り立つ。

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \rightarrow_d N(0, 1)$$

$f(x) = x^2$ が連続関数であるから、**連続写像定理**により、次の**分布収束**が成り立つ。

$$\left(\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma}\right)^2 \rightarrow_d \chi^2(1)$$

何これ：極限の世界でも「連続関数」ならそのまま適用していいというチート能力

「極限をとってから関数に入れる」と、「関数に入れてから極限をとる」のを入れ替えても結果が同じになる、という超便利ツールです。上の例のように、「標準正規分布に収束するなら、それを2乗したものは（標準正規分布の2乗である）カイ二乗分布に収束する」と瞬時に言えるようになります。

7.8 スルツキーの補題

$U_n \rightarrow_d U$, $V_n \rightarrow_p a$ であるとき、 $U_n + V_n \rightarrow_d U + a$, $U_n V_n \rightarrow_d aU$ が成り立ちます。

何これ：ふわふわ揺れる「分布」と、ガッチリ固まった「定数」は自由に計算してヨシ

分布収束（極限が確率変数のまま残る U ）と、確率収束（極限がただの定数 a になるもの）が混ざった複雑な式でも、普通の四則演算のように定数 a を代入して極限をとって構わないという「許可証」です。t検定などの極限を証明する際に必須のテクニックです。

7.9 デルタ法

次のように正規分布に分布収束する確率変数列 U_n （サンプルサイズ n の標本平均 $\overline{X}_n$ など）を考えます。

$$\sqrt{n}(U_n - \mu) \rightarrow_d N(0, \sigma^2)$$

このとき、導関数が連続で $h'(\mu) \neq 0$ を満たす関数 h に対して次の**分布収束**が成り立ちます。

$$\sqrt{n}\{h(U_n) - h(\mu)\} \rightarrow_d N(0, \sigma^2\{h'(\mu)\}^2)$$

7.9.1 例

対数正規分布 $\Lambda(\mu, \sigma^2)$ の中央値 e^μ の推定量の分布を考える。

この対数正規分布に独立に従う確率変数 X_i とすると、 $Y_i \equiv \ln X_i \sim N(\mu, \sigma^2)$ であるので、それらの標本平均も次のように正規分布に従う。

$$\sqrt{n}(\overline{Y}_n - \mu) \rightarrow_d N(0, \sigma^2)$$

ここで、 $h(X) = e^X$ として、**デルタ法**を適用すると、次の**分布収束**が成り立つ。

$$\sqrt{n}(e^{\overline{Y}_n} - e^\mu) \rightarrow_d N(0, \sigma^2 e^{2\mu})$$

これは、中央値の推定量の分布が次のように近似できることを示しています。

$$e^{\bar{Y}_n} \sim N\left(e^\mu, \frac{e^{2\mu}\sigma^2}{n}\right)$$

何これ：複雑な関数の分散を知りたいとき、微分（接線）を使って無理やり正規分布に近似するハック

手元にあるデータ U_n が正規分布に従うことは分かっているけど、それを複雑な関数 h （例えば $\log$ や e^x など）に入れた後の分散がどうなるか分からない！という時に使います。

関数を「接線（一次近似）」で真っ直ぐな線とみなし、元の分散 σ^2 に「接線の傾きの2乗（ $\{h'(\mu)\}^2$ ）」を掛け合わせることで、強引に近似的な正規分布を作り出す裏技です。

8 統計的推定の基礎

8.1 統計的推定

- 標本： $X_1, \dots, X_n$
- 分布： $f(x; \theta)$
- 統計的推定とは観測値をもとに、その分布のパラメータ θ を求めること
- 点推定：標本の関数 $h(X_1, \dots, X_n)$ を用いてそのパラメータの値を推定すること

関数 $h(X_1, \dots, X_n)$ を **推定量**、観測値を代入した $h(x_1, \dots, x_n)$ を **推定値** という。推定量のように標本のみの関数を **統計量** という。

何これ：鍋の「味見」でスープ全体の塩加減を当てるゲーム

「統計的推定」とは、大きな鍋で作ったスープ全体（母集団）の塩加減（パラメータ θ ）を知るために、おたま一杯分（標本 X ）をすくって味見し、全体の味を推測することです。

- 推定量**：すくったスープから塩加減を計算するための「計算式（システム）」のこと。
- 推定値**：実際にスープをすくって計算式に入れ、出てきた「具体的な数値（例：塩分濃度1.2%）」のこと。

8.2 順序統計量

同一の分布からの標本の観測値を次のように大きさの順に並べかえたもの。

$$X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$$

何これ：テストの点数を「背の順」に並び替えること

バラバラに集めたデータそのままではなく、「最小値」「最大値」「中央値」などを探すために、とりあえず小さい順（あるいは大きい順）に並べ直したデータたちのことです。これを基に様々な分析がスタートします。

8.3 モーメント法

平均 μ の確率変数 X に対し、 $E[X]$ 、 $E[X^2]$...などのように、 $E[X^k]$ を原点まわりの k 次のモーメントと言い、 $E[X - \mu]$ 、 $E[(X - \mu)^2]$ 、...などのように、 $E[(X - \mu)^k]$ を平均まわりの k 次のモーメントと言います。

大数の法則に基づいてボスの推定量を得る方法。 $\theta = (\theta_1, \dots, \theta_k)$ とし、確率変数 X が確率密度関数 $f(x; \theta)$ に従うとき、次のように k 次までのモーメントが θ の関数として表されている場合を考える。

この時、 j 次のモーメントを次のように置き換えて、これを母数 $\theta_1, \dots, \theta_k$ について解くことで母数の推定量を得る。

$$E[X^j] = g_j(\theta) \therefore \frac{1}{n} \sum_{i=1}^n X_i^j = g_j(\theta)$$

何これ：「影の形」から「実体のサイズ」を逆算する推理法

「モーメント」とは、データの「重心（平均）」や「広がり（分散）」などの特徴を表す指標のことです。モーメント法は、「手元のデータの平均や分散（影）」と、「数式上の平均や分散（実体）」がイコールになるはずだ！と強引に方程式を立てて、未知のパラメータを逆算して解くという、非常に直感的で古典的なアプローチです。



$X \sim \text{Bin}(n, p)$ について考える。

$p(x) = \binom{n}{k} x^k (1-x)^{n-k}$ なので、 $E[X] = np$ 、 $V[X] = np(1-p)$ なので、 $X_i \sim \text{Bin}(n, p)$ ($i \in \{1, \dots, m\}$) が独立に成り立つと

$$\begin{cases} \overline{X} = \frac{1}{m} \sum_{i=1}^m X_i = np \\ \frac{1}{m} \sum_{i=1}^m X_i^2 = np(1-p) + n^2 p^2 \end{cases}$$

これを n, p について解くと、標本分散を S として次のモーメント推定量を得ることができる。

$$\begin{cases} \hat{n} = \frac{\overline{X}^2}{\overline{X} - S} \\ \hat{p} = \frac{\overline{X} - S}{\overline{X}} \end{cases}$$

8.4 最尤法

尤度が最大になるようにパラメータの推定値を決める方法。まず、確率密度関数 $f(x; \theta)$ をもつ同一の分布に独立にしたがう標本の観測値を $x_1, \dots, x_n$ として、次の式を θ の関数と見たものを尤度関数と言います。

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta)$$

$L(\theta)$ (or $\ln L(\theta)$) が最大になる θ を**最尤推定値**といい、それを確率変数としてあらわしたものを**最尤推定量**と言います。母数 θ の関数 $g(\theta)$ の最尤推定量は θ の最尤推定量を関数 g で変換したものに等しく、これを**不変性**と言います。

何これ：「この結果が起きたってことは、元々の設定はこうだったと考えるのが一番自然だよね！」という逆転の発想

例えば、表が出る確率が分からないコインを10回投げて「表が8回」出たとします。このとき「元々の表が出る確率は50%だった」と考えるより、「元々の確率は80%だった」と考えた方が、**今起きている現実（表8回）を一番上手く説明できますよね。**
このように、「今のデータが観測される確率（尤度＝もっともらしさ）が一番高くなるようなパラメータ」を探し当てる、現代統計学の最強ツールです。

Hint

$X_1, \dots, X_n \sim N(\mu, \sigma^2)$ について考える。

- μ の最尤推定量は標本平均 $\overline{X} = \frac{1}{n} \sum_{i=1}^n X_i$ である。
- σ^2 の最尤推定量は標本分散 $S = \frac{1}{n} \sum_{i=1}^n (X_i - \overline{X})^2$ である。

標本平均と標本分散は**一貫性**を持ちます。つまり、 $n \rightarrow \infty$ において母数の真値に収束します。

8.5 漸近正規性

確率密度関数 $f(x; \theta)$ を持つ同一の分布に独立に従う $X_1, \dots, X_n$ で、 θ の最尤推定量をハットをつけて表すと、 $n \rightarrow \infty$ のとき、適当な正則条件のもとで次の分布収束が成り立つ。

$$\sqrt{n}(\hat{\theta} - \theta) \rightarrow_d N\left(0, \frac{1}{J_1(\theta)}\right)$$

上記の $J_1(\theta)$ は次の**フィッシャー情報量**で $n = 1$ としたものである。

$$J_n(\theta) = E \left[\left(\frac{d}{d\theta} \log f(x_1, \dots, x_n; \theta) \right)^2 \right]$$

フィッシャー情報量は、ある条件のもとで次のようにも表せます。

$$J_n(\theta) = -E \left[\frac{d^2}{d\theta^2} \log f(x_1, \dots, x_n; \theta) \right]$$

何これ：データが増えれば、最尤推定量は「真の値」を中心に美しい正規分布を描く

最尤法で求めた推定量も、完璧ではなくブレがあります。しかしデータ数 n が増えれば増えるほど、そのブレは真の値 θ を中心とした美しい正規分布（ベルカーブ）に近づいていきます。

また、**フィッシャー情報量**とは「手元のデータが、真のパラメータについてどれくらい有益な情報を隠し持っているか」を表す感度のようなものです。情報量が多い（山のカーブが急である）ほど、推定のブレ（分散）は小さくなります。

8.6 バイアス・バリエンス分解

確率密度関数 $f(x; \theta)$ を持つ分布において、 θ の推定量をハットをつけて表すと、次の式の左辺が平均二乗誤差で、右辺第1項の θ ハットの分散（バリエンス）と、第2項のバイアスの2乗の和に一致します。

$$E[(\hat{\theta} - \theta)^2] = V[\hat{\theta}] + (E[\hat{\theta}] - \theta)^2$$

何これ：推定の「ヘタクソさ」は、「狙いのズレ（バイアス）」と「腕のブレ（バリエンス）」の足し算である

ダーツをイメージしてください。的に当てるのが下手な理由には2種類あります。

1. **バイアス（偏り）**：そもそも狙っている場所が的の中心からズレている（クセがある）。
2. **バリエンス（分散）**：狙いは合っていても、投げるたびに矢が色んなところに散らばる（手が震える）。
機械学習や統計学において、この2つは「あちらを立てればこちらが立たず（トレードオフ）」の関係になりやすく、両方のバランスを取ることが重要になります。

8.7 不偏推定量

母数 θ に対して、バイアスが0である推定量（期待値が母数の真値に一致する推定量）。例えば、最尤法の説明の中で紹介した標本分散は母分散の不偏推定量ではありませんが、次の不偏分散は母分散の不偏推定量です。

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

何これ：「何回も繰り返せば、平均的にはちゃんと真の値（的のド真ん中）に一致する」という優れた計算式

前の項でいう「バイアスがゼロ」の状態です。

ただの標本分散（ n で割る）だと、手元のデータの中だけでバラつきを計算するため、真のバラつきよりも「少し小さめ」に見積もるクセ（バイアス）があります。そこで、分母をあえて $n-1$ に減らすことで計算結果を少し大きくし、偏りを打ち消したものが「不偏分散」です。

8.8 ジャックナイフ推定量

バイアスのある推定量について、次の方法でバイアスを補正したもの。

1. 標本 $X_1 \cdots X_n$ のから求められる θ の推定量（バイアスあり） θ_1 を考える。
2. X_1 を取り除き、残りから1. と同じように求めた θ の推定量を $\theta_{(1)}, \cdots, \theta_{(n)}$ としていき、その平均 θ_2 を求める
3. 新しい推定量を次のように定義する

$$\theta_{\text{new}} = n\theta_1 - (n-1)\theta_2$$

何これ：わざとデータを1個ずつ仲間外れにして、推定の「クセ」をあぶり出して打ち消す職人技

「データ全部で計算した結果」と、「1個だけ隠して計算した結果たち」を比べることで、「この計算式、どれくらい偏るクセがあるのかな？」を自力で測り、そのクセを引いて補正するゴリ押しテクニックです。ジャックナイフ（万能サバイバルナイフ）のように、「どんな複雑な状況でもとりあえず使える便利な道具」という意味で名付けられました。

8.9 一様最小分散不偏推定量（UMVUE）

不偏推定量の中で、分散が最小であるもの。

（※最小2乗法、ガウス・マルコフの定理、BLUEについては、第16章で紹介します。）

何これ：偏りがなく（不偏）、かつ一番ブレない（最小分散）、「最強のダーツプレイヤー」

バイアスがない（常に的の中心を狙える）推定量はたくさんありますが、その中でもバリエーション（手の震えによる散らばり）が一番小さく、最もキョッと中心に矢がまとまる、理論上最強の推定量のことを指します。

8.10 クラメール・ラオの不等式

不偏推定量の分散の下限を与える次の不等式のこと。

$$V(\hat{\theta}) \geq J_n(\theta)^{-1}$$

8.10.1 漸近有効推定量

$n \rightarrow \infty$ のとき、分散がクラメール・ラオの下限を達成する一致推定量。

8.10.2 有効推定量

不偏推定量の中で、クラメール・ラオの下限を達成するもの。有効推定量はUMVUEです。

何これ：「どんなに頑張っても、この限界線より精度を良くすることは物理的に不可能だよ」という絶望と希望の不等式

推定のブレ（分散）をどこまで小さくできるかには、実は「データの情報量（フィッシャー情報量）」によって決まる絶対的な限界値が存在します。光の速度を超えられないのと同じです。

この限界（下限）まで見事に到達できた究極の推定量を「有効推定量」と呼びます。

8.11 十分統計量

確率密度関数 $f(x; \theta)$ を持つ同一の分布に独立にしたがう標本の観測値を $x_1, \dots, x_n$ として $\mathbf{X} = (X_1, \dots, X_n)$ の実現値 $\mathbf{x} = (x_1, \dots, x_n)$ とするとき、統計量 $T(\mathbf{X})$ が θ に関する十分統計量であるとは、 $T(\mathbf{X}) = t$ を与えた時の $\mathbf{X} = \mathbf{x}$ の条件付確率が θ に依存しないことをいう。

Andalusite

そして、 $T(\mathbf{X})$ が θ に関する十分統計量であることは、 $\mathbf{X}$ の同時密度関数 $f(\mathbf{x}; \theta)$ が次の式の右辺のように分解できることと同値です。

$$f(\mathbf{x}; \theta) = h(\mathbf{x})g(T(\mathbf{x}), \theta)$$

つまり、 θ に依存する部分は、 $T(\mathbf{x})$ の関数として表せるということで、これを **フィッシャー・ネイマンの分解定理** と言います。

何これ：元のデータが1万個あっても、この「要約された値」さえ知っていれば情報ロスはゼロ！という究極のデータ圧縮

例えば、コインの表が出る確率 θ を推定したいとき、「表、裏、裏、表、表...」という個別の結果の順番はどうでもよくて、「全部で何回表が出たか（合計値）」さえ知っていれば十分ですね。

このように、パラメータを推定するために必要な「旨味（情報）」を100%保ったまま、データをギュッと圧縮した値のことを「十分統計量」と呼びます。

Tip

互いに独立なパラメータ λ のポアソン分布に従う確率変数を $X_1, \dots, X_n$ とすると、同時確率関数は次のようになります。

$$\prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

パラメータ λ に依存する部分は $\sum_{i=1}^n x_i$ の関数として表されるので、 $\sum_{i=1}^n x_i$ が λ の十分統計量です。

9 区間推定

母集団分布が $N(\mu, \sigma^2)$ であるとき、標本の大きさ n の標本平均は $N\left(\mu, \frac{\sigma^2}{n}\right)$ に従います。

何これ：「点」ではなく「網」でターゲットを捕まえる技術

「あの人の体重は60kgだ！」と一点張りで当てる（点推定）のはほぼ不可能ですが、「58kg〜62kgの間だろう」と幅を持たせれば、高い確率で正解できます。手元のデータ（標本）から、本当の値（母数）がすっぽり収まる「網の広さ」を計算するのが区間推定です。

9.1 母平均の推定（母分散が既知）

母集団分布が $N(\mu, \sigma^2)$ で標本の大きさが n の時、信頼度95%の信頼区間は以下のように計算できる。

$$\bar{X} - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{\sigma}{\sqrt{n}}$$

何これ：理想的なボーナスタイム（基本形）

神様が「全体のバラつき（母分散 σ^2 ）」だけはこっそり教えてくれた、という現実には滅多にないラッキーな状況です。バラつきが確定しているので、堂々と「標準正規分布（1.96）」を使って幅を決められます。すべての基本になる式です。

9.2 母平均の推定（母分散が未知、小標本）

信頼度95%の信頼区間は以下のように計算できる。

$$\bar{X} - t_{0.025}(n-1) \frac{U}{\sqrt{n}} \leq \mu \leq \bar{X} + t_{0.025}(n-1) \frac{U}{\sqrt{n}}$$

何これ：「分からないこと」が多いから、少し広めに網を張る（ t 分布の出番）

現実世界では、全体のバラつき（母分散）なんて誰も知りません。仕方ないので、手元のデータから計算した「不偏分散 U 」で代用します。しかし、代用品を使っている分、推定に「自信のなさ（不確実性）」が混ざります。そのため、正規分布よりも少しだけ裾が広がってファジーな**「 t 分布」**を使って、網を少し広めに張る（安全マージンをとる）のがこの式です。

9.3 母平均の推定（母分散未知、大標本）の場合

信頼度95%の信頼区間は以下のように計算できる。

$$\bar{X} - 1.96 \frac{U}{\sqrt{n}} \leq \mu \leq \bar{X} + 1.96 \frac{U}{\sqrt{n}}$$

この場合、中心極限定理により、母集団分布はどんなものでもかまいません。



Tip

ここで出てくる U とは、不偏標本分散であることに注意

何これ：データが大量にあれば、代用品(U)でも正規分布(1.96)を使ってヨシ！という力技

サンプルサイズ n が十分に大きい（大標本）なら、中心極限定理という最強の魔法が発動します。「データがいっぱいあるから、代用品の不偏分散 U を使っても、ほぼ真の分散と同じしょ！」と見なし、ファジーな t 分布を使わずに、再びシャープな正規分布（1.96）に戻ってこられるという強力な定理です。

9.4 母分散の推定（母平均が未知）の場合

母集団分布が正規分布で標本の大きさが n のとき、信頼度95%の信頼区間は次の式から計算できます。

$$\frac{(n-1)U^2}{\chi_{0.025}^2(n-1)} \leq \sigma^2 \leq \frac{(n-1)U^2}{\chi_{0.975}^2(n-1)}$$

何これ：平均ではなく「バラつきのブレ幅」を推定する

「工場の機械で作ったネジの長さが、どれくらいバラついているか？」を推定したいときに使います。分散は「2乗」して計算されるため、マイナスの値にならず、左右非対称な形をした**「カイ二乗（ χ^2 ）分布」**を使います。分母にカイ二乗の値が来るのが特徴です。

9.5 母比率の推定（大標本）の場合

大きさ n の無作為標本において、注目している性質をもつ要素の数が X であるとき、信頼度95%の信頼区間は次の式から計算できます。

$$\frac{X}{n} - 1.96 \sqrt{\frac{\frac{X}{n} \left(1 - \frac{X}{n}\right)}{n}} \leq p \leq \frac{X}{n} + 1.96 \sqrt{\frac{\frac{X}{n} \left(1 - \frac{X}{n}\right)}{n}}$$

何これ：テレビでよく見る「内閣支持率」のカラクリ

標本比率（ $\frac{X}{n}$ または $\hat{p}$ ）を使った推定です。ルートの中身が「成功確率 × 失敗確率 / n 」になっているのは、二項分布の分散 $np(1 - p)$ を n^2 で割ったもの（比率の分散）だからです。

9.6 分散の比の区間推定

2つの正規母集団の無作為標本（標本の大きさはそれぞれ n_A, n_B ）から求められる不偏分散をそれぞれ U_A^2, U_B^2 とし、これらが独立であるものとします。2つの正規母集団の母分散を σ_A^2, σ_B^2 とおくと、信頼度95%の信頼区間は次の不等式で計算します。

$$\frac{U_B^2}{U_A^2} \frac{1}{F_{0.025}(n_B - 1, n_A - 1)} \leq \frac{\sigma_B^2}{\sigma_A^2} \leq \frac{U_B^2}{U_A^2} \frac{1}{F_{0.975}(n_B - 1, n_A - 1)}$$

ここでは F 分布が登場している

何これ：「機械Aと機械B、どっちが安定してる？」を比べるための割り算

2つのグループのバラつき（分散）を比べるときは、引き算ではなく「割り算（比）」を使います（もし同じバラつきなら比は 1 になります）。そして、2つのカイ二乗分布の割り算から生まれるのが**「 F 分布」**です。分散分析（ANOVA）にも繋がる超重要キャラクターです。

9.7 多項分布の差の信頼区間

$(X_1, X_2 \cdots, X_k) \sim M(n, p_1, p_2, \cdots, p_k)$ のとき、 $p_1 - p_2$ の信頼度95%の信頼区間は次の不等式で計算します。

$$\hat{p}_1 - \hat{p}_2 - 1.96 \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}} \leq p_1 - p_2 \leq \hat{p}_1 - \hat{p}_2 + 1.96 \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}}$$

ただし、上の不等式で p_1, p_2 にハットをつけた記号は、 X_1, X_2 の実現値を x_1, x_2 として、 $\hat{p}_1 = \frac{x_1}{n}, \hat{p}_2 = \frac{x_2}{n}$ とします。

💡 Tip

なぜルートの中に $+\frac{2\hat{p}_1\hat{p}_2}{n}$ という項があるのか？

多項分布（例：アンケートでA党、B党、C党から1つ選ぶ）では、「A党（ p_1 ）に投票する人が増えれば、必然的にB党（ p_2 ）に投票する人が減る」という**負の相関**があります。

分散の公式 $V(X - Y) = V(X) + V(Y) - 2Cov(X, Y)$ に当てはめると、共分散 Cov がマイナスになるため、結果的にマイナス×マイナスで「プラス」の項として登場するのです。

10 検定の基礎と検定法の導出

次の手順により、母数に関する2つの仮説のうち、データによって支持されるものを選ぶ手法。

- 1. 母数に関して、帰無仮説（否定したい仮説）と対立仮説（正しいことが期待される仮説）を設定する。
- 2. 帰無仮説を仮定したもとの検定統計量の確率分布を求め、有意水準と棄却域を決める。
- 3. 検定統計量の実現値が棄却域に落ちれば帰無仮説を棄却（否定すること）し、そうでなければ帰無仮説を受容する。

何これ：統計学における「刑事裁判」

仮説検定は、刑事裁判にそっくりです。

- **帰無仮説**：「被告人は無罪（ただの偶然である）」という大前提。
- **対立仮説**：「被告人は有罪（意味のある差がある）」という検察（あなた）の主張。
「無罪だとしたら、こんな証拠（データ）が揃う確率はたった5%未満（有意水準）だ！だから無罪（帰無仮説）という前提は間違っている！」と論破して棄却し、有罪（対立仮説）を勝ち取るゲームです。

10.1 検出力とサンプルサイズ

母比率 p に関する有意水準2.5%の片側検定で、帰無仮説を $p = p_0$ 、対立仮説を $p = p_1 (p_1 > p_0)$ として、サンプルサイズ n が十分に大きいとき、標本比率は近似的に正規分布にしたがい、それぞれの仮説のもとの分布は次の図のように表せます。



このときの棄却限界値は $p_0 + 1.96 \sqrt{\frac{p_0(1 - p_0)}{n}}$ である。

対立仮説のもとでの正規分布の曲線下面積のうち、上の棄却限界値を超える部分が検出力になるので、棄却限界値が p_1 から標準偏差の何倍離れているか（上の図の c 、ここでは $p_1 - p_0 = 1.96\sqrt{\frac{p_0(1-p_0)}{n}} + c\sqrt{\frac{p_1(1-p_1)}{n}}$ が成り立つ）がわかれば、標準正規分布にしたがう確率変数を Z として、検出力は $P(Z \geq -c)$ で計算できます。 $p_1 - p_0$ は帰無仮説のもとでの標準偏差の1.96倍と、対立仮説のもとでの標準偏差の c 倍の和に等しいという次の関係式が成り立つので、 p_0 、 p_1 に加えて、サンプルサイズ n が与えられれば検出力が求められ、逆に検出力が与えられればサンプルサイズ n が求められます。

次に、上の2つの正規分布を $N(\mu_0, \sigma^2/n)$ 、 $N(\mu_1, \sigma^2/n)$ とすると、上の式と同じように次の式が導けます。

$$\begin{aligned}\mu_1 - \mu_0 &= (1.96 + c) \frac{\sigma}{\sqrt{n}} \\ \therefore \frac{\mu_1 - \mu_0}{\sigma} &= \frac{1.96 + c}{\sqrt{n}}\end{aligned}$$

上記の左辺の $\frac{\mu_1 - \mu_0}{\sigma}$ を**エフェクトサイズ**といい、エフェクトサイズが大きくなるのは、 μ_0 と μ_1 が離れていて σ が小さい場合であり、このとき、2つの正規分布の確率密度関数のグラフはしっかりと離れて、あまり重ならなくなります。一定の検出力を得る（ c が一定である）ためには、エフェクトサイズが大きい場合ほど、サンプルサイズは少なくともすむことが上の式からわかります。

何これ：「犯人を見つけ出す能力」と「手がかりのデカさ」

- **検出力（Power）**：本当は有罪（差がある）のときに、ちゃんと見逃さずに「有罪！」と見抜ける力のこと。
- **エフェクトサイズ（効果量）**：薬を飲んだグループと飲んでないグループの「差のデカさ」。
差がめちゃくちゃデカイ（エフェクトサイズ大）なら、数人調べるだけ（少ないサンプルサイズ）で「絶対効いてるじゃん！」と一発で分かります。逆に、微妙な差しかないなら、何千人も集めないで「本当に効いてる」と証明できません。

10.2 生産者危険

帰無仮説が正しいときに、誤って帰無仮説を棄却してしまう誤りが**第一種の過誤**でした。出荷基準に適合しているかどうかを判定する抜取検査での呼び方にならない、この確率を**生産者危険**とも言います。なぜなら、生産者が正しく管理できている状態を帰無仮説とすると、正しく管理できているのに、抜取検査でたまたま不良品が多く観測されて出荷できなくなった場合、生産者が損失を被るからです。帰無仮説のもとでの不良品率を p_0 、サンプルサイズを n とすると、不良品数が合格規準値の c を超えてしまう確率（生産者危険、偽陽性率）は次のように計算できます。

$$\sum_{k=c+1}^n \binom{n}{k} p_0^k (1-p_0)^{n-k}$$

何これ：【冤罪（えんざい） / 誤報】（あわてんぼうのエラー）

「本当は不良品なんてない（無罪）」のに、検査官が厳しすぎて、たまたま運悪く引っかかった正常な製品を「不良品だ！（有罪）」と判定して廃棄してしまう悲劇です。工場（生産者）が丸損するので「生産者危険」と呼びます。一般的に「 α （アルファ）」で表されます。

10.3 消費者危険

対立仮説が正しいときに、誤って帰無仮説を受容してしまう誤りが**第二種の過誤**でした。抜取検査での呼び方にならない、この確率を**消費者危険**とも言います。なぜなら、生産者が正しく管理できていない状態を対立仮説とすると、正しく管理できていないのに、抜取検査でたまたま不良品が少なく観測されて出荷してしまった場合、消費者が損失を被るからです。対立仮説のもとでの不良品率を p_1 、サンプルサイズを n とすると、不良品数が合格規準値の c 以内となる確率（消費者危険、偽陰性率）は次のように計算できます。

$$\sum_{k=0}^c \binom{n}{k} p_1^k (1-p_1)^{n-k}$$

何これ：【見逃し / 隠蔽】（ぼんやりさんのエラー）

「本当はヤバい不良品が混ざっている（有罪）」のに、検査官がザルすぎて「まあ大丈夫でしょ（無罪）」と見逃し、そのまま市場に出回ってしまう悲劇です。それを買わされたお客さん（消費者）が大怪我などの損害を被るため「消費者危険」と呼びます。一般的に「 β （ベータ）」で表されます。