

統計検定準1級section17～20

- 統計検定準1級section17～20
 - 17 回帰診断法
 - 17.1 残差プロット
 - 17.2 正規Q-Qプロット
 - 17.3 てこ比
 - 17.4 Cookの距離
 - 18 質的回帰
 - 18.1 一般化線形モデル
 - 18.2 ロジスティック回帰モデル
 - 18.3 プロビット回帰モデル
 - 18.4 ポアソン回帰モデル
 - 18.5 指数型分布族
 - 19 回帰分析その他
 - 19.1 トービットモデル
 - 19.2 生存時間
 - 19.3 生存関数
 - 19.4 ハザード関数
 - 19.5 累積ハザード関数
 - 19.6 カプラン・マイヤー法
 - 19.7 Cox比例ハザードモデル
 - 19.8 ニューラルネットワークモデル
 - 20 分散分析と実験計画法
 - 20.1 フィッシャーの3原則
 - 20.2 1元配置完全無作為化法
 - 20.3 1元配置乱塊法
 - 20.4 2元配置完全無作為化法
 - 20.5 2元配置乱塊法
 - 20.6 直交表


https://toketarou.com/quasi_1_cheatsheet/

17 回帰診断法

回帰分析は「最小二乗法で直線を引いて終わり」ではありません。その直線が本当に信頼できるものなのか、外れ値に振り回されていないかを確認する「健康診断」が必要です [1, 2]。

17.1 残差プロット

縦軸に残差，横軸に予測値をとってプロットした次のような図。線形回帰モデルの誤差項は互いに独立で分散が一定であることを仮定していますが，残差プロットに何らかの傾向が見られると，これらの仮定の成立が疑われます。 [2, 3]



- 何これ：予測の「惜しさ（外れ具合）」を可視化して、モデルの嘘を暴くグラフ


🔗 **たとえ話：的当てゲームのクセ**

たとえ話：的当てゲームのクセ

的（予測値）に対して、矢（残差）がランダムに散らばっているなら公平なゲームです。しかし、「右にいくほど外れ方が大きくなる（扇形）」や「U字型に曲がっている」なら、それは風（別の要因）が吹いているか、定規が曲がっている証拠です。これが「等分散性」や「独立性」のチェックです [1, 3]。

17.2 正規Q-Qプロット

縦軸に標準化した残差の（経験的）分位点，横軸に標準正規分布の（理論的）分位点をとってプロットした次のような図。線形回帰モデルの誤差項に正規性を仮定するとき，標準化した残差は近似的に標準正規分布にしたがうので，傾き1の直線上に点が並びます。 [2, 3]



- **何これ**：残差がどれくらい「普通のノイズ（正規分布）」に近いかを確認するセンサー

🔥 **たとえ話：理想と現実の整列**

たとえ話：理想と現実の整列

「理論上の正規分布さんチーム」と「手元のデータくんチーム」を、値の小さい順に背の順で並べさせます。両者の背の伸び方が同じなら、ペアを組んだときに綺麗な一直線（傾き1）になります。端っこで列がグニャリと曲がるなら、それは正規分布では説明できない「異質なノイズ」が混ざっています [1, 3]。

17.3 てこ比

説明変数の値が他のデータ点から見て極端な位置にあることを見つけるための指標。予測値ベクトル $\hat{\mathbf{y}}$ は $X(X^T X)^{-1} X^T \mathbf{y}$ と表せますが、この行列 $X(X^T X)^{-1} X^T$ の対角成分 h_{ii} が**てこ比**で、てこ比が大きいはずれ値はモデルへの影響が大きいデータ点である可能性があります。 [2, 4]

- **何これ**：モデルを「てこの原理」でグイッと動かしてしまいそうな、影響力のある端っこのデータ

🔥 **たとえ話：シーソーの両端**

たとえ話：シーソーの両端

シーソーの真ん中に座っている人が多少暴れても板は揺れませんが、一番端っこ（説明変数の外れ値）に座っている人が少し動くだけで、シーソー全体（回帰直線）は大きく傾きます。この「端っこ度合い」を数値化したのが h_{ii} （ハット行列の対角成分）です [2, 5]。

17.4 Cookの距離

1つのデータ点を除いたときの回帰モデルへの影響度の指標。サイズ n のサンプル $(y_1, x_{11}, \dots, x_{1d}), \dots, (y_n, x_{n1}, \dots, x_{nd})$ から求めた予測値を $\hat{y}_1, \dots, \hat{y}_n$ とし、1つのデータ点 $(y_i, x_{i1}, \dots, x_{id})$ を除いたサイズ $n - 1$ のデータから求めた予測値を $\hat{y}_{1(-i)}, \dots, \hat{y}_{n(-i)}$ とするとき、これらのズレを次の式のように計算します。 [2, 4]

$$D_i = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(-i)})^2}{(d+1) \cdot \hat{\sigma}^2}$$

- **何これ：**「もし君がいなかったら、このモデルはどうなった？」を測る影響度測定器

💡 **たとえ話：カリスマ・エースの存在感**

たとえ話：カリスマ・エースの存在感
ある選手が一人抜けただけで、チームの勝率予測（予測値ベクトル）が劇的に変わってしまうなら、その選手はチーム（モデル）を支配していると言えます。Cookの距離 D_i が大きい点は、その1点だけで直線の角度を決めてしまっている恐れがあるため、「要注意人物」としてマークします。一般に0.5や1.0を超えると影響大とみなされます [1, 6]。

18 質的回帰

18.1 一般化線形モデル

次の式のように、 $X_1, \dots, X_k$ を与えたもとの Y の条件付き期待値が、1対1の関数 g を用いて $X_1, \dots, X_k$ の一次結合に一致するようなモデル。 g は Y の条件付き期待値を右辺の線形予測子と結びつける役割を果たしており、**リンク関数**と呼ばれます。また、 Y がしたがう確率分布を誤差構造と呼びます。

$$g(E(Y|X_1, \dots, X_k)) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

一般化線形モデルの代表的なものは次の表の通りです。

	リンク関数	誤差構造
線形回帰	恒等関数	正規分布
ロジスティック回帰	ロジット関数	ベルヌーイ分布
プロビット回帰	プロビット関数	ベルヌーイ分布
ポアソン回帰	対数関数	ポアソン分布

線形回帰の目的変数（応答変数）は量的変数ですが、応答変数が2値の質的変数の場合の代表的なモデルには、次のロジスティック回帰モデルとプロビット回帰モデルがあります。

- **何これ：**重回帰分析（直線）では対応できないデータを扱うための「変幻自在なアタッチメント」 [1, 2]

💡 **たとえ話：特製レンズを通した視界**

たとえ話：特製レンズを通した視界
現実のデータ Y が直線に乗らない形をしていても、適切な「リンク関数 g 」というメガネをかけることで、親しみのある「直線（重回帰）」の世界に持ち込んで分析する仕組みです。

18.2 ロジスティック回帰モデル

$\beta^T \mathbf{x} = \beta_0 + \beta_1 x_1 \dots \beta_k x_k$ として、応答変数 y が2値（0と1）をとる確率を、次のようにモデル化します。

$$\begin{cases} P(y = 1|\mathbf{x}) = \frac{1}{1 + \exp(-\beta^T \mathbf{x})} \\ P(y = 0|\mathbf{x}) = \frac{1}{1 + \exp(\beta^T \mathbf{x})} \end{cases}$$

このモデルは、 $\mathbf{x}_i$ が与えられたもとで応答変数 y_i が1をとる確率（条件付き期待値）を π_i として次のようにも表せます。

$$\ln \frac{\pi_1}{1 - \pi_1} = \beta^T \mathbf{x}_i \quad (*)$$

上の式の左辺は π_i の対数オッズです。左辺の関数はロジット関数と呼ばれ、 $\pi_i \rightarrow (\pi_i \text{の対数オッズ})$ の変換を**ロジット変換**と言います。ロジスティック回帰モデルはロジット関数をリンク関数とする一般化線形モデルです。この式から、他の説明変数の値を固定したまま、 j 番目の説明変

数 x_{ij} の値を1増加させると、 π_i の対数オッズは β_j 増加することがわかります。
また、対数の定義から、上のモデルは次のようにも表せます。

$$\frac{\pi_1}{1 - \pi_1} = \exp(\beta^T \mathbf{x}_i)$$

上の式から、他の説明変数の値を固定したまま、説明変数 x_{ij} の値を1増加させると、 π_i のオッズが $\exp(\beta_j)$ 倍されることがわかります。
さらに、上の式を π_i について解くと、次のようにも表せます。

$$\begin{aligned}\pi_i &= \frac{1}{1 + \exp(-\beta^T \mathbf{x}_i)} \\ &= \frac{\exp(\beta^T \mathbf{x}_i)}{1 + \exp(\beta^T \mathbf{x}_i)} \quad (**)\end{aligned}$$

上の式の $x \rightarrow \frac{\exp x}{1 + \exp x}$ という変換を**ロジスティック変換**と呼びます。これはロジット変換の逆変換です。

ロジスティック回帰モデルのパラメータの推定には最尤法が用いられます。 i 番目の観測値を $y_i (= 0 \text{ or } 1)$ 、 y_i がしたがうベルヌーイ分布を $Bin(1, \pi_i)$ とすると、その確率関数は次のように表せます。

$$\pi_i^{y_i} (1 - \pi_i)^{1-y_i}$$

尤度関数はこれらの積なので、サンプルサイズを n として、対数尤度関数は次のように表せます。

$$\begin{aligned}l(\boldsymbol{\pi}) &= \ln \left(\prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \right) \\ &= \sum_{i=1}^n (y_i \ln \pi_i + (1 - y_i) \ln(1 - \pi_i)) \\ &= \sum_{i=1}^n y_i \ln \frac{\pi_i}{1 - \pi_i} + \ln(1 - \pi_i)\end{aligned}$$

(*)および(**)を代入すると、対数尤度関数は次のように表せます。

$$l(\boldsymbol{\pi}) = \sum_{i=1}^n \left(y_i \beta^T \mathbf{x}_i - \ln(1 + \exp \beta^T \mathbf{x}_i) \right)$$

- **何これ：**「合格・不合格」などの2択の確率を、S字カーブで予測するモデル [1]

💡 **たとえ話：試験の合否ライン**

たとえ話：試験の合否ライン

勉強時間 x を増やせば合格確率 p は上がりますが、確率は「0から1の間」に収まらなければなりません。重回帰だと直線が100%を突き抜けたりマイナスになったりしますが、ロジスティック回帰は「S字型の滑り台」のようなカーブを使って、どんなに x が大きくても確率を1（100%）にピタリと着地させてくれます。

18.3 プロビット回帰モデル

応答変数が2値の場合、応答変数 y が1をとる確率（条件付き期待値） p を、標準正規分布の累積分布関数 Φ を用いて次のようにモデル化したものの。

$$p = \Phi(\beta^T \mathbf{x}) \quad \text{or} \quad \Phi^{-1}(p) = \beta^T \mathbf{x}$$

上の式の左辺の $p \rightarrow \Phi^{-1}(p)$ の変換を**プロビット変換**と言います。プロビット回帰モデルはプロビット関数をリンク関数とする一般化線形モデルで、パラメータの推定には最尤法を使います。

説明変数の値を増加させたときの p の変化については、上の p の式を説明変数 x_i で偏微分した式を用いて知ることができます。これを**限界効果**と言って、標準正規分布の確率密度関数を ϕ として、次の式で表せます。

$$\frac{\partial p}{\partial x_i} = \phi(\beta^T \mathbf{x}) \beta_i$$

- **何これ：** ロジスティック回帰のライバル。正規分布の「階段」に登るモデル [3]

🔥 **たとえ話：心理的なハードルの高さ**

たとえ話：心理的なハードルの高さ

「ある基準（しきい値）を超えたら1、超えなければ0」という現象を考えます。そのしきい値自体が「正規分布」に従ってバラついていると仮定するのがプロビットです。

また、**限界効果**とは「いまの状況から、説明変数をほんの少し動かしたときに、確率はどれくらいピクッと動くか？」という感度を測る指標です。

18.4 ポアソン回帰モデル

一定期間の1店舗の来客数などの0以上のカウントデータの平均 π と、いくつかの説明変数との関係を次のようにモデル化したもの。

$$\ln \pi = \beta^T \mathbf{x} = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

上の式は、 $\pi = \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)$ と書き直せるので、説明変数 x_i の値が1増えると、平均 π は $\exp(\beta_i)$ 倍になります。

ポアソン回帰モデルのパラメータの推定も最尤法によって行うことができます。

- **何これ：** 「何回起きたか？」という回数の平均値を、指数関数的に予測するモデル [1]

🔥 **たとえ話：店舗の来客数予測**

たとえ話：店舗の来客数予測

「駅からの距離」や「広告費」などの条件によって、1日の平均来客数が何倍になるかを計算します。対数（log）をとって計算するため、重回帰のような「足し算の積み上げ」ではなく、「広告を打つと客数が1.2倍になる」といった「掛け算の響き方」を捉えるのが得意です。

18.5 指数型分布族

一般化線形モデルにおける応答変数 Y は、正規分布、二項分布、ポアソン分布など、理論上の性質が良い確率分布にしたがうことを仮定します。この確率分布のファミリーを指数型分布族と呼び、その確率（密度）関数は次のように表せます。

$$f(y; \theta, \phi) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(\frac{y\theta - b(\theta)}{a(\phi)} - c(y, \phi)\right)$$

- **何これ：** 数学的に「扱いやすい」というエリートの血を引く、確率分布のロイヤルファミリー [1, 2]

🔥 **「微分の魔法」で期待値・分散をゲット**

「微分の魔法」で期待値・分散をゲット

通常、期待値や分散を求めるには複雑な「積分」の計算が必要ですが、指数型分布族なら $b(\theta)$ を **1回微分すれば期待値、2回微分すれば分散（に $a(\phi)$ を掛けたもの）** が一瞬で手に入ります [1, 2]。この「微分の作業だけで済む」というチート級の性質が、GLMの計算を支えています。

ここで、 $a(\cdot)$ 、 $b(\cdot)$ 、 $c(\cdot)$ は既知の関数で、 θ は正準母数、 ϕ は散らばり母数と呼ばれます。例えば、正規分布の確率密度関数は次のように変形できます。

$$\begin{aligned} f(y; \theta, \phi) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \mu)^2}{2\sigma^2}\right) \\ &= \exp\left[\frac{y\mu - \frac{1}{2}\mu^2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \frac{1}{2}\ln(2\pi\sigma^2)\right] \end{aligned}$$

正規分布の確率密度関数は、指数型分布族の確率密度関数の一般式において、次のようにおいたものになっています。

$$\begin{cases} \theta = \mu \\ \phi = \sigma^2 \\ a(\phi) = \phi \\ b(\theta) = \frac{1}{2}\theta^2 \\ c(y, \phi) = \frac{1}{2} \left(\frac{y^2}{\phi} + \ln(2\pi\phi) \right) \end{cases}$$

また、指数型分布族の確率分布にしたがう確率変数 Y の期待値、分散は次のように計算できます。

$$\begin{cases} \mathbb{E}[Y] = b'(\theta) \\ \mathbb{V}[Y] = b''(\theta)a(\phi) \end{cases}$$

実際に、正規分布にしたがう確率変数 Y について、 $\mathbb{E}[Y] = \mu$ 、 $\mathbb{V}[Y] = \sigma^2$ となることが確認できます。

🔗 **なぜGLMはこれを使うのか？**

なぜGLMはこれを使うのか？

GLMでは「期待値 μ 」を線形予測子 $\beta^T x$ とリンク関数で結びつけますが、指数型分布族であれば、期待値が $b'(\theta)$ というシンプルな形で表されるため、数理的なつながりが非常に良くなります [1, 2]。いわば「パズルのピースがピタリと合う」ような相性の良さがあるので

19 回帰分析その他

19.1 トービットモデル

Y を目的変数とした回帰モデルをつくりたいが、 Y が0以上の値しかとらないというケースがよくあります。このような場合に、 $Y^* = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \epsilon$ などの回帰モデルで表せる潜在変数 Y^* を考え、 Y^* が0以下の場合には $Y = 0$ 、 Y^* が0より大きい場合には $Y = Y^*$ とするのがトービットモデルの例です。

では、データ $(x_1, y_1) \cdots (x_n, y_n)$ に対して、次のトービットモデルを考え、尤度関数を構成します。

$$\begin{cases} y_i^* = \beta_0 + \beta_1 x_i + \epsilon_i & (i = 1, 2, \dots, n) \\ y_i = \begin{cases} y_i^* & (\text{for } y_i^* > 0) \\ 0 & (\text{else}) \end{cases} \end{cases}$$

ここで、 ϵ_i は互いに独立に正規分布 $N(0, \sigma^2)$ にしたがう誤差項であるとする、 x_i を与えたもとで、 y_i^* は次の正規分布にしたがいます。

$$y_i^* \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$$

つまり、 $y_i^* > 0$ のとき、 y_i ($= y_i^*$) の確率密度関数は次の式になります。

$$\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2} \left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \right)^2 \right)$$

標準正規分布の確率密度関数を $\phi(x)$ とすると、上の y_i の確率密度関数は次のように表せます。

$$\frac{1}{\sigma} \phi \left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \right)$$

次に、 $y_i^* \leq 0$ となる確率は、 y_i^* の確率密度関数を使って次のように表せます。

$$P(y_i^* \leq 0) = \int_{-\infty}^0 \frac{1}{\sigma} \phi \left(\frac{y - (\beta_0 + \beta_1 x_i)}{\sigma} \right) dy$$

上の被積分関数 $\phi(\cdot)$ のかっこ内を z と置換すると、次のようになります。

$$\int_{-\infty}^{-\frac{\beta_0 + \beta_1 x_i}{\sigma}} \phi(z) dz = \Phi\left(-\frac{\beta_0 + \beta_1 x_i}{\sigma}\right)$$

ここで、上の式の右辺の $\Phi(\cdot)$ は、標準正規分布の累積分布関数です。よって、尤度関数は、 $y_i^* > 0$ となる i に関する確率密度関数の積と $y_i^* \leq 0$ となる i に関する累積分布関数の積を合わせて、次のようになります。

$$\prod_{i: y_i > 0} \frac{1}{\sigma} \phi\left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma}\right) \times \prod_{i: y_i = 0} \Phi\left(-\frac{\beta_0 + \beta_1 x_i}{\sigma}\right)$$

- **何これ：** 下限（または上限）でデータが「壁」にぶつかって止まっている状態を扱うモデル

🔥 **たとえ話：0点未満がないテスト**

たとえ話：0点未満がないテスト

本当は「実力がマイナス」の人もいるはずなのに、テストの点数は最低でも0点にしかありません。このとき、0点の集団には「本当は-10点の人」や「本当は-50点の人」が混ざっています。トービットモデルは、この「壁（0点）」に張り付いた人たちの裏側にある「潜在的な実力 y^* 」を、正規分布を仮定して推定する賢い仕組みです。

19.2 生存時間

入院してから退院するまでの時間や就職してから退職するまでの時間など、基準となる時点からイベントが発生するまでの時間。

19.3 生存関数

生存時間が t 以上である確率のことであり、生存時間を表す確率変数 T の確率密度関数を $f(x)$ として、次の式で表されるような $S(t)$ です。

$$S(t) = P(T \geq t) = \int_t^{\infty} f(x) dx$$

累積分布関数を $F(t)$ として、 $S(t) = 1 - F(t)$ の関係があり、 $S(t)$ を t で微分すると、次のようになります。

$$\frac{d}{dt} S(t) = \frac{d}{dt} \{1 - F(t)\} = -f(t)$$

19.4 ハザード関数

時刻 t における瞬間イベント発生率（時刻 t までイベントが発生していない条件のもとで直後にイベントが発生する条件付き確率）を表す関数で、次のように確率密度関数と生存関数を用いて表せる $h(t)$ です。

$$h(t) = \frac{f(t)}{S(t)} = -\frac{d}{dt} \log S(t)$$

19.5 累積ハザード関数

次のようにハザード関数を積分したものであり、最右辺のように生存関数を用いて表せます。

$$H(t) = \int_0^t h(x) dx = -\log S(t)$$

確率密度関数は、ハザード関数と累積ハザード関数を用いて次のように表せます。

$$f(t) = h(t) \exp[-H(t)]$$

- **何これ：** 「いつ終わるか？」という寿命や待ち時間を分析する「生存時間解析」の三種の神器

🔥 **たとえ話：生存・脱落のドラマ**

たとえ話：生存・脱落のドラマ

- **生存関数 $S(t)$ ：** 時刻 t までに「生き残っている（イベントが起きていない）」確率。時間が経つほど減っていきます。
- **ハザード関数 $h(t)$ ：** 「瞬間的なリスク」。今この瞬間まで無事だったものが、次の瞬間にドカンとイベント（故障や死亡）に見舞われる確率の「濃さ」です。

- **累積ハザード関数 $H(t)$** ：これまでのリスクの「積み重ね」。これが生存関数の対数（マイナス付き）に対応しているのが数理的な面白さです。

19.6 カプラン・マイヤー法

生存時間に特定の確率分布を仮定することなく、生存関数を推定する方法。例えば、時点 t までに、次の表のような k 時点でイベントが発生した場合を考えます。

項目	値
イベントの発生時点	$t_1, t_2, \dots, t_k$
イベントの発生数	$d_1, d_2, \dots, d_k$
直前のリスク集合	$n_1, n_2, \dots, n_k$

このとき、時点 t における生存率を次の式で計算します。

$$\frac{n_1 - d_1}{n_1} \times \frac{n_2 - d_2}{n_2} \times \dots \times \frac{n_k - d_k}{n_k}$$

このような計算を観察期間全体について行い、その結果をプロットしてできる階段状のグラフを**カプラン・マイヤー曲線**と言います。

- **何これ**：データの「脱落者」を数えるだけで描ける、もっとも有名な生存曲線

💧 **たとえ話：サバイバルレースの生存率**

たとえ話：サバイバルレースの生存率

100人で始まったレースで、第1チェックポイントで5人脱落したら生存率は 95/100。第2チェックポイントで残った95人のうち10人脱落したら、その時点の生存率は 95/100 × 85/95。このように、各イベント発生時に「その時の残り人数に対して何割生き残ったか」を次々に掛け算してグラフにします。数式（分布）を仮定しない「ノンパラメトリック」な手法なので、どんなデータにも使えます。

19.7 Cox比例ハザードモデル

イベントの発生に影響を与えることが想定される共変量を $x_1, \dots, x_n$ として、次のようにハザード関数を表すモデル。

$$\begin{aligned} h(t; \mathbf{x}) &= h_0(t) \exp(\mathbf{x}^\top \boldsymbol{\beta}) \\ &= h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n) \end{aligned}$$

$h_0(t)$ は基準ハザード（ベースラインハザード）と呼ばれる正の値をとる t の関数で、特定の分布形を仮定しません。Cox比例ハザードモデルをあてはめる場合には、**比例ハザード性**（ハザード比が時間によって変化しない）を確認する必要があります。

- **何これ**：生存時間の長さを、複数の原因（年齢、薬の有無など）で説明する最強モデル

💧 **たとえ話：リスクの掛け算（平行移動）**

たとえ話：リスクの掛け算（平行移動）

「薬を飲んでいるグループ」のリスクが「飲んでいないグループ」の常に0.5倍である、というように、グループ間のリスクの「比率」が時間によらず一定だと仮定します。生存関数の2重対数プロットが平行になるかどうかで、この「比例ハザード性」という前提が正しいかをチェックします。

19.8 ニューラルネットワークモデル

d 個の入力 $x_1, x_2, \dots, x_d$ にそれぞれの重み $w_1, w_2, \dots, w_d$ をかけ、これらの積の合計にバイアス b を加えた $\mathbf{w}^T \mathbf{x} + b = b + w_1 x_1 + \dots + w_d x_d$ の入力を受けた1つのユニットは、活性化関数 f を施して $f(\mathbf{w}^T \mathbf{x} + b)$ を出力します。このようなユニットを層状に並べ、層自体も複数並べたものがニューラルネットワークモデルです。各ユニットに非線形活性化関数を使用することで、複雑な非線形関係をモデル化することが可能になります。

- **何これ**：脳の神経回路をマネして、どんな複雑な「グニャグニャの図形」でも近似するモデル

🔥 **たとえ話：情報のバケツリレー**

たとえ話：情報のバケツリレー

各ユニットは、たくさんの友人（入力）から話を聞きますが、それぞれの友人の信頼度（重み）を変えて聞き取り、最後に自分の意見（活性化関数）を乗せて次の層へ伝えます。この「重み」をデータから学習することで、人間には見抜けないような複雑なパターンをコンピュータが発見できるようになります。

20 分散分析と実験計画法

2級で学習した1元配置分散分析は3群以上の母平均の差の検定でした。まず、基本となる用語を確認しておく、観測データに影響を与える可能性のあるもののうち、実験で取り上げるものを因子、因子がとりうる一つひとつの条件を水準、複数の因子の水準の組み合わせを処理と言います。因子が2つ以上の場合も含めて、一般的に分散分析は、複数の因子の主効果とそれらの交互作用効果の有無を評価する検定といえます。

- **何これ：** たくさんのグループの平均値を、「一括で」比較して違いがあるか暴く手法 [1, 2]

🔥 **たとえ話：3つのスープの味見**

たとえ話：3つのスープの味見

「鍋A、鍋B、鍋Cの塩加減がすべて同じか？」を調べたいとき、2つずつ味見して比べる（A vs B, B vs C, C vs A）のは手間がかかるし、何度もやると判定が甘くなります。分散分析は、3つの鍋の「味のバラつき」をまとめて計算し、「これは誤差の範囲か、それとも明らかにレシピ（因子）が違うのか」を天秤（F分布）にかけて一発でジャッジします。

20.1 フィッシャーの3原則

1. 無作為化・・・処理をランダムに割り当てる
2. 反復・・・同じ処理を複数回行う
3. 局所管理・・・ブロック内で均一な条件を実現

上の1.と2.を満たすものを**完全無作為化法**、1.～3.のすべてを満たすものを**乱塊法**と言います。 [1, 3]

- **何これ：** 科学的に正しい実験をするための「3つの鉄則」

🔥 **たとえ話：フェアな栽培実験**

たとえ話：フェアな栽培実験

1. **無作為化：** 「日当たりの良い場所にはこの肥料を…」といったエコひいき（バイアス）を排除するために、くじ引きで決めること。
2. **反復：** たまたま1個だけ大きく育った（ラッキー）だけかもしれないので、何度も繰り返して実力を確かめること。
3. **局所管理：** 「畑の端と中央」で条件が変わらないよう、似た環境のエリア（ブロック）に区切って、その中で比較を行うこと。

20.2 1元配置完全無作為化法

応答変数 Y に関して1つの因子を取り上げ、 $A_1, \dots, A_a$ の水準ごとの母平均を $\mu_1, \dots, \mu_a$ 、水準の効果を $\alpha_1, \dots, \alpha_a$ とすると、構造モデルは次の式です。

$$Y_{ij} = \mu_i + \varepsilon_{ij} = \mu + \alpha_i + \varepsilon_{ij}; \varepsilon_{ij} \sim N(0, \sigma^2) \\ (i = 1, 2, \dots, a, j = 1, 2, \dots, n_i)$$

ただし、水準ごとのくり返し数を $n_1, \dots, n_a$ ($n_1 + \dots + n_a = n$) として、 $n_1\alpha_1 + \dots + n_a\alpha_a = 0$ が成り立つものとし、 μ は次の式で定まる一般平均です。 [1, 3]

$$\mu = \frac{1}{n} \sum_{i=1}^a n_i \mu_i$$

次に、第 i 水準の標本平均と標本全体の平均を次のように定めます。 [4, 5]

$$\bar{y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}, \bar{y}_{\cdot\cdot} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij}$$

上記の記号を用いると、平方和の分解は次のようになります。[4, 6]

$$\sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}_{..})^2$$

上の式の左辺を**総平方和**，右辺第1項を**誤差（残差）平方和**，右辺第2項を**水準間平方和**と呼び，それぞれ S_T ， S_E ， S_A と表します。これらの平方和を自由度でわったものを****平均平方（分散）****と呼び，次のような分散分析表にまとめます。[4, 6]

	平方和	自由度	分散	F値
水準間	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{2}$
誤差	S_E	$n - a$	$\frac{1}{n-a} S_E \cdots \textcircled{2}$	
合計	S_T	$n - 1$		

帰無仮説を「すべての水準の母平均は等しい」，対立仮説は「少なくとも1つの水準の母平均が異なる」として， $\textcircled{1} \div \textcircled{2}$ の統計量が $F(a-1, n-a)$ にしたがうことを利用して検定します。[4, 7]
水準の母平均の区間推定を行うには，上の表の②が誤差分散 σ^2 の推定値であることを使います。この推定値を $\hat{\sigma}^2$ と表すと， i 番目の水準の母平均の信頼度95%の信頼区間は次の通りです。[4, 7]

$$\bar{y}_i \pm t_{0.025}(n-a) \frac{\hat{\sigma}}{\sqrt{n_i}}$$

- **何これ：**「グループ間の差」が、「グループ内のガヤガヤ（ノイズ）」に比べてどれくらい大きいかを測る作業 [8, 9]

🔗 ****たとえ話：クラス対抗テスト****

たとえ話：クラス対抗テスト
クラスA、B、Cの平均点が違っていたとします。
もし、各クラス内の生徒の点数がみんな似たり寄ったり（誤差平方和 S_E が小さい）なら、平均点のわずかな差も「クラスの実力差だ！」と確信できます。
逆に、各クラス内が天才から赤点までバラバラ（ S_E が大きい）なら、平均の差なんてただの偶然に見えます。この「実力差 S_A 」と「個人のバラつき S_E 」の比率を計算するのがF値です。

20.3 1元配置乱塊法

1元配置完全無作為化法にブロック $R_1, \cdots, R_r$ を取り入れたもので，ブロック因子を γ_j として，構造モデルは次の式です。[4, 7]

$$Y_{ij} = \mu + \alpha_i + \gamma_j + \varepsilon_{ij} ; \varepsilon_{ij} \sim N(0, \sigma^2) \\ (i = 1, 2, \cdots, a, j = 1, 2, \cdots, r)$$

ただし， $\alpha_1 + \cdots + \alpha_a = 0$ ， $\gamma_1 + \cdots + \gamma_r = 0$ が成り立つものとします。平方和の分解は次の式です。[4, 10]

$$\sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \bar{y}_{..})^2 \\ = \sum_{i=1}^a \sum_{j=1}^r (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^r (\bar{y}_{.j} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{y}_{..})^2$$

上の式の右辺第1項は水準間平方和，第2項はブロック平方和，第3項は誤差平方和であり，ブロック平方和を S_R と表すと，分散分析表は次のようになります。[4, 11]

	平方和	自由度	分散	F値
水準間	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{3}$
ブロック	S_R	$r - 1$	$\frac{1}{r-1} S_R \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{3}$
誤差	S_E	$(a - 1)(r - 1)$	$\frac{1}{(a-1)(r-1)} S_E \cdots \textcircled{3}$	

	平方和	自由度	分散	F値
合計	S_T	$ar - 1$		

因子の効果については、①+③の統計量が $F[a-1, (a-1)(r-1)]$ にしたがうことを利用し、ブロックの効果については、②+③の統計量が $F[r-1, (a-1)(r-1)]$ にしたがうことを利用して検定します。[11, 12]

- 何これ：**分かっている「邪魔魔虫（場所の差など）」を計算で取り除き、本当の信号を際立たせる手法 [13, 14]

🔗 ****たとえ話：オープンごとの焼き上がりの差****

たとえ話：オープンごとの焼き上がりの差
 3人のパティシエ（因子）の腕を比べたいのですが、使っている3台のオープン（ブロック因子）の火力がバラバラだとします。
 そのまま焼くと、「腕がいいパティシエ」が「火力の弱いオープン」のせいで負けてしまうかもしれません。そこで、オープンごとのクセを S_R として計算から差し引くことで、純粋なパティシエの技術の差 S_A だけを取り出します。これによって、誤差に埋もれていた実力差が見えやすくなります。

20.4 2元配置完全無作為化法

2つの因子を考えるのが2元配置法で、それぞれの因子の効果（**主効果**）だけでなく、2つの因子の組み合わせ効果（**交互作用**）まで調べることができます。2つの因子を A, B とし、 $A_1, \dots, A_a$ の水準の効果を $\alpha_1, \dots, \alpha_a$, $B_1, \dots, B_b$ の水準の効果を $\beta_1, \dots, \beta_b$ とし、交互作用があることを仮定するとき、構造モデルは次の式です。

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk} ; \varepsilon_{ijk} \sim N(0, \sigma^2)$$

$$(i = 1, 2, \dots, a, j = 1, 2, \dots, b, k = 1, 2, \dots, n)$$

ただし、 $\alpha_1 + \dots + \alpha_a = 0$, $\beta_1 + \dots + \beta_b = 0$ が成り立つものとし、交互作用項については次の式が成り立つものとします。

$$\sum_{i=1}^a \alpha_i = 0, \sum_{j=1}^b \beta_j = 0, \sum_{i=1}^a (\alpha\beta)_{ij} = 0, \sum_{j=1}^b (\alpha\beta)_{ij} = 0$$

- 何これ：**2つの原因（因子）を同時に分析して、それぞれの単独の効果だけでなく、2つが組み合わさった時の「化学反応（交互作用）」まで一気に調べる手法 [1, 2]。

🔗 ****たとえ話：肉とタレの相性（シナジー）****

たとえ話：肉とタレの相性（シナジー）
 「お肉の種類（因子A）」の実力と、「タレの種類（因子B）」の実力を調べる実験をします。
 主効果は「高い肉はやっぱり旨い」「このタレは単体で旨い」という話です。
 しかし、**交互作用**は「この肉にはこのタレが最高に合うけど、別のタレだと台無しになる」という**組み合わせの妙（相性）**のことで
 す。1+1が3になったり0.5になったりする現象を数学的に捉えます [1, 2]。

平方和の分解は次の式です。

$$\begin{aligned} &\sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (y_{ijk} - \bar{y}_{...})^2 \\ &= bn \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2 + an \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...})^2 \\ &+ n \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2 + \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij.})^2 \end{aligned}$$

上の式の右辺第1項は A の水準間平方和、第2項は B の水準間平方和、第3項は交互作用平方和、第4項は誤差平方和であり、それぞれ $S_A, S_B, S_{A \times B}, S_E$ と表すと、分散分析表は次のようになります。

	平方和	自由度	分散	F値
因子A	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{4}$

	平方和	自由度	分散	F値
因子B	S_B	$b - 1$	$\frac{1}{b-1} S_B \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{4}$
交互作用AB	S_{AB}	$(a - 1)(b - 1)$	$\frac{1}{(a-1)(b-1)} S_{AB} \cdots \textcircled{3}$	$\textcircled{3} \div \textcircled{4}$
誤差	S_E	$ab(n - 1)$	$\frac{1}{ab(n-1)} S_E \cdots \textcircled{4}$	
合計	S_T	$abn - 1$		

①÷④の統計量は $F[a-1, ab(n-1)]$, ②÷④の統計量は $F[b-1, ab(n-1)]$, ③÷④の統計量は $F[(a-1)(b-1), ab(n-1)]$ にしたがうことを利用して検定します。

 グラフで見抜く交互作用

グラフで見抜く交互作用
 横軸に因子A、縦軸に応答 y をとり、因子Bの水準ごとに折れ線グラフを描いたとき、もし2つの線が**「平行」なら交互作用はありません。
 ** 逆に、線が「交差」していたり「ハの字」に開いていたりするなら、相性（交互作用）が存在する証拠です [1-3]。この「ズレ」を交互作用平方和 $S_{A \times B}$ として抽出して検定します。

20.5 2元配置乱塊法

2元配置完全無作為化法にブロック $R_1, \cdots, R_r$ を取り入れたもので、ブロック因子を γ_k として、構造モデルは次の式です。

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \gamma_k + \varepsilon_{ijk} ; \varepsilon_{ijk} \sim N(0, \sigma^2)$$

$$(i = 1, 2, \cdots, a, j = 1, 2, \cdots, b, k = 1, 2, \cdots, r)$$

ただし、2元配置完全無作為化法における $\alpha_i, \beta_j, (\alpha\beta)_{ij}$ の制約に加え、 $\gamma_1 + \cdots + \gamma_r = 0$ が成り立つものとします。[1] 平方和の分解は次の式です。

$$\sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (y_{ijk} - \bar{y} \cdots)^2$$

$$= br \sum_{i=1}^a (\bar{y}_{i \cdots} - \bar{y} \cdots)^2 + ar \sum_{j=1}^b (\bar{y}_{\cdots j} - \bar{y} \cdots)^2 + ab \sum_{k=1}^r (\bar{y}_{\cdots \cdots k} - \bar{y} \cdots)^2$$

$$+ r \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij \cdots} - \bar{y}_{i \cdots} - \bar{y}_{\cdots j} + \bar{y} \cdots)^2 + \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (y_{ijk} - \bar{y}_{ij \cdots} - \bar{y}_{\cdots \cdots k} + \bar{y} \cdots)^2$$

上の式の右辺第1項は A の水準間平方和、第2項は B の水準間平方和、第3項はブロック平方和、第4項は交互作用平方和、第5項は誤差平方和であり、それぞれ $S_A, S_B, S_R, S_{A \times B}, S_E$ と表すと、分散分析表は次のようになります。[1]

	平方和	自由度	分散	F値
A	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{5}$
B	S_B	$b - 1$	$\frac{1}{b-1} S_B \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{5}$
A×B	$S_{A \times B}$	$(a - 1)(b - 1)$	$\frac{1}{(a-1)(b-1)} S_{A \times B} \cdots \textcircled{3}$	$\textcircled{3} \div \textcircled{5}$
ブロック	S_R	$r - 1$	$\frac{1}{r-1} S_R \cdots \textcircled{4}$	$\textcircled{4} \div \textcircled{5}$
誤差	S_E	$(ab - 1)(r - 1)$	$\frac{1}{(ab-1)(r-1)} S_E \cdots \textcircled{5}$	
合計	S_T	$abr - 1$		

- 何これ：2つの原因（因子A、B）とその相性（交互作用）を調べつつ、さらに「場所や日時の差（ブロック）」というお邪魔虫の影響も排除して、極限まで精度を高める手法。[1, 2]

 たとえ話：さらに精密な肉とタレの実験

たとえ話：さらに精密な肉とタレの実験
 前回の実験（20.4）では、肉とタレの相性を調べました。
 でも、実は「実験した曜日（ブロック）」によって肉の鮮度が違っていたり、調理した「コンロの個体差」があったりするかもしれませ

ん。[1]
2元配置乱塊法は、肉（A）とタレ（B）の最強コンビを探しながら、同時に曜日やコンロの差（ブロック）も計算で引っこ抜きます。これにより、誤差（ガヤガヤ）を最小限に抑え、真の実力差を浮き彫りにします。[1]

20.6 直交表

因子の数や水準の数が増えるにしたがい、すべての水準組み合わせの実験を実施するのはコストが大きくなるため、一部の交互作用のみを取り上げることで実験の回数を減らしたものが**一部実施要因計画**で、そのために用いるのが直交表です。[1] 例えば、次の直交表は水準の数が2つの因子を割り付けるために使われるものです。

＼	[3]	[4]	[5]	[6]	[7]	[8]	[9]
①	1	1	1	1	1	1	1
②	1	1	1	2	2	2	2
③	1	2	2	1	1	2	2
④	1	2	2	2	2	1	1
⑤	2	1	2	1	2	1	2
⑥	2	1	2	2	1	2	1
⑦	2	2	1	1	2	2	1
⑧	2	2	1	2	1	1	2
成分	a	b	ab	c	ac	bc	abc

上の表の①～⑧の行は実験を表していて、いくつかの列には因子を対応（**割り付け**と言う）させます。[1] 例えば、[5]の列に因子A、[8]の列に因子Bを割り付ければ、①はA1B1での実験、②はA1B2での実験、...という感じで、⑧までで4つの水準組み合わせの実験を2回ずつ行う計画になります。[1] 上の表のいちばん下の行の「成分」は列の性質を表していて、[5]の成分の"ab"と[8]の成分の"bc"の積は、 $b^2=1$ より、 $ab \times bc=ac$ となります。[1] これは、[5]に割り付けた因子Aと[8]に割り付けた因子Bの交互作用が[7]に現れることを意味します。したがって、3つの2水準因子A、B、Cの主効果と交互作用A×Bについて調べる場合に、Aを[5]、Bを[8]に割り付け、Cを[7]に割り付けたら、Cの主効果と交互作用A×Bが区別できなくなります。このことを**交絡**と言います。[1]

なお、上の直交表は $L_8(2^7)$ と呼ばれるもので、2が水準の数、7が列の数、8は実験の数を表しています。[10]

- **何これ：** すべての組み合わせを試すと時間もお金も足りなくなる大規模な実験で、数学的な「間引き」を行って、効率よく正解にたどり着くための魔法の対照表。[1]

🔥 **たとえ話：全メニュー制覇を諦める賢い試食**

たとえ話：全メニュー制覇を諦める賢い試食
例えば7つのスイッチ（因子）があり、それぞれON/OFF（2水準）ある場合、全部試すと $2^7 = 128$ 通り必要です。
直交表 L_8 を使えば、数学的に計算された「たった8回」の実験だけで、各スイッチのメインの効果を把握できます。「食べていない組み合わせの結果も予想できる」ガイドマップのようなものです。[1, 10]

🔥 **交絡（Confounding）のイメージ**

交絡（Confounding）のイメージ
「コーヒーの豆の種類」と「砂糖の量」の効果を調べたいのに、常に「高い豆のときは砂糖を入れ、安い豆のときは砂糖を入れない」というセット（同じ列）でしか試さなかったら、美味しかった理由が「豆」なのか「砂糖」なのか区別できなくなります。これが「交絡」です。[1]