

統計検定準1級section21～32

- 統計検定準1級section21～32
 - 第21章 標本調査法
 - 何これ：データ集めの基本中の基本
 - 21.1 標本平均の期待値と分散
 - 21.2 層化抽出法
 - 何これ：グループごとの「特徴の違い」を利用してブレを減らす
 - 21.3 標本配分法
 - ① 比例配分法
 - 何これ：割合に合わせて平等に集める
 - ② 等配分法
 - 何これ：どのグループからも同じ数だけ集める
 - ③ ネイマン配分法
 - 何これ：暴れ馬のグループほど、たくさんデータを取って手なずける！
 - 第22章 主成分分析
 - 何これ：たくさんある情報を、なるべく損なわずに「要約」するテクニック
 - 22.1 寄与率
 - 何これ：その主成分が、元のデータを「どれくらい説明できているか」の割合
 - 22.2 累積寄与率
 - 何これ：「ここまで見れば、元のデータの〇％は把握できる！」という達成度
 - 22.3 主成分得点
 - 何これ：新しい「ものさし」で測ったときの、各データの「点数」
 - 22.4 主成分負荷量
 - 何これ：新しい「ものさし」が、元のどの変数から強く影響を受けているか
 - 22.5 自己符号化器（オートエンコーダ）
 - 何これ：AIに「データの圧縮・解凍」をやらせる技術
 - 第23章 判別分析
 - 何これ：過去のデータから「境界線」を学び、未知のデータを分類するAIの基本！
 - 23.1 フィッシャーの線形判別分析
 - 何これ：一番キレイに「パカッ」と分かれる直線を引く！
 - 23.2 マハラノビス距離による判別
 - 23.3 バイズ判別
 - 何これ：「そもそもの起きやすさ（事前確率）」を考慮して補正する
 - 23.4 正準判別分析
 - 23.5 ハードマージンSVM（サポートベクターマシン）
 - 何これ：境界線ギリギリのデータだけを見て、なるべく「安全地帯」を広くする
 - 23.6 ソフトマージンSVM
 - 23.7 混同行列
 - 第24章 クラスター分析
 - 何これ：「正解」がないデータから、似たもの同士をグループ化する！
 - 24.1 階層的クラスタリング
 - 何これ：トーナメント表のように、近いものから順番に合体させていく
 - 24.2 最短距離法（最近隣法）
 - 24.3 最長距離法（最遠隣法）
 - 何これ：一番遠いメンバー同士の距離を見る
 - 24.4 群平均法
 - 何これ：全パターンの平均を取るマイルドな手法
 - 24.5 重心法
 - 24.6 ウォード法
 - 何これ：試験・実務で一番よく使われる大本命！
 - 24.7 K-means法（ k 平均法）
 - 何これ：最初から「 K 個のグループに分ける！」と決めて中心を探す
 - 第25章 因子分析・グラフィカルモデル
 - 何これ：表面上のデータから「裏に潜む共通の原因（才能や性格など）」を見つけ出す！
 - 25.1 寄与率
 - 何これ：その隠れキャラクター（因子）の「影響力の大きさ」
 - 25.2 因子軸の回転
 - 何これ：結果に「人間の言葉で名前」をつけやすくするための微調整
 - 25.3 操作変数法（パス解析・構造方程式モデル）
 - 何これ：変数同士の「ビタゴラスイッチ（因果の連鎖）」を読み解く
 - 25.4 グラフィカルモデル

- 何これ：変数同士の「本当の直接関係」だけを線で結んだネットワーク図
- 第26章 その他の多変量解析手法
 - 26.1 多次元尺度構成法（MDS）
 - 何これ：「距離のデータ」だけを頼りに、元の「地図」を復元するマジック！
 - 26.2 正準相関分析
 - 何これ：2つのグループ間で、最も「相性の良い」総合得点の作り方を探す！
 - 26.3 数量化法
 - 何これ：「文字（カテゴリ）」データを、無理やり「数字」に変換して分析する日本発のテクニック！
- 第27章 時系列解析
 - 27.1 弱定常過程（共分散定常過程）
 - 何これ：時間によらず「波の高さ（平均）」と「波の振れ幅（分散）」が一定で安定しているデータ
 - 27.2 ホワイトノイズ
 - 何これ：過去のデータと一切関係がない「完全なランダムノイズ」
 - 27.3 p次自己回帰過程

$$AR(p)$$

- 何これ：「今日の値」は「過去の値」に引っ張られる！というモデル
- 27.4 q次移動平均過程

$$MA(q)$$

- 何これ：「今日の値」は「過去に起きた突発的なショック（ノイズ）」の余韻が残っている！というモデル
- 27.5 (p,q)次自己回帰移動平均過程

$$ARMA(p, q)$$

- 何これ：AR（過去の値の影響）とMA（過去のショックの影響）の「いいとこ取り」！
- 27.6 (p,1,q)次自己回帰分移動平均過程

$$ARIMA(p, 1, q)$$

- 何これ：「トレンド（右肩上がりなど）」があるデータでも使える最強の実用モデル
- 27.7 ディッキー・フラー検定
 - 何これ：このデータ、酔っ払いの千鳥足（ランダムウォーク）じゃないか？を確認するテスト
- 27.8 状態空間モデル
 - 何これ：「真の姿」は見えないけれど、「観測データ」から推測しよう！というモデル
- 27.9 ACFとPACF
 - 何これ：過去のデータがどれくらい今のデータに影響しているかの「強さ」を測る
- 27.10 ダービン・ワトソン検定
 - 何これ：回帰分析の「残りカス（残差）」に、時間のパターンのクセが残っていないかチェック！
- 27.11 スペクトル密度関数（スペクトラム）
 - 何これ：データを「時間軸」ではなく「周波数（波の細かさ）」で分解して見る！
- 第28章 分割表
 - 何これ：要するに「クロス集計表」のこと！
 - 28.1 相対リスク
 - 疫学の研究デザイン（28.2 ～ 28.5）
 - 28.2 前向き研究
 - 28.3 後向き研究
 - 28.4 コホート研究
 - 28.5 ケースコントロール研究（患者対照研究）
 - オッズとオッズ比（28.6 ～ 28.9）
 - 28.6 オッズ
 - 何これ：「起きない確率」に対して「起きる確率」が何倍か？
 - 28.7 オッズ比
 - 28.8 標本オッズ
 - 28.9 標本オッズ比
 - 28.10 フィッシャーの正確検定
 - 何これ：データが少なすぎる時の救世主！「全パターンの確率をガチで計算する」検定
 - 28.11 独立性の検定（カイ2乗検定）
 - 28.12 逸脱度
 - 28.13 対数線形モデル
 - 何これ：複雑な確率の「かけ算」を、対数（ $\log$ ）をとって「足し算」の式にする！
 - 28.14 無向独立グラフ
 - 28.15 グラフィカルモデル
 - 28.16 分解可能モデル
- 第29章 不完全データの統計処理
 - 何これ：アンケートの未記入や実験脱落など「穴抜けデータ」をどう扱うか？
 - 29.1 打ち切り（Censoring） vs 29.2 トランケーション（Truncation）

- 29.1 打ち切り (Censoring)
- 29.2 トランケーション (Truncation)
- 欠測メカニズム (MCAR, MAR, MNAR)
- 欠測への対処法 (29.3 ~ 29.5)
 - 29.3 CC(complete case)解析
 - 何これ：一番単純な「欠測がある人は全員削除！」
 - 29.4 単一代入法
 - 29.5 多重代入法 (Multiple Imputation)
 - 何これ：現在の統計学・臨床試験における「大本命」の手法！
 - 29.6 1変量正規分布における推測 (EMアルゴリズム的アプローチ)
 - 29.7 2変量正規分布における推測 (MARにおける最尤推定)
 - 何これ：Xの情報 (完全データ) を使って、Yの欠測の影響を打ち消す！
- 第30章 モデル選択
 - 何これ：モデルの「コスパ」を測るスコア！
 - 重回帰モデルにおけるAICとBIC
 - 交差検証法 (クロスバリデーション)
 - 30.1 交差検証法 (クロスバリデーション)
 - 何これ：「カンニング」を防ぐためのテスト！
 - 30.2 Leave-one-out法 (LOOCV)
 - 何これ：たった1個だけテストに回すのを、全員分やる！
 - 30.3 k分割交差検証法 (k-fold CV)
 - 何これ：実務で一番よく使われる手法！
- 第31章 ベイズ法
 - 何これ：データを得るたびに「予想 (確率分布)」をアップデートしていく手法！
 - 31.1 共役事前分布
 - 何これ：計算をめちゃくちゃ楽にするための「相性の良い組み合わせ」！
 - 代表的なモデル (31.2 ~ 31.4)
 - 31.2 ベータ二項モデル
 - 31.3 ガンマポアソンモデル
 - 31.4 正規-正規モデル
 - 事後分布からの要約 (31.5 ~ 31.8)
 - 31.5 ベイズ推定値 (EAP推定量)
 - 31.6 MAP推定量 (最大事後確率推定量)
 - 31.7 ベイズ予測分布
 - 31.8 $100(1-\alpha)\%$ 信用区間
 - MCMC法 (マルコフ鎖モンテカルロ法) (31.9 ~ 31.12)
 - 何これ：計算できない複雑な事後分布を、コンピュータに大量の乱数を引かせて再現する裏技！
 - 31.9 MCMC法
 - 31.10 メトロポリス法
 - 何これ：「山登り」のようなアルゴリズム！
 - 31.11 メトロポリス・ヘイスティングス法 (MH法)
 - 何これ：メトロポリス法の一般化版！
 - 31.12 ギブスサンプリング
 - 何これ：変数を1つずつ順番に更新していく手法！
- 第32章 シミュレーション
 - 32.1 擬似乱数
 - 何これ：コンピュータが作る「サイコロの目」は実は計算式で作られている！
 - 乱数の生成法 (32.2 ~ 32.3)
 - 32.2 逆関数法
 - 何これ：「0から1の乱数」を「欲しい分布の乱数」に変換する魔法！
 - 32.3 採択・棄却法
 - 何これ：作りやすい別の乱数を作って、条件を満たすものだけ「採用」する！
 - 32.4 モンテカルロ法
 - 何これ：ランダムに「ダーツ」を投げて、当たった割合から面積を求める！
 - 32.5 モンテカルロ積分
 - リサンプリング手法 (32.6 ~ 32.8)
 - 32.6 経験分布関数
 - 32.7 ジャックナイフ法
 - 何これ：「1個だけ仲間外れ」にしたデータセットを全員分作る！
 - 32.8 ブートストラップ法

第21章 標本調査法

調査単位と抽出単位が一致していて、各標本を抽出する確率が等しい抽出法が**単純無作為抽出**で、それ以外の抽出法としては、調査者が決めた基準にしたがって標本を抽出する**有意抽出法**（街頭インタビューやモニター調査など）などがあります。以下では、単純無作為抽出かつ非復元抽出（同じ対象を2回以上抽出しない）の場合を考えます。

何これ：データ集めの基本中の基本

「全員調査は無理だから、全体を代表するメンバーをランダムに選ぶ」という手法です。アンケート調査や製品の抜き取り検査など、世の中の調査の土台となる考え方です。

21.1 標本平均の期待値と分散

大きさ N の母集団（母平均 μ ，母分散 σ^2 ）から大きさ n の標本を非復元単純無作為抽出するとき、母平均の推定量として標本平均 $\overline{X}$ を用いると、その期待値、分散は次のようになります。

$$E(\overline{X}) = \mu, \quad V(\overline{X}) = \frac{N-n}{N-1} \cdot \frac{\sigma^2}{n}$$

無限母集団の場合や復元抽出の場合と比べて、標本平均の分散には $\frac{N-n}{N-1}$ がかけられており、これを**有限修正項（有限母集団修正）**と言います。標本平均の分散を一定値以下におさえるにはサンプルサイズ n をある程度大きくすればよく、 $V(\overline{X}) \leq c$ という不等式を解けば、 n は次の不等式の右辺以上でなければならないことがわかります。

$$n \geq \frac{N\sigma^2}{\sigma^2 + (N-1)c}$$

Tip

💡 直感理解：なぜ全体の数 N が関わると分散が小さくなるの？

例えば、**100個のりんご**（ $N = 100$ ）から**99個**（ $n = 99$ ）を引く場面を想像してください。
ほぼ全数を調べることになるので、残った1個の影響は小さく、標本平均は「ほぼ本当の母平均」になりますよね。つまり、**全体の数 N に近づくほど推定のブレ（分散）はゼロに近づく**わけです。

この「全数調査に近づくほどブレが小さくなる効果」を数式にしたのが有限修正項 $\frac{N-n}{N-1}$ です。

- $n \rightarrow N$ になると分子が0に近づき、分散も0になります。
- 母集団が巨大（ $N \gg n$ ）な場合は $\frac{N-n}{N-1} \approx 1$ となり、馴染みのある $V(\overline{X}) = \frac{\sigma^2}{n}$ に戻ります。

21.2 層化抽出法

企業を大企業、中小企業、零細企業の3つに分けるように、基準を決めていくつかのグループ（層）に分けた後、それぞれの層から無作為抽出する方法です。**できるだけ層内を均質に、層間を異質に**層化すれば、事前に層化しない場合よりも精度の高い結果を得やすくなります。

何これ：グループごとの「特徴の違い」を利用してブレを減らす

無作為に選ぶと「たまたま大企業ばかり当たって平均年収が高く出ちゃった...」という事故が起き得ます。あらかじめ「大・中・小」の枠を作ってから選ぶことで、より正確な全体像を掴むテクニックです。

Tip

🔍 たとえ話：コンソメスープの味見

- 単純無作為抽出**：鍋を混ぜずに適当にスプーンですくう。（上澄みだけ、底の具だけ取れるリスクがある）
- 層化抽出**：「スープの層」と「底に沈んだ具の層」に分けて、それぞれから決めた割合だけすくって味見する。

「グループの中身（層内）はどれも似ていて、グループ同士（層間）はハッキリ違いがある」状態で作ると、一番効果を発揮します！

21.3 標本配分法

層化抽出法での各層（層の数を k とする）からの標本の大きさ $n_1, \dots, n_k$ （ $n_1 + \dots + n_k = n$ ）の決め方として、代表的なものを3つ紹介します。

① 比例配分法

層の大きさを $N_1, \dots, N_k$ （ $N_1 + \dots + N_k = N$ ）として、**層の大きさ（人数の多さ）の比**で標本の配分を決める方法です。

$$\frac{n_1}{N_1} = \frac{n_2}{N_2} = \cdots = \frac{n_k}{N_k} = \frac{n}{N}$$

比例配分法のもとでの標本平均の分散は、単純無作為抽出の場合の標本平均の分散を超えない（＝必ず同等以上の精度になる）ことを示すことができます。

何これ：割合に合わせて平等に集める

全体で「大企業1：中小企業3：零細企業6」なら、集めるデータも「10件：30件：60件」の比率で集める、最もシンプルで自然な分け方です。

② 等配分法

それぞれの層からの標本の大きさがすべて等しくなるように決める方法です。

$$n_1 = n_2 = \cdots = n_k = \frac{n}{k}$$

Important

訂正：数式の分母について

元のテキストでは分母が $\frac{N}{k}$ になっていましたが、全体から抽出するサンプルサイズの合計は n です。各層均等に分けるため、正しくは $\frac{n}{k}$ となります。

何これ：どのグループからも同じ数だけ集める

層ごとの人数比率は無視して、「大企業から100件、中小から100件、零細から100件」と一律で集めます。人数の少ないグループ（レアな層）の分析をしっかり行いたい時に使います。

③ ネイマン配分法

推定量の分散（推定のブレ）が**最小**になるように計算された、最も効率的な決め方です。 j 番目の層の母標準偏差を σ_j として、標本の大きさを次の式で決めます。

$$n_j = \frac{N_j \sigma_j \sqrt{\frac{N_j}{N_j - 1}}}{\sum_{j=1}^k N_j \sigma_j \sqrt{\frac{N_j}{N_j - 1}}} \times n$$

層の大きさが十分に大きい（ N_j が大きい）場合には、ルートの部分を1とみなして、次の簡略式で表せます。つまり、「**層の大きさ × 層内のばらつき（標準偏差）の比**」で配分することになります。

$$n_j = \frac{N_j \sigma_j}{\sum_{j=1}^k N_j \sigma_j} \times n$$

何これ：暴れ馬のグループほど、たくさんデータを取って手なずける！

人数の多さ（ N_j ）だけでなく、「**データがどれくらいバラついているか（ σ_j ）**」にも注目します。

Tip

直感理解：ネイマン配分はなぜばらつきが大きい層を多く取る？

- **みんなの意見が揃っている層（ σ が小さい）**：数人に聞くだけで全体像が分かるので、サンプルは少なくてもOK。
- **意見がバラバラで荒れている層（ σ が大きい）**：少し取っただけでは平均がブレるので、**データを多めに取ってブレを抑え込む**必要がある。

したがって、「**人数が多くて、かつデータが激しくバラついている層**」に一番多くのサンプルを割り振るのが、全体の精度を一番高くするベストな戦略（ネイマン配分）になります。

※集落抽出法、二段抽出法、系統抽出法は、2級内容のため、統計検定2級のチートシートを参照してください。

第22章 主成分分析

相関のある p 変数 $x_1, x_2, \dots, x_p$ を、相関のない p 変数 $y_1, y_2, \dots, y_p$ で $V[y_1] \geq V[y_2] \geq \dots \geq V[y_p]$ を満たすものに再編成する手法。分散共分散行列からはじめる場合と**相関行列**（※原文「相系列」から修正）からはじめる場合があります。

何これ：たくさんある情報を、なるべく損なわずに「要約」するテクニック

変数（データの種類）が多くて見づらい時に、互いに似ている（相関がある）変数をまとめて、より少ない新しい変数（主成分）を作り出します。「分散が大きい＝データの特徴・情報量がたくさん詰まっている」と考えるため、分散が最大になるように新しい「ものさし」を順番に作っていきます。


Tip


たとえ話：5教科のテストを「2つの力」に要約する

生徒の「国語、数学、理科、社会、英語」の5教科の点数（5次元）があるとします。5つも数字があると全体像を掴みにくいです。主成分分析にかけると以下のような新しい「ものさし」を作れます。

- 第1主成分**：全体的に点数が高いか低いかを表す「総合的な学力」
- 第2主成分**：文系科目が得意か、理系科目が得意かを表す「文理の偏り」

このように、5つの数字を見なくても、2つの新しい数字（主成分）を見るだけで、その生徒の成績の特徴がざっくりと分かるようになります。これが主成分分析（次元削減）の威力です！

分散共分散行列に対する主成分分析では、 $x_1, x_2, \dots, x_p$ に関する標本分散共分散行列の固有値を $\lambda_1, \lambda_2, \dots, \lambda_p$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$)、対応するノルム1の固有ベクトルを $w_1, w_2, \dots, w_p$ とするとき、 $w_i = (w_{1i}, \dots, w_{pi})$ と表せば、第 i 主成分は次のようになります。

$$y_i = w_{1i}(x_1 - \bar{x}_1) + \dots + w_{pi}(x_p - \bar{x}_p)$$

第 i 主成分の分散は λ_i で、 $V[x_1] + V[x_2] + \dots + V[x_p] = \lambda_1 + \lambda_2 + \dots + \lambda_p$ です。

相関行列に対する主成分分析では、標準化された変数を $z_1, z_2, \dots, z_p$, $x_1, x_2, \dots, x_p$ に関する標本相関行列の固有値を $\lambda_1, \lambda_2, \dots, \lambda_p$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$)、対応するノルム1の固有ベクトルを $w_1, w_2, \dots, w_p$ とするとき、 $w_i = (w_{1i}, \dots, w_{pi})$ と表せば、第 i 主成分は次のようになります。

$$y_i = w_{1i}z_1 + \dots + w_{pi}z_p$$

第 i 主成分の分散は λ_i で、 $\lambda_1 + \lambda_2 + \dots + \lambda_p = p$ です。


Important


訂正と補足：「相系列」→「相関行列」

原文の「相系列からはじめる場合と」はおそらく「**相関行列**」のタイポ（誤字）だと思われますので修正しました。


分散共分散行列と相関行列、どっちを使う？

- 分散共分散行列**：すべての変数の「単位」が同じとき（例：国語、数学など全て100点満点のデータ）。データのばらつきのスケールがそのまま反映されます。
- 相関行列**：変数の「単位」が違うとき（例：「身長(cm)」と「体重(kg)」など）。データを標準化して、すべての変数を平等に扱ってから分析したいときに使います。実務ではこちらが圧倒的に多いです。

22.1 寄与率

分散の合計のうち、ある主成分の分散が占める割合。例えば、第1主成分の寄与率は、 $\frac{\lambda_1}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$

何これ：その主成分が、元のデータを「どれくらい説明できているか」の割合

全体の情報量（ばらつき）のうち、その新しい「ものさし」が何%の情報をキャッチできているかを表すスコアです。

22.2 累積寄与率

寄与率を大きいほうから合計したもので、例えば、第2主成分までの累積寄与率は、 $\frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$ です。次元削減を目的とする場合には、「累積寄与率が80%を超えるまでの主成分だけを使う」といった目安として使われます。

何これ：「ここまで見れば、元のデータの〇%は把握できる！」という達成度

「第1主成分で60%、第2主成分で25%」なら、上位2つ合わせれば「85%」の情報がカバーできていることになります。「いくつまで主成分を採用するか」の基準になります。

22.3 主成分得点

データの主成分軸上での値。例えば、相関行列に対する主成分分析の第 i 主成分得点は、上の y_i の式の右辺の $z_1, z_2, \dots, z_p$ に各データを標準化した値を代入したもの。

何これ：新しい「ものさし」で測ったときの、各データの「点数」

さきほどの例えで言えば、A君の第1主成分得点が「+50」（総合力が高い）、第2主成分得点が「-30」（理系寄り）といった具体的な値のことです。この得点をプロットして散布図を描くのが、主成分分析の定番の可視化方法です。

22.4 主成分負荷量

分散共分散行列に対する主成分分析では、もとの変数の1つと1つの主成分の相関係数であり、例えば、上の y_i と x_2 との相関係数（主成分負荷量）は次の式で計算できます。

$$\frac{\sqrt{\lambda_i}w_{2i}}{\sqrt{V[x_2]}}$$

相関行列に対する主成分分析では、標準化された変数の1つと1つの主成分の相関係数であり、上の主成分負荷量の式の分母は1になります。

何これ：新しい「ものさし」が、元のどの変数から強く影響を受けているか

主成分負荷量が高い変数を見ると、「あ、この第1主成分は『国語』と『英語』との相関が強いから『文系力』の指標だな」といったように、**機械的に作り出した主成分に「人間の言葉で名前（意味）」をつけるためのヒント**になります。

22.5 自己符号化器（オートエンコーダ）

ニューラルネットワークモデル（第19章参照）の一種で、入力 $\boldsymbol{x}$ を低次元の表現に変換（**符号化**）した後、この低次元表現から元の入力に近いデータを再構築（**復号化**）することを目的としており、主成分分析と同じように、データの圧縮や特徴抽出に利用されます。自己符号化器は2つの主要な部分から構成され、入力 $\boldsymbol{x}$ に変換 $\boldsymbol{y} = f(\boldsymbol{w}^T \boldsymbol{x} + \boldsymbol{b})$ を適用する符号化器と、この $\boldsymbol{y}$ に次の変換を適用する復号化器です。

$$\tilde{\boldsymbol{x}} = \tilde{f}(\tilde{\boldsymbol{w}}^T \boldsymbol{y} + \tilde{\boldsymbol{b}})$$

元の入力 $\boldsymbol{x}$ にできるだけ近い出力 $\tilde{\boldsymbol{x}}$ が得られるように、符号化器と復号化器の重みとバイアスを調整します。

何これ：AIに「データの圧縮・解凍」をやらせる技術

主成分分析のディープラーニング版のようなものです。入力データを一旦わざと狭い道（低次元の $\boldsymbol{y}$ ）に通して情報を圧縮させ、そこから元のデータに復元させる訓練をします。

うまく復元できるようになれば、その「狭い道」を通ったデータこそが、**ノイズが取り除かれた本質的な特徴の要約**になっている、という賢い仕組みです。（※実は、活性化関数 $f, \tilde{f}$ を使わないシンプルな線形のモデルにすると、主成分分析と全く同じ働きになります）

第23章 判別分析

あらかじめグループ分けが判明しているデータを学習して、新たに得られたデータが属するグループを特徴量に基づいて判定する手法。分類規則の与え方には様々なものがあります。

何これ：過去のデータから「境界線」を学び、未知のデータを分類するAIの基本！

「身長と体重から性別を当てる」「検査値から病気が健康かを当てる」など、正解のグループが分かっているデータ（教師データ）をもとにルールを作り、新しいデータがどのグループに入るかを予測（判別）する手法の総称です。

23.1 フィッシャーの線形判別分析

2変数 (x_1, x_2) の場合を例とし、 $Y = w_1x_1 + w_2x_2$ という1次式で、 Y の値によって属するグループをより良く判別できるように $\boldsymbol{w} = (w_1, w_2)^T$ を決めます。そのために、群間変動 $\boldsymbol{w}^T \boldsymbol{S}_B \boldsymbol{w}$ を群内変動 $\boldsymbol{w}^T \boldsymbol{S}_W \boldsymbol{w}$ でわった比が最大になるようにすればいいと考えます。ここで、2群の学習データの標本平均ベクトルを $\bar{\boldsymbol{x}}^{(1)}, \bar{\boldsymbol{x}}^{(2)}$ とするとき、 $\boldsymbol{S}_B = (\bar{\boldsymbol{x}}^{(1)} - \bar{\boldsymbol{x}}^{(2)})(\bar{\boldsymbol{x}}^{(1)} - \bar{\boldsymbol{x}}^{(2)})^T$ であり、 $\boldsymbol{S}_W$ は2群のプールされた標本分散共分散行列です。この最適化問題の解 $\hat{\boldsymbol{w}}$ は次の式で与えられます。

$$\hat{\boldsymbol{w}} = \boldsymbol{S}_W^{-1}(\bar{\boldsymbol{x}}^{(1)} - \bar{\boldsymbol{x}}^{(2)})$$

よって、2群の標本平均ベクトルの中点を基準として、次の関数が正になるか、負になるかによって、新たなデータの属する群を判定します。

$$f(\boldsymbol{x}) = \hat{\boldsymbol{w}}^T \boldsymbol{x} - \frac{1}{2}(\bar{\boldsymbol{x}}^{(1)} - \bar{\boldsymbol{x}}^{(2)})^T \boldsymbol{S}_W^{-1}(\bar{\boldsymbol{x}}^{(1)} + \bar{\boldsymbol{x}}^{(2)})$$

この関数 $f(\boldsymbol{x})$ をフィッシャーの線形判別関数と言います。

何これ：一番キレイに「パカッ」と分かれる直線を引く！

グループ同士はなるべく遠くに離し（群間変動の最大化）、同じグループの仲間なるべくギュッと集める（群内変動の最小化）ような、最高の「境界線（斜めものさし）」を探す方法です。

23.2 マハラノビス距離による判別

データの標本平均ベクトルを $\bar{\boldsymbol{x}}$ 、標本分散共分散行列を $\boldsymbol{S}$ とするとき、次の $D^2(\boldsymbol{x})$ を $\boldsymbol{x}$ と $\bar{\boldsymbol{x}}$ のマハラノビス平方距離と言います。

$$D^2(\boldsymbol{x}) = (\boldsymbol{x} - \bar{\boldsymbol{x}})^T \boldsymbol{S}^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}})$$

$\boldsymbol{x}$ と 2 群の標本平均ベクトル $\bar{\boldsymbol{x}}^{(1)}, \bar{\boldsymbol{x}}^{(2)}$ とのマハラノビス平方距離を比べて、小さいほうの群に $\boldsymbol{x}$ が属すると判別するとき、2 群のプールされた標本分散共分散行列 $\boldsymbol{S}_W$ を使った次の関数が正ならば $\boldsymbol{x}$ は群 2、負ならば群 1 と考えることができます。

$$(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(1)})^T \boldsymbol{S}_W^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(1)}) - (\boldsymbol{x} - \bar{\boldsymbol{x}}^{(2)})^T \boldsymbol{S}_W^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(2)})$$

上の関数はフィッシャーの線形判別関数の -2 倍に等しくなり、2 種類の判別は一致します。

また、群 1 の標本分散共分散行列を $\boldsymbol{S}_1$ 、群 2 の標本分散共分散行列を $\boldsymbol{S}_2$ として、次の関数により群の判別を行うことを**2次判別分析**と言います。

$$(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(1)})^T \boldsymbol{S}_1^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(1)}) - (\boldsymbol{x} - \bar{\boldsymbol{x}}^{(2)})^T \boldsymbol{S}_2^{-1}(\boldsymbol{x} - \bar{\boldsymbol{x}}^{(2)})$$

Tip

💡 マハラノビス距離って何？なぜ「2次」判別？

普通の直線距離（ユークリッド距離）だと、データが「細長い楕円状」に散らばっている時にうまく判定できません。マハラノビス距離は**「データの散らばり方のクセ（分散共分散行列）」**を考慮して、「中心から何歩分か」を測る等高線のような距離です。

- **線形判別**：2つの群の散らばり方が「同じ形」だと仮定するから、境界が**直線（線形）**になる。
- **2次判別**：2つの群の散らばり方が「違う形」だと仮定するから、境界がカーブを描く**曲線（2次関数）**になる。

23.3 ベイズ判別

データ $\boldsymbol{x}$ を与えたもとで、群 1 に属する事後確率 $P(G_1|\boldsymbol{x})$ の群 2 に属する事後確率 $P(G_2|\boldsymbol{x})$ に対する比の対数は、ベイズの定理を用いて次の式の右辺のように表せます。

$$\log \frac{P(G_1|\boldsymbol{x})}{P(G_2|\boldsymbol{x})} = \log P(\boldsymbol{x}|G_1) - \log P(\boldsymbol{x}|G_2) + \log \frac{P(G_1)}{P(G_2)}$$

上の式の $P(G_1), P(G_2)$ は事前確率であり、各群に属する事前確率を分類規則に反映できるのがベイズ判別です。 $P(G_1) = P(G_2)$ と 2 群のデータが同一の分散共分散行列をもつ多変量正規分布にしたがうことを仮定すれば、マハラノビス距離による判別と一致します。

何これ：「そもそもの起きやすさ（事前確率）」を考慮して補正する

例えば、「1万人に1人しかかからないレアな病気」の場合、検査結果が多少クロ寄りでも、「そもそも病気である確率（事前確率）が極めて低いから、たぶん健康だろう」と判定を引っ張ることができます。この「下馬評」を組み込めるのがベイズの強みです。

23.4 正準判別分析

p 変数 $(x_1, \dots, x_p)$ の g 個の群 $G_1, \dots, G_g$ を2次元や3次元などの低次元への射影を利用する判別分析。 g 個の群ができるだけよく分離できるような射影軸 $y = w_1x_1 + \dots + w_px_p = \boldsymbol{w}^T \boldsymbol{x}$ の係数ベクトル $\boldsymbol{w}$ は、フィッシャーの線形判別分析と同じように、群間変動 $\boldsymbol{w}^T \boldsymbol{S}_B \boldsymbol{w}$ を群内変動 $\boldsymbol{w}^T \boldsymbol{S}_W \boldsymbol{w}$ でわった比の最大化を通して、 $\boldsymbol{S}_W^{-1} \boldsymbol{S}_B$ の最大の固有値に対する固有ベクトルとして求められます。なお、 $\boldsymbol{S}_B$ と $\boldsymbol{S}_W$ は、第 i 群について、標本平均ベクトルを $\bar{\boldsymbol{x}}^{(i)}$ 、サンプルサイズを n_i 、標本分散共分散行列を $\boldsymbol{S}_i$ 、学習データ全体の標本平均ベクトルを $\bar{\boldsymbol{x}}$ として、次のように定義します。

$$\boldsymbol{S}_B = \sum_{i=1}^g n_i (\bar{\boldsymbol{x}}^{(i)} - \bar{\boldsymbol{x}})(\bar{\boldsymbol{x}}^{(i)} - \bar{\boldsymbol{x}})^T, \quad \boldsymbol{S}_W = \sum_{i=1}^g (n_i - 1) \boldsymbol{S}_i$$

同じように、次に最適な射影軸の係数ベクトルは、 $\boldsymbol{S}_W^{-1} \boldsymbol{S}_B$ の2番目に大きな固有値に対する固有ベクトルとして求められます。

23.5 ハードマージンSVM（サポートベクターマシン）

超平面によって線形分離可能な場合のSVM（サポートベクターマシン）。超平面 $\boldsymbol{w}^T \boldsymbol{x} + b = 0$ によって2群に分けると、その超平面に最も近い学習データを**サポートベクター**と言い、マージン（サポートベクターから超平面までの距離）を最大にするように $\boldsymbol{w}, b$ を決定します。具体的には、データ $\boldsymbol{x}_i$ のクラスラベルを表す変数を y_i として、 $y_i(\boldsymbol{w}^T \boldsymbol{x}_i + b) \geq 1 \quad (i = 1, 2, \dots, n)$ のもとで、 $0.5 \|\boldsymbol{w}\|^2$ を最小化することで、次のように求められます。

$$\begin{aligned} \hat{\boldsymbol{w}} &= \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i \\ \hat{b} &= -\frac{1}{2} \hat{\boldsymbol{w}}^T (\boldsymbol{x}_+ + \boldsymbol{x}_-) \end{aligned}$$

ただし、ラグランジュ乗数の α_i には最適化問題の解を代入し、 $\boldsymbol{x}_+$ は $y_i = 1$ を満たすサポートベクター、 $\boldsymbol{x}_-$ は $y_i = -1$ を満たすサポートベクターです。

何これ：境界線ギリギリのデータだけを見て、なるべく「安全地帯」を広くする

遠くにあるデータは無視して、敵同士が最も近づいている「最前線のデータ（サポートベクター）」だけに注目します。2つの群の間に「できるだけ太い道路（マージン）」を引こうとする職人的なアプローチです。

23.6 ソフトマージンSVM

線形分離可能でない場合（データが少し入り混じっている場合）に、はみ出したデータに罰則を課す線形SVM。はみ出しを表すスラック変数を $\xi_i \geq 0$ として、 $y_i(\boldsymbol{w}^T \boldsymbol{x}_i + b) \geq 1 - \xi_i$ のもとで、次の和が最小になる $\boldsymbol{w}$ と ξ_i を求めます。

$$\frac{1}{2} \|\boldsymbol{w}\|^2 + \lambda \sum_{i=1}^n \xi_i$$

λ ははみ出しに対する罰則の強さを決めるパラメータで、 λ が大きいと罰則が強くなり、 ξ_i の和はあまり大きな値をとれません。

💡 Tip

🔍 たとえ話：道路のセンターライン引き

- ハードマージン：絶対に反対車線にはみ出してはいけないルール。ちょっとでも相手陣地に食い込んでいるデータがあると線を引けずエラーになる。
- ソフトマージン：「数個のはみ出しなら、ペナルティ（罰金 λ ）を払えば許してあげるよ」という柔軟なルール。現実世界のデータはノイズが混じっているの、基本的にこちらを使います。

23.7 混同行列

判別器による判別結果を次の表の形式でまとめたもの。

		予測	
		$Y = 1$	$Y = 0$
実際	$Y = 1$	TP	FN
	$Y = 0$	FP	TN


上の表のPは予測結果が陽性（positive）、Nは予測結果が陰性（negative）であることを示しています。

- $TPR = TP / (TP + FN)$ は、実際に $Y = 1$ であるもののうち、正しく $Y = 1$ と予測できた割合で、**真陽性率** と言います。


- $FPR = FP / (FP + TN)$ は、実際に $Y = 0$ であるもののうち、誤って $Y = 1$ と予測した割合で、**偽陽性率**と言います。

例えば、次の図の青の点は合格者の偏差値、黄色の点は不合格者の偏差値で、緑の破線の右側を合格、左側を不合格と判別するとしましょう。

合格する確率



このとき、緑の破線を右端から左へ移動させると、合格者6人のデータを合格と判定した後、1人の不合格者のデータを合格と判定し、最終的には全員を合格と判定するようになります。このように、 $TP=FP=0$ の状態から、 $FN=TN=0$ の状態へ移る過程を、横軸にFPR、縦軸にTPRをとって、グラフにしたもの（下の図の赤い線）が**ROC曲線**で、ROC曲線と横軸で囲まれた部分の面積が**AUC（曲線下面積）**です。



上の図では、 $AUC=0.88$ であり、AUCが1に近いほど、判別器の性能が良いと言えます。なお、TPRを**感度（再現率）**、 $1-FPR$ を**特異度**とも言います。病気の判別では、感度は病気にかかっている人を漏らさずに陽性と判定する割合を意味するので、高いことが重要です。また、全サンプルを健康と予測するモデルだと特異度が1（※この記述については下記の補足参照）になります。

Important

訂正と補足：特異度と「全サンプル健康予測」について

- **感度（TPR：見逃さない力）**：病気の人を正しく病気（陽性）と当てる確率。
- **特異度（ $TN / (FP + TN)$ ：冤罪を防ぐ力）**：健康な人を正しく健康（陰性）と当てる確率。

原文の「全サンプルを健康（陰性）と予測するモデルだと特異度が1になります」はその通りです。全員陰性とするので、誤って陽性（FP）と判定する人がゼロになり、特異度は100%（FPRは0）になります。ただし、病気の人を全員見逃すため**感度は0**になってしまう、というトレードオフの関係があります。このトレードオフの全体像を見るのがROC曲線です。

第24章 クラスター分析

分類の手本（正解ラベル）がない状態で、近さを測る指標（距離など）を定めて、データをグループ分け（クラスタリング）する**教師なし学習**の手法。 $\boldsymbol{x} = (x_1, \dots, x_p)$ と $\boldsymbol{y} = (y_1, \dots, y_p)$ の距離として、最も問われやすいのは次のユークリッド距離です。

$$d(\boldsymbol{x}, \boldsymbol{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_p - y_p)^2}$$

何これ：「正解」がないデータから、似たもの同士をグループ化する！

第23章の「判別分析」が正解ラベルのある「教師あり学習」だったのに対し、クラスター分析は正解のない「教師なし学習」です。「顧客アンケートから似たタイプのセグメントを作る」「購買履歴から似た商品をまとめる」などに使われます。

24.1 階層的クラスタリング

1つのデータ（個体）を1つのクラスターとみなし、距離の近いクラスターを順次融合していくクラスタリング。融合の過程を表した樹形図を**デンドログラム**と言います。データ間の距離をユークリッド距離などによって定め、それをもとにクラスター間の距離を次の最短距離法、最長距離法、群平均法、重心法、ウード法などによって定めます。

何これ：トーナメント表のように、近いものから順番に合体させていく

最初は全員が「一人ぼっちのクラスター」からスタートし、一番近い二人を合体させ、また次に近いものを合体させ...を繰り返して大きなグループを作っていきます。

24.2 最短距離法（最近隣法）

2つのクラスターから1個体ずつ選んで求めた距離のうち、最も短い距離をクラスター間の距離とする方法。**鎖効果**を起こしやすく、クラスター構造が捉えにくい場合があります。



Tip

💡 鎖効果（チェイニング効果）とは？

端と端の「最も近い一点」だけを見て結合していくため、点と点が数珠つなぎになって、**「細長いへビのような不自然なクラスター」**ができてしまう現象の事です。

24.3 最長距離法（最遠隣法）

2つのクラスターから1個体ずつ選んで求めた距離のうち、最も長い距離をクラスター間の距離とする方法。

何これ：一番遠いメンバー同士の距離を見る

最短距離法とは逆に、クラスター内で一番離れている二人を見て決定します。ぎゅっと引き締まった「球状（コンパクト）のクラスター」がしやすいですが、外れ値の影響を受けやすいデメリットもあります。

24.4 群平均法

2つのクラスターから1個体ずつ選んで求めたペアすべての距離の平均をクラスター間の距離とする方法。

何これ：全パターンの平均を取るマイルドな手法

一部の極端なデータ（外れ値）に振り回されにくく、バランスの良い判定ができます。

24.5 重心法

クラスター内の重心どうしの距離をクラスター間の距離とする方法。

⚠ Warning

⚠ 逆転現象に注意

重心法や中点法では、結合を進めていくとクラスター間の距離が以前より小さくなってしまう**「逆転現象（デンドログラムの枝が下に下がってしまう現象）」**が起きることがあります。

24.6 ウォード法

クラスター内のデータの重心からの距離の2乗和の増分（偏差平方和の増加量）が最小となるクラスターを順に合併していく方法。

何これ：試験・実務で一番よく使われる大本命！

「合体させたときに、グループ内のバラつき（平方和）が一番増えない組み合わせ」を選んで結合していきます。分類の精度が非常に高く、サイズが均等な美しいクラスターが作れやすいため、**階層的クラスタリングでは最も推奨される手法**です。

24.7 K-means法（ k 平均法）

非階層的クラスタリングの代表例であり、データ数が膨大な場合にも高速に動作します。クラスタリングの手順の一例は次の通りです。

1. クラスターの数 K をあらかじめ決める
2. クラスター中心（初期値）をランダムに決める
3. 全データと各クラスター中心との距離を計算する
4. 中心との距離が最も近いクラスターにデータを振り分ける
5. クラスターの重心を計算して中心（重心）を更新する
6. ③～⑤をくり返してデータのクラスター間の移動がなくなったら終了

何これ：最初から「 K 個のグループに分ける！」と決めて中心を探す

階層的クラスタリング（デンドログラムを作る）と違って、**データ数が数万件～数百万件あっても爆速で計算できる**のが最大のメリットです。

Tip

たとえ話：席替えとリーダー決め

1. 「今日は3つのグループ（ $K = 3$ ）に分けるぞ」と決める。
2. 適当に3人の暫定リーダー（中心）を指名する。
3. クラスのメンバー全員は、一番近いリーダーのもとに移動する（グループ分け）。
4. 集まったグループの中で「本当の重心（真のリーダー）」を決め直す。
5. 新しいリーダーをもとに、全員がもう一度一番近いリーダーへ移動する。
6. これを繰り返し、リーダーもメンバーも動かなくなったら完成！

※最初の「暫定リーダーの選び方（初期値）」によって結果が変わってしまうため、初期値を工夫する「K-means++」などの改良手法もよく使われます。

※混合分布とEMアルゴリズムについては第6章を参照。

第25章 因子分析・グラフィカルモデル

5教科の得点を総合的な学力と教科ごとの能力で捉えるように、多数の観測変数間の構造を明らかにする目的で、それらに影響を与える少数の**共通因子**と変数ごとの**独自因子**を想定した分析。例えば、3つの観測変数 x_1, x_2, x_3 を考えるとき、これらを平均0、分散1に標準化した上で、何個の共通因子によって説明するかを決めます。ここでは、2つの共通因子 f_1, f_2 を仮定するとして、2因子モデルは次のように表せます。

$$\begin{aligned}x_1 &= \beta_{11}f_1 + \beta_{12}f_2 + d_1 \\x_2 &= \beta_{21}f_1 + \beta_{22}f_2 + d_2 \\x_3 &= \beta_{31}f_1 + \beta_{32}f_2 + d_3\end{aligned}$$

β_{ij} は**因子負荷量**と呼ばれる係数です。 d_1, d_2, d_3 は独自因子を表していて、 f_1, f_2, d_1, d_2, d_3 はすべて互いに独立で、 $E[f_1] = E[f_2] = 0, V[f_1] = V[f_2] = 1, E[d_1] = E[d_2] = E[d_3] = 0$ を仮定します。 d_1 の分散を σ_1^2 とすると、観測変数 x_1 の分散について、 $\beta_{11}^2 + \beta_{12}^2 + \sigma_1^2 = 1$ が成り立ちます。このとき、 $\beta_{11}^2 + \beta_{12}^2$ を**共通性**、 σ_1^2 を**独自性**と言います。観測変数の変動のうち、共通因子で説明できる部分が共通性、説明できない部分が独自性だと解釈します。

何これ：表面上のデータから「裏に潜む共通の原因（才能や性格など）」を見つけ出す！

「テストの点数」や「アンケートの回答」など、目に見えるデータ（観測変数）の背後には、目に見えない「才能」や「性格」といった共通の原因（因子）が隠れているはずだ！と仮定して、その正体をあぶり出す手法です。



Tip

💡 主成分分析（22章）と因子分析の違い

どちらも「変数を減らす（まとめる）」手法で似ていますが、矢印の向き（因果関係）が逆です。

- ・ **主成分分析**：データ → 主成分（データをギュッと要約して作った新しい指標）
- ・ **因子分析**：因子 → データ（背後にある見えない原因が、表面のデータに影響を与えていると考える）

25.1 寄与率

すべての観測変数の変動を、それぞれの共通因子がどれだけ説明できているかを表すもので、上の例の f_1 の寄与率は次の式で計算できます。

$$\frac{1}{3} \sum_{i=1}^3 \beta_{i1}^2$$

何これ：その隠れキャラクター（因子）の「影響力の大きさ」

「第1因子（例えば『文系力』）は、テスト全体の点数のばらつきをどれくらい説明しているか？」を表すスコアです。

25.2 因子軸の回転

回転によって因子負荷量を解釈しやすいものにとり直すことが可能です。因子軸が直交した状態での回転（直交回転）の代表例が**バリマックス回転**で、因子軸が必ずしも直交しない回転（斜交回転）の代表例が**プロマックス回転**です。

何これ：結果に「人間の言葉で名前」をつけやすくするための微調整

因子分析をやった直後は、「どのデータも第1因子とそこそこ関係がある」みたいな中途半端な結果になりがちです。そこで、見る角度（軸）を回して、「このデータは第1因子だけのせい！」「このデータは第2因子だけのせい！」と白黒ハッキリさせる作業が「回転」です。




Tip

🔍 たとえ話：直交回転と斜交回転

- ・ **バリマックス回転（直交回転）**：因子同士は「絶対に無関係（相関ゼロ）」という厳しいルールで軸を回します。（例：「文系力」と「理系力」は全く別物とする）
- ・ **プロマックス回転（斜交回転）**：因子同士が「少し相関していてもOK」という現実的なルールで軸を回します。（例：「文系力」が高い人は「理系力」もそこそこ高いよね、と妥協する）。**実務や研究ではプロマックス回転がよく使われます。**

25.3 操作変数法（パス解析・構造方程式モデル）

次のような図を**パス図**と呼び、ここに示される因果関係を $Z = aX + bY + u, Y = cX + v$ という式（**構造方程式**）で表すことができます。



a, b, c は**パス係数**と呼ばれます。 $E[X] = E[Y] = E[Z] = 0, V[X] = V[Y] = V[Z] = 1$, 誤差項 u は X, Y と, v は X とそれぞれ無相関であることを仮定した上で、構造方程式に変数をかけて期待値をとることで、次の例のようにパス係数を相関係数を用いて表すことができます。(例) $Y = cX + v \rightarrow E[XY] = cE[X^2] + E[vX] \rightarrow c = r_{XY}$

$Z = aX + bY + u$ で同じように計算すると、 $r_{XZ} = a + bc$ が得られます。このとき、 a は $X \rightarrow Z$ の**直接効果**, bc は $X \rightarrow Y \rightarrow Z$ のように Y を介した**間接効果**であり、両者を合わせて**総合効果**と呼ばれます。

🔥 Important

🔥 用語の補足：「操作変数法」と「パス解析」

ここのテキストの見出しは「操作変数法」となっていますが、解説されている内容は**「パス解析（構造方程式モデリング：SEMの一部）」**の基礎です。

（※操作変数法は、原因と結果の間に隠れた交絡因子がある場合に、外部から影響を与える「操作変数」を使って純粋な因果関係を推定する計量経済学の手法ですが、計算にパス図の考え方を使うためここでまとめられていると思われます。）

何これ：変数同士の「ピタゴラスイッチ（因果の連鎖）」を読み解く

「広告(X)を出したら売上(Z)が直接上がったのか？（直接効果： a ）」それとも「広告(X)を出したら認知度(Y)が上がり、その結果として売上(Z)が上がったのか？（間接効果： bc ）」を切り分けて計算する手法です。

25.4 グラフィカルモデル

確率変数ベクトル $(X_1, \dots, X_d)$ が d 変量正規分布にしがっているとき、グラフィカルモデルでは、指示の変数を頂点に対応させ、変数間の条件付き独立性を辺の有無で表現します。例えば、**相関行列の逆行列**の $(1, 2)$ 成分が 0 ならば、 X_1 と X_2 が他の変数を与えたもとで条件付き独立だと言えます。このように間接的な関係しかない変数どうしには辺をひかず、直接的な関係にある変数どうしを辺で結んでできるのが**無向独立グラフ**です。

何これ：変数同士の「本当の直接関係」だけを線で結んだネットワーク図

世の中には「一見すると関係がありそうに見えるけど、実は別の要因のせい（擬似相関）」というデータがたくさんあります。グラフィカルモデルは、そういった「偽物の相関」を排除して、本当に直接的な繋がりがあるものだけを線（辺）で結んだ相関図を作る技術です。

🔥 Tip

💡 相関行列の「逆行列（精度行列）」がカギ！

- 普通に相関を計算した場合：「アイスの売上」と「水難事故の件数」には強い相関が出ます（夏だから）。
- 逆行列（偏相関係数）を使った場合：「気温」という他の変数の影響を取り除いて計算するため、「アイス」と「水難事故」の数値は 0 になります。結果として、グラフ上ではアイスと水難事故の間には線（辺）が引かれず、「気温」を中心とした正しいネットワーク図が完成します。

第26章 その他の多変量解析手法

26.1 多次元尺度構成法（MDS）

個体間の距離が与えられたときに、その距離関係を保つような個体の座標を求める手法。特に、2～3次元の座標で表すことで個体間の位置関係を視覚化できます。

何これ：「距離のデータ」だけを頼りに、元の「地図」を復元するマジック！

普通は「座標（位置）」が分かっている、そこから「距離」を計算します。多次元尺度構成法はこれの逆で、「各データ間の距離」だけが入った表から、それぞれの点があったはずの「座標」を逆算してプロットする手法です。

 Tip

 **たとえ話：運賃表から日本地図を描く**

「東京～大阪は500km」「大阪～福岡は500km」「東京～福岡は1000km」……という各都市間の距離データ（距離行列 D ）だけをコンピュータに渡します。コンピュータは「あ、これらがつつまを合わせるには、一直線に並べる（1次元）、あるいは平面上にこう配置する（2次元）しかないな」と計算して、見事に日本地図を復元してくれます。

計算方法は次の通り。

- 与えられた n 次距離行列 D に対して、 n 次単位行列を I_n 、すべての成分が1の n 次正方行列を J_n として、次の行列 B を計算
$$B = -\frac{1}{2} \left(I_n - \frac{1}{n} J_n \right) D \left(I_n - \frac{1}{n} J_n \right)$$
- B の固有値、互いに直交するノルム1の固有ベクトルを求める。正の固有値を対角成分に並べた行列を Λ 、固有ベクトルを並べた行列を U として、 $B = U \Lambda U^T$ と表せることに注意
- $XX^T = B$ を満たす行列 X として、 $X = U \Lambda^{0.5}$ ($\Lambda^{0.5}$ は対角成分に固有値の正の平方根を並べたもの) がとれる。例えば、2次元座標で表すには、並べる固有ベクトル、固有値を2つつつにする

26.2 正準相関分析

$\boldsymbol{x} = (x_1, x_2, \dots, x_p)^T$ と $\boldsymbol{y} = (y_1, y_2, \dots, y_q)^T$ の変数間の相関係数は pq 通りあるため、 p, q が大きいときには相関関係の把握が煩雑になりやすいです。そこで、 $u = a_1x_1 + a_2x_2 + \dots + a_px_p$ と $v = b_1y_1 + b_2y_2 + \dots + b_qy_q$ の相関係数が最大になるように $\boldsymbol{a} = (a_1, a_2, \dots, a_p)$ と $\boldsymbol{b} = (b_1, b_2, \dots, b_q)$ を決めて、 $\boldsymbol{x}$ と $\boldsymbol{y}$ の関係を理解しようとするのが正準相関分析です。

何これ：2つのグループ間で、最も「相性の良い」総合得点の作り方を探す！

変数同士がバラバラにたくさんあると見つらいので、「 x グループの総合力 u 」と「 y グループの総合力 v 」というように、重み付けをして1つの指標にまとめてから相関を見ます。

 Tip

 **たとえ話：体力と学力の関係を調べる**

- $\boldsymbol{x}$ グループ（体力）：50m走、握力、反復横跳び、上体起こし...
- $\boldsymbol{y}$ グループ（学力）：国語、数学、理科、社会、英語...

これら全ての組み合わせ（50m走と国語、握力と理科...）の相関を見るのは大変です。そこで、「体力テストの総合スコア u 」と「学力テストの総合スコア v 」を作ります。この**総合スコア同士の相関（正準相関係数）が最大になるような、完璧な重み付け（ $\boldsymbol{a}$ と $\boldsymbol{b}$ ）を見つけるのが正準相関分析です。**

このような相関係数の最大化は、行列の固有値問題に帰着し、最大の固有値に対する固有ベクトルとして1組の $\boldsymbol{a}$ と $\boldsymbol{b}$ が得られます。この固有ベクトルを $\boldsymbol{a}_1, \boldsymbol{b}_1$ としてできる $u_1 = \boldsymbol{a}_1^T \boldsymbol{x}$ と $v_1 = \boldsymbol{b}_1^T \boldsymbol{y}$ の組を第1正準変数と呼び、同じように2番目に大きい固有値に対する固有ベクトル $\boldsymbol{a}_2, \boldsymbol{b}_2$ から u_1, v_1 と無相関であるような u_2, v_2 が得られ、第2正準変数と呼びます。（以下同様）

26.3 数量化法

質的データなどを「数量化」して多変量解析の枠組みで分析する手法です。下の表などを通して数量化Ⅰ～Ⅲ類の区別を覚え、理論の概要を知っておきましょう。

何これ：「文字（カテゴリ）」データを、無理やり「数字」に変換して分析する日本発のテクニック！

「男/女」や「東京/大阪」のような質的データ（名義尺度）は、そのままでは数式の計算に使えません。それを「0と1」などのダミー変数に置き換えて分析する手法の総称です。（※日本人統計学者の林知己夫先生が開発したため「林の数量化理論」と呼ばれ、日本の検定試験では頻出です）

目的変数 \ 説明変数	間隔尺度（数値）	名義尺度（カテゴリ）
間隔尺度（数値）	重回帰分析	数量化Ⅰ類

目的変数 \ 説明変数	間隔尺度（数値）	名義尺度（カテゴリ）
名義尺度（カテゴリ）	判別分析	数量化Ⅱ類



Tip

💡 どう使い分けるの？

- **数量化Ⅰ類（重回帰の親戚）**：説明変数がカテゴリで、目的変数が数値。
（例：「性別」と「居住地」から、「年収」を予測する）
- **数量化Ⅱ類（判別分析の親戚）**：説明変数がカテゴリで、目的変数もカテゴリ。
（例：「性別」と「居住地」から、その商品に「興味あり/なし」を分類する）

また、数量化Ⅲ類は、いわば主成分分析の名義尺度版であり、アンケートデータのような○と×のデータから得られる相関をもとに固有値を計算してデータを縮約します。

数量化Ⅰ類や数量化Ⅱ類では、変数が説明変数と目的変数に二分されていて、この場合に目的変数を説明変数に関する**外的基準**と呼びます。一方で、数量化Ⅲ類では変数どうしの関係は対等であり、内部構造に基づく分析であるため、外的基準のない（教師なし学習のような）手法と言えます。

第27章 時系列解析

月や年など、時間軸にそって観測されるのが時系列データであり、確率変数 Y_t ($t = 1, 2, \dots$) で表します。

27.1 弱定常過程（共分散定常過程）

平均と分散が一定であり、自己共分散が時点によらずラグのみによって決まる時系列。 h 次の自己共分散を $Cov[Y_t, Y_{t-h}] = \gamma_h$ と表すと、 $V[Y_t] = V[Y_{t-h}] = \gamma_0$ であり、 h 次の自己相関係数は γ_h/γ_0 です。

何これ：時間によらず「波の高さ（平均）」と「波の振れ幅（分散）」が一定で安定しているデータ

時系列分析の基本となる大前提です。株価のように右肩上がりやトレンドがあるデータ（非定常）はそのままでは分析しづらいため、差分をとるなどして「弱定常」な状態にしてから分析するのが鉄則です。

27.2 ホワイトノイズ

平均が 0、分散が一定で、0 でないラグに対する自己共分散がすべて 0 である時系列で、弱定常過程の一種。以下では、 U_t は分散 σ^2 のホワイトノイズを表すものとしてします。

何これ：過去のデータと一切関係がない「完全なランダムノイズ」

テレビの「砂嵐」のようなイメージです。過去のデータから未来を予測することが全くできない、完全にランダムな偶然の変動を表します。

27.3 p次自己回帰過程 [AR(p)]

現在の値が過去 p 時点の値の影響と現在の偶然変動により説明できるとする次のようなモデル。

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + U_t$$

何これ：「今日の値」は「過去の値」に引っ張られる！というモデル

「昨日の気温が高かったから、今日も高いだろう」「1時間前の株価が上がっていたから、今も上がる勢いが残っているだろう」というように、**自分自身の過去のデータ（自己）に回帰（依存）** すると考えます。

例えば、AR(1) 過程 $Y_t = c + \phi_1 Y_{t-1} + U_t$ ならば、 $|\phi_1| < 1$ のときに弱定常になり、このときの Y_t の期待値、分散、自己共分散、自己相関係数は次のようにまとめることができます。

期待値	分散	h 次の自己共分散	h 次の自己相関係数
$\frac{c}{1 - \phi_1}$	$\frac{\sigma^2}{1 - \phi_1^2}$	$\frac{\phi_1^h \sigma^2}{1 - \phi_1^2}$	ϕ_1^h

27.4 q次移動平均過程 [MA(q)]

現在の値が過去 q 時点の偶然変動の影響と現在の偶然変動により説明できるとする次のようなモデル。

$$Y_t = c + U_t + \theta_1 U_{t-1} + \dots + \theta_q U_{t-q}$$

何これ：「今日の値」は「過去に起きた突発的なショック（ノイズ）」の余韻が残っている！というモデル

ARが「過去の値そのもの」に引っ張られるのに対し、MAは「過去の予想外の出来事（ホワイトノイズ U ）」の影響が、何日後まで引きずられると考えます。



Tip



移動平均過程は常に「弱定常」！

ARモデルは係数（ ϕ ）の条件によっては発散して非定常になってしまいますが、MAモデルは過去の有限個のノイズの足し合わせなので、無条件で弱定常過程になります。

移動平均過程は弱定常です。MA(1) モデル $Y_t = c + U_t + \theta_1 U_{t-1}$ のとき、期待値、分散、自己共分散、自己相関係数は次のようにまとめることができます。

期待値	分散	自己共分散（1次）	自己共分散（2次以上）	自己相関係数（1次）	自己相関係数（2次以上）
c	$(1 + \theta_1^2)\sigma^2$	$\theta_1\sigma^2$	0	$\frac{\theta_1}{1 + \theta_1^2}$	0

27.5 (p,q)次自己回帰移動平均過程 [ARMA(p,q)]

AR過程とMA過程の両方の性質をもつ次のようなモデル。

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + U_t + \theta_1 U_{t-1} + \cdots + \theta_q U_{t-q}$$

何これ：AR（過去の値の影響）とMA（過去のショックの影響）の「いいとこ取り」！

ただし、 $p = 0$ の場合はMA過程、 $q = 0$ の場合はAR過程、 $p = q = 0$ の場合はホワイトノイズとします。

AR過程の部分が弱定常であるときにARMA過程は弱定常になりますが、次の方程式のすべての解の絶対値が1より大きいことと同値です。

$$1 - \phi_1 z - \phi_2 z^2 - \cdots - \phi_p z^p = 0$$

27.6 (p,1,q)次自己回帰和分移動平均過程 [ARIMA(p,1,q)]

弱定常過程ではない $\{Y_t\}$ で、差分系列 $\Delta Y_t = Y_t - Y_{t-1}$ が弱定常かつ反転可能なARMA過程になるもの。

何これ：「トレンド（右肩上がりなど）」があるデータでも使える最強の実用モデル

株価のように上昇トレンドがある（定常じゃない）データでも、「今日と昨日の差額（差分）」をとれば、トレンドが消えて平坦（定常）になることがよくあります。この**「差分（Integrated）」をとってからARMAを適用しよう！」**というのがARIMAモデルです。真ん中の「1」は「1回差分をとった」という意味です。

ここで、反転可能とは、MA過程がAR過程に書き直せることを言い、次の方程式のすべての解の絶対値が1より大きいことと同値です。

$$1 + \theta_1 z + \theta_2 z^2 + \cdots + \theta_q z^q = 0$$

27.7 ディッキーマー・フラー検定

AR(1)モデル $Y_t = \phi Y_{t-1} + U_t$ にしたがう $\{Y_t\}$ について、帰無仮説を $\phi = 1$ ，対立仮説を $|\phi| < 1$ と振る検定。

何これ：このデータ、酔っ払いの千鳥足（ランダムウォーク）じゃないか？を確認するテスト

$\phi = 1$ の状態（単位根を持つ）とは、データが平均に戻ろうとせず、あっちこっちに発散してさまよい続ける「非定常」な状態（ランダムウォーク）を意味します。これを検定で確かめます。

27.8 状態空間モデル

通常は観測できない状態の変化を記述する状態方程式と、その状態から観測値が得られる過程を記述する観測方程式を組み合わせたものです。このモデルは、ARMAモデルを含む様々な時系列データを表現できます。

何これ：「真の姿」は見えないけれど、「観測データ」から推測しよう！というモデル



Tip



たとえば話：自動運転の車の位置推定

- 状態方程式：「本当の車の位置（真の姿）」が時間とともにどう移動するか。
- 観測方程式：「GPSセンサーが示した位置（観測値）」。ここにはセンサーの誤差（観測誤差）が含まれます。

本当の位置は直接見えませんが、過去の移動法則と、誤差まみれのGPSデータから、「本当は今ここにいるはずだ！」と推測（フィルタリング）する強力なモデルです。

27.9 ACFとPACF

弱定常過程では、 h 次の自己相関係数は γ_h/γ_0 と表せますが、これを h の関数と見たものが**自己相関関数（ACF）です。また、 Y_t と Y_{t-h} の h 次の自己相関係数には、その間にある $Y_{t-1}, \dots, Y_{t-h+1}$ の影響が含まれていますが、この影響を取り除いたものが h 次の偏自己相関係数で、これを h の関数と見たものが偏自己相関関数（PACF）**です。

何これ：過去のデータがどれくらい今のデータに影響しているかの「強さ」を測る

- ACF（自己相関関数）：直接的な影響だけでなく、間接的な影響も含めた総合的な影響力。
- PACF（偏自己相関関数）：間の影響を取り除いた、「純粋な直接の影響力」。

AR(p)モデル、MA(q)モデル、ARMA(p,q)モデルのACFとPACFは次のような特徴を持ちます。

モデル	ACF	PACF
AR(p)	h とともに減衰	$p + 1$ 次以降は 0（パツンと切れる）

モデル	ACF	PACF
MA(q)	$q + 1$ 次以降は 0（パツンと切れる）	h とともに減衰
ARMA(p, q)	h とともに減衰	h とともに減衰

なお、（標本）自己相関関数のグラフは**コレログラム**と呼ばれます。

27.10 ダービン・ワトソン検定

時系列データに回帰モデルをあてはめたときに、残差に自己相関（系列相関）が見られる場合があります、そのような系列相関の有無を判定するための検定。

何これ：回帰分析の「残りカス（残差）」に、時間のパターンのクセが残っていないかチェック！

残差（予測の誤差）は本来「完全なランダム（ホワイトノイズ）」であるべきです。しかし、もし残差に「昨日の誤差が今日の誤差に似ている」というクセが残っていたら、モデルが時系列の情報をうまく吸収できていない証拠になります。

誤差項 u_t にAR(1)モデル $u_t = \rho u_{t-1} + U_t$ を仮定し，帰無仮説を $\rho = 0$ とします。検定統計量は，最小2乗法で推定したときの残差を e_t として，次の式で表せます。

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \doteq 2(1 - \hat{\rho})$$

上の式の $\hat{\rho}$ (ρ ハット) は 1 次の自己相関係数の推定値で，この値が 0 に近づけば DW の値は 2 に近くなりますから，** DW の値が 2 から離れて 0 や 4 に近くなるときに帰無仮説を棄却（自己相関ありと判定）**することになります。

27.11 スペクトル密度関数（スペクトラム）

時系列の変動を様々な周期成分によって表し，その特徴を分析します。

何これ：データを「時間軸」ではなく「周波数（波の細かさ）」で分解して見る！

複雑な波の形をしている時系列データを、「ゆっくりした波（低周波・長期的トレンド）」と「細かくギザギザした波（高周波・短期的ノイズ）」に分けて分析するアプローチ（周波数領域の分析）です。

- （例1）AR(1)モデル $Y_t = c + \phi Y_{t-1} + U_t$ （ $-1 < \phi < 1$ ）のスペクトル密度関数は次の $f(\lambda)$ になるので， $\phi > 0$ ならば低周波で大きな値， $\phi < 0$ ならば高周波で大きな値をとり， ϕ の絶対値が大きいほど周波数による違いが顕著になります。

$$f(\lambda) = \frac{\sigma^2}{2\pi} \cdot \frac{1}{1 + \phi^2 - 2\phi \cos \lambda}$$

- （例2）MA(1)モデル $Y_t = c + U_t + \theta U_{t-1}$ のスペクトル密度関数は次の $f(\lambda)$ になるので， $\theta > 0$ ならば低周波で大きな値， $\theta < 0$ ならば高周波で大きな値をとり， θ の絶対値が大きいほど周波数による違いが顕著になります。

$$f(\lambda) = \frac{\sigma^2}{2\pi} (1 + \theta^2 + 2\theta \cos \lambda)$$

真のスペクトラムを推定するために標本から求められる推定値を与えるのが**ペリオドグラム**です。

第28章 分割表

a 個のカテゴリーマをもつ変数 X と b 個のカテゴリーマをもつ変数 Y の ab 通りのカテゴリーマの組み合わせについて、カウントされたデータを表にまとめたものが $a \times b$ 分割表です。このとき、変数を**因子**、各カテゴリーマを**水準**と呼び、2因子の分割表を2元分割表と言います。因子の数が3, 4, ...ならば、3元分割表、4元分割表、...と言います。

何これ：要するに「クロス集計表」のこと！

「男性/女性」×「賛成/反対」のように、カテゴリーマごとの人数を数え上げた表です。

28.1 相対リスク

例えば、ある疾患の発症率を、喫煙群と非喫煙群で比べる場合、発症率の差ではなく、発症率の比をとることがあり、これを**相対リスク**と言います。例えば、喫煙群の発症率が0.15、非喫煙群の発症率が0.03ならば、相対リスクは、 $0.15 \div 0.03 = 5$

疫学の研究デザイン（28.2 ～ 28.5）

データを集めるときの「時間の向き（未来に向かって追跡するか、過去を振り返るか）」による分類です。試験でもよく対比して問われます。

28.2 前向き研究

研究開始以降に被験者の状態の変化を記録する研究。

28.3 後向き研究

研究開始以前のデータをもとに行う研究。

28.4 コホート研究

特定の集団（コホート）を追跡し、処置とアウトカム（病気など）の関連を調べる研究。（※通常は前向き研究）

28.5 ケースコントロール研究（患者対照研究）

特定のアウトカムをもつ被験者ともたない被験者を比較し、過去のリスク要因を調べる研究。（※通常は後向き研究）

 Tip

 **コホート vs ケースコントロール**

- ・ **コホート研究**：「健康な人」をたくさん集めて、「タバコを吸う人・吸わない人」に分け、**未来に向かって数年間追跡**し、どちらがガンになりやすいかを見る。（時間とコストがかかるが、精度は高い）
- ・ **ケースコントロール研究**：「すでにガンになった人（ケース）」と「健康な人（コントロール）」を集めてきて、**過去を振り返って**「昔タバコ吸ってましたか？」と尋ねる。（安くて早いですが、記憶違いなどのバイアスが入りやすい）

オッズとオッズ比（28.6 ～ 28.9）

28.6 オッズ

失敗の確率に対する成功の確率の比。例えば、ある疾患から5年以内に回復する確率が0.8ならば、回復しない確率は0.2なので、オッズは、 $0.8 \div 0.2 = 4$

何これ：「起きない確率」に対して「起きる確率」が何倍か？

競馬の「オッズ」と同じ語源です。確率 p を使って $\frac{p}{1-p}$ で計算します。

28.7 オッズ比

オッズの比。例えば、疾患Aから5年以内に回復するオッズが6、疾患Bから5年以内に回復するオッズが2ならば、オッズ比は、 $6 \div 2 = 3$

ここで、次の2元分割表を考えます。ある手術を受けた患者が退院までにかかった日数が10日以上かどうかを年齢別に集計したものです。

表1

	10日未満	10日以上	合計
65歳未満	5	1	6
65歳以上	4	8	12

	10日未満	10日以上	合計
合計	9	9	18

28.8 標本オッズ

分割表の度数から求められる母オッズの推定値。例えば、上の表1で、年齢別に10日未満で退院した人数を10日以上で退院した人数でわった値が標本オッズであり、65歳未満なら、 $5 \div 1 = 5$ ，65歳以上なら、 $4 \div 8 = 0.5$ となります。

28.9 標本オッズ比

標本オッズの比であり、母オッズ比の推定値。例えば、上の表1で標本オッズ比は、 $5 \div 0.5 = 10$ となります。また、標本オッズ比の対数の標準誤差はサンプルサイズが大きければ簡単な式で近似できます。

$$\sqrt{\frac{1}{5} + \frac{1}{1} + \frac{1}{4} + \frac{1}{8}} \approx 1.255$$

28.10 フィッシャーの正確検定

2元分割表で、2つの変数が独立であるかどうかをP値を直接計算することによって検定する手法。

何これ：データが少なすぎる時の救世主！「全パターンの確率をガチで計算する」検定

サンプルサイズが小さいと、後述のカイ2乗検定（近似を使う検定）が不正確になってしまいます。そこで、「表の周辺（合計人数）が固定された状態で、この表の数字の並びになる確率」を、組み合わせの計算（超幾何分布）を使って直接算出するゴリ押し手法です。

「年齢と退院までの日数が独立＝オッズ比が1」という帰無仮説を仮定し、「65歳未満のほうが10日未満の退院が多い＝オッズ比が1より大きい」に対立仮説とすると、実際に観測された表1以上に極端な結果となる場合として、次の表3が考えられます。

表3

	10日未満	10日以上	合計
65歳未満	6	0	6
65歳以上	3	9	12
合計	9	9	18

各行の合計と各列の合計を固定した上で、独立なのに偶然に表1の度数になる確率と偶然に表3の度数になる確率は次のように計算できます。

$$\frac{{}_6C_5 \times {}_{12}C_4}{{}_{18}C_9} + \frac{{}_6C_6 \times {}_{12}C_3}{{}_{18}C_9} = \frac{29}{442}$$

片側P値は約0.0656なので、有意水準を5%とすれば有意ではありません。つまり、年齢と退院までの日数が独立なのに、度数がたまたま表1のようになったという可能性を否定できないことになります。

28.11 独立性の検定（カイ2乗検定）

フィッシャーの正確検定と同じように、2元分割表の2つの変数が独立であるかどうかを検定する手法として、分割表の度数が十分に大きい場合にカイ2乗分布を用いる手法があります。

検定統計量は次の式で計算できます。（※「観測値」と「期待値」のズレを計算しています）

$$\sum_{i=1}^a \sum_{j=1}^b \frac{\left(n_{ij} - \frac{n_{i \cdot} \cdot n_{\cdot j}}{n}\right)^2}{\frac{n_{i \cdot} \cdot n_{\cdot j}}{n}}$$

n が大きいとき、この検定統計量は、「2つの変数が独立」という帰無仮説のもとで近似的に自由度 $(a - 1)(b - 1)$ のカイ2乗分布にしたがうことを利用して検定します。

この 2×2 分割表における検定統計量に第12章で紹介した**イエーツの補正**を施すと、 $a + b + c + d = n$ として、次の式になります。

$$\frac{n(|ad - bc| - 0.5n)^2}{(a + b)(c + d)(a + c)(b + d)}$$

Warning

サンプルサイズが大きすぎるときの罠

独立性の検定は、サンプルサイズ（人数）を増やすだけで、実用上はどうでもいいような小さな差でも「有意（関係がある!）」と判定されやすくなります。

そこで、分割表のすべての度数を r 倍しても変化しない指標として、次のような**クラメールの連関係数 V** を用いることがあります。

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

クラメールの連関係数 V は 0 以上 1 以下の値をとり、1 に近いほど 2 元分割表の 2 つの変数に関連があることを示唆します。（※検定ではなく、「関連の強さ」を表す指標です）

28.12 逸脱度

特定の統計モデルの分割表のデータへのあてはまりを判断するための統計量。 $a \times b$ 分割表において、フルモデルのもとでの尤度といくつかのパラメータを 0 とおいたモデルのもとでの尤度の比を λ 、 i 行 j 列の観測度数を x_{ij} 、モデルのもとでの期待度数を m_{ij} として、逸脱度は次の式で表せます。

$$2 \log \lambda = 2 \sum_{i=1}^a \sum_{j=1}^b x_{ij} \log \frac{x_{ij}}{m_{ij}}$$

28.13 対数線形モデル

分割表の因子間の独立性や条件付き独立性を解析するために使われるモデル。

何これ：複雑な確率の「かけ算」を、対数（log）をとって「足し算」の式にする！

例えば、3元分割表におけるフルモデルは、3因子 $A_i B_j C_k$ に属する同時確率を p_{ijk} として、次の式の右辺のように、主効果項 $\alpha_i, \beta_j, \gamma_k$ ，交互作用項 $(\alpha\beta)_{ij}, (\alpha\gamma)_{ik}, (\beta\gamma)_{jk}, (\alpha\beta\gamma)_{ijk}$ を用いて表せます。

$$\log p_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk}$$


交互作用項がある場合、それに含まれる低次の交互作用項と主効果項をすべて含むものを**階層的対数線形モデル**と言います。また、主効果項からはじめて、より高次の交互作用項をたどることで、極大項が見つけれられます。これを**生成集合**と言います。

3因子の階層的対数線形モデルのうち、フルモデル以外は大きく分けて次の3通りに分類できます。

モデル	記号	生成集合
完全独立モデル	$A \perp B \perp C$	A/B/C
周辺独立モデル	$A \perp (B, C)$	A/BC
条件付き独立モデル	$A \perp B \mid C$	AC/BC

28.14 無向独立グラフ

因子を頂点に対応させて、モデルに2因子交互作用が含まれている2頂点の間に辺をひいたグラフ。例えば、3元分割表におけるフルモデルに対応する無向独立グラフは次の図のようになります。



28.15 グラフィカルモデル

与えられた無向独立グラフのクリーク（極大な完全部分グラフをなす頂点集合）が生成集合となる階層的対数線形モデル。無向独立グラフに対して、ただ1つ定まります。

28.16 分解可能モデル

対応する無向独立グラフが長さ4以上の弦のない閉路を持たないグラフィカルモデル。このモデルのもとでは、分割表の周辺度数を使って、特定の水準組み合わせの同時確率や期待度数が計算できます。

第29章 不完全データの統計処理

欠測（データの一部が観測されない）の例として、次のような場合などが考えられます。

何これ：アンケートの未記入や実験脱落など「穴抜けデータ」をどう扱うか？

現実のデータ解析では、完璧に全員分のデータが揃うことは稀です。欠測があるデータをそのまま捨てたり、安易に埋めたりすると誤った結論（バイアス）を導いてしまうため、欠測の「発生理由」に応じた適切な対処が求められます。

29.1 打ち切り（Censoring） vs 29.2 トランケーション（Truncation）

 Tip

 違いを理解するカギ：「存在（件数）すら分からないかどうか」

29.1 打ち切り（Censoring）

あらかじめ期間が決められている製品の寿命検査のように、ある値以上（または以下）であることはわかるが、その値自体は得られないタイプの欠測。

- 例：「5年間の臨床試験が終わった時点でまだ生存している患者」→ 5年以上生きたこと（および人数）は分かるが、正確に何年何ヶ月生きたかは分からない。

29.2 トランケーション（Truncation）

特定の幅の値しか観測できず、この幅に入っていないデータの個数もわからないタイプの欠測。

- 例：「標高1,000m以上に生息する高山植物の調査」→ 1,000m未満に何株存在したのか、個体数すら全く分からない。

欠測メカニズム（MCAR, MAR, MNAR）

試験・実務で最も頻出する「欠測の発生理由」の3分類です。

欠測メカニズム	内容	たとえば（体重アンケートの欠測）
MCAR (Missing Completely at Random)	すべての欠測は完全にランダムに生じる	アンケート用紙をうっかり破いてしまい、誰のデータか分からなくなった（完全に無関係）
MAR (Missing at Random)	欠測は完全にランダムではないが、観測されている変数によって説明できる	男性より女性の方が「体重」を空欄にしがちだが、「性別」データが残っているので調整可能
MNAR (Missing Not at Random)	欠測は観測されている変数だけでは完全には説明できず、観測されていない変数の影響を受ける	「体重が重い人ほど」体重を隠して空欄にした（欠測した数値そのものが理由）

欠測への対処法（29.3 ～ 29.5）

29.3 CC(complete case)解析

少なくとも1つの変数に欠測が生じた個体を除いた解析。サンプルサイズが小さくなるため、推定精度や検出力が下がり、MCAR以外の場合にはバイアスが生じます。

何これ：一番単純な「欠測がある人は全員削除！」

最も手軽ですが、MCAR（完全ランダム）以外の状況でこれをやると、偏ったデータだけが残ってしまい危険です。

29.4 単一代入法

欠測値に適切な値を埋め込み、擬似的な完全データを作成する方法。代表的なものは次の通り。

手法	内容
平均値代入	観測データの平均値を使う。分散を過小評価することになり、MCAR以外の場合は平均にも偏りが生じる
回帰代入	観測データから求めた回帰モデルによる予測値を使う。MNAR以外ならば平均に偏りは生じないが、分散は過小評価となる
Hot Deck法	同じデータセット内で類似のデータを使う。適切なデータを探すのに手間がかかる

⚠ Warning

⚠ 単一代入法の共通の弱点

「埋めた値」をあたかも「最初から正しく観測されたデータ」として扱うため、データのバラつき（分散や標準誤差）を実際よりも**小さく見積もってしまう（過小評価する）**問題があります。

29.5 多重代入法（Multiple Imputation）

欠測値に適切な値を埋め込んだ複数組の擬似的な完全データを作成し、独立に推定値を計算し、最後にそれらの結果を統合する手法。不確実性をつくり出し、単一代入法で起こりがちな誤差の過小評価を補正します。

何これ：現在の統計学・臨床試験における「大本命」の手法！

「たった1つの値で埋めるから誤差を無視してしまうんだ」と考え、確率的に少しずつ違う値を埋めたデータを**何パターンか（例：5～10個）作成**します。それぞれのデータで分析を行い、最後に結果を合体させることで、「代入による不確実性（誤差）」を正しく反映させます。

29.6 1変量正規分布における推測（EMアルゴリズムのアプローチ）

$X \sim \mathcal{N}(\mu, \sigma^2)$ であり、標準正規分布の確率密度関数を $\varphi(x)$ 、累積分布関数を $\Phi(x)$ 、 $a = (c - \mu)/\sigma$ として、 $X \geq c$ のもとでの X の条件付き期待値は、次のように表せます。

$$E[X \mid c \leq X] = \mu + \frac{\varphi(a)}{1 - \Phi(a)}\sigma$$

c 以上の値が観測されない打ち切りのケースで、母平均 μ が未知、母分散 σ^2 が既知であるとき、上の条件付き期待値を用いて、母平均 μ の最尤推定値を求める手順は、サンプルサイズを n 、観測されたデータのサイズを m ($m < n$) として、次の①～④です。

- ① $\mu^{(0)}$ を観測されたサイズ m のデータの平均とする
- ② $t = 0, 1, 2, \dots$ に対し、 $\mu^{(t)}$ をもとに次の式で $a^{(t)}$ を計算

$$a^{(t)} = \frac{c - \mu^{(t)}}{\sigma}$$

- ③ $a^{(t)}, \mu^{(t)}$ をもとに $\mu^{(t+1)}$ を次の式で計算

$$\mu^{(t+1)} = \frac{1}{n} \left[\sum_{i=1}^m x_i + (n - m) \left(\mu^{(t)} + \frac{\varphi(a^{(t)})}{1 - \Phi(a^{(t)})}\sigma \right) \right]$$

- ④ $\mu^{(t)}$ が収束するまで②と③をくり返す

同じ設定でトランケーションの場合、母平均 μ の最尤推定値は次の①～④の手順で求めます。

- ① $\mu^{(0)}$ を観測されたサイズ m のデータの平均とする
- ② $t = 0, 1, 2, \dots$ に対し、 $\mu^{(t)}$ をもとに次の式で $a^{(t)}$ を計算

$$a^{(t)} = \frac{c - \mu^{(t)}}{\sigma}$$

- ③ $a^{(t)}$ をもとに次の式で $\mu^{(t+1)}$ を計算

$$\mu^{(t+1)} = \bar{x} + \frac{\varphi(a^{(t)})}{\Phi(a^{(t)})}\sigma$$

- ④ $\mu^{(t)}$ が収束するまで②と③をくり返す

29.7 2変量正規分布における推測（MARにおける最尤推定）

$(X, Y)^\top$ が次の2変量正規分布にしたがうものとしします。

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix} \right)$$

欠測は Y のみに生じて、観測されたデータを $(x_1, y_1), \dots, (x_m, y_m), x_{m+1}, \dots, x_n$ ($m < n$) とし、欠測メカニズムが MAR だとするとき、パラメータの推定値は次の手順で求めます。

何これ：Xの情報（完全データ）を使って、Yの欠測の影響を打ち消す！

Yだけに欠測がある場合、XとYの関係（回帰モデル）を利用して、X全体の平均 $\hat{\mu}_X$ からY全体の平均 $\hat{\mu}_Y$ や分散を正しく推測する手順です。

- ① μ_X, σ_X^2 の最尤推定値をサイズ n のデータを使って、次の式で計算

$$\hat{\mu}_X = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_X)^2$$

② サイズ m のデータ（ Y も揃っているデータ）を使って、 $\bar{x}, S_X^2, \bar{y}, S_Y^2, S_{XY}$ を計算

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \quad S_X^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2$$

$$\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i, \quad S_Y^2 = \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2$$

$$S_{XY} = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})$$

③ ②で求めた統計量をもとに、 X を与えたもとの Y の条件付き分布を $\mathcal{N}(\alpha + \beta x, \tau^2)$ と表したときの α, β, τ^2 を計算

④ α, β, τ^2 を使って、次の式で $\mu_Y, \sigma_Y^2, \sigma_{XY}$ の最尤推定値を計算

$$\hat{\mu}_Y = \alpha + \beta \hat{\mu}_X$$

$$\hat{\sigma}_Y^2 = \tau^2 + \beta^2 \hat{\sigma}_X^2$$

$$\hat{\sigma}_{XY} = \beta \hat{\sigma}_X^2$$

なお、MCARの場合には、単純に観測されている $(x_1, y_1), \dots, (x_m, y_m)$ のみを用いてMARの②のように計算するだけでよく、 $x_{m+1}, \dots, x_n$ から $y = \alpha + \beta x$ によって求めた y の値を使うことも X と Y に相関がある場合には効果的です。

第30章 モデル選択

- **AIC (赤池情報量規準)** ... $-2 \times (\text{最大対数尤度}) + 2 \times (\text{推定するパラメータ数})$
- **BIC (バイズ情報量規準)** ... $-2 \times (\text{最大対数尤度}) + \log(n) \times (\text{推定するパラメータ数})$

どちらの情報量規準も、候補となる統計モデルの中から、**相対的に数値が小さいものを最適なモデルとして選びます**。

何これ：モデルの「コスパ」を測るスコア！

複雑なモデル（パラメータ数が多い）を使えば、手元のデータへの「当てはまり（最大対数尤度）」はいくらでも良くできますが、未知のデータには弱くなります（過学習）。
そこで、**「当てはまりの良さ（マイナスにして小さくする）」と「モデルの複雑さへの罰則（ペナルティとして足し算）」**の合計を計算し、最もバランスの取れた（スコアが小さい）モデルを選びます。

重回帰モデルにおけるAICとBIC

例えば、説明変数が p 個の次の重回帰モデルを考え、サンプルサイズを n とし、誤差項が独立に同一の正規分布にしたがうことを仮定します。

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

上の重回帰モデルに対して、誤差分散の最尤推定量を $\hat{\sigma}^2$ (σ ハット2乗) として、AICは次のように表せます。

$$n \log(2\pi\hat{\sigma}^2) + n + 2(p + 2)$$

ここで、推定するパラメータ数は、説明変数の数 + 切片 + 誤差分散 = $p + 2$ であることに注意します。

上の重回帰モデルに対するBICは、AICの第3項の先頭の2を $\log(n)$ でおきかえて、次のようになります。

$$n \log(2\pi\hat{\sigma}^2) + n + (p + 2) \log n$$



Tip

💡 AICとBICの選び方の違い

$\log(n) > 2$ を満たすサンプルサイズ ($n \geq 8$ 程度) である場合がほとんどなので、**BICのほうがAICよりモデルのパラメータ数に対する罰則が強く、よりパラメータ数の少ないシンプルなモデルを選ぶ傾向**があります。

また、BICには**モデル選択の一致性**があり、候補となる統計モデルの中に真のモデルがあるとき、 $n \rightarrow \infty$ （サンプルサイズを無限大に）で真のモデルを選ぶ確率が1に収束します。（※AICには一致性はありませんが、予測精度を最適化する目的でよく使われます）

交差検証法（クロスバリデーション）

データを使ってモデルを作るだけでなく、「作ったモデルが未知のデータにどれくらい通用するか（汎化性能）」を評価する手法です。

30.1 交差検証法（クロスバリデーション）

データを訓練用とテスト用に分け、訓練用データによるパラメータの推定とテスト用データによる予測誤差の検証をくり返し、予測誤差が最小となるモデルを見つけ出す方法。

何これ：「カンニング」を防ぐためのテスト！

手元のデータを全部使ってモデルを作り、その同じデータでテストをすると、必ず良い点数が出てしまいます。これを防ぐため、「学習に使うデータ」と「テストに使うデータ」をきっちり分けるのが基本です。

30.2 Leave-one-out法 (LOOCV)

サンプルサイズを n として、次の手順でモデルを選択する交差検証法。

- ① i 番目のデータを取り除き、それ以外の $n - 1$ 個を訓練用としてモデルを推定する
- ② 推定したモデルを用いて、 i 番目のデータに対する予測誤差を求める
- ③ すべての i ($i = 1, 2, \dots, n$) についての予測誤差の平均によってモデルを評価する

何これ：たった1個だけテストに回すのを、全員分やる！

手持ちのデータが少ない時に有効です。ただし、データが1万件あれば1万回モデルを作らないといけないため、計算時間が膨大になるのが弱点です。

30.3 k分割交差検証法 (k-fold CV)

データをほぼ同じサイズの k 個のグループに分割して、そのうちの1個のグループをテスト用、それ以外の $k - 1$ 個のグループを訓練用とし、予測誤差を k 回求めることをくり返す交差検証法。

（※ $k = n$ の場合が Leave-one-out 法になります。）

何これ：実務で一番よく使われる手法！

たとえば $k = 5$ （5分割）なら、データを5つのグループに分け、「4つで学習・残り1つでテスト」を5パターン繰り返します。計算量と精度のバランスが良く、機械学習の標準的な評価方法です。

第31章 ベイズ法

ベイズ法では、確率分布のパラメータ自体が確率分布にしたがうことを仮定し、このパラメータについて、データを得る前の分布を得られたデータ情報を反映した分布に更新する仕組みがベイズ法です。

何これ：データを得るたびに「予想（確率分布）」をアップデートしていく手法！

- 頻度論（従来の統計学）：「真のパラメータ（母平均など）は世の中に1つだけ固定で存在する」と考えます。
- ベイズ統計：「パラメータ自体も確からしさの分布（確率分布）を持つ」と考えます。
データを得る前の予想を**事前分布**、データを得た後の更新された予想を**事後分布**と呼びます。

事後分布 ∝ 尤度（データの情報） × 事前分布

31.1 共役事前分布

事前分布と事後分布が同じタイプの確率分布になるような事前分布。次の表の 3 種類は覚えておきましょう。

何これ：計算をめちゃくちゃ楽にするための「相性の良い組み合わせ」！

事後分布を手計算で求めるのは通常非常に大変ですが、この特定の組み合わせを使うと、計算式に数値を当てはめるだけで簡単に事後分布が求まります。

事前分布	標本分布（データ）	事後分布
ベータ分布	二項分布	ベータ分布
ガンマ分布	ポアソン分布	ガンマ分布
正規分布	正規分布（平均未知・母分散既知）	正規分布

代表的なモデル（31.2 ～ 31.4）

31.2 ベータ二項モデル

標本分布が $Y \mid \theta \sim \text{Bin}(n, \theta)$ のとき、 θ の事前分布としてベータ分布 $\text{Be}(a, b)$ を採用するモデル。 n 回の試行のうち成功が y 回だとすると、事後分布は $\text{Be}(a + y, b + n - y)$ に更新されます。

31.3 ガンマポアソンモデル

標本分布が $Y_1, \dots, Y_n \mid \theta \sim \text{Po}(\theta)$ のとき、 θ の事前分布としてガンマ分布 $\text{Ga}(a, 1/b)$ を採用するモデル。実現値を $y_1, \dots, y_n$ とすると、事後分布は次のように更新されます。

$$\text{Ga}\left(a + \sum_{i=1}^n y_i, \frac{1}{b + n}\right)$$

31.4 正規-正規モデル

標本分布が $Y_1, \dots, Y_n \mid \theta \sim \mathcal{N}(\theta, \sigma^2)$ のとき、 θ の事前分布として正規分布 $\mathcal{N}(\mu_0, \sigma_0^2)$ を採用するモデル。実現値を $y_1, \dots, y_n$ とすると、事後分布は次のように更新されます。

$$\mathcal{N}\left(\frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2}\bar{y} + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2}\mu_0, \frac{\sigma_0^2\sigma^2}{n\sigma_0^2 + \sigma^2}\right)$$

 Tip

 **正規-正規モデルの事後平均の意味**

事後分布の平均（第一成分）を見ると、**「データの平均 $\bar{y}$ 」と「事前に持っていた予想 μ_0 」の加重平均（内分）**になっていることがわかります。サンプルサイズ n が大きくなるほどデータの重みが増し、事後平均は標本平均 $\bar{y}$ に近づきます。

事後分布からの要約（31.5 ～ 31.8）

31.5 ベイズ推定値（EAP推定量）

事後分布の期待値（平均値）。

- ガンマ分布 $\text{Ga}(a, b)$ の期待値は ab
- ベータ分布 $\text{Be}(a, b)$ の期待値は $\frac{a}{a + b}$

31.6 MAP推定量（最大事後確率推定量）

事後分布のモード（確率密度が最も高くなる確率変数の値／グラフの頂点）。

- ガンマ分布 $\text{Ga}(a, b)$ のモードは $a > 1$ のとき $(a - 1)b$
- ベータ分布 $\text{Be}(a, b)$ のモードは $a > 1, b > 1$ のとき $\frac{a - 1}{a + b - 2}$

31.7 ベイズ予測分布

事後分布を用いて、新たなデータを予測する確率分布。

31.8 100(1-α)%信用区間

母数の事後分布の積分値が $1 - \alpha$ になるような区間。

（例）95%最大事後密度(HPD)区間は、事後密度の高い順に確率を集めていき、面積の合計が 0.95 になるような $[L(\boldsymbol{x}), U(\boldsymbol{x})]$ です。

 Tip

 95%「信頼」区間 vs 95%「信用」区間

- 95%信頼区間（頻度論）**：「同じ実験を100回繰り返したとき、作成した区間のうち95回は真のパラメータを含む」という意味。（区間の方が動く）
- 95%信用区間（ベイズ）**：「パラメータ自体が 95% の確率でこの区間内に存在する」という意味。（直感的に理解しやすい！）

MCMC法（マルコフ鎖モンテカルロ法）（31.9 ～ 31.12）

何これ：計算できない複雑な事後分布を、コンピュータに大量の乱数を引かせて再現する裏技！

共役事前分布が使えない複雑なモデルでは、事後分布の式を手計算で解くことができません。そこで「事後分布に従う乱数」を何万回も発生させ、その集計結果で事後分布をシミュレーションします。

31.9 MCMC法

事前分布が共役事前分布以外のときには事後分布の計算が困難になることが多いため、その代わりに事後分布からの多数の独立なサンプルを得ることで事後分布を近似する手法。

パラメータベクトルを $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)$ とし、 $\boldsymbol{\theta}^{(0)} \rightarrow \boldsymbol{\theta}^{(1)} \rightarrow \dots$ のように、あるルールでパラメータの更新をくり返すと、十分な回数の更新後には事後分布 $\pi(\boldsymbol{\theta} \mid \boldsymbol{x})$ からのサンプルを得ることができます。

31.10 メトロポリス法

次の①～④の手順で事後分布 $\pi(\boldsymbol{\theta} \mid \boldsymbol{x})$ からのサンプルを得る手法。

- 初期値 $\boldsymbol{\theta}^{(0)}$ を決め、 $t = 0$ として②へ進む
- $\boldsymbol{\theta}' = \boldsymbol{\theta}^{(t)} + \boldsymbol{u}$ ($\boldsymbol{u}$ の各成分は独立に正規分布などの対称な分布にしたがう) によって発生させる
- $v \sim U(0, 1)$ を発生させ、次の r を計算する。 $r \geq 1$ のとき $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}'$ として採用し、 $r < 1$ のとき、 $r \geq v$ ならば $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}'$ 、 $r < v$ ならば $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)}$ とする

$$r = \frac{\pi(\boldsymbol{\theta}' \mid \boldsymbol{x})}{\pi(\boldsymbol{\theta}^{(t)} \mid \boldsymbol{x})}$$

- t を $t + 1$ でおきかえ、十分な数のサンプルが得られるまで②と③をくり返す

何これ：「山登り」のようなアルゴリズム！

新しい候補地点 $\boldsymbol{\theta}'$ の方が確率が高い ($r \geq 1$) なら確実にそこへ移動し、確率が低い ($r < 1$) 場合でも、確率に応じた「運（乱数 v ）」次第でたまに移動を許可します。これにより、一番高い山の頂点周辺にサンプルが集まりやすくなります。

31.11 メトロポリス・ヘイスティングス法（MH法）

メトロポリス法の手順②で $\boldsymbol{\theta}'$ を非対称な確率分布 $q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)})$ を用いて発生させ、手順③の r を次の式に取り替えた手法。

$$r = \frac{\pi(\boldsymbol{\theta}' \mid \boldsymbol{x})q(\boldsymbol{\theta}^{(t)} \mid \boldsymbol{\theta}')}{\pi(\boldsymbol{\theta}^{(t)} \mid \boldsymbol{x})q(\boldsymbol{\theta}' \mid \boldsymbol{\theta}^{(t)})}$$

何これ：メトロポリス法の一般化版！

移動候補の提案分布 q が左右非対称でも正しく動作するように、確率の補正項を組み込んだものです。

31.12 ギブスサンプリング

n 変量でもかまいませんが、ここでは 2 変量の例を挙げます。 (X, Y) の同時分布 $f(x, y)$ からの抽出は難しいものの、条件付き分布 $f(x | y), f(y | x)$ からの抽出は可能であるものとして、次の①～④の手順で行います。

① 初期値 $(x^{(0)}, y^{(0)})$ を決める

② $(x^{(j)}, y^{(j)})$ が与えられたとき、 $y^{(j+1)}$ を次のように得ます

$$y^{(j+1)} \sim f(y | x^{(j)})$$

③ $y^{(j+1)}$ から次のように $x^{(j+1)}$ を得ます

$$x^{(j+1)} \sim f(x | y^{(j+1)})$$

④ ②と③をくり返す

何これ：変数を1つずつ順番に更新していく手法！

複数あるパラメータをまとめて動かすのが難しいとき、「他のパラメータを固定した状態での条件付き分布」から1文字ずつ交互にサンプルを更新していく効率的な手法です。

第32章 シミュレーション

32.1 擬似乱数

再現不可能な本来の乱数に対し、計算機によって生成される乱数の解に、一定の条件のもとで再現できてしまう乱数。

何これ：コンピュータが作る「サイコロの目」は実は計算式で作られている！

完全にランダムな数（真の乱数）を作るのは難しいため、コンピュータは複雑な計算式を使って「一見ランダムに見える数列（擬似乱数）」を作ります。初期値（シード値）を同じにすれば、全く同じ乱数の列を再現できるのが特徴です。

乱数の生成法（32.2 ～ 32.3）

32.2 逆関数法

特定の確率分布にしたがう乱数を、その確率分布の累積分布関数の逆関数を使って得る方法。一様分布 $U(0, 1)$ にしたがう乱数を u 、確率変数 X の累積分布関数を $F_X(x)$ として、 $x = F_X^{-1}(u)$ とすれば X の確率分布にしたがう乱数を得ることができます。

何これ：「0から1の乱数」を「欲しい分布の乱数」に変換する魔法！

累積分布関数は必ず 0 から 1 の値をとる性質を利用します。「0から1の一様乱数」を逆関数に放り込むだけで、簡単に目的の分布に従う乱数が生成できます。

32.3 採択・棄却法

特定の確率分布にしたがう乱数を、その確率分布より乱数を発生させやすい確率分布を使って得る方法。確率密度関数 $f(x)$ を持つ分布にしたがう乱数を得たいとき、 $f(x)$ と同じ定義域を持つ関数 $g(x)$ とある定数 R について、すべての x に対して、 $f(x) \leq R \cdot g(x)$ が成り立つとします。ここで、確率密度関数 $g(x)$ を持つ分布にしたがう乱数は容易に得られるものとします。このとき、次の①②の手順で確率密度関数 $f(x)$ を持つ分布にしたがう乱数を得ることができます。

- ① $y \sim g(x)$, $u \sim U(0, 1)$ を独立に生成する
- ② 次の不等式が成立すれば y を出力（採択）し、そうでなければ①に戻る（棄却）

$$u \leq \frac{f(y)}{R \cdot g(y)}$$

乱数を得る効率を上げるには、 R をできるだけ小さくとったほうが良いです。

何これ：作りやすい別の乱数を作って、条件を満たすものだけ「採用」する！

目的の分布 $f(x)$ の乱数を直接作るのが難しい場合に、作りやすい分布 $g(x)$ を「すっぽり覆いかぶせる」ようにして乱数を作り、はみ出た部分は捨てる（棄却する）という手法です。

32.4 モンテカルロ法

正方形領域 $(0, 1) \times (0, 1)$ 内の図形 A の面積 S の近似値を乱数を使って求めるには、一様分布 $U(0, 1)$ にしたがう乱数 (u, v) を n 組発生させて、そのうち A 内に入ったものの個数が X 組ならば、 $S \approx X/n$ と推定できます。 $X \sim \text{Bin}(n, S)$ であることから、 $V[X] = nS(1 - S)$ です。

何これ：ランダムに「ダーツ」を投げて、当たった割合から面積を求める！

円周率 π の近似値を求めるときなどによく使われます。

32.5 モンテカルロ積分

積分を直接的に求めることが難しいとき、乱数を発生させて近似的に積分値を求める方法。

$[a, b]$ 上で定義された確率密度関数 $f(x)$ を持つ分布からの乱数が容易に得られるならば、 $X_1, \dots, X_n \sim f(x)$ として、 $g(X_1), \dots, g(X_n)$ の平均を計算すれば、次の積分の近似値を求めることができます。

$$E[g(X)] = \int_a^b g(x)f(x)dx$$

この積分値を θ とおき、推定量とその分散、標準誤差は次のように表せます。

- 推定量: $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n g(X_i)$
- 標準誤差: $\frac{1}{n} \left(\sum_{i=1}^n \{g(X_i) - \hat{\theta}\}^2 \right)^{\frac{1}{2}}$

モンテカルロ積分の精度を向上させる方法にはいくつかあり、そのうちの**「主部の分離」と「負の相関の利用」**について、次の積分値 $I = \int_a^b f(x)dx$ の推定量を求める手順は下のようになります。

- 【主部の分離による手順】
- ① $f(x)$ を近似し、積分しやすい関数 $h(x)$ をテーラー展開などを利用して決める

- ② $g(x) = f(x) - h(x) + \mu$ とおく。ここで、 μ は $\mu = \frac{1}{b-a} \int_a^b h(x) dx$ で定める
- ③ 無作為標本を $X_1, \dots, X_n \sim U(a, b)$ として、 I の推定量を $\hat{I} = \frac{b-a}{n} \sum_{i=1}^n g(X_i)$ とおく

【負の相関を利用する場合の手順】

- ① $g(x) = \frac{f(x)+f(a+b-x)}{2}$ と定める
- ② 無作為標本を $X_1, \dots, X_m \sim U(a, b)$ として、 I の推定量を $\hat{I} = \frac{b-a}{m} \sum_{i=1}^m g(X_i)$ とおく

リサンプリング手法（32.6 ～ 32.8）

「手元にある限られたデータ」を再利用（リサンプリング）して、推定値のばらつき（標準誤差）を評価する超強力な手法です。

32.6 経験分布関数

分布関数が $F(x)$ である確率分布からの無作為標本を $X_1, \dots, X_n$ とするとき、サイズ n の標本のうち x 以下であるものの個数を n でわった値を x の関数とみたもののこと。経験分布関数 $F_n(x)$ は分布関数 $F(x)$ に確率収束します。（※階段状のグラフになります）

32.7 ジャックナイフ法

母集団分布のパラメータを θ とし、無作為標本 $X_1, \dots, X_n$ から構成した θ の推定量を $\hat{\theta}$ とします。 $j = 1, 2, \dots, n$ とし、 X_j を除いたサイズ $n - 1$ の標本によって $\hat{\theta}$ と同様に構成した推定量 $\hat{\theta}_{(j)}$ の平均を次のように置きます。

$$\bar{\theta}_{(\cdot)} = \frac{1}{n} \sum_{j=1}^n \hat{\theta}_{(j)}$$

このとき、 $\hat{\theta}$ の標準誤差のジャックナイフ推定量は次のように表せます。

$$\sqrt{\frac{n-1}{n} \sum_{j=1}^n (\hat{\theta}_{(j)} - \bar{\theta}_{(\cdot)})^2}$$

何これ：「1個だけ仲間外れ」にしたデータセットを全員分作る！

「Aさんを抜いたデータで計算」「Bさんを抜いたデータで計算」...と n 回繰り返し、その計算結果がどれくらいブレるかを見ることで、元の推定量のばらつきを測ります。

32.8 ブートストラップ法

互いに独立に同一の確率分布 F にしたがう確率変数 $X_1, \dots, X_n$ の実現値を $x_1, \dots, x_n$ とし、 F に関するパラメータ θ を推定量 $\hat{\theta}$ によって推定することを考えます。

$\{x_1, \dots, x_n\}$ から復元抽出によって得られたサイズ n の標本を $\mathbf{x}^* = \{x_1^*, \dots, x_n^*\}$ とすることを B 回繰り返し、次のような B 個の θ の推定値を求めます。

$$\{\hat{\theta}^*(i) : i = 1, \dots, B\}$$

また、上の B 個の θ の推定値の平均を $\hat{\theta}^*(\cdot) = \frac{1}{B} \sum_{i=1}^B \hat{\theta}^*(i)$ と置きます。

このとき、推定量のバイアスと分散を次のように推定します。

$$b(\hat{F}) \approx \frac{1}{B} \sum_{i=1}^B \hat{\theta}^*(i) - \hat{\theta}$$
$$\sigma^2(\hat{F}) \approx \frac{1}{B-1} \sum_{i=1}^B \{\hat{\theta}^*(i) - \hat{\theta}^*(\cdot)\}^2$$

🔥 Tip

💡 ジャックナイフ法 vs ブートストラップ法

- ジャックナイフ法：「非復元抽出」で、要素を1つだけ除外する。サンプルサイズが n なら必ず n 回だけ計算する。
- ブートストラップ法：「復元抽出（引いたくじを戻す）」で、元のデータと同じサイズの仮想データを何千回も作る。同じデータが重複して選ばれることもあれば、一度も選ばれないデータもある。現代の統計解析ではこちらが圧倒的によく使われます。