

【完全網羅】統計検定®準1級チートシート

統計学

統計検定® 準1級の 全知識

これは革命...



© 2023.12.28 2025.09.14

統計検定®準1級のCBTの出題内容を、ほぼカバーしている唯一の書籍が統計学実践ワークブック（以下、ワークブック）です。以前のCBTでは、ワークブックの例題と同様の出題が多かったのですが、最近はそうでもなくなってきています。とはいえ、準1級の合格を目指すならば、まずこの書籍を購入することからはじめましょう。



統計学実践ワークブック

しかし、ワークブックの解説には難解な表現が見られ、合格には不要な内容も含まれています。そこで、ワークブックの構成を尊重しつつも、本稿では全体をスッキリと読みやすいものに再構成し、次のような工夫を取り入れて、試験前に準1級で必須の知識を短時間で確認できるようにしています。

- 文章や数式は理解しやすいものに書き直した

- オリジナルの例や図を追加して、イメージしやすいようにした
- 試験対策としては明らかに不要と思われる内容はカットした
- ワークブックの正誤表にも載っていない誤りを訂正した
- ワークブックに記載がなくても、PBTで出題実績がある項目など、必要な内容を追加した

なお、説明が詳しい項目とそうでない項目がありますが、統計検定®準1級講座（リンクは[こちら](#)）を利用している人にとって使いやすいように配慮して、説明の仕方を決めています。

また、本稿を執筆する上で、ワークブック以外に参考にした書籍は[こちら](#)にまとめてあります。

※統計検定®は一般財団法人統計質保証推進協会の登録商標です。

第1章 事象と確率

事象Aが起きる確率を $P(A)$ と表します。

・ **包除原理**…事象A, Bについて、AまたはBが起きる（和事象）確率は一般に次の式の右辺のように求められます。

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

上の式の右辺第3項は、AとBがどちらも起きる（積事象）確率を表しています。

事象AとBが**排反**（同時には起きない）ならば、上の式は次のようになります。

$$P(A \cup B) = P(A) + P(B)$$

・ **事象の独立**…事象AとBについて、次の式が成り立つこと。

$$P(A \cap B) = P(A)P(B)$$

・ **条件付き確率**…Aが起きたもとでBが起きる確率を次の式の右辺で定義します。

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

上の式の両辺に $P(A)$ をかけると、次の式が成り立ちます。（AとBが独立の場合との違いに注意）

$$P(A \cap B) = P(B|A) \times P(A)$$

事象AとBが同時に起こる確率について、 $P(B|A) \times P(A) = P(A|B) \times P(B)$ が成り立つことから、両辺を $P(B)$ でわって次の式が得られます。

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

$$= \frac{P(B|A) \times P(A)}{P(B|A) \times P(A) + P(B|A^c) \times P(A^c)}$$

上の式は**ベイズの定理**と呼ばれ、2行目の分母では、 $P(B)$ をAが起きたもとでBが起きる場合とAが起きなかったもとでBが起きる場合に分けています。ここで、 A^c はAの**余事象**（A以外のすべて）を表しています。例えば、ある病気に罹患している確率を $P(A)$ とすると、罹患していない確率が $P(A^c)$ です。このとき、 $P(B)$ を検査で陽性となる確率とすると、 $P(A|B)$ は陽性であったときにこの病気に罹患している確率であり、 $P(A)$ は**事前確率**、 $P(A|B)$ は陽性という情報を得た上での条件付き確率ということで**事後確率**と呼ばれます。

・ **条件付き独立**…事象A, B, Cについて、Cを与えたもとでAとBが条件付き独立であるとは、次の式が成り立つこと。

$$P(A \cap B|C) = P(A|C)P(B|C)$$

・ **確率変数**…事象に対して実数を対応させる関数。

確率変数には離散型と連続型がありましたね（2級講座参照）。

・ **確率関数**…離散型確率変数Xがとりうるすべての値について、次の2つの式を満たすような関数 $p(x)$ のこと。

$$p(x) \geq 0, \sum_x p(x) = 1$$

・ **確率密度関数**…連続型確率変数Xの定義域全体について、次の2つの式を満たすような関数 $f(x)$ のこと。

$$f(x) \geq 0, \int_{-\infty}^{\infty} f(x)dx = 1$$

・ **期待値（平均）**…確率変数がとりうる値の起きやすさを加味した平均。

離散型確率変数Xの確率関数を $p(x)$ とすると、Xの期待値はかつこ内の条件のもとで次の式で定めます。

$$E[X] = \sum_x xp(x) \left(\sum_x |x|p(x) < \infty \right)$$

より一般に、離散型確率変数Xの関数 $g(X)$ の期待値は、かつこ内の条件のもとで次の式で定めます。

$$E[g(X)] = \sum_x g(x)p(x) \quad \left(\sum_x |g(x)|p(x) < \infty \right)$$

連続型確率変数 X の確率密度関数を $f(x)$ とすると、 X の期待値は、かっこ内の条件のもとで次の式で定めます。

$$E[X] = \int_{-\infty}^{\infty} xf(x)dx \quad \left(\int_{-\infty}^{\infty} |x|f(x)dx < \infty \right)$$

より一般に、連続型確率変数 X の関数 $g(X)$ の期待値は、かっこ内の条件のもとで次の式で定めます。

$$E[g(X)] = \int_{-\infty}^{\infty} g(x)f(x)dx \quad \left(\int_{-\infty}^{\infty} |g(x)|f(x)dx < \infty \right)$$

確率変数 X , Y が離散型の場合でも連続型の場合でも、 a , b , c を定数として、期待値について次の式が成り立ちます。

$$E[aX + bY + c] = aE[X] + bE[Y] + c$$

・ **分散**…確率変数がとりうる値の期待値からのばらつき具合の平均。

離散型確率変数 X の確率関数を $p(x)$, $E[X]=\mu$ とすると、 X の分散はかっこ内の条件のもとで次の式で定めます。

$$\begin{aligned} V[X] &= E[(X - \mu)^2] \\ &= \sum_x (x - \mu)^2 p(x) \quad (E[X^2] < \infty) \end{aligned}$$

連続型確率変数 X の確率密度関数を $f(x)$, $E[X]=\mu$ とすると、 X の分散は、かっこ内の条件のもとで次の式で定めます。

$$\begin{aligned} V[X] &= E[(X - \mu)^2] \\ &= \int_{-\infty}^{\infty} (x - \mu)^2 f(x)dx \quad (E[X^2] < \infty) \end{aligned}$$

確率変数 X が離散型の場合でも連続型の場合でも、 a , b を定数として、分散について次の式が成り立ちます。

$$V[aX + b] = a^2 V[X]$$
$$V[X] = E[X^2] - (E[X])^2$$

分散の正の平方根を**標準偏差**と言います。

第2章 確率分布と母関数

・ **累積分布関数**…確率変数 X に対し、 $F(x) = P(X \leq x)$ のこと。非減少関数で、分布関数とも言います。 X が連続型確率変数で、その累積分布関数が微分可能で、その確率密度関数が連続である場合、累積分布関数を微分すると確率密度関数が得られます。

※生存関数、ハザード関数は第19章を参照

・ **同時累積分布関数**…確率変数 X, Y に対し、 $F(x, y) = P(X \leq x, Y \leq y)$ のこと。

・ **同時確率関数**…離散型確率変数 X, Y に対し、 $p(x, y) = P(X=x, Y=y)$ のこと。次の式のように、同時確率関数を1つの確率変数のとりうるすべての値についてたし上げたものを**周辺確率関数**と言います。

$$p_X(x) = \sum_y p(x, y)$$

・ **条件付き確率関数**… X の周辺確率関数 $p_X(x) \neq 0$ となる x に対して、同時確率関数を $p_X(x)$ でわった次の関数を、 X を与えたときの Y の条件付き確率関数と言います。 Y を与えたときの X の条件付き確率関数も同様。

$$p_{Y|X}(y|x) = \frac{p(x, y)}{p_X(x)}$$

・ **同時確率密度関数**…連続型確率変数 X, Y の同時累積分布関数 $F(x, y)$ が2回連続微分可能であるとき、次の式を満たす $f(x, y)$ のこと。

$$f(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y)$$

$f(x, y)$ はつねに0以上の値をとり、全体で積分すれば1になります。

また、次の式は、 X と Y の同時確率密度関数を y について積分したものであり、 X の**周辺確率密度関数**と言います。

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$$

・ **条件付き確率密度関数**…Xの周辺確率密度関数 $f_X(x) \neq 0$ となるxに対して、同時確率密度関数を $f_{X,Y}(x,y)$ でわった次の関数を、Xを与えたときのYの条件付き確率密度関数と言います。Yを与えたときのXの条件付き確率密度関数も同様。

$$f_{Y|X}(y|x) = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

・ **条件付き期待値**…Xを与えたときのYの条件付き期待値は、次の式のように条件付き確率密度関数を使って定めます。

$$E[Y|X=x] = \int_{-\infty}^{\infty} y f_{Y|X}(y|x) dy$$

離散型の確率変数に対しても、条件付き確率関数を使って、同じように条件付き期待値を定めることができます。

条件付き期待値については、くり返しの法則と呼ばれる次の式が成り立ちます。

$$E[E(X|Y)] = E[X]$$

※条件付き分散は出題されないと考えられるので省略。

・ **確率変数の独立**…次のようにXとYの同時確率(密度)関数がXの周辺確率(密度)関数とYの周辺確率(密度)関数の積に一致すること。

$$f_{X,Y}(x,y) = f_X(x)f_Y(y)$$

・ **条件付き独立**…Zを与えたときのX, Yの条件付き確率密度関数が、次の式のように、Zを与えたときのXの条件付き確率密度関数とZを与えたときのYの条件付き確率密度関数の積に等しいとき、Z=zを与えたときにXとYは条件付き独立であると言います。

$$f_{X,Y|Z}(x,y|z) = f_{X|Z}(x|z)f_{Y|Z}(y|z)$$

・ **確率母関数**…離散型確率変数Xの確率関数を $p(k)$ とすると、1に十分に近いすべてのsに対して、次のべき級数が収束するときの $G_X(s)$ のこと。

$$G_X(s) = E[s^X] = \sum_{k=0}^{\infty} s^k p(k)$$

確率母関数を微分して $s = 1$ を代入することで、次のような X の階乗モーメントを求めることができるので、これを利用して X の期待値や分散などがわかります。

$$E[X(X-1)\cdots(X-k+1)] = G_X^{(k)}(1)$$

・**モーメント（積率）母関数**…0に十分に近いすべての t に対して、次の期待値が存在するときの $M_X(t)$ のこと。

$$M_X(t) = G_X(e^t) = E[e^{tX}]$$

モーメント母関数を微分して $t = 0$ を代入することで、次のような原点まわりのモーメントを求めることができます。

$$E[X^k] = M_X^{(k)}(0)$$

また、 X と Y が独立なとき、 $X+Y$ のモーメント母関数は次の式のように X のモーメント母関数と Y のモーメント母関数の積で求めることができます。

$$M_{X+Y}(t) = M_X(t)M_Y(t)$$

※特性関数は出題されないと考えられるので省略。

第3章 分布の特性値

・**分位点**… X が連続型の確率変数で、累積分布関数 $F(x)$ が増加関数のとき、 $F(x_{0.25}) = 0.25$ となる $x_{0.25}$ を第1四分位数、 $F(x_{0.5}) = 0.5$ となる $x_{0.5}$ を中央値、 $F(x_{0.75}) = 0.75$ となる $x_{0.75}$ を第3四分位数、 $x_{0.75} - x_{0.25}$ を四分位範囲と言います。

- ・**最頻値（モード）**…確率密度関数 $f(x)$ （または確率関数 $p(x)$ ）を最大にする x
- ・**変動係数**…非負値の確率変数 X のばらつきが期待値に対してどれくらいかを示す次の指標。

$$\frac{\sqrt{V[X]}}{E[X]}$$

・**歪度**…確率変数 X の期待値を μ 、分散を σ^2 とすると、次のように X を標準化した確率変数の3乗の期待値。

$$\frac{E[(X - \mu)^3]}{\sigma^3}$$

分布が、右に長い裾を持つときには正の値、左に長い裾を持つときには負の値をとりやすく、左右対称ならば0になります。

・**尖度**…確率変数 X の期待値を μ 、分散を σ^2 とすると、次のように X を標準化した確率変数の4乗の期待値。

$$\frac{E[(X - \mu)^4]}{\sigma^4}$$

確率密度関数のグラフに山が1つあり、その山が尖っているほど尖度は大きな値をとる傾向があります。この期待値を正規分布で計算すると3になるので、上の式から3をひいた値が正か負かによって分布の形状を正規分布と比べることがあります。

・**共分散**…確率変数 X 、 Y の関連性を表す量であり、 $E[X]=\mu_X$ 、 $E[Y]=\mu_Y$ として、次の式で表せます。

$$\begin{aligned} Cov[X, Y] &= E[(X - \mu_X)(Y - \mu_Y)] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

X と Y が独立ならば共分散は0であり、そのとき次の式が成り立ちます。

$$E[XY] = E[X]E[Y]$$

X 、 Y を確率変数、 a 、 b 、 c 、 d を定数として、共分散について次の式が成り立ちます。

$$Cov[aX + b, cY + d] = acCov[X, Y]$$

分散について、共分散を使った次の式が成り立ちます。

$$V[X \pm Y] = V[X] + V[Y] \pm 2Cov[X, Y]$$

特に、 X と Y が独立ならば、次の式が成り立ちます。

$$V[X \pm Y] = V[X] + V[Y]$$

・**相関係数**…確率変数を基準化し、 -1 以上 1 以下の値をとるようにして確率変数 X 、 Y の関連性を表した次の量。

$$\rho[X, Y] = \frac{Cov[X, Y]}{\sqrt{V[X]}\sqrt{V[Y]}}$$

- ・ **偏相関係数**…Zが、XとYの両方に相関があるとき、XとYの間に直接的な相関がなくてもZを介して相関が発生します（**擬似相関**）。偏相関係数は、Zの影響を除いた場合のXとYの相関係数で、次の式で計算できます。

$$\rho[X, Y|Z] = \frac{\rho[X, Y] - \rho[X, Z]\rho[Y, Z]}{\sqrt{(1 - \rho[X, Z]^2)(1 - \rho[Y, Z]^2)}}$$

- ・ **加重平均**…データ $x_1, \dots, x_n$ に対して、 $w_1, \dots, w_n$ を重みとして次の式で定めます。

$$\sum_{i=1}^n w_i x_i \quad (w_i > 0, w_1 + \dots + w_n = 1)$$

特に、 $w_1 = \dots = w_n = 1/n$ のとき、算術平均に一致します。

- ・ **幾何平均**…正の値をとるデータ $x_1, \dots, x_n$ に対して、次の式で定めます。

$$\sqrt[n]{x_1 \cdots x_n}$$

- ・ **調和平均**…正の値をとるデータ $x_1, \dots, x_n$ に対して、次の式で定めます。

$$\left(\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i} \right)^{-1}$$

- ・ **確率変数ベクトル**…確率変数 $x_1, \dots, x_p$ に対して、 $\mathbf{x} = (x_1, \dots, x_p)^T$ をp次元確率変数ベクトルと言います。

- ・ **平均ベクトル**…確率変数 $x_1, \dots, x_p$ に対して、 $E[\mathbf{x}] = (E[x_1], \dots, E[x_p])^T$ をp次元平均ベクトルまたは期待値ベクトルと言います。平均ベクトルについて、Aを $r \times p$ 定数行列、bをr次元定数ベクトルとして、次の式が成り立ちます。

$$E[A\mathbf{x} + \mathbf{b}] = A \cdot E[\mathbf{x}] + \mathbf{b}$$

- ・ **分散共分散行列**…p次元確率変数ベクトル $\mathbf{x} = (x_1, \dots, x_p)^T$ に対して、 $\text{Cov}[x_i, x_j]$ を(i, j)成分とする次のような半正定値対称行列。

$$V[\mathbf{x}] = \begin{pmatrix} V[x_1] & Cov[x_1, x_2] & \cdots & Cov[x_1, x_p] \\ Cov[x_2, x_1] & V[x_2] & \cdots & Cov[x_2, x_p] \\ \vdots & & \ddots & \vdots \\ Cov[x_p, x_1] & Cov[x_p, x_2] & \cdots & V[x_p] \end{pmatrix}$$

・ **標本分散共分散行列**…p変数($x_1, \dots, x_p$)のサイズnの標本($x_{11}, \dots, x_{1p}$), $\dots$, ($x_{n1}, \dots, x_{np}$)に対して, 次のような x_i と x_j の共分散を(i, j)成分とするp次正方行列。

$$S_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)$$

・ **相関行列**…p次元確率変数ベクトル $\mathbf{x} = (x_1, \dots, x_p)^T$ に対して, $\rho[x_i, x_j]$ を(i, j)成分とする半正定値対称行列。

・ **標本相関行列**…p変数($x_1, \dots, x_p$)のサイズnの標本($x_{11}, \dots, x_{1p}$), $\dots$, ($x_{n1}, \dots, x_{np}$)に対して, x_i と x_j の相関係数を(i, j)成分とするp次正方行列。

第4章 変数変換

・ **Y=g(X)の確率密度関数**…X, Yを連続型確率変数, Xの確率密度関数を $f_X(x)$, Yの確率密度関数を $f_Y(y)$ として, $y=g(x)$ が単調増加または単調減少の関数のとき, 逆関数 $x=g^{-1}(y)$ が存在します。 $g^{-1}(y)$ が微分可能ならば, $f_X(x)$ から $f_Y(y)$ が次のように求められます。

$$\begin{aligned} f_Y(y) &= f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \\ &= f_X(g^{-1}(y)) \frac{1}{|g'(g^{-1}(y))|} \end{aligned}$$

(例) $f_X(x) = \lambda e^{-\lambda x}$ ($x > 0, \lambda > 0$), $y = g(x) = 1 - e^{-x}$ とすると, $0 < y < 1$ です。 $x = g^{-1}(y) = -\log(1 - y)$ だから, 上の公式にあてはめると, $f_Y(y)$ は次のようになります。

$$\begin{aligned} f_Y(y) &= \lambda e^{\lambda \log(1-y)} \cdot \frac{1}{1-y} \\ &= \lambda \{e^{\log(1-y)}\}^\lambda \cdot \frac{1}{1-y} \\ &= \lambda(1-y)^{\lambda-1} \end{aligned}$$

・ **X+Yの確率密度関数**…X, Yを連続型確率変数, Xの確率密度関数を $f_X(x)$, Yの確率密度関数を $f_Y(y)$ として, X, Yが独立だとすると, X, Yの同時確率密度関数は $f_X(x)f_Y(y)$ です。Z=X+Y, T=Yという変数変換を考えると, その逆変換は $X=Z-T$, $Y=T$ であるから, Z, Tの同時確率密度関数は $f_X(z-t)f_Y(t)$ となり, 周辺分布を求めてZの確率密度関数は次のようになります。

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(z-t)f_Y(t)dt$$

ここで, $(x, y) \rightarrow (z, t)$ の変換にともなって登場する次の行列式 (**ヤコビアン**) が1になっていることに注意します。

$$dxdy = \begin{vmatrix} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial t} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial t} \end{vmatrix} dzdt$$

(例) Xの確率密度関数 $f_X(x)$ ($x > 0$) とYの確率密度関数 $f_Y(y)$ ($y > 0$) を, $m > 0$, $n > 0$ のもとで次の式で定義します。

$$f_X(x) = \frac{1}{\Gamma\left(\frac{m}{2}\right) 2^{\frac{m}{2}}} x^{\frac{m}{2}-1} e^{-\frac{x}{2}}, \quad f_Y(y) = \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}$$

$X=Z-T > 0$, $Y=T > 0$ より, $0 < t < z$ であるから, Zの確率密度関数 $f_Z(z)$ は次のように計算できます。

$$\begin{aligned} & \int_0^z f_X(z-t)f_Y(t)dt \\ &= \int_0^z \frac{1}{\Gamma\left(\frac{m}{2}\right) 2^{\frac{m}{2}}} (z-t)^{\frac{m}{2}-1} e^{-\frac{z-t}{2}} \cdot \frac{1}{\Gamma\left(\frac{n}{2}\right) 2^{\frac{n}{2}}} t^{\frac{n}{2}-1} e^{-\frac{t}{2}} dt \\ &= \frac{e^{-\frac{z}{2}}}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right) 2^{\frac{m+n}{2}}} \int_0^z (z-t)^{\frac{m}{2}-1} t^{\frac{n}{2}-1} dt \end{aligned}$$

ここで, $t=zx$ と置換すると, 次のようになります。

$$\frac{e^{-\frac{z}{2}} z^{\frac{m+n}{2}-1}}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right) 2^{\frac{m+n}{2}}} \int_0^1 (1-x)^{\frac{m}{2}-1} x^{\frac{n}{2}-1} dx$$

上の積分は, 次のようなベータ関数になっています。

$$B\left(\frac{m}{2}, \frac{n}{2}\right) = \frac{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)}{\Gamma\left(\frac{m+n}{2}\right)}$$

よって、積分をガンマ関数を用いて書き直すと、 $Z=X+Y$ の確率密度関数が次のように求められます。

$$f_Z(z) = \frac{e^{-\frac{z}{2}} z^{\frac{m+n}{2}-1}}{\Gamma\left(\frac{m+n}{2}\right) 2^{\frac{m+n}{2}}}$$

・ **Box-Cox変換**…非対称であるなど、正規分布からずれている非負のデータ x を正規分布に近づける次の変換のこと。

$$\begin{cases} \frac{x^\lambda - 1}{\lambda} & (\lambda \neq 0) \\ \log x & (\lambda = 0) \end{cases}$$

λ の値を変化させることでべき乗変換や対数変換など、様々な変換が可能であり、その中で変換後のデータが正規分布に近づくものを選択します。

※ロジット変換、ロジスティック変換、プロビット変換については第18章を参照。

第5章 離散型分布

・ **離散一様分布**…サイコロを1回投げたときに出る目の分布のように、有限個の事象が等確率で起きる場合の確率分布。 X が $\{1, 2, \dots, k\}$ 上の離散一様分布にしたがうとは、 X がこれらの k 通りの値を等確率でとることであり、次のように表せます。

$$P(X = 1) = P(X = 2) = \dots = P(X = k) = \frac{1}{k}$$

X が $\{1, 2, \dots, k\}$ 上の離散一様分布にしたがうとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = \frac{k+1}{2}, \quad V[X] = \frac{k^2-1}{12}$$

$$G(s) = E[s^X] = \frac{s(1-s^k)}{k(1-s)}$$

・ **ベルヌーイ分布**…コイン投げのように、結果が2通り（一方を成功、他方を失敗と呼ぶ）の試行をベルヌーイ試行と言い、ベルヌーイ試行を1回行ったときの成功回数がしたがう確率分布。ベルヌーイ試行の成功確率を p として、ベルヌーイ分布を $\text{Bin}(1, p)$ と表します。確率関数は次の通りです。

$$P(X = x) = p^x (1 - p)^{1-x} \quad (x = 0, 1)$$

$X \sim \text{Bin}(1, p)$ のとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = p, \quad V[X] = p(1 - p)$$

$$G(s) = E[s^X] = ps + 1 - p$$

・ **二項分布**…成功確率 p の独立なベルヌーイ試行を n 回行ったときの成功回数がしたがう確率分布で、 $\text{Bin}(n, p)$ と表します。確率関数は次の通りです。

$$P(X = x) = {}_n C_x p^x (1 - p)^{n-x} \quad (x = 0, 1, \dots, n)$$

$X \sim \text{Bin}(n, p)$ のとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = np, \quad V[X] = np(1 - p)$$

$$G(s) = E[s^X] = (ps + 1 - p)^n$$

二項分布には再生性があり、 $X_1 \sim \text{Bin}(n_1, p)$, $X_2 \sim \text{Bin}(n_2, p)$ が独立であるとき、 $X_1 + X_2 \sim \text{Bin}(n_1 + n_2, p)$ が成り立ちます。

・ **超幾何分布**… N 本のくじの中に M 本の当たりがあり、 n 本のくじを非復元抽出するとき、ひいた当たりの本数がしたがう確率分布で、 $\text{HG}(N, M, n)$ と表します。確率関数は次の通りです。

$$P(X = x) = \frac{{}_M C_x \times {}_{N-M} C_{n-x}}{{}_N C_n}$$

$$(\max\{0, n - (N - M)\} \leq x \leq \min\{n, M\})$$

$X \sim \text{HG}(N, M, n)$ のとき、期待値、分散は次の通りです。

$$E[X] = \frac{nM}{N}, \quad V[X] = \frac{nM}{N} \left(1 - \frac{M}{N}\right) \cdot \frac{N - n}{N - 1}$$

n と M/N を一定にしたまま、 $N \rightarrow \infty$ とすると、二項分布 $\text{Bin}(n, M/N)$ に収束します。

・ **ポアソン分布**… $\lambda > 0$ を平均発生率とすると、特定の時間（空間）内に事象が x 回発生する確率のモデル化に用いられる確率分布で、 $Po(\lambda)$ と表します。確率関数は次の通りです。

$$P(X = x) = \frac{e^{-\lambda} \cdot \lambda^x}{x!} \quad (x = 0, 1, 2, \dots)$$

$X \sim Po(\lambda)$ のとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = \lambda, \quad V[X] = \lambda$$

$$G(s) = E[s^X] = e^{(s-1)\lambda}$$

ポアソン分布には再生性があり、 $X_1 \sim Po(\lambda_1)$, $X_2 \sim Po(\lambda_2)$ が独立であるとき、 $X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$ が成り立ちます。

二項分布 $Bin(n, p)$ で、 $np = \lambda$, $n \rightarrow \infty$ とすると、 $Po(\lambda)$ に分布収束します。（少数の法則）

・ **幾何分布**…独立な成功確率 p のベルヌーイ試行をくり返すとき、はじめての成功が起きるまでの失敗の回数 X がしたがう分布で、 $Geo(p)$ と表します。確率関数は次の通りです。

$$P(X = x) = p(1 - p)^x \quad (x = 0, 1, 2, \dots)$$

はじめての成功が起きるまでの試行の回数 Y がしたがう分布を幾何分布と呼ぶ場合もあり、そのときの確率関数は次の通りです。

$$P(Y = y) = p(1 - p)^{y-1} \quad (y = 1, 2, \dots)$$

$X \sim Geo(p)$ のとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = \frac{1 - p}{p}, \quad V[X] = \frac{1 - p}{p^2}$$

$$G(s) = E[s^X] = \frac{p}{1 - (1 - p)s}$$

$Y = X + 1$ であることを利用して、 Y の期待値、分散、確率母関数も求められます。

幾何分布については、どんな0以上の整数 m , n に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$P(X \geq m + n | X \geq m) = P(X \geq n)$$

・ **負の二項分布**…成功確率 p のベルヌーイ試行をくり返すとき、 r 回目の成功が起きるまでの失敗の回数がしたがう分布で、 $NB(r, p)$ と表します。 $r = 1$ のときには幾何分布に一致します。確率関数は次の通りです。

$$P(X = x) = {}_{r+x-1}C_x p^r (1-p)^x \quad (x = 0, 1, 2, \dots)$$

$X \sim NB(r, p)$ のとき、期待値、分散、確率母関数は次の通りです。

$$E[X] = \frac{r(1-p)}{p}, \quad V[X] = \frac{r(1-p)}{p^2}$$

$$G(s) = E[s^X] = \left(\frac{p}{1 - (1-p)s} \right)^r$$

負の二項分布には再生性があり、 $X_1 \sim NB(r_1, p)$ 、 $X_2 \sim NB(r_2, p)$ が独立であるとき、 $X_1 + X_2 \sim NB(r_1 + r_2, p)$ が成り立ちます。

・ **多項分布**…ベルヌーイ試行は結果が2通りですが、より一般的に結果が k 通りで、それぞれが起こる確率が $p_1, p_2, \dots, p_k$ ($p_1 + p_2 + \dots + p_k = 1$) で一定の場合を多項試行と呼ぶことにします。独立な多項試行を n 回行ったとき、 k 通りの結果が起きる回数がしたがう確率分布が多項分布で、 $M(n; p_1, p_2, \dots, p_k)$ と表します。 $k = 2$ のときには二項分布に一致します。同時確率関数は次の通りです。

$$P(X_1 = x_1, X_2 = x_2, \dots, X_k = x_k) \\ = \frac{n!}{x_1! x_2! \dots x_k!} p_1^{x_1} p_2^{x_2} \dots p_k^{x_k} \quad (x_1 + x_2 + \dots + x_k = n)$$

$(X_1, \dots, X_k) \sim M(n; p_1, p_2, \dots, p_k)$ のとき、 $X_i \sim \text{Bin}(n, p_i)$ であり、 X_i と X_j ($i \neq j$) の共分散と相関係数は次の通りです。

$$\text{Cov}(X_i, X_j) = -np_i p_j \\ \rho(X_i, X_j) = -\frac{\sqrt{p_i p_j}}{\sqrt{(1-p_i)(1-p_j)}}$$

※多変数の確率母関数は出題されないと考えられるので省略。

第6章 連続型分布と標本分布

・ **連続一様分布**…区間 $[a, b]$ で一定の確率密度をもつ確率分布で、 $a < b$ として、 $U(a, b)$ と表します。確率密度関数は次の通りです。

$$f(x) = \begin{cases} 0 & (x < a) \\ \frac{1}{b-a} & (a \leq x \leq b) \\ 0 & (x > b) \end{cases}$$

$X \sim U(a, b)$ のとき、平均、分散、モーメント母関数は次の通りです。

$$E[X] = \frac{a+b}{2}, \quad V[X] = \frac{(b-a)^2}{12}$$

$$M(t) = E[e^{tX}] = \frac{e^{bt} - e^{at}}{(b-a)t}$$

・ **正規分布**…偶然誤差に見られるように、平均 μ を中心とする対称な確率分布で、 $\sigma > 0$ として、 $N(\mu, \sigma^2)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

特に、 $\mu = 0$ 、 $\sigma^2 = 1$ の場合を標準正規分布と言います。

$X \sim N(\mu, \sigma^2)$ のとき、平均、分散、モーメント母関数は次の通りです。

$$E[X] = \mu, \quad V[X] = \sigma^2$$

$$M(t) = E[e^{tX}] = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right)$$

正規分布には再生性があり、 $X_1 \sim N(\mu_1, \sigma_1^2)$ 、 $X_2 \sim N(\mu_2, \sigma_2^2)$ が独立であるとき、 $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ が成り立ちます。より一般的に、 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$ も成り立ちます。

・ **指数分布**…機械が故障するまでの時間などを表すのにも使われる確率分布で、 $\lambda > 0$ として、 $\text{Exp}(\lambda)$ と表します。確率密度関数は次の通りです。

$$f(x) = \lambda e^{-\lambda x} \quad (x > 0)$$

$X \sim \text{Exp}(\lambda)$ のとき、平均、分散、モーメント母関数は次の通りです。

$$E[X] = \frac{1}{\lambda}, \quad V[X] = \frac{1}{\lambda^2}$$

$$M(t) = E[e^{tX}] = \frac{\lambda}{\lambda - t}$$

指数分布については、どんな正の数 a , b に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$P(X \geq a + b | X \geq a) = P(X \geq b)$$

・**ガンマ分布**… $x > 0$ で定義される確率分布で、 $a > 0$, $b > 0$ として、 $Ga(a, b)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}} \quad (x > 0)$$

a を形状母数, b を尺度母数と言い、上の式の $\Gamma(a)$ はガンマ関数です。 $a = 1$ のときには、指数分布 $\text{Exp}(1/b)$ に一致します。

$X \sim Ga(a, b)$ のとき、平均、分散、モーメント母関数は次の通りです。

$$E[X] = ab, \quad V[X] = ab^2$$

$$M(t) = E[e^{tX}] = (1 - bt)^{-a}$$

ガンマ分布には再生性があり、 $X_1 \sim Ga(a_1, b)$, $X_2 \sim Ga(a_2, b)$ が独立であるとき、 $X_1 + X_2 \sim Ga(a_1 + a_2, b)$ が成り立ちます。

・**ベータ分布**… $0 < x < 1$ で定義される確率分布で、 $a > 0$, $b > 0$ として、 $Be(a, b)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{B(a, b)} x^{a-1} (1 - x)^{b-1} \quad (0 < x < 1)$$

上の式の $B(a, b)$ はベータ関数です。

$X \sim Be(a, b)$ のとき、平均、分散は次の通りです。

$$E[X] = \frac{a}{a + b}, \quad V[X] = \frac{ab}{(a + b)^2(a + b + 1)}$$

※コーシー分布は省略

・ **対数正規分布**... $Y \sim N(\mu, \sigma^2)$ のとき, $X = e^Y$ がしたがう確率分布で, $\Lambda(\mu, \sigma^2)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma x}} \exp \left[-\frac{(\log x - \mu)^2}{2\sigma^2} \right] \quad (x > 0)$$

$X \sim \Lambda(\mu, \sigma^2)$ のとき, 平均, 分散は次の通りです。

$$E[X] = \exp \left(\mu + \frac{1}{2}\sigma^2 \right), \quad V[X] = \exp(2\mu + \sigma^2) (\exp(\sigma^2) - 1)$$

・ **多変量正規分布**... $\mathbf{x} = (x_1, \dots, x_k)^\top$, その平均ベクトルを $\boldsymbol{\mu} = (\mu_1, \dots, \mu_k)^\top$, 分散共分散行列を Σ とする k 変量正規分布を $N(\boldsymbol{\mu}, \Sigma)$ と表します。同時確率密度関数は次の通りです。

$$f(\mathbf{x}) = \frac{1}{\sqrt{2^k \pi^k |\Sigma|}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

2変量の場合には次のように表せます。

$$f(\mathbf{x}) = \frac{1}{2\pi \sqrt{|\Sigma|}} \exp \left[-\frac{1}{2} \begin{pmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{pmatrix} \Sigma^{-1} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix} \right]$$

また, X_1 と X_2 の相関係数を ρ として, $(X_1, X_2)^\top$ が次の2変量正規分布にしたがうとき, $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$ が成り立ちます。

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right]$$

このとき, $aX_1 + bX_2$ は次の正規分布にしたがいます。

$$aX_1 + bX_2 \sim N[a\mu_1 + b\mu_2, a^2\sigma_1^2 + 2ab\rho\sigma_1\sigma_2 + b^2\sigma_2^2]$$


$X_1 = x_1$ が与えられたときの X_2 の条件付き分布は次の期待値, 分散をもつ正規分布です。

$$E[X_2|X_1 = x_1] = \mu_2 + \frac{\rho\sigma_1\sigma_2}{\sigma_1^2}(x_1 - \mu_1)$$

$$V[X_2|X_1 = x_1] = \sigma_2^2(1 - \rho^2)$$

※多変数のモーメント母関数は出題されないと考えられるので省略。

・ **混合正規分布**…複数の正規分布を合成してできる確率分布。例えば、 $N(0, 1)$ の確率密度関数を $\phi_1(x)$ 、 $N(4, 1)$ の確率密度関数を $\phi_2(x)$ として、 $f(x) = 0.3\phi_1(x) + 0.7\phi_2(x)$ は2成分混合正規分布の確率密度関数であり、そのグラフは次の図のようになります。



より一般に、 $\pi_1 + \pi_2 + \dots + \pi_k = 1$ を満たす正の数を $\pi_1, \pi_2, \dots, \pi_k$ 、正規分布の確率密度関数を $\phi_1, \phi_2, \dots, \phi_k$ として、 k 成分混合正規分布の確率密度関数は $f = \pi_1\phi_1 + \pi_2\phi_2 + \dots + \pi_k\phi_k$ のように定めます。

(例) ある大学の入試では60点以上の得点が合格です。文系の生徒の得点は正規分布 $N(55, 6^2)$ にしたがい、理系の生徒の得点は正規分布 $N(65, 8^2)$ にしたがうことがわかっており、受験者のうち、文系と理系の生徒の割合は2 : 1です。このとき、ランダムに選んだ1人の受験生が合格である確率を求めます。ランダムに選んだ1人の受験生の得点を X とすると、標準正規分布の確率密度関数を $\phi(x)$ として、

$$\begin{aligned}
& P(X \geq 60) \\
&= \int_{60}^{\infty} \frac{2}{3} \cdot \frac{1}{\sqrt{2\pi} \cdot 6} \exp \left[-\frac{1}{2} \left(\frac{x-55}{6} \right)^2 \right] + \frac{1}{3} \cdot \frac{1}{\sqrt{2\pi} \cdot 8} \exp \left[-\frac{1}{2} \left(\frac{x-65}{8} \right)^2 \right] dx \\
&= \frac{2}{3} \int_{\frac{5}{6}}^{\infty} \phi(z) dz + \frac{1}{3} \int_{-\frac{5}{8}}^{\infty} \phi(z) dz \\
&= \frac{2}{3} \cdot 0.2033 + \frac{1}{3} \cdot 0.7340 \\
&\approx 0.38
\end{aligned}$$

いま、2成分混合正規分布の確率密度関数を $f = \pi\phi_1 + (1-\pi)\phi_2$ とし、 π , ϕ_1 , ϕ_2 が未知のとき、そのパラメータ $\theta = (\mu_1, \sigma_1^2, \mu_2, \sigma_2^2, \pi)$ は、データから次の手順で推定します。これを **EMアルゴリズム** と言います。

① パラメータの初期値 $\theta^{(0)}$ を決める

② 【Eステップ】 観測値 x_i が $N(\mu_1, \sigma_1^2)$ から得られる確率を γ_i として、パラメータの k 回目の更新値 $\theta^{(k)}$ を使い、次の式で $\gamma_i^{(k+1)}$ を求める

$$\gamma_i^{(k+1)} = \frac{\pi^{(k)} \phi_1^{(k)}(x_i)}{\pi^{(k)} \phi_1^{(k)}(x_i) + (1 - \pi^{(k)}) \phi_2^{(k)}(x_i)}$$

③ 【Mステップ】 $\gamma_i^{(k+1)}$ を使って、パラメータの $k+1$ 回目の更新値を次の式で求める

$$\begin{aligned}
\mu_1^{(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} x_i}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\
(\sigma_1^2)^{(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} (x_i - \mu_1^{(k+1)})^2}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\
\mu_2^{(k+1)} &= \frac{\sum_{i=1}^n (1 - \gamma_i^{(k+1)}) x_i}{\sum_{i=1}^n (1 - \gamma_i^{(k+1)})} \\
(\sigma_2^2)^{(k+1)} &= \frac{\sum_{i=1}^n (1 - \gamma_i^{(k+1)}) (x_i - \mu_2^{(k+1)})^2}{\sum_{i=1}^n (1 - \gamma_i^{(k+1)})} \\
\pi^{(k+1)} &= \frac{1}{n} \sum_{i=1}^n \gamma_i^{(k+1)}
\end{aligned}$$

④ ②と③を収束するまでくり返す

・ **カイ2乗分布**… n を自然数として、 $\text{Ga}(n/2, 2)$ を自由度 n のカイ2乗分布と言って、 $\chi^2(n)$ と表します。確率密度関数は、ガンマ分布の確率密度関数から導けるので、覚える必要はありません。

【特徴①】 $Z \sim N(0, 1)$ のとき、 $Z^2 \sim \chi^2(1)$ であり、 $Z_1, Z_2, \dots, Z_n$ が独立でそれぞれ標準正規分布にしたがうとき、 $Z_1^2 + Z_2^2 + \dots + Z_n^2 \sim \chi^2(n)$

【特徴②】ガンマ分布の再生性から、 $X \sim \chi^2(m)$ 、 $Y \sim \chi^2(n)$ で X と Y が独立のとき、 $X + Y \sim \chi^2(m + n)$

【特徴③】 $X \sim \chi^2(n)$ のとき、 $E[X] = n$ 、 $V[X] = 2n$ であり、モーメント母関数はガンマ分布のモーメント母関数から導けるので、覚える必要はありません。

また、 $Z_1, Z_2, \dots, Z_n$ が独立に標準正規分布にしたがい、 $\lambda = \mu_1^2 + \mu_2^2 + \dots + \mu_n^2 > 0$ のとき、 $(Z_1 + \mu_1)^2 + (Z_2 + \mu_2)^2 + \dots + (Z_n + \mu_n)^2$ は、自由度 n 、非心度 λ の非心カイ2乗分布にしたがうと言って、 $\chi^2(n, \lambda)$ と表します。カイ2乗分布の再生性は非心カイ2乗分布の再生性として一般化でき、 $X_1, X_2, \dots, X_n$ が独立に（非心）カイ2乗分布にしたがい、 $X_i \sim \chi^2(n_i, \lambda_i)$ であるとき、これらの和は次の（非心）カイ2乗分布にしたがいます。

$$\sum_{i=1}^n X_i \sim \chi^2 \left(\sum_{i=1}^n n_i, \sum_{i=1}^n \lambda_i \right)$$

・ **t分布**… $Z \sim N(0, 1)$ 、 $Y \sim \chi^2(n)$ で Z と Y が独立のとき、次の T がしたがう確率分布を自由度 n のt分布と言って、 $t(n)$ と表します。

$$T = \frac{Z}{\sqrt{Y/n}}$$

確率密度関数は覚えなくていいので省略します。

$t(1)$ はコーシー分布に一致し、 $n \rightarrow \infty$ で $t(n)$ は標準正規分布に分布収束します。また、 $X \sim t(n)$ ならば、 $n > 1$ のとき $E[X] = 0$ で、 $n > 2$ のとき $V[X] = n/(n-2)$ です。

上の T の式で、 $Z \sim N(\lambda, 1)$ のとき、 T がしたがう確率分布を自由度 n 、非心度 λ の非心t分布と言います。

・ **F分布**… $X_1 \sim \chi^2(n_1)$ 、 $X_2 \sim \chi^2(n_2)$ で X_1 と X_2 が独立のとき、次の F がしたがう確率分布を自由度 (n_1, n_2) のF分布と言って、 $F(n_1, n_2)$ と表します。

$$F = \frac{X_1/n_1}{X_2/n_2}$$

確率密度関数, 期待値, 分散は覚えなくていいので省略します。


$T \sim t(n)$ のとき, $Z \sim N(0, 1)$, $Y \sim \chi^2(n)$ として, T^2 は次のように表せて, $Z^2 \sim \chi^2(1)$ であるから, 自由度 $(1, n)$ のF分布にしたがいます。

$$T^2 = \frac{Z^2/1}{Y/n}$$

$X_1 \sim \chi^2(n_1, \lambda)$, $X_2 \sim \chi^2(n_2)$ で X_1 と X_2 が独立のとき, 上のFがしたがう確率分布を自由度 (n_1, n_2) , 非心度 λ の非心F分布と言います。

第7章 極限定理, 漸近理論

確率変数列 $X_1, X_2, \dots$ の4つの収束は, 条件の強さの順で次の図のようにまとめられます。



・ X_n が確率変数 Y に **概収束** するとは次が成り立つことです。(例) 大数の強法則

$$P\left(\lim_{n \rightarrow \infty} X_n = Y\right) = 1$$

・ X_n が確率変数 Y に **平均二乗収束** するとは, 次が成り立つことです。(例) 大数の弱法則 (確率収束の例でもある)

$$\lim_{n \rightarrow \infty} E[(X_n - Y)^2] = 0$$

・ X_n が確率変数 Y に **確率収束** するとは, 任意の $\varepsilon > 0$ に対して次が成り立つことであり, 「 $X_n \rightarrow_p Y$ 」と表します。

$$\lim_{n \rightarrow \infty} P(|X_n - Y| > \varepsilon) = 0$$

・ F_n が確率分布 G に **分布収束（法則収束）** するとは、 X_n の分布関数を $F_n(x)$ として、 G のすべての連続点 x において次が成り立つことであり、「 $F_n \rightarrow_d G$ 」と表します。


$$\lim_{n \rightarrow \infty} F_n(x) = G(x)$$

・ **大数の弱法則** … $X_1, X_2, \dots, X_n$ が平均 μ 、分散有限の同一の分布に独立にしたがうとき、その標本平均は μ に平均二乗収束します。

・ **中心極限定理** … $X_1, X_2, \dots, X_n$ が平均 μ 、分散 σ^2 の同一の分布に独立にしたがうとき、その標本平均について、次の分布収束が成り立ちます。

$$\sqrt{n}(\bar{X}_n - \mu) \rightarrow_d N(0, \sigma^2)$$

・ **連続修正** … 離散分布を中心極限定理によって正規分布で近似するとき、区間幅を0.5だけずらして近似の精度を上げる方法。例えば、 $X \sim \text{Bin}(n, p)$, $Y \sim N[np, np(1-p)]$ として、 $P(a \leq X \leq b)$ は $P(a-0.5 \leq Y \leq b+0.5)$ でよく近似できます。次の図で、黄色いアミかけ部分 ($8.5 \leq Y \leq 11.5$) と二項分布の $P(9 \leq X \leq 11)$ を比べてみてください。



※ 極値分布は出題されないと考えられるので省略。

・ **連続写像定理** … $X_n \rightarrow_d X$ で、関数 h が連続であるとき、 $h(X_n) \rightarrow_d h(X)$ が成り立ちます。

（例） $\{X_n\}$ が平均 μ 、分散 σ^2 の同一の分布に独立にしたがうとき、その標本平均について、中心極限定理によって次の分布収束が成り立ちます。

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \rightarrow_d N(0, 1)$$

$f(x) = x^2$ が連続関数であることから、連続写像定理により、次の分布収束が成り立ちます。

$$\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \right)^2 \rightarrow_d \chi^2(1)$$

- ・ **スルツキーの補題**… $U_n \rightarrow_d U$, $V_n \rightarrow_p a$ であるとき, $U_n + V_n \rightarrow_d U + a$, $U_n V_n \rightarrow_d aU$ が成り立ちます。
- ・ **デルタ法**…次のように正規分布に分布収束する確率変数列 U_n (サンプルサイズ n の標本平均 $\bar{X}_n$ など) を考えます。

$$\sqrt{n}(U_n - \mu) \rightarrow_d N(0, \sigma^2)$$

このとき, 導関数が連続で $h(\mu) \neq 0$ を満たす関数 h に対して次の分布収束が成り立ちます。

$$\sqrt{n}\{h(U_n) - h(\mu)\} \rightarrow_d N(0, \sigma^2\{h'(\mu)\}^2)$$

(例) 対数正規分布 $\Lambda(\mu, \sigma^2)$ の中央値 e^μ の推定量の分布

この対数正規分布に独立にしたがう確率変数を $X_1, \dots, X_n$ とすると, $Y_1 = \log X_1, \dots, Y_n = \log X_n$ は $N(\mu, \sigma^2)$ にしたがうので, それらの標本平均も次のように正規分布にしたがいます。

$$\sqrt{n}(\bar{Y}_n - \mu) \sim N(0, \sigma^2)$$

ここで, $h(X) = e^X$ として, デルタ法を適用すると, 次の分布収束が成り立つことがわかります。

$$\sqrt{n}(e^{\bar{Y}} - e^\mu) \rightarrow_d N(0, \sigma^2 e^{2\mu})$$

これは, 中央値の推定量の分布が次のように近似できることを示しています。

$$e^{\bar{Y}} \sim N\left(e^\mu, \frac{\sigma^2 e^{2\mu}}{n}\right)$$

※多次元の分布収束は出題されないと考えられるので省略。

第8章 統計的推定の基礎

・ **統計的推定**…次のような独立に同一の分布 $f(x; \theta)$ にしたがう標本 $X_1, \dots, X_n$ の観測値をもとに, その分布のパラメータ θ を推測すること。標本の関数 $h(X_1, \dots, X_n)$ を用いて, パラメータの値を推定することを**点推定**, 関数 $h(X_1, \dots, X_n)$ を**推定量**, 観測値を代入した $h(x_1, \dots, x_n)$ を**推定値**と言い, 推定量のように標本のみの関数を**統計量**と言います。推定量の具体例としては標本平均や標本分散がありますが, これらは最尤法の説明の中で紹介します。

・ **順序統計量**…同一の分布からの標本の観測値を次のように大きさの順に並べかえたもの。

$$X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$$

・ **モーメント**…平均 μ の確率変数 X に対し、 $E[X]$, $E[X^2]$, …などのように、 $E[X^k]$ を原点まわりの k 次のモーメントと言い、 $E[X-\mu]$, $E[(X-\mu)^2]$, …などのように、 $E[(X-\mu)^k]$ を平均まわりの k 次のモーメントと言います。

・ **モーメント法**…大数の法則に基づいて母数の推定量を得る方法。 $\theta = (\theta_1, \dots, \theta_k)$ とし、確率変数 X が確率密度関数 $f(x; \theta)$ をもつ分布にしたがうとき、次のように k 次までのモーメントが θ の関数として表されている場合を考えます。

$$E[X^j] = g_j(\theta) \quad (j = 1, 2, \dots, k)$$

このとき、 j 次のモーメントを次のように $(1/n)\sum X_i^j$ でおきかえ、これを母数 $\theta_1, \dots, \theta_k$ について解くことで母数の推定量を得ます。

$$\frac{1}{n} \sum_{i=1}^n X_i^j = g_j(\theta) \quad (j = 1, 2, \dots, k)$$

(例) $X \sim \text{Bin}(n, p)$ のとき、 $E[X] = np$, $V[X] = np(1-p)$ です。 $X_1, \dots, X_m$ が独立に $\text{Bin}(n, p)$ にしたがうとき、 $E[X]$ を $(1/m)\sum X_i$, $E[X^2]$ を $(1/m)\sum X_i^2$ でおきかえると、次の式が成り立ちます。

$$\begin{cases} \bar{X} = \frac{1}{m} \sum_{i=1}^m X_i = np \\ \frac{1}{m} \sum_{i=1}^m X_i^2 = np(1-p) + n^2 p^2 \end{cases}$$

上の連立方程式を n, p について解くと、標本分散を S として、次のモーメント推定量を得ます。

$$\hat{n} = \frac{\bar{X}^2}{\bar{X} - S}, \quad \hat{p} = \frac{\bar{X} - S}{\bar{X}}$$

・ **最尤法**…尤度が最大になるようにパラメータの推定値を決める方法。まず、確率密度関数 $f(x; \theta)$ をもつ同一の分布に独立にしたがう標本の観測値を $x_1, \dots, x_n$ として、次の式を θ の関数と見たものを**尤度関数**と言います。

$$L(\theta) = f(x_1; \theta) f(x_2; \theta) \cdots f(x_n; \theta)$$

尤度関数 $L(\theta)$ が微分可能であるとき、 $L(\theta)$ が最大になるような θ を求めるためには、 $L(\theta)$ を微分するか、対数をとった $\log L(\theta)$ (**対数尤度関数**) を微分して、導関数が0になるような θ の値を求めます。 $L(\theta)$ が最大になるような θ は**最尤推定値**と呼ばれ、それを確率変数として表したものを**最尤推定量**と言います。母数 θ の関数 $g(\theta)$ の最尤推定量は θ の最尤推定量を関数 g で変換したものに等しく、これを不変性と言います。

(例) $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ のとき、 μ の最尤推定量は次の標本平均です。

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

また、 σ^2 の最尤推定量は次の標本分散です。

$$S = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

標本平均と標本分散は**一貫性**をもちます。つまり、 $n \rightarrow \infty$ のとき、母数の真値に確率収束します。

・ **漸近正規性**…確率密度関数 $f(x; \theta)$ をもつ同一の分布に独立にしたがう確率変数を $X_1, \dots, X_n$ とし、 θ の最尤推定量をハットをつけて表すと、 $n \rightarrow \infty$ のとき、適当な正則条件のもとで次の分布収束が成り立ちます。

$$\sqrt{n}(\hat{\theta} - \theta) \rightarrow_d N\left(0, \frac{1}{J_1(\theta)}\right)$$

上の $J_1(\theta)$ は、次の**フィッシャー情報量**で $n=1$ としたものです。

$$J_n(\theta) = E \left[\left(\frac{d}{d\theta} \log f(x_1, \dots, x_n; \theta) \right)^2 \right]$$

フィッシャー情報量は、ある条件のもとで次のようにも表せます。

$$J_n(\theta) = -E \left[\frac{d^2}{d\theta^2} \log f(x_1, \dots, x_n; \theta) \right]$$

・ **バイアス・バリエンス分解**…確率密度関数 $f(x; \theta)$ をもつ分布について、 θ の推定量をハットをつけて表すと、次の式の左辺が**平均2乗誤差**で、右辺第1項の θ ハットの分散（バリエンス）と、第2項の**バイアス**の2乗の和に一致します。

$$E[(\hat{\theta} - \theta)^2] = E[\{\hat{\theta} - E(\hat{\theta})\}^2] + \{E(\hat{\theta}) - \theta\}^2$$

・ **不偏推定量**…母数 θ に対して、バイアスが0である推定量（期待値が母数の真値に一致する推定量）。例えば、最尤法の説明の中で紹介した標本分散は母分散の不偏推定量ではありませんが、次の不偏分散は母分散の不偏推定量です。

$$U = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

・ **ジャックナイフ推定量**…バイアスのある推定量について、次の方法でバイアスを補正したもの。

①標本 $X_1, \dots, X_n$ から求められる θ の推定量（バイアスあり）を考える

② X_1 を取り除き、 $X_2, \dots, X_n$ から①と同じように求めた θ の推定量を $\theta_{(1)}$ 、 X_2 を取り除き、 $X_1, X_3, \dots, X_n$ から①と同じように求めた θ の推定量を $\theta_{(2)}$ 、…とし、 $\theta_{(1)}, \theta_{(2)}, \dots, \theta_{(n)}$ の平均を求める

③新しい推定量を $n \times \text{①} - (n-1) \times \text{②}$ とする

・ **一様最小分散不偏推定量 (UMVUE)**…不偏推定量の中で、分散が最小であるもの。

※最小2乗法、ガウス・マルコフの定理、BLUEについては、第16章で紹介します。

・ **クラメール・ラオの不等式**…不偏推定量の分散の下限を与える次の不等式のこと。（ワークブックでは「ラーメル」と書かれているが誤植）

$$V(\hat{\theta}) \geq J_n(\theta)^{-1}$$

・ **漸近有効推定量**… $n \rightarrow \infty$ のとき、分散がクラメール・ラオの下限を達成する一致推定量。

・ **有効推定量**…不偏推定量の中で、クラメール・ラオの下限を達成するもの。有効推定量はUMVUEです。

・ **十分統計量**…確率（密度）関数 $f(x; \theta)$ をもつ同一の分布に独立にしたがう確率変数を $X_1, \dots, X_n$ とし、 $\mathbf{X} = (X_1, \dots, X_n)$ の実現値を $\mathbf{x} = (x_1, \dots, x_n)$ とすると、統計量 $T(\mathbf{X})$ が θ に関する十分統計量であるとは、 $T(\mathbf{X}) = t$ を与えたときの $\mathbf{X} = \mathbf{x}$ の条件付き確率が θ に依存しないことを言います。そして、 $T(\mathbf{X})$ が θ に関する十分統計量であることは、 $\mathbf{X}$ の同時密度関数 $f(\mathbf{x}; \theta)$ が次の式の右辺のように分解できることと同値です。

$$f(\mathbf{x}; \theta) = h(\mathbf{x})g(T(\mathbf{x}), \theta)$$

つまり、 θ に依存する部分は、 $T(\mathbf{x})$ の関数として表せるということで、これを**フィッシャー・ネイマンの分解定理**と言います。

（例）互いに独立にパラメータ λ のポアソン分布にしたがう確率変数を $X_1, \dots, X_n$ とすると、同時確率関数は次のようになります。

$$\prod_{i=1}^n \frac{e^{-\lambda} \cdot \lambda^{x_i}}{x_i!} = \frac{e^{-n\lambda} \cdot \lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$

パラメータ λ に依存する部分は $\sum x_i$ の関数として表せるので、 $\sum x_i$ が λ の十分統計量です。

第9章 区間推定

母集団分布が正規分布である場合の母平均の区間推定と母分散の区間推定はいずれも2級内容のため、[統計検定2級のチートシート](#)を参照してください。また、多項分布の信頼区間は、実質的に母比率の区間推定と同じなので、これも[統計検定2級のチートシート](#)を参照してください。

・ **分散の比の区間推定**…2つの正規母集団の無作為標本（標本の大きさはそれぞれ n_A , n_B ）から求められる不偏分散をそれぞれ U_A^2 , U_B^2 とし、これらが独立であるものとします。2つの正規母集団の母分散を σ_A^2 , σ_B^2 とおくとき、信頼度95%の信頼区間は次の不等式で計算します。

$$\frac{U_B^2}{U_A^2} \cdot \frac{1}{F_{0.025}(n_B - 1, n_A - 1)} \leq \frac{\sigma_B^2}{\sigma_A^2} \leq \frac{U_B^2}{U_A^2} \cdot \frac{1}{F_{0.975}(n_B - 1, n_A - 1)}$$

ただし、上の不等式に出てくる $F_{0.025}(n_B - 1, n_A - 1)$ と $F_{0.975}(n_B - 1, n_A - 1)$ は、それぞれ自由度 $(n_B - 1, n_A - 1)$ のF分布の上側2.5%点と上側97.5%点を表しています。

・ **多項分布の差の信頼区間**… $(X_1, X_2, \dots, X_k) \sim M(n, p_1, p_2, \dots, p_k)$ のとき、 $p_1 - p_2$ の信頼度95%の信頼区間は次の不等式で計算します。

$$\begin{aligned} \hat{p}_1 - \hat{p}_2 - 1.96 \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}} &\leq p_1 - p_2 \leq \\ \hat{p}_1 - \hat{p}_2 + 1.96 \sqrt{\frac{\hat{p}_1(1 - \hat{p}_1)}{n} + \frac{\hat{p}_2(1 - \hat{p}_2)}{n} + \frac{2\hat{p}_1\hat{p}_2}{n}} & \end{aligned}$$

ただし、上の不等式で p_1 , p_2 にハットをつけた記号は、 X_1 , X_2 の実現値を x_1 , x_2 として、次の標本比率を表しています。


$$\hat{p}_1 = \frac{x_1}{n}, \quad \hat{p}_2 = \frac{x_2}{n}$$

第10章 検定の基礎と検定法の導出

次の手順により、母数に関する2つの仮説のうち、データによって支持されるものを選ぶ手法。（2級内容のため、用語については[統計検定2級のチートシート](#)を参照）

1. 母数に関して、帰無仮説（否定したい仮説）と対立仮説（正しいことが期待される仮説）を設定する。
2. 帰無仮説を仮定したもとでの検定統計量の確率分布を求め、有意水準と棄却域を決める。
3. 検定統計量の実現値が棄却域に落ちれば帰無仮説を棄却（否定すること）し、そうでなければ帰無仮説を受容する。

・ **検出力とサンプルサイズ**…母比率 p に関する有意水準2.5%の片側検定で、帰無仮説を $p = p_0$ 、対立仮説を $p = p_1 (p_1 > p_0)$ として、サンプルサイズ n が十分に大きいとき、標本比率は近似的に正規分布にしたがい、それぞれの仮説のもとでの分布は次の図のように表せます。



このときの棄却限界値は次の値です。

$$p_0 + 1.96\sqrt{\frac{p_0(1-p_0)}{n}}$$

対立仮説のもとでの正規分布の曲線下面積のうち、上の棄却限界値を超える部分が検出力になるので、棄却限界値が p_1 から標準偏差の何倍離れているか（上の図の c ）がわかれば、標準正規分布にしたがう確率変数を Z として、検出力は $P(Z \geq -c)$ で計算できます。 $p_1 - p_0$ は帰無仮説のもとでの標準偏差の1.96倍と、対立仮説のもとでの標準偏差の c 倍の和に等しいという次の関係式が成り立つので、 p_0 、 p_1 に加えて、サンプルサイズ n が与えられれば検出力が求められ、逆に検出力が与えられればサンプルサイズ n が求められます。

$$p_1 - p_0 = 1.96\sqrt{\frac{p_0(1-p_0)}{n}} + c\sqrt{\frac{p_1(1-p_1)}{n}}$$

次に、上の2つの正規分布を $N(\mu_0, \sigma^2/n)$ 、 $N(\mu_1, \sigma^2/n)$ とすると、上の式と同じように次の式が導けます。

$$\mu_1 - \mu_0 = (1.96 + c)\frac{\sigma}{\sqrt{n}}$$

両辺を σ でわると次の式になり、左辺を**エフェクトサイズ**と呼びます。

$$\frac{\mu_1 - \mu_0}{\sigma} = \frac{1.96 + c}{\sqrt{n}}$$

エフェクトサイズが大きくなるのは、 μ_0 と μ_1 が離れていて σ が小さい場合であり、このとき、2つの正規分布の確率密度関数のグラフはしっかりと離れて、あまり重ならなくなります。一定の検出力を得る（ c が一定である）ためには、エフェクトサイズが大きい場合ほど、サンプルサイズは少なくてもすむことが上の式からわかります。

・ **生産者危険**…帰無仮説が正しいときに、誤って帰無仮説を棄却してしまう誤りが**第一種の過誤**でした。出荷基準に適合しているかどうかを判定する抜取検査での呼び方にならい、この確率を生産者危険とも言います。なぜなら、生産者が正しく管理できている状態を帰無仮説とすると、正しく管理できているのに、抜取検査でたまたま不良品が多く観測されて出荷できなくなった場合、生産者が損失を被るからです。帰無仮説のもとでの不良品率を p_0 、サンプルサイズを n とすると、不良品数が合格規準値の c を超えてしまう確率（生産者危険、偽陽性率）は次のように計算できます。

$$\sum_{k=c+1}^n {}_nC_k p_0^k (1 - p_0)^{n-k}$$

・ **消費者危険**…対立仮説が正しいときに、誤って帰無仮説を受容してしまう誤りが**第二種の過誤**でした。抜取検査での呼び方にならい、この確率を消費者危険とも言います。なぜなら、生産者が正しく管理できていない状態を対立仮説とすると、正しく管理できていないのに、抜取検査でたまたま不良品が少なく観測されて出荷してしまった場合、消費者が損失を被るからです。対立仮説のもとでの不良品率を p_1 、サンプルサイズを n とすると、不良品数が合格規準値の c 以内となる確率（消費者危険、偽陰性率）は次のように計算できます。

$$\sum_{k=0}^c {}_nC_k p_1^k (1 - p_1)^{n-k}$$

第11章 正規分布に関する検定

母集団分布が正規分布であることを仮定する検定。1 標本の平均の検定（母分散が既知・未知）、2 標本の平均の検定（母分散が既知・未知で等しい）、1 標本の分散の検定、2 標本の等分散の検定はいずれも2級内容のため、[統計検定2級のチートシート](#)を参照してください。

第12章 一般の分布に関する検定法

母比率の検定と母比率の差の検定は2級内容のため、[統計検定2級のチートシート](#)を参照してください。

・ **ポアソン分布に関する検定**… λ が大きいとき、 $Po(\lambda)$ は $N(\lambda, \lambda)$ で近似できるため、 $\lambda = \lambda_0$ を帰無仮説として、次の統計量が近似的に標準正規分布にしたがうと考えて検定することが可能。

$$\frac{\hat{\lambda} - \lambda_0}{\sqrt{\lambda_0}}$$

・ **適合度検定**… $(X_1, \dots, X_k) \sim M(n, p_1, \dots, p_k)$ ($X_1 + \dots + X_k = n$, $p_1 + \dots + p_k = 1$) のとき, 帰無仮説 $p_1 = p_{10}, \dots, p_k = p_{k0}$ のもとでの期待度数は $np_{10}, \dots, np_{k0}$ となります。 n が大きいとき, 実現値を $x_1, \dots, x_k$ として, 次の検定統計量が帰無仮説のもとで近似的に自由度 $k-1$ のカイ2乗分布にしたがうことを利用して検定します。

$$\sum_{i=1}^k \frac{(x_i - np_{i0})^2}{np_{i0}}$$

また, 帰無仮説に ℓ 個のパラメータが含まれる場合, パラメータに最尤推定値をあてはめて期待度数を計算し, 上の検定統計量が帰無仮説のもとで近似的に自由度 $k - \ell - 1$ のカイ2乗分布にしたがうことを利用します。

また, 度数が極端に小さいカテゴリーがある場合には, 検定統計量の分子を $(|x_i - np_{i0}| - 0.5)^2$ とおきかえることがあり, これを **イエーツの補正** と言います。これによって, 検定統計量の実現値は小さくなり, 第一種の過誤を犯しにくく (第二種の過誤は犯しやすく) になります。

・ **尤度比検定**…確率 (密度) 関数 $f(x; \theta)$ に対して, 最尤推定値を代入した尤度を分子, 帰無仮説のもとでの最尤推定値を代入した尤度を分母とする次のような尤度比 λ を考えます。

$$\lambda = \frac{L(\hat{\theta}) \leftarrow \text{最尤推定値}}{L(\hat{\theta}') \leftarrow \text{帰無仮説のもとでの最尤推定値}}$$

ただし, 帰無仮説は次のようにパラメータベクトル θ の一部分 θ_1 を定数に固定するものとします。

$$\theta = (\underbrace{\theta_1, \dots, \theta_p}_{\theta_1}, \underbrace{\theta_{p+1}, \dots, \theta_{p+q}}_{\theta_2})$$

このとき, 帰無仮説のもとで, サンプルサイズが大きいときに近似的に, $2\log\lambda$ は自由度 p のカイ2乗分布にしたがうことを利用して検定を行うことができます。

※尤度比検定の例は第28章を参照。

第13章 ノンパラメトリック法

母集団分布を有限個のパラメータで記述することで推定や検定を行うのがパラメトリック法, そうでないのがノンパラメトリック法です。代表的なパラメトリック検定とノンパラメトリック検定の対応は次の表の通り。

パラメトリック	ノンパラメトリック
1 標本t検定	符号検定
対応のある 2 標本t検定	符号付き順位検定
対応のない 2 標本t検定	順位和検定, 並べ替え検定
一元配置分散分析	クラスカル・ウォリス検定

・ **符号検定**… 1 標本の中央値の検定または対応のある 2 標本の差の中央値の検定。 $X_1, \dots, X_n$ は独立に $F(x)$ を累積分布関数とする確率分布にしたがうとし、 $F(x)$ は連続で、中央値がただ 1 つに定まるものとします。1 標本で中央値が m_0 であるかどうかに関心がある場合には $Z = X - m_0$ とおき、2 標本 (X と Y) の差の中央値に関心がある場合には $Z = X - Y$ とおきます。

帰無仮説: Z の中央値 = 0, 対立仮説: Z の中央値 > 0 など

(手順 1) Z の符号が「+のデータ」と「-のデータ」に分ける。0 のデータは除く (除いた後のサンプルサイズを改めて n とする)。

(手順 2) +である Z の個数 T を検定統計量として、帰無仮説のもとで T は $\text{Bin}(n, 1/2)$ にしたがうことを利用して P 値を計算する。また、 n が十分に大きいときには、 $\text{Bin}(n, 1/2)$ が $N(n/2, n/4)$ で近似できることを使うこともできる。

・ **符号付き順位検定**… 1 標本の中央値の検定または対応のある 2 標本の差の中央値の検定。符号検定の仮定に加えて、母集団分布の対称性を仮定し、帰無仮説や対立仮説は符号検定と同様です。

(手順 1) Z の符号が「+のデータ」と「-のデータ」に分ける。0 のデータは除く (除いた後のサンプルサイズを改めて n とする)。

(手順 2) $|Z|$ が小さい順に 1 からはじまる順位をつける。タイ (同順位) のケースについては略。

(手順 3) 「+のデータ」の順位の合計 T_+ を検定統計量とする。帰無仮説のもとでは、1 ~ n の順位が $1/2$ の確率で+か-をとるので、 2^n 通りのパターンの中で T_+ 以上に極端な結果となる確率 (P 値) を計算する。または、 n が十分に大きくタイ (同順位) がなければ、帰無仮説のもとで T_+ が近似的に次の正規分布にしたがうことを利用して P 値を計算する。

$$T_+ \sim N \left(\frac{n(n+1)}{4}, \frac{n(n+1)(2n+1)}{24} \right)$$

・ **ウィルコクソンの順位和検定**… 対応のない 2 群の差の検定。 $X_1, \dots, X_m$ は独立に $F(x)$ を累積分布関数とする確率分布にしたがい、 $Y_1, \dots, Y_n$ は独立に $G(x)$ を累積分布関数とする確率分布にしたがい、2 標本は独立とします。 $F(x)$ と $G(x)$ は分布形が同じであることを仮定します。

帰無仮説: $F(x) = G(x)$, 対立仮説: $F(x) = G(x + \delta)$ ($\delta \neq 0$, $\delta > 0$ など)

(手順 1) 2 群のデータをひとまとめにして、値が小さい順に 1 からはじまる順位をつける。

(手順 2) 一方の群の順位和 W を検定統計量とし、2 群のサンプルサイズ m, n が大きく、タイがなければ、帰無仮説のもとで検定統計量が近似的に次の正規分布にしたがうことを利用して検定を行う。

$$W \sim N \left(\frac{m(m+n+1)}{2}, \frac{mn(m+n+1)}{12} \right)$$

サンプルサイズが極めて小さい場合には、次の並べ替え検定と同じ方法でP値を直接求めることも可能。

・ **並べ替え検定**…対応のない2群の差の検定。

帰無仮説：2群の母集団は共通である，対立仮説：2群の母集団は異なる

(手順) 平均値や中央値などの統計量Tを決め，標本を固定したもとでTの分布をつくり，観測値以上に極端な値となる確率(P値)を求める。

・ **クラスカル・ウォリス検定**…3群以上の差の検定。分散分析とは異なり，母集団分布が正規分布であることを仮定することなく，データを順位におきかえて，群ごとに違いがあるかどうかを検定します。帰無仮説は「すべての群の分布が等しい」，対立仮説は「少なくとも1つの群の分布が異なる」

(手順1) 独立なk群の全データをひとまとめにして，値が小さい順に1からはじまる順位をつける。

(手順2) 群ごとのサンプルサイズを $n_1, \dots, n_k (n_1 + \dots + n_k = N)$ ，群ごとの順位の合計を $R_1, \dots, R_k$ ，群ごとの順位の平均を $\bar{R}_1, \dots, \bar{R}_k$ として，タイがなければ検定統計量は，

$$\begin{aligned} H &= \frac{12}{N(N+1)} \sum_{i=1}^k n_i \left(\bar{R}_i - \frac{N+1}{2} \right)^2 \\ &= \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1) \end{aligned}$$

この検定統計量が，サンプルサイズが大きいときに帰無仮説のもとで近似的に自由度 $k-1$ のカイ2乗分布にしたがうことを利用して検定を行います。

・ **順位相関係数**…2変数の順序尺度データの相関係数，または，2変数の量的データを順位におきかえて計算した相関係数。外れ値の影響を受けにくいという特徴があります。サイズ n の2変量順位データを $(x_1, y_1), \dots, (x_n, y_n)$ とすると，タイがなければ， $1 \sim n$ の平均が $(n+1)/2$ であることから，2変数の相関係数は次のように計算できます。

$$\begin{aligned} r_s &= \frac{\sum_{i=1}^n (x_i - \frac{n+1}{2})(y_i - \frac{n+1}{2})}{\sqrt{\sum_{i=1}^n (x_i - \frac{n+1}{2})^2} \sqrt{\sum_{i=1}^n (y_i - \frac{n+1}{2})^2}} \\ &= 1 - \frac{6}{n(n^2-1)} \sum_{i=1}^n (x_i - y_i)^2 \end{aligned}$$

上の r_s を**スピアマンの順位相関係数**と言います。

一方で、2組の順位データ (x_i, y_i) と (x_j, y_j) ($i \neq j$) について、 $(x_i - x_j)(y_i - y_j)$ が正ならば+1, $(x_i - x_j)(y_i - y_j)$ が負ならば-1として、 $n(n-1)/2$ 組の平均を計算したものが**ケンドールの順位相関係数**であり、 $(x_i - x_j)(y_i - y_j)$ が正になる組の数を P , 負になる組の数を N として、次の式で表せます。

$$r_k = \frac{2(P - N)}{n(n - 1)}$$

第14章 マルコフ連鎖

$\{1, 2, \dots, N\}$ のいずれかの値をとる確率変数 X_n を、時点 $n=0, 1, 2, \dots$ の順に並べた確率変数列 $X_0, X_1, X_2, \dots$ が、次の式を満たすとき、この確率変数列を**マルコフ連鎖**と言います。

$$P(X_{n+1} = j | X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1, X_0 = i_0) \\ = P(X_{n+1} = j | X_n = i)$$

とりうる状態の全体 $\{1, 2, \dots, N\}$ を**状態空間**と言い、 i や j は $\{1, 2, \dots, N\}$ のいずれかを表します。このような条件付き確率が n によらずに i と j だけで決まる場合を**斉時的**と言い、その場合だけを考えれば十分です。

・**状態確率ベクトル**…時点 n でそれぞれの状態にある確率を並べたベクトル $\pi_n = (p_n(1), \dots, p_n(N))$ のこと。

特に、 π_0 を**初期分布**と言います。

・**推移確率行列**… $\pi_{n+1} = \pi_n Q$ を満たし、時点 n の各状態から時点 $n+1$ の各状態へ移る確率をまとめた N 次正方行列 Q 。

・**定常分布**… $\pi = \pi Q$ を満たす状態確率ベクトル π のこと。ある条件のもとで、マルコフ連鎖はただ1つの定常分布をもちます。

・**パラメータの推定**…推移確率行列がパラメータ θ を含むとき、観測データ $X_0 = x_0, X_1 = x_1, \dots, X_n = x_n$ を用いて θ を最尤推定するには、次の変形を利用します。

$$P(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n) \\ = P(X_n = x_n | X_{n-1} = x_{n-1}) P(X_0 = x_0, \dots, X_{n-1} = x_{n-1}) \\ \vdots \\ = P(X_n = x_n | X_{n-1} = x_{n-1}) \cdots P(X_1 = x_1 | X_0 = x_0) P(X_0 = x_0)$$

推移確率行列の成分

初期分布 $P(X_0 = x_0)$ が定数として与えられれば、同時確率 $P(X_0 = x_0, X_1 = x_1, \dots, X_n = x_n)$ は推移確率行列の成分の積で表せ、 θ の関数になります。これを尤度関数として、最尤推定値を求めます。

第15章 確率過程の基礎

・ **確率過程**... $X_1, X_2, \dots$ のような確率変数列 $X = (X_t)$ を離散時間の確率過程, t が 0 以上のすべての実数をとるとき, $X = (X_t)$ を連続時間の確率過程と言います。

・ **ブラウン運動**... 離散時間の確率過程であるランダムウォークの時間間隔を短くした極限として得られる連続時間の確率過程で, 次の条件を満たす $B = (B_t)$ のこと。

① $B_0 = 0$ で B のパスは連続

② 【独立増分性】 任意の時間分割 $0 = t_0 < t_1 < \dots < t_n$ に対して, 次のような n 個の増分は互いに独立

$$B_{t_1} - B_{t_0}, B_{t_2} - B_{t_1}, \dots, B_{t_n} - B_{t_{n-1}}$$

③ 【定常増分性】 任意の $t > s \geq 0$ に対して, 増分は, 次のような正規分布にしたがう

$$B_t - B_s \sim N[\mu(t - s), \sigma^2(t - s)]$$

ブラウン運動のパラメータ μ, σ は, 一定の時間間隔 Δ で観測したときの増分 Z_k が $N(\mu\Delta, \sigma^2\Delta)$ にしたがうことを利用して, 次の式によって推定します。

$$\hat{\mu}\Delta = \frac{1}{n} \sum_{k=1}^n Z_k$$

$$\hat{\sigma}^2\Delta = \frac{1}{n} \sum_{k=1}^n Z_k^2 - \left(\frac{1}{n} \sum_{k=1}^n Z_k \right)^2$$

・ **ポアソン過程**... 店に訪れる客の数のように, 0 以上の整数値をとる連続時間の確率過程で, 次の条件を満たす $N = (N_t)$ が強度 λ のポアソン過程です。

① $N_0 = 0$

② 【独立増分性】 任意の時間分割 $0 = t_0 < t_1 < \dots < t_n$ に対して, 次のような n 個の増分は互いに独立

$$N_{t_1} - N_{t_0}, N_{t_2} - N_{t_1}, \dots, N_{t_n} - N_{t_{n-1}}$$

③ 【定常増分性】 任意の $t > 0, s \geq 0$ に対して,

$$P(N_{s+t} - N_s = k) = \frac{e^{-\lambda t} \cdot (\lambda t)^k}{k!} \quad (k = 0, 1, 2, \dots)$$

強度 λ のポアソン過程で、イベントの発生時刻を $T_1, T_2, \dots, T_n$ として、イベント発生の間隔 $W_k = T_k - T_{k-1}$ ($k = 1, 2, \dots, n$) はパラメータ λ の指数分布に独立にしたがうことから、 λ は n/T_n によって推定できることがわかります。また別の方法として、時間間隔 Δ ごとに n 回の観測を行い、観測されたイベントの回数を $N_\Delta, N_{2\Delta}, \dots, N_{n\Delta}$ とすると、 Δ の間に発生したイベントの数 $M_k = N_{k\Delta} - N_{(k-1)\Delta}$ ($k = 1, 2, \dots, n$) は平均 $\lambda\Delta$ のポアソン分布に独立にしたがうことから、 λ は $N_{n\Delta}/n\Delta$ によって推定できることがわかります。どちらの場合も、(イベントの総数) ÷ (観測期間) が推定値になります。

・ **複合ポアソン過程**…あとの①, ②の条件のもとで、次の式で定まる確率過程 $X = (X_t)$

$$X_t = \sum_{k=1}^{N_t} U_k$$

① $N = (N_t)$ はポアソン過程

② (U_k) は独立に同じ分布にしたがう確率変数列で、 N とも独立

複合ポアソン過程 $X = (X_t)$ について、 $E[N_t] = \lambda t$, $E[U_k] = \mu$, $V[U_k] = \sigma^2$ のとき、 $E[X_t] = \lambda \mu t$, $V[X_t] = \lambda t(\mu^2 + \sigma^2)$ が成り立ちます。

第16章 重回帰分析

観測値ベクトル $\mathbf{y} = (y_1, \dots, y_n)^T$, 説明変数行列 $X = (x_{ij})$, 回帰係数ベクトル $\boldsymbol{\beta} = (\beta_0, \dots, \beta_d)^T$, 誤差ベクトル $\boldsymbol{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)^T$ に対し、 $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ は、次のように n 本の式をまとめたものです。

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1d} \\ 1 & x_{21} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nd} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_d \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

・ **最小2乗法**… X を定数行列とみなし、 $X^T X$ が正則であるならば、誤差平方和 $\boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon}$ が最小になるような $\boldsymbol{\beta}$ は次の式のように求められます。

$$\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T \mathbf{y}$$

これを**最小2乗推定量**と言います。 $E[\boldsymbol{\varepsilon}] = \mathbf{0}$ であるとき、最小2乗推定量は $\boldsymbol{\beta}$ の不偏推定量です。また、誤差ベクトル $\boldsymbol{\varepsilon}$ の分散共分散行列が $V[\boldsymbol{\varepsilon}] = E[\boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon}] = \sigma^2 \mathbf{I}$ と表されるとき、最小2乗推定量の分散共分散行列は $\sigma^2 (X^T X)^{-1}$ となります。最小2乗推定量は $\boldsymbol{\beta}$ の最良線形不偏推定量 (BLUE) であり、これを**ガウス・マルコフの定理**と言います。

最小2乗推定量を用いてつくった回帰式から予測される値を並べて、次のように**予測値ベクトル**を定めます。

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

また、**残差ベクトル**は、観測値ベクトルと予測値ベクトルの差として、次のように定めます。

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}$$

残差の自由度は $n-d-1$ であり、残差平方和 $\mathbf{e}^\top \mathbf{e}$ をその自由度でわったものが誤差分散 σ^2 の不偏推定量になります。

・ **決定係数**…次の式のような総変動に対する回帰変動の割合のこと。0以上1以下の値をとり、1に近いほど回帰式のデータへのあてはまりが良いと解釈できますが、モデルの予測性能を表すものではありません。また、説明変数を増やすだけで値が大きくなってしまうという欠点があります。

$$\begin{aligned} R^2 &= \frac{\sum_{i=1}^n \{\hat{\beta}_1(x_{i1} - \bar{x}_1) + \cdots + \hat{\beta}_d(x_{id} - \bar{x}_d)\}^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \\ &= 1 - \frac{\sum_{i=1}^n e_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \end{aligned}$$

・ **自由度調整済み決定係数**…次の式のように、決定係数に自由度による調整を加えたもので、説明変数を増やしただけでは必ずしも値が大きくなりません。

$$\begin{aligned} R^{*2} &= 1 - \frac{\frac{1}{n-d-1} \sum_{i=1}^n e_i^2}{\frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2} \\ &= 1 - \frac{n-1}{n-d-1} (1 - R^2) \end{aligned}$$

・ **回帰係数の推定と検定**…誤差ベクトル $\boldsymbol{\varepsilon}$ が n 変量正規分布 $N(\mathbf{0}, \sigma^2 \mathbf{I})$ にしたがうことを仮定すると、最小2乗推定量は $(d+1)$ 変量正規分布 $N(\boldsymbol{\beta}, \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1})$ にしたがうことを利用して、回帰係数の推定や検定を行うことができます。例えば、 $\beta_i = 0$ を帰無仮説とすると、 $(\beta_i \text{の推定量}) / (\beta_i \text{の標準誤差})$ は自由度 $n-d-1$ の t 分布にしたがい、 $\beta_1 = \beta_2 = \cdots = \beta_d = 0$ を帰無仮説とすると、次の統計量が自由度 $(d, n-d-1)$ の F 分布にしたがうことを利用します。

$$\frac{\frac{1}{d} \sum_{i=1}^n \{\hat{\beta}_1(x_{i1} - \bar{x}_1) + \cdots + \hat{\beta}_d(x_{id} - \bar{x}_d)\}^2}{\frac{1}{n-d-1} \sum_{i=1}^n e_i^2}$$

・ **一般化最小2乗法**…回帰モデルの誤差項が不均一分散であったり、相関がある場合には、通常の最小2乗推定量はBLUEではなくなり、適切な変換を組み込んだ一般化最小2乗推定量がBLUEになります。

・ **正則化**…例えば、多項式回帰モデル $y = \beta_0 + \beta_1 x + \dots + \beta_d x^d$ の次数を十分に大きくすると、誤差2乗和を0にすることができますが、非常に大きな絶対値の回帰係数を用いて学習データに無理やり合わせたモデルとなってしまいます（過学習）。これでは予測性能の面で使いものにならないので、正則化項を追加することで回帰係数の絶対値を制御し、モデルが複雑になりすぎないようにします。

・ **L₂正則化（リッジ回帰）**…定数項を除くパラメータの2乗和を正則化項として、次の式全体が最小になるようにパラメータを推定します。

$$\sum_{i=1}^n \left[y_i - \left(\beta_0 + \sum_{j=1}^d \beta_j x_{ij} \right) \right]^2 + \lambda \sum_{j=1}^d \beta_j^2$$


λ は正則化パラメータと呼ばれ、 $\lambda = 0$ ならば通常の最小2乗法と一致します。 λ を大きくすると、正則化項の影響が大きくなり、回帰係数は0に近い値をとるようになります。

・ **L₁正則化（Lasso回帰）**…定数項を除くパラメータの絶対値の和を正則化項として、次の式全体が最小になるようにパラメータを推定します。


$$\sum_{i=1}^n \left[y_i - \left(\beta_0 + \sum_{j=1}^d \beta_j x_{ij} \right) \right]^2 + \lambda \sum_{j=1}^d |\beta_j|$$

回帰係数の値の多くを、0に近い値ではなく、0と推定する傾向（スパース性）があるため、パラメータの推定とモデル選択を同時に行うことができます。なお、正則化パラメータ λ の適切な値を決める方法としては、第30章で説明する交差検証法があります。

・ **正則化パス**…横軸に $\log \lambda$ 、縦軸に回帰係数の値をとり、正則化パラメータの値の変化に対して、それぞれの回帰係数の値の変化をグラフにしたものです。次のグラフはリッジ回帰における正則化パスの例です。 $\log \lambda$ が大きくなると、回帰係数が0に近い値になっていくことが見てとれます。



次のグラフはLasso回帰における正則化パスの例です。 $\log \lambda$ が大きくなるにつれて、回帰係数が真に0になるものが増えていくことが見てとれます。




・ **Elastic Net**… L_1 正則化と L_2 正則化を混ぜたもので、変数選択と係数の縮小を同時に行います。変数間の相関が高い場合などに有効です。

・ **Fused lasso**…隣接する回帰係数の差に罰則を課す L_1 正則化で、隣接する回帰係数が同じ値になりやすくなります。時系列データなどに適用すると、時間的に滑らかな変化を示すモデルを構築できます。


※Mallows' C_p 規準は出題されないと考えられるので省略。

第17章 回帰診断法

・ **残差プロット**…縦軸に残差、横軸に予測値をとってプロットした次のような図。線形回帰モデルの誤差項は互いに独立で分散が一定であることを仮定していますが、残差プロットに何らかの傾向が見られると、これらの仮定の成立が疑われます。



・ **正規Q-Qプロット**…縦軸に標準化した残差の（経験的）分位点、横軸に標準正規分布の（理論的）分位点をとってプロットした次のような図。線形回帰モデルの誤差項に正規性を仮定するとき、標準化した残差は近似的に標準正規分布にしたがうので、傾き1の直線上に点が並びます。



・ **てこ比**…説明変数の値が他のデータ点から見て極端な位置にあることを見つけるための指標。予測値ベクトル $\mathbf{y}$ ハットは $\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$ と表せますが、この行列 $\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ の対角成分 h_{ii} がてこ比で、てこ比が大きいはずれ値はモデルへの影響が大きいデータ点である可能性があります。

・ **Cookの距離**…1つのデータ点を除いたときの回帰モデルへの影響度の指標。サイズ n のサンプル $(y_1, x_{11}, \dots, x_{1d}), \dots, (y_n, x_{n1}, \dots, x_{nd})$ から求めた予測値を y_1 ハット, $\dots, y_n$ ハットとし、1つのデータ点 $(y_i, x_{i1}, \dots, x_{id})$ を除いたサイズ $n-1$ のデータから求めた予測値を $y_{1(-i)}$ ハット, $\dots, y_{n(-i)}$ ハットとすると、これらのズレを次の式のように計算します。

$$D_i = \frac{\sum_{j=1}^n \{\hat{y}_j - \hat{y}_{j(-i)}\}^2}{(d+1) \cdot \hat{\sigma}^2}$$

※系列相関とDW比は第27章を参照。

第18章 質的回帰

・ **一般化線形モデル**…次の式のように、 $X_1, \dots, X_k$ を与えたもとでの Y の条件付き期待値が、1対1の関数 g を用いて $X_1, \dots, X_k$ の一次結合に一致するようなモデル。 g は Y の条件付き期待値を右辺の線形予測子と結びつける役割を果たしており、**リンク関数**と呼ばれます。また、 Y がしたがう確率分布を**誤差構造**と呼びます。

$$g(E(Y|X_1, \dots, X_k)) = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$$

一般化線形モデルの代表的なものは次の表の通りです。

	リンク関数	誤差構造
線形回帰	恒等関数	正規分布
ロジスティック回帰	ロジット関数	ベルヌーイ分布
プロビット回帰	プロビット関数	ベルヌーイ分布
ポアソン回帰	対数関数	ポアソン分布

線形回帰の目的変数（応答変数）は量的変数ですが、応答変数が2値の質的変数の場合の代表的なモデルには、次のロジスティック回帰モデルとプロビット回帰モデルがあります。

・ **ロジスティック回帰モデル**… $\beta^T \mathbf{x} = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$ として、応答変数 y が2値（0と1）をとる確率を、次のようにモデル化します。

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + \exp(-\beta^T \mathbf{x})}$$

$$P(y = 0|\mathbf{x}) = \frac{\exp(-\beta^T \mathbf{x})}{1 + \exp(-\beta^T \mathbf{x})}$$

このモデルは、 $\mathbf{x}_i$ が与えられたもとで応答変数 y_i が1をとる確率（条件付き期待値）を π_i として次のようにも表せます。

$$\log \frac{\pi_i}{1 - \pi_i} = \beta^T \mathbf{x}_i \quad (*)$$

上の式の左辺は π_i の対数オッズです。左辺の関数はロジット関数と呼ばれ、 $\pi_i \rightarrow (\pi_i \text{の対数オッズ})$ の変換を**ロジット変換**と言います。ロジスティック回帰モデルはロジット関数をリンク関数とする一般化線形モデルです。この式から、他の説明変数の値を固定したまま、j番目の説明変数 x_{ij} の値を1増加させると、 π_i の対数オッズは β_j 増加することがわかります。

また、対数の定義から、上のモデルは次のようにも表せます。

$$\frac{\pi_i}{1 - \pi_i} = \exp(\boldsymbol{\beta}^\top \mathbf{x}_i)$$

上の式から、他の説明変数の値を固定したまま、説明変数 x_{ij} の値を1増加させると、 π_i のオッズが $\exp(\beta_j)$ 倍されることがわかります。

さらに、上の式を π_i について解くと、次のようにも表せます。

$$\begin{aligned} \pi_i &= \frac{1}{1 + \exp(-\boldsymbol{\beta}^\top \mathbf{x}_i)} \\ &= \frac{\exp(\boldsymbol{\beta}^\top \mathbf{x}_i)}{1 + \exp(\boldsymbol{\beta}^\top \mathbf{x}_i)} \quad (**) \end{aligned}$$

上の式の $x \rightarrow \exp(x)/(1 + \exp(x))$ という変換を**ロジスティック変換**と呼びます。これはロジット変換の逆変換です。

ロジスティック回帰モデルのパラメータの推定には最尤法が用いられます。i番目の観測値を $y_i (= 0 \text{ or } 1)$ 、 y_i がしたがうベルヌーイ分布を $\text{Bin}(1, \pi_i)$ とすると、その確率関数は次のように表せます。

$$\pi_i^{y_i} (1 - \pi_i)^{1-y_i}$$

尤度関数はこれらの積なので、サンプルサイズを n として、対数尤度関数は次のように表せます。

$$\begin{aligned} &\log \left[\prod_{i=1}^n \pi_i^{y_i} (1 - \pi_i)^{1-y_i} \right] \\ &= \sum_{i=1}^n [y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i)] \\ &= \sum_{i=1}^n \left[y_i \log \frac{\pi_i}{1 - \pi_i} + \log(1 - \pi_i) \right] \end{aligned}$$

(*)および(**)を代入すると、対数尤度関数は次のように表せます。

$$\sum_{i=1}^n \left[y_i \boldsymbol{\beta}^\top \mathbf{x}_i - \log \{ 1 + \exp(\boldsymbol{\beta}^\top \mathbf{x}_i) \} \right]$$

・ **プロビット回帰モデル**…応答変数が2値の場合，応答変数 y が1をとる確率（条件付き期待値） p を，標準正規分布の累積分布関数 Φ を用いて次のようにモデル化したもの。

$$p = \Phi(\boldsymbol{\beta}^\top \mathbf{x})$$

上の式は次のようにも表せます。

$$\Phi^{-1}(p) = \boldsymbol{\beta}^\top \mathbf{x}$$

上の式の左辺の $p \rightarrow \Phi^{-1}(p)$ の変換を**プロビット変換**と言います。プロビット回帰モデルはプロビット関数をリンク関数とする一般化線形モデルで，パラメータの推定には最尤法を使います。

説明変数の値を増加させたときの p の変化については，上の p の式を説明変数 x_i で偏微分した式を用いて知ることができます。これを**限界効果**と言って，標準正規分布の確率密度関数を ϕ として，次の式で表せます。

$$\frac{\partial p}{\partial x_i} = \phi(\boldsymbol{\beta}^\top \mathbf{x}) \beta_i$$

・ **ポアソン回帰モデル**…一定期間の1店舗の来客数などの0以上のカウントデータの平均 π と，いくつかの説明変数との関係を次のようにモデル化したもの。

$$\log \pi = \boldsymbol{\beta}^\top \mathbf{x} = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k$$

上の式は， $\pi = \exp(\beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k)$ と書き直せるので，説明変数 x_i の値が1増えると，平均 π は $\exp(\beta_i)$ 倍になります。

ポアソン回帰モデルのパラメータの推定も最尤法によって行うことができます。

・ **指数型分布族**…一般化線形モデルにおける応答変数 Y は，正規分布，二項分布，ポアソン分布など，理論上の性質が良い確率分布にしたがうことを仮定します。この確率分布のファミリーを指数型分布族と呼び，その確率（密度）関数は次のように表せます。

$$f(y; \theta, \phi) = \exp \left[\frac{y\theta - b(\theta)}{a(\phi)} - c(y, \phi) \right]$$

ここで， $a(\cdot)$ ， $b(\cdot)$ ， $c(\cdot)$ は既知の関数で， θ は正準母数， ϕ は散らばり母数と呼ばれます。例えば，正規分布の確率密度関数は次のように変形できます。

$$\begin{aligned}
 f(y; \theta, \phi) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right] \\
 &= \exp \left[\frac{y\mu - \frac{1}{2}\mu^2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \frac{1}{2} \log(2\pi\sigma^2) \right]
 \end{aligned}$$

正規分布の確率密度関数は、指数型分布族の確率密度関数の一般式において、次のようにおいたものになっています。

$$\begin{aligned}
 \theta &= \mu, \quad \phi = \sigma^2, \quad a(\phi) = \phi, \\
 b(\theta) &= \frac{1}{2}\theta^2, \quad c(y, \phi) = \frac{1}{2} \left[\frac{y^2}{\phi} + \log(2\pi\phi) \right]
 \end{aligned}$$

また、指数型分布族の確率分布にしたがう確率変数Yの期待値、分散は次のように計算できます。

$$E[Y] = b'(\theta), \quad V[Y] = b''(\theta)a(\phi)$$

実際に、正規分布にしたがう確率変数Yについて、 $E[Y] = \mu$ 、 $V[Y] = \sigma^2$ となることが確認できます。

第19章 回帰分析その他

・**トービットモデル**…Yを目的変数とした回帰モデルをつくりたいが、Yが0以上の値しかとらないというケースがよくあります。このような場合に、 $Y^* = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$ などの回帰モデルで表せる潜在変数Y*を考え、Y*が0以下の場合には $Y = 0$ 、Y*が0より大きい場合には $Y = Y^*$ とするのがトービットモデルの例です。

では、データ $(x_1, y_1) \dots, (x_n, y_n)$ に対して、次のトービットモデルを考え、尤度関数を構成します。

$$\begin{aligned}
 y_i^* &= \beta_0 + \beta_1 x_i + \varepsilon_i \quad (i = 1, 2, \dots, n) \\
 y_i &= \begin{cases} y_i^* & (y_i^* > 0) \\ 0 & (y_i^* \leq 0) \end{cases}
 \end{aligned}$$

ここで、 ε_i は互いに独立に正規分布 $N(0, \sigma^2)$ にしたがう誤差項であるとする、 x_i を与えたもとで、 y_i^* は次の正規分布にしたがいます。

$$y_i^* \sim N(\beta_0 + \beta_1 x_i, \sigma^2)$$

つまり、 $y_i^* > 0$ のとき、 $y_i (= y_i^*)$ の確率密度関数は次の式になります。

$$\frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \right)^2 \right]$$

標準正規分布の確率密度関数を $\phi(x)$ とすると、上の y_i の確率密度関数は次のように表せます。

$$\frac{1}{\sigma} \phi \left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \right)$$

次に、 $y_i^* \leq 0$ となる確率は、 y_i^* の確率密度関数を使って次のように表せます。

$$P(y_i^* \leq 0) = \int_{-\infty}^0 \frac{1}{\sigma} \phi \left(\frac{y - (\beta_0 + \beta_1 x_i)}{\sigma} \right) dy$$

上の被積分関数 $\phi(\cdot)$ のかっこ内を z と置換すると、次のようになります。

$$\int_{-\infty}^{-\frac{\beta_0 + \beta_1 x_i}{\sigma}} \phi(z) dz = \Phi \left(-\frac{\beta_0 + \beta_1 x_i}{\sigma} \right)$$

ここで、上の式の右辺の $\Phi(\cdot)$ は、標準正規分布の累積分布関数です。よって、尤度関数は、 $y_i^* > 0$ となる i に関する確率密度関数の積と $y_i^* \leq 0$ となる i に関する累積分布関数の積を合わせて、次のようになります。

$$\prod_{i: y_i > 0} \frac{1}{\sigma} \phi \left(\frac{y_i - (\beta_0 + \beta_1 x_i)}{\sigma} \right) \times \prod_{i: y_i \leq 0} \Phi \left(-\frac{\beta_0 + \beta_1 x_i}{\sigma} \right)$$

・ **生存時間**…入院してから退院するまでの時間や就職してから退職するまでの時間など、基準となる時点からイベントが発生するまでの時間。

・ **生存関数**…生存時間が t 以上である確率のことであり、生存時間を表す確率変数 T の確率密度関数を $f(x)$ として、次の式で表されるような $S(t)$ です。

$$S(t) = P(T \geq t) = \int_t^{\infty} f(x) dx$$

累積分布関数を $F(t)$ として、 $S(t) = 1 - F(t)$ の関係があり、 $S(t)$ を t で微分すると、次のようになります。

$$\frac{d}{dt}S(t) = \frac{d}{dt}\{1 - F(t)\} = -f(t)$$

・ **ハザード関数**…時刻 t における瞬間イベント発生率（時刻 t までイベントが発生していない条件のもとで直後にイベントが発生する条件付き確率）を表す関数で、次のように確率密度関数と生存関数を用いて表せる $h(t)$ です。

$$h(t) = \frac{f(t)}{S(t)} = -\frac{d}{dt} \log S(t)$$

・ **累積ハザード関数**…次のようにハザード関数を積分したものであり、最右辺のように生存関数を用いて表せます。

$$H(t) = \int_0^t h(x)dx = -\log S(t)$$

確率密度関数は、ハザード関数と累積ハザード関数を用いて次のように表せます。

$$f(t) = h(t) \exp[-H(t)]$$

・ **カプラン・マイヤー法**…生存時間に特定の確率分布を仮定することなく、生存関数を推定する方法。例えば、時点 t までに、次の表のような k 時点でイベントが発生した場合を考えます。

イベントの発生時点	$t_1, t_2, \dots, t_k$
イベントの発生数	$d_1, d_2, \dots, d_k$
直前のリスク集合	$n_1, n_2, \dots, n_k$

このとき、時点 t における生存率を次の式で計算します。

$$\frac{n_1 - d_1}{n_1} \times \frac{n_2 - d_2}{n_2} \times \dots \times \frac{n_k - d_k}{n_k}$$

このような計算を観察期間全体について行い、その結果をプロットしてできる階段状のグラフを**カプラン・マイヤー曲線**と言います。

・ **Cox比例ハザードモデル**…イベントの発生に影響を与えることが想定される共変量を $x_1, \dots, x_n$ として、次のようにハザード関数を表すモデル。

$$\begin{aligned}
 h(t; \mathbf{x}) &= h_0(t) \exp(\mathbf{x}^\top \boldsymbol{\beta}) \\
 &= h_0(t) \exp(\beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n)
 \end{aligned}$$

$h_0(t)$ は**基準ハザード**（ベースラインハザード）と呼ばれる正の値をとる t の関数で、特定の分布形を仮定しません。Cox比例ハザードモデルをあてはめる場合には、**比例ハザード性**（ハザード比が時間によって変化しない）を確認する必要があります。

・ **ニューラルネットワークモデル**… d 個の入力 $x_1, x_2, \dots, x_d$ にそれぞれの重み $w_1, w_2, \dots, w_d$ をかけ、これらの積の合計にバイアス b を加えた $\mathbf{w}^\top \mathbf{x} + b = b + w_1 x_1 + \cdots + w_d x_d$ の入力を受けた1つのユニットは、活性化関数 f を施して $f(\mathbf{w}^\top \mathbf{x} + b)$ を出力します。このようなユニットを層状に並べ、層自体も複数並べたものがニューラルネットワークモデルです。各ユニットに非線形活性化関数を使用することで、複雑な非線形関係をモデル化することが可能になります。

第20章 分散分析と実験計画法

2級で学習した1元配置分散分析は3群以上の母平均の差の検定でした。まず、基本となる用語を確認しておくと、観測データに影響を与える可能性のあるもののうち、実験で取り上げるものを**因子**、因子がとりうる一つひとつの条件を**水準**、複数の因子の水準の組み合わせを**処理**と言います。因子が2つ以上の場合も含めて、一般的に分散分析は、複数の因子の主効果とそれらの交互作用効果の有無を評価する検定といえます。

・ **フィッシャーの3原則**

- ①無作為化…処理をランダムに割り当てる
- ②反復…同じ処理を複数回行う
- ③局所管理…ブロック内で均一な条件を実現

上の①と②を満たすものを完全無作為化法、①～③のすべてを満たすものを乱塊法と言います。

・ **1元配置完全無作為化法**…応答変数 Y に関して1つの因子を取り上げ、 $A_1, \dots, A_a$ の水準ごとの母平均を $\mu_1, \dots, \mu_a$ 、水準の効果を $\alpha_1, \dots, \alpha_a$ とすると、構造モデルは次の式です。

$$\begin{aligned}
 Y_{ij} &= \mu_i + \varepsilon_{ij} = \mu + \alpha_i + \varepsilon_{ij} ; \varepsilon_{ij} \sim N(0, \sigma^2) \\
 (i &= 1, 2, \dots, a, j = 1, 2, \dots, n_i)
 \end{aligned}$$

ただし、水準ごとのくり返し数を $n_1, \dots, n_a$ ($n_1 + \cdots + n_a = n$) として、 $n_1 \alpha_1 + \cdots + n_a \alpha_a = 0$ が成り立つものとし、 μ は次の式で定まる一般平均です。

$$\mu = \frac{1}{n} \sum_{i=1}^a n_i \mu_i$$

次に、第 i 水準の標本平均と標本全体の平均を次のように定めます。

$$\bar{y}_{i.} = \frac{1}{n_i} \sum_{j=1}^{n_i} y_{ij}, \quad \bar{y}_{..} = \frac{1}{n} \sum_{i=1}^a \sum_{j=1}^{n_i} y_{ij}$$

上記の記号を用いると、平方和の分解は次のようになります。

$$\sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{..})^2 = \sum_{i=1}^a \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_{i.})^2 + \sum_{i=1}^a n_i (\bar{y}_{i.} - \bar{y}_{..})^2$$

上の式の左辺を**総平方和**、右辺第1項を**誤差（残差）平方和**、右辺第2項を**水準間平方和**と呼び、それぞれ S_T , S_E , S_A と表します。これらの平方和を自由度でわったものを**平均平方（分散）**と呼び、次のような分散分析表にまとめます。

	平方和	自由度	分散	F値
水準間	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{2}$
誤差	S_E	$n - a$	$\frac{1}{n-a} S_E \cdots \textcircled{2}$	
合計	S_T	$n - 1$		

帰無仮説を「すべての水準の母平均は等しい」、対立仮説は「少なくとも1つの水準の母平均が異なる」として、 $\textcircled{1} \div \textcircled{2}$ の統計量が $F(a-1, n-a)$ にしたがうことを利用して検定します。

水準の母平均の区間推定を行うには、上の表の②が誤差分散 σ^2 の推定値であることを使います。この推定値を σ^2 ハットと表すと、 i 番目の水準の母平均の信頼度95%の信頼区間は次の通りです。

$$\bar{y}_i \pm t_{0.025}(n-a) \frac{\hat{\sigma}}{\sqrt{n_i}}$$

・ **1元配置乱塊法**…1元配置完全無作為化法にブロック $R_1, \dots, R_r$ を取り入れたもので、ブロック因子を γ_j として、構造モデルは次の式です。

$$Y_{ij} = \mu + \alpha_i + \gamma_j + \varepsilon_{ij} ; \varepsilon_{ij} \sim N(0, \sigma^2)$$

$$(i = 1, 2, \dots, a, j = 1, 2, \dots, r)$$

ただし、 $\alpha_1 + \dots + \alpha_a = 0$, $\gamma_1 + \dots + \gamma_r = 0$ が成り立つものとします。平方和の分解は次の式です。

$$\sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \bar{y}_{..})^2$$

$$= \sum_{i=1}^a \sum_{j=1}^r (\bar{y}_{i.} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^r (\bar{y}_{.j} - \bar{y}_{..})^2 + \sum_{i=1}^a \sum_{j=1}^r (y_{ij} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{y}_{..})^2$$

上の式の右辺第1項は水準間平方和、第2項はブロック平方和、第3項は誤差平方和であり、ブロック平方和を S_R と表すと、分散分析表は次のようになります。

	平方和	自由度	分散	F値
水準間	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{3}$
ブロック	S_R	$r - 1$	$\frac{1}{r-1} S_R \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{3}$
誤差	S_E	$(a-1)(r-1)$	$\frac{1}{(a-1)(r-1)} S_E \cdots \textcircled{3}$	
合計	S_T	$ar - 1$		

因子の効果については、 $\textcircled{1} \div \textcircled{3}$ の統計量が $F[a-1, (a-1)(r-1)]$ にしたがうことを利用し、ブロックの効果については、 $\textcircled{2} \div \textcircled{3}$ の統計量が $F[r-1, (a-1)(r-1)]$ にしたがうことを利用して検定します。

・ **2元配置完全無作為化法**…2つの因子を考えるのが2元配置法で、それぞれの因子の効果（**主効果**）だけでなく、2つの因子の組み合わせ効果（**交互作用**）まで調べることができます。2つの因子をA、Bとし、 $A_1, \dots, A_a$ の水準の効果を $\alpha_1, \dots, \alpha_a$ 、 $B_1, \dots, B_b$ の水準の効果を $\beta_1, \dots, \beta_b$ とし、交互作用があることを仮定するとき、構造モデルは次の式です。

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk} ; \varepsilon_{ijk} \sim N(0, \sigma^2)$$

$$(i = 1, 2, \dots, a, j = 1, 2, \dots, b, k = 1, 2, \dots, n)$$

ただし、 $\alpha_1 + \dots + \alpha_a = 0$ 、 $\beta_1 + \dots + \beta_b = 0$ が成り立つものとし、交互作用項については次の式が成り立つものとします。

$$\sum_{i=1}^a (\alpha\beta)_{ij} = \sum_{j=1}^b (\alpha\beta)_{ij} = 0$$

平方和の分解は次の式です。

$$\begin{aligned}
& \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (y_{ijk} - \bar{y}_{...})^2 \\
&= bn \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2 + an \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...})^2 \\
&\quad + n \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2 + \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^n (y_{ijk} - \bar{y}_{ij.})^2
\end{aligned}$$

上の式の右辺第1項はAの水準間平方和、第2項はBの水準間平方和、第3項は交互作用平方和、第4項は誤差平方和であり、それぞれ S_A 、 S_B 、 $S_{A \times B}$ 、 S_E と表すと、分散分析表は次のようになります。

	平方和	自由度	分散	F値
A	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{4}$
B	S_B	$b - 1$	$\frac{1}{b-1} S_B \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{4}$
A×B	$S_{A \times B}$	$(a - 1)(b - 1)$	$\frac{1}{(a-1)(b-1)} S_{A \times B} \cdots \textcircled{3}$	$\textcircled{3} \div \textcircled{4}$
誤差	S_E	$ab(n - 1)$	$\frac{1}{ab(n-1)} S_E \cdots \textcircled{4}$	
合計	S_T	$abn - 1$		

①÷④の統計量は $F[a-1, ab(n-1)]$ 、②÷④の統計量は $F[b-1, ab(n-1)]$ 、③÷④の統計量は $F[(a-1)(b-1), ab(n-1)]$ にしたがうことを利用して検定します。

・ **2元配置乱塊法**…2元配置完全無作為化法にブロック $R_1, \dots, R_r$ を取り入れたもので、ブロック因子を γ_k として、構造モデルは次の式です。

$$\begin{aligned}
Y_{ijk} &= \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \gamma_k + \varepsilon_{ijk} ; \varepsilon_{ijk} \sim N(0, \sigma^2) \\
&(i = 1, 2, \dots, a, j = 1, 2, \dots, b, k = 1, 2, \dots, r)
\end{aligned}$$

ただし、2元配置完全無作為化法における α_i 、 β_j 、 $(\alpha\beta)_{ij}$ の制約に加え、 $\gamma_1 + \dots + \gamma_r = 0$ が成り立つものとします。平方和の分解は次の式です。

$$\begin{aligned}
& \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (y_{ijk} - \bar{y}_{...})^2 \\
&= br \sum_{i=1}^a (\bar{y}_{i..} - \bar{y}_{...})^2 + ar \sum_{j=1}^b (\bar{y}_{.j.} - \bar{y}_{...})^2 + ab \sum_{k=1}^r (\bar{y}_{..k} - \bar{y}_{...})^2 \\
&\quad + r \sum_{i=1}^a \sum_{j=1}^b (\bar{y}_{ij.} - \bar{y}_{i..} - \bar{y}_{.j.} + \bar{y}_{...})^2 + \sum_{i=1}^a \sum_{j=1}^b \sum_{k=1}^r (y_{ijk} - \bar{y}_{ij.} - \bar{y}_{..k} + \bar{y}_{...})^2
\end{aligned}$$

上の式の右辺第1項はAの水準間平方和、第2項はBの水準間平方和、第3項はブロック平方和、第4項は交互作用平方和、第5項は誤差平方和であり、それぞれ S_A 、 S_B 、 S_R 、 $S_{A \times B}$ 、 S_E と表すと、分散分析表は次のようになります。

	平方和	自由度	分散	F値
A	S_A	$a - 1$	$\frac{1}{a-1} S_A \cdots \textcircled{1}$	$\textcircled{1} \div \textcircled{5}$
B	S_B	$b - 1$	$\frac{1}{b-1} S_B \cdots \textcircled{2}$	$\textcircled{2} \div \textcircled{5}$
A×B	$S_{A \times B}$	$(a - 1)(b - 1)$	$\frac{1}{(a-1)(b-1)} S_{A \times B} \cdots \textcircled{3}$	$\textcircled{3} \div \textcircled{5}$
ブロック	S_R	$r - 1$	$\frac{1}{r-1} S_R \cdots \textcircled{4}$	$\textcircled{4} \div \textcircled{5}$
誤差	S_E	$(ab - 1)(r - 1)$	$\frac{1}{(ab-1)(r-1)} S_E \cdots \textcircled{5}$	
合計	S_T	$abr - 1$		

・ **直交表**…因子の数や水準の数が増えるにしたがい、すべての水準組み合わせの実験を実施するのはコストが大きくなるため、一部の交互作用のみを取り上げることで実験の回数を減らしたものが**一部実施要因計画**で、そのために用いるのが直交表です。例えば、次の直交表は水準の数が2つの因子を割り付けるために使われるものです。

	[1]	[2]	[3]	[4]	[5]	[6]	[7]
①	1	1	1	1	1	1	1
②	1	1	1	2	2	2	2
③	1	2	2	1	1	2	2
④	1	2	2	2	2	1	1
⑤	2	1	2	1	2	1	2
⑥	2	1	2	2	1	2	1
⑦	2	2	1	1	2	2	1
⑧	2	2	1	2	1	1	2
成分	a	b	ab	c	ac	bc	abc

上の表の①～⑧の行は実験を表していて、いくつかの列には因子を対応（割り付けと言う）させます。例えば、[3]の列に因子A、[6]の列に因子Bを割り付ければ、①は A_1B_1 での実験、②は A_1B_2 での実験、…という感じで、⑧までで4つの水準組み合わせの実験を2回ずつ行う計画になります。上の表のいちばん下の行の「成分」は列の性質を表していて、[3]の成分の“ab”と[6]の成分の“bc”の積は、 $b^2 = 1$ より、 $ab \times bc = ac$ となります。これは、[3]に割り付けた因子Aと[6]に割り付けた因子Bの交互作用が[5]に現れることを意味します。したがって、3つの2水準因子A、B、Cの主効果と交互作用 $A \times B$ について調べる場合に、Aを[3]、Bを[6]に割り付け、Cを[5]に割り付けたら、Cの主効果と交互作用 $A \times B$ が区別できなくなります。このことを**交絡**と言います。

なお、上の直交表は $L_8(2^7)$ と呼ばれるもので、2が水準の数、7が列の数、8は実験の数を表しています。

第21章 標本調査法

調査単位と抽出単位が一致していて、各標本を抽出する確率が等しい抽出法が**単純無作為抽出**で、それ以外の抽出法としては、調査者が決めた基準にしたがって標本を抽出する**有意抽出法**などがあります。以下では、単純無作為抽出かつ非復元抽出（同じ対象を2回以上抽出しない）の場合を考えます。

・ **標本平均の期待値と分散**…大きさNの母集団（母平均 μ 、母分散 σ^2 ）から大きさnの標本を非復元単純無作為抽出するとき、母平均の推定量として標本平均 $\bar{X}$ を用いると、その期待値、分散は次のようになります。

$$E(\bar{X}) = \mu, \quad V(\bar{X}) = \frac{N - n}{N - 1} \cdot \frac{\sigma^2}{n}$$

無限母集団の場合や復元抽出の場合と比べて、標本平均の分散には $(N - n)/(N - 1)$ がかけられており、これを**有限修正項**と言います。標本平均の分散を一定値以下におさえるにはサンプルサイズnをある程度大きくす

ればよく、 $V(\bar{X}) \leq c$ という不等式を解けば、 n は次の不等式の右辺以上でなければならないことがわかります。

$$n \geq \frac{N\sigma^2}{\sigma^2 + (N-1)c}$$

・**層化抽出法**…企業を大企業、中小企業、零細企業の3つに分けるように、基準を決めていくつかの層に分けた後、それぞれの層から無作為抽出する方法です。できるだけ層内を均質に、層間を異質に層化すれば、事前に層化しない場合よりも精度の高い結果を得やすくなります。

・**標本配分法**…層化抽出法での各層（層の数を k とする）からの標本の大きさ $n_1, \dots, n_k$ ($n_1 + \dots + n_k = n$) の決め方として、代表的なものを3つ紹介します。次の式のように、層の大きさを $N_1, \dots, N_k$ ($N_1 + \dots + N_k = N$) として、層の大きさの比で標本の配分を決めるのが**比例配分法**です。

$$\frac{n_1}{N_1} = \frac{n_2}{N_2} = \dots = \frac{n_k}{N_k} = \frac{n}{N}$$

比例配分法のもとでの標本平均の分散は、単純無作為抽出の場合の標本平均の分散を超えないことを示すことができます。

次の式のように、それぞれの層からの標本の大きさがすべて等しいような決め方が**等配分法**です。

$$n_1 = n_2 = \dots = n_k = \frac{N}{k}$$

推定量の分散が最小になるような決め方が**ネイマン配分法**で、 j 番目の層の母標準偏差を σ_j として、標本の大きさは次の式で決めます。

$$n_j = \frac{N_j \sigma_j \sqrt{\frac{N_j}{N_j - 1}}}{\sum_{j=1}^k N_j \sigma_j \sqrt{\frac{N_j}{N_j - 1}}} \times n$$

層の大きさが十分に大きい場合には、ルートの部分を1とみなして、次の式で表せます。つまり、層の大きさ×層内標準偏差の比で配分することになります。

$$n_j = \frac{N_j \sigma_j}{\sum_{j=1}^k N_j \sigma_j} \times n$$

※集落抽出法，二段抽出法，系統抽出法は，2級内容のため，[統計検定2級のチートシート](#)を参照してください。

第22章 主成分分析

相関のある p 変数 $x_1, x_2, \dots, x_p$ を，相関のない p 変数 $y_1, y_2, \dots, y_p$ で $V[y_1] \geq V[y_2] \geq \dots \geq V[y_p]$ を満たすものに再編成する手法。分散共分散行列からはじめる場合と相関行列からはじめる場合があります。

分散共分散行列に対する主成分分析では， $x_1, x_2, \dots, x_p$ に関する標本分散共分散行列の固有値を $\lambda_1, \lambda_2, \dots, \lambda_p$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$)，対応するノルム1の固有ベクトルを $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_p$ とするととき， $\mathbf{w}_i = (w_{1i}, \dots, w_{pi})$ と表せば，第 i 主成分は次のようになります。

$$y_i = w_{1i}(x_1 - \bar{x}_1) + \dots + w_{pi}(x_p - \bar{x}_p)$$

第 i 主成分の分散は λ_i で， $V[x_1] + V[x_2] + \dots + V[x_p] = \lambda_1 + \lambda_2 + \dots + \lambda_p$ です。

相関行列に対する主成分分析では，標準化された変数を $z_1, z_2, \dots, z_p$ ， $x_1, x_2, \dots, x_p$ に関する標本相関行列の固有値を $\lambda_1, \lambda_2, \dots, \lambda_p$ ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$)，対応するノルム1の固有ベクトルを $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_p$ とするととき， $\mathbf{w}_i = (w_{1i}, \dots, w_{pi})$ と表せば，第 i 主成分は次のようになります。

$$y_i = w_{1i}z_1 + \dots + w_{pi}z_p$$

第 i 主成分の分散は λ_i で， $\lambda_1 + \lambda_2 + \dots + \lambda_p = p$ です。

- ・ **寄与率**…分散の合計のうち，ある主成分の分散が占める割合。例えば，第1主成分の寄与率は， $\lambda_1 / (\lambda_1 + \lambda_2 + \dots + \lambda_p)$
- ・ **累積寄与率**…寄与率を大きいほうから合計したもので，例えば，第2主成分までの累積寄与率は， $(\lambda_1 + \lambda_2) / (\lambda_1 + \lambda_2 + \dots + \lambda_p)$ です。次元削減を目的とする場合には，「累積寄与率が80%を超えるまでの主成分だけを使う」といった目安として使われます。
- ・ **主成分得点**…データの主成分軸上での値。例えば，相関行列に対する主成分分析の第 i 主成分得点は，上の y_i の式の右辺の $z_1, z_2, \dots, z_p$ に各データを標準化した値を代入したもの。
- ・ **主成分負荷量**…分散共分散行列に対する主成分分析では，もとの変数の1つと1つの主成分の相関係数であり，例えば，上の y_i と x_2 との相関係数（主成分負荷量）は次の式で計算できます。

$$\frac{\sqrt{\lambda_i} w_{2i}}{\sqrt{V[x_2]}}$$

相関行列に対する主成分分析では、標準化された変数の1つと1つの主成分の相関係数であり、上の主成分負荷量の式の分母は1になります。

・ **自己符号化器**…ニューラルネットワークモデル（第19章参照）の一種で、入力 $\mathbf{x}$ を低次元の表現に変換（**符号化**）した後、この低次元表現から元の入力に近いデータを再構築（**復号化**）することを目的としており、主成分分析と同じように、データの圧縮や特徴抽出に利用されます。自己符号化器は2つの主要な部分から構成され、入力 $\mathbf{x}$ に変換 $\mathbf{y} = f(\mathbf{w}^T \mathbf{x} + b)$ を適用する符号化器と、この $\mathbf{y}$ に次の変換を適用する復号化器です。

$$\tilde{\mathbf{x}} = \tilde{f}(\tilde{\mathbf{w}}^T \mathbf{y} + \tilde{b})$$

元の入力 $\mathbf{x}$ にできるだけ近い出力が得られるように、符号化器と復号化器の重みとバイアスを調整します。

第23章 判別分析

あらかじめグループ分けが判明しているデータを学習して、新たに得られたデータが属するグループを特徴量に基づいて判定する手法。分類規則の与え方には様々なものがあります。

・ **フィッシャーの線形判別分析**…2変数(x_1, x_2)の場合を例とし、 $Y = w_1 x_1 + w_2 x_2$ という1次式で、 Y の値によって属するグループをより良く判別できるように $\mathbf{w} = (w_1, w_2)^T$ を決めます。そのために、群間変動 $\mathbf{w}^T S_B \mathbf{w}$ を群内変動 $\mathbf{w}^T S_W \mathbf{w}$ でわった比が最大になるようにすればいいと考えます。ここで、2群の学習データの標本平均ベクトルを $\bar{\mathbf{x}}^{(1)}, \bar{\mathbf{x}}^{(2)}$ とすると、 $S_B = (\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})(\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})^T$ であり、 S_W は2群のプールされた標本分散共分散行列です。この最適化問題の解 $\mathbf{w}$ は次の式で与えられます。

$$\hat{\mathbf{w}} = S_W^{-1}(\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})$$

よって、2群の標本平均ベクトルの中点を基準として、次の関数が正になるか、負になるかによって、新たなデータの属する群を判定します。

$$f(\mathbf{x}) = \hat{\mathbf{w}}^T \mathbf{x} - \frac{1}{2}(\bar{\mathbf{x}}^{(1)} - \bar{\mathbf{x}}^{(2)})^T S_W^{-1}(\bar{\mathbf{x}}^{(1)} + \bar{\mathbf{x}}^{(2)})$$

この関数 $f(\mathbf{x})$ を**フィッシャーの線形判別関数**と言います。

・ **マハラノビス距離による判別**…データの標本平均ベクトルを $\bar{\mathbf{x}}$ 、標本分散共分散行列を S とすると、次の $D^2(\mathbf{x})$ を $\mathbf{x}$ と $\bar{\mathbf{x}}$ の**マハラノビス平方距離**と言います。

$$D^2(\mathbf{x}) = (\mathbf{x} - \bar{\mathbf{x}})^T S^{-1}(\mathbf{x} - \bar{\mathbf{x}})$$

$\mathbf{x}$ と2群の標本平均ベクトル $\bar{\mathbf{x}}^{(1)}$, $\bar{\mathbf{x}}^{(2)}$ とのマハラノビス平方距離を比べて、小さいほうの群に $\mathbf{x}$ が属すると判別するとき、2群のプールされた標本分散共分散行列 S_W を使った次の関数が正ならば $\mathbf{x}$ は群2、負ならば群1と考えることができます。

$$(\mathbf{x} - \bar{\mathbf{x}}^{(1)})^\top S_W^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(1)}) - (\mathbf{x} - \bar{\mathbf{x}}^{(2)})^\top S_W^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(2)})$$

上の関数はフィッシャーの線形判別関数の-2倍に等しくなり、2種類の判別は一致します。

また、群1の標本分散共分散行列を S_1 、群2の標本分散共分散行列を S_2 として、次の関数により群の判別を行うことを**2次判別分析**と言います。

$$(\mathbf{x} - \bar{\mathbf{x}}^{(1)})^\top S_1^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(1)}) - (\mathbf{x} - \bar{\mathbf{x}}^{(2)})^\top S_2^{-1} (\mathbf{x} - \bar{\mathbf{x}}^{(2)})$$

・ **ベイズ判別**…データ $\mathbf{x}$ を与えたもとで、群1に属する事後確率 $P(G_1|\mathbf{x})$ の群2に属する事後確率 $P(G_2|\mathbf{x})$ に対する比の対数は、ベイズの定理を用いて次の式の右辺のように表せます。

$$\log \frac{P(G_1|\mathbf{x})}{P(G_2|\mathbf{x})} = \log P(\mathbf{x}|G_1) - \log P(\mathbf{x}|G_2) + \log \frac{P(G_1)}{P(G_2)}$$

上の式の $P(G_1)$, $P(G_2)$ は事前確率であり、各群に属する事前確率を分類規則に反映できるのがベイズ判別です。 $P(G_1)=P(G_2)$ と2群のデータが同一の分散共分散行列をもつ多変量正規分布にしたがうことを仮定すれば、マハラノビス距離による判別と一致します。

・ **正準判別分析**… p 変数($x_1, \dots, x_p$)の g 個の群 $G_1, \dots, G_g$ を2次元や3次元などの低次元への射影を利用する判別分析。 g 個の群をできるだけよく分離できるような射影軸 $y = w_1x_1 + \dots + w_px_p = \mathbf{w}^\top \mathbf{x}$ の係数ベクトル $\mathbf{w}$ は、フィッシャーの線形判別分析と同じように、群間変動 $\mathbf{w}^\top S_B \mathbf{w}$ を群内変動 $\mathbf{w}^\top S_W \mathbf{w}$ でわった比の最大化を通して、 $S_W^{-1} S_B$ の最大の固有値に対する固有ベクトルとして求められます。なお、 S_B と S_W は、第 i 群について、標本平均ベクトルを $\bar{\mathbf{x}}^{(i)}$ 、サンプルサイズを n_i 、標本分散共分散行列を S_i 、学習データ全体の標本平均ベクトルを $\bar{\mathbf{x}}$ として、次のように定義します。

$$S_B = \sum_{i=1}^g n_i (\bar{\mathbf{x}}^{(i)} - \bar{\mathbf{x}})(\bar{\mathbf{x}}^{(i)} - \bar{\mathbf{x}})^\top, \quad S_W = \sum_{i=1}^g (n_i - 1) S_i$$

同じように、次に最適な射影軸の係数ベクトルは、 $S_W^{-1} S_B$ の2番目に大きな固有値に対する固有ベクトルとして求められます。

・ **ハードマージンSVM**…超平面によって線形分離可能な場合のSVM（サポートベクターマシン）。超平面 $\mathbf{w}^\top \mathbf{x} + b = 0$ によって2群に分けると、その超平面に最も近い学習データを**サポートベクター**と言い、**マージン**（サポートベクターから超平面までの距離）を最大にするように $\mathbf{w}$, b を決定します。具体的には、デー

タ $\mathbf{x}_i$ のクラスラベルを表す変数を y_i として, $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1$ ($i = 1, 2, \dots, n$) のもとで, $0.5 \|\mathbf{w}\|^2$ を最小化することで, 次のように求められます。

$$\hat{\mathbf{w}} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\hat{b} = -\frac{1}{2} \hat{\mathbf{w}}^T (\mathbf{x}_+ + \mathbf{x}_-)$$

ただし, ラグランジュ乗数の α_i には最適化問題の解を代入し, $\mathbf{x}_+$ は $y_i = 1$ を満たすサポートベクター, $\mathbf{x}_-$ は $y_i = -1$ を満たすサポートベクターです。

・ **ソフトマージンSVM**…線形分離可能でない場合に, はみ出したデータに罰則を課す線形SVM。はみ出しを表すスラック変数を $\xi_i \geq 0$ として, $y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$ のもとで, 次の和が最小になる $\mathbf{w}$ と ξ_i を求めます。

$$\frac{1}{2} \|\mathbf{w}\|^2 + \lambda \sum_{i=1}^n \xi_i$$

λ ははみ出しに対する罰則の強さを決めるパラメータで, λ が大きいと罰則が強く, ξ_i の和はあまり大きな値をとれません。


・ **混同行列**…判別器による判別結果を次の表の形式でまとめたもの。

予測


		Y = 1	Y = 0
実 際	Y = 1	TP	FN
	Y = 0	FP	TN

上の表のPは予測結果が陽性 (positive) , Nは予測結果が陰性 (negative) であることを示しています。TPR = TP/(TP+FN)は, 実際にY = 1であるもののうち, 正しくY = 1と予測できた割合で, **真陽性率**と言います。また, FPR = FP/(FP+TN)は, 実際にY = 0であるもののうち, 誤ってY = 1と予測した割合で, **偽陽性率**と言います。例えば, 次の図の青の点は合格者の偏差値, 黄色の点は不合格者の偏差値で, 緑の破線の右側を合格, 左側を不合格と判別するとしましょう。

合格する確率



緑の破線を右端から左へ移動させると、合格者6人のデータを合格と判定した後、1人の不合格者のデータを合格と判定し、最終的には全員を合格と判定ようになります。このように、 $TP=FP=0$ の状態から、 $FN=TN=0$ の状態へ移る過程を、横軸にFPR、縦軸にTPRをとって、グラフにしたもの（下の図の赤い線）が**ROC曲線**で、ROC曲線と横軸で囲まれた部分の面積が**AUC**（曲線下面積）です。



上の図では、 $AUC=0.88$ であり、AUCが1に近いほど、判別器の性能が良いと言えます。なお、TPRを**感度（再現率）**， $1-FPR$ を**特異度**とも言います。病気の判別では、感度は病気にかかっている人を漏らさずに陽性と判定する割合を意味するので、高いことが重要です。また、全サンプルを健康と予測するモデルだと特異度が1になります。

第24章 クラスター分析

分類の手本がない状態で、近さを測る指標（距離など）を定めて、データをグループ分け（クラスタリング）する手法。 $\mathbf{x}=(x_1, \dots, x_p)$ と $\mathbf{y}=(y_1, \dots, y_p)$ の距離として、最も問われやすいのは次のユークリッド距離です。

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_p - y_p)^2}$$

・**階層的クラスタリング**…1つのデータ（個体）を1つのクラスターとみなし、距離の近いクラスターを順次融合していくクラスタリング。融合の過程を表した図を**デンドログラム**と言います。データ間の距離をユーク

リッド距離などによって定め、それをもとにクラスター間の距離を次の最短距離法、最長距離法、群平均法、重心法、ウォード法などによって定めます。

・ **最短距離法（最近隣法）** … 2つのクラスターから1個体ずつ選んで求めた距離のうち、最も短い距離をクラスター間の距離とする方法。鎖効果を起こしやすく、クラスター構造が捉えにくい場合があります。

・ **最長距離法（最遠隣法）** … 2つのクラスターから1個体ずつ選んで求めた距離のうち、最も長い距離をクラスター間の距離とする方法。

・ **群平均法** … 2つのクラスターから1個体ずつ選んで求めた距離の平均をクラスター間の距離とする方法。

・ **重心法** … クラスター内の重心どうしの距離をクラスター間の距離とする方法。

・ **ウォード法** … クラスター内のデータの重心からの距離の2乗和の増分が最小となるクラスターを順に合併していく方法。

・ **K-means法** … 非階層的クラスタリングの代表例であり、クラスタリングの手順の一例は次の通りです。

- ① クラスターの数を決める
- ② クラスター中心をランダムに決める
- ③ 全データと各クラスター中心との距離を計算する
- ④ 中心との距離が最も近いクラスターにデータを振り分ける
- ⑤ クラスターの重心を計算して中心を更新する
- ⑥ ③～⑤をくり返してデータのクラスター間の移動がなくなったら終了

※混合分布とEMアルゴリズムについては第6章を参照。

第25章 因子分析・グラフィカルモデル

5教科の得点を総合的な学力と教科ごとの能力で捉えるように、多数の観測変数間の構造を明らかにする目的で、それらに影響を与える少数の**共通因子**と変数ごとの**独自因子**を想定した分析。例えば、3つの観測変数 x_1, x_2, x_3 を考えると、これらを平均0、分散1に標準化した上で、何個の共通因子によって説明するかを決めます。ここでは、2つの共通因子 f_1, f_2 を仮定するとして、2因子モデルは次のように表せます。

$$x_1 = \beta_{11}f_1 + \beta_{12}f_2 + d_1$$

$$x_2 = \beta_{21}f_1 + \beta_{22}f_2 + d_2$$

$$x_3 = \beta_{31}f_1 + \beta_{32}f_2 + d_3$$


β_{ij} は**因子負荷量**と呼ばれる係数です。 d_1, d_2, d_3 は独自因子を表していて、 f_1, f_2, d_1, d_2, d_3 はすべて互いに独立で、 $E[f_1]=E[f_2]=0$ 、 $V[f_1]=V[f_2]=1$ 、 $E[d_1]=E[d_2]=E[d_3]=0$ を仮定します。 d_1 の分散を σ_1^2 とすると、観測変数 x_1 の分散について、 $\beta_{11}^2 + \beta_{12}^2 + \sigma_1^2 = 1$ が成り立ちます。このとき、 $\beta_{11}^2 + \beta_{12}^2$ を**共通性**、 σ_1^2 を**独自性**と言います。観測変数の変動のうち、共通因子で説明できる部分が共通性、説明できない部分が独自性だと解釈します。

・ **寄与率** … すべての観測変数の変動を、それぞれの共通因子がどれだけ説明できているかを表すもので、上の例の f_1 の寄与率は次の式で計算できます。

$$\frac{1}{3} \sum_{i=1}^3 \beta_{i1}^2$$

・ **因子軸の回転**…回転によって因子負荷量を解釈しやすいものにとり直すことが可能です。因子軸が直交した状態での回転（直交回転）の代表例が**バリマックス回転**で、因子軸が必ずしも直交しない回転（斜交回転）の代表例が**プロマックス回転**です。

・ **操作変数法**…次のような図を**パス図**と呼び、ここに示される因果関係を $Z = aX + bY + u$, $Y = cX + v$ という式（**構造方程式**）で表すことができます。



a, b, c は**パス係数**と呼ばれます。 $E[X] = E[Y] = E[Z] = 0$, $V[X] = V[Y] = V[Z] = 1$, 誤差項 u は X, Y と、 v は X とそれぞれ無相関であることを仮定した上で、構造方程式に変数（**操作変数**と言う）をかけて期待値をとることで、次の例のようにパス係数を相関係数を用いて表すことができます。（例） $Y = cX + v \rightarrow E[XY] = cE[X^2] + E[vX] \rightarrow c = r_{XY}$

$Z = aX + bY + u$ で同じように計算すると、 $r_{XZ} = a + bc$ が得られます。このとき、 a は $X \rightarrow Z$ の**直接効果**、 bc は $X \rightarrow Y \rightarrow Z$ のように Y を介した**間接効果**であり、両者を合わせて**総合効果**と呼ばれます。

・ **グラフィカルモデル**…確率変数ベクトル $(X_1, \dots, X_d)$ が d 変量正規分布にしたがっているとき、グラフィカルモデルでは、これらの変数を頂点に対応させ、変数間の条件付き独立性を辺の有無で表現します。例えば、相関行列の逆行列の $(1, 2)$ 成分が0ならば、 X_1 と X_2 が他の変数を与えたもとで条件付き独立だと言えます。このように間接的な関係しかない変数どうしには辺をひかず、直接的な関係にある変数どうしを辺で結んでできるのが無向独立グラフです。

第26章 その他の多変量解析手法

・ **多次元尺度構成法**…個体間の距離が与えられたときに、その距離関係を保つような個体の座標を求める手法。特に、2～3次元の座標で表すことで個体間の位置関係を視覚化できます。計算方法は次の通り。

① 与えられた n 次距離行列 D に対して、 n 次単位行列を I_n 、すべての成分が1の n 次正方行列を J_n として、次の行列 B を計算

$$B = -\frac{1}{2} \left(I_n - \frac{1}{n} J_n \right) D \left(I_n - \frac{1}{n} J_n \right)$$

② Bの固有値, 互いに直交するノルム1の固有ベクトルを求める。正の固有値を対角成分に並べた行列を Λ , 固有ベクトルを並べた行列をUとして, $B = U\Lambda U^T$ と表せることに注意

③ $XX^T = B$ を満たす行列Xとして, $X = U\Lambda^{0.5}$ ($\Lambda^{0.5}$ は対角成分に固有値の正の平方根を並べたもの) がとれる。例えば, 2次元座標で表すには, 並べる固有ベクトル, 固有値を2つずつにする

・ **正準相関分析**… $\mathbf{x} = (x_1, x_2, \dots, x_p)^T$ と $\mathbf{y} = (y_1, y_2, \dots, y_q)^T$ の変数間の相関係数はpq通りあるため, p, q が大きいときには相関関係の把握が煩雑になりやすいです。そこで, $u = a_1x_1 + a_2x_2 + \dots + a_px_p$ と $v = b_1y_1 + b_2y_2 + \dots + b_qy_q$ の相関係数が最大になるように $\mathbf{a} = (a_1, a_2, \dots, a_p)$ と $\mathbf{b} = (b_1, b_2, \dots, b_q)$ を決めて, $\mathbf{x}$ と $\mathbf{y}$ の関係を理解しようとするのが正準相関分析です。このような相関係数の最大化は, 行列の固有値問題に帰着し, 最大の固有値に対する固有ベクトルとして1組の $\mathbf{a}$ と $\mathbf{b}$ が得られます。この固有ベクトルを $\mathbf{a}_1, \mathbf{b}_1$ としてできる $u_1 = \mathbf{a}_1^T \mathbf{x}$ と $v_1 = \mathbf{b}_1^T \mathbf{y}$ の組を第1正準変数と呼び, 同じように2番目に大きい固有値に対する固有ベクトル $\mathbf{a}_2, \mathbf{b}_2$ から u_1, v_1 と無相関であるような u_2, v_2 が得られ, 第2正準変数と呼びます。

(以下同様)

・ **数量化法**…質的データなどを「数量化」して多変量解析の枠組みで分析する手法です。下の表などを通して数量化Ⅰ～Ⅲ類の区別を覚え, 理論の概要を知っておきましょう。

説明変数 目的変数	間隔尺度	名義尺度
間隔尺度	重回帰分析	数量化Ⅰ類
名義尺度	判別分析	数量化Ⅱ類

また, 数量化Ⅲ類は, いわば主成分分析の名義尺度版であり, アンケートデータのような○と×のデータから得られる相関をもとに固有値を計算してデータを縮約します。

数量化Ⅰ類や数量化Ⅱ類では, 変数が説明変数と目的変数に二分されていて, この場合に目的変数を説明変数に関する**外的基準**と呼びます。一方で, 数量化Ⅲ類では変数どうしの関係は対等であり, 内部構造に基づく分析であるため, 外的基準のない手法と言えます。

第27章 時系列解析

月や年など, 時間軸にそって観測されるのが時系列データであり, 確率変数 Y_t ($t = 1, 2, \dots$) で表します。

・ **弱定常過程 (共分散定常過程)** …平均と分散が一定であり, 自己共分散が時点によらずラグのみによって決まる時系列。 h 次の自己共分散を $\text{Cov}[Y_t, Y_{t-h}] = \gamma_h$ と表すと, $V[Y_t] = V[Y_{t-h}] = \gamma_0$ であり, h 次の自己相関係数は γ_h/γ_0 です。

・ **ホワイトノイズ**…平均が0, 分散が一定で, 0でないラグに対する自己共分散がすべて0である時系列で, 弱定常過程の一種。以下では, U_t は分散 σ^2 のホワイトノイズを表すものとします。

・ **p次自己回帰過程[AR(p)]**…現在の値が過去p時点の値の影響と現在の偶然変動により説明できるとする次のようなモデル。

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + U_t$$

例えば, AR(1)過程 $Y_t = c + \phi_1 Y_{t-1} + U_t$ ならば, $|\phi_1| < 1$ のときに弱定常になり, このときの Y_t の期待値, 分散, 自己共分散, 自己相関係数は次のようにまとめることができます。

期待値	分散	h次の自己共分散	h次の自己相関係数
$\frac{c}{1 - \phi_1}$	$\frac{\sigma^2}{1 - \phi_1^2}$	$\frac{\phi_1^h \sigma^2}{1 - \phi_1^2}$	ϕ_1^h

・ **q次移動平均過程[MA(q)]**…現在の値が過去q時点の偶然変動の影響と現在の偶然変動により説明できるとする次のようなモデル。

$$Y_t = c + U_t + \theta_1 U_{t-1} + \cdots + \theta_q U_{t-q}$$

移動平均過程は弱定常です。MA(1)モデル $Y_t = c + U_t + \theta_1 U_{t-1}$ のとき, 期待値, 分散, 自己共分散, 自己相関係数は次のようにまとめることができます。

期待値	分散	自己共分散		自己相関係数	
		1次	2次以上	1次	2次以上
c	$(1 + \theta_1^2)\sigma^2$	$\theta_1 \sigma^2$	0	$\frac{\theta_1}{1 + \theta_1^2}$	0

・ **(p,q)次自己回帰移動平均過程[ARMA(p,q)]**…AR過程とMA過程の両方の性質をもつ次のようなモデル。

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + U_t + \theta_1 U_{t-1} + \cdots + \theta_q U_{t-q}$$

ただし, $p = 0$ の場合はMA過程, $q = 0$ の場合はAR過程, $p = q = 0$ の場合はホワイトノイズとします。AR過程の部分が弱定常であるときにARMA過程は弱定常になりますが, 次の方程式のすべての解の絶対値が1より大きいことと同値です。

$$1 - \phi_1 z - \phi_2 z^2 - \cdots - \phi_p z^p = 0$$

・ **(p,1,q)次自己回帰和分移動平均過程[ARIMA(p,1,q)]**…弱定常過程ではない $\{Y_t\}$ で、差分系列 $\Delta Y_t = Y_t - Y_{t-1}$ が弱定常かつ反転可能なARMA過程になるもの。ここで、反転可能とは、MA過程がAR過程に書き直せることを言い、次の方程式のすべての解の絶対値が1より大きいことと同値です。

$$1 + \theta_1 z + \theta_2 z^2 + \cdots + \theta_q z^q = 0$$

・ **ディッキー・フラー検定**…AR(1)モデル $Y_t = \phi Y_{t-1} + U_t$ にしたがう $\{Y_t\}$ について、帰無仮説を $\phi = 1$ 、対立仮説を $|\phi| < 1$ とする検定。

・ **状態空間モデル**…通常は観測できない状態の変化を記述する状態方程式と、その状態から観測値が得られる過程を記述する観測方程式を組み合わせたものです。このモデルは、ARMAモデルを含む様々な時系列データを表現できます。状態方程式は、時点 $t-1$ での状態に時点 t での誤差を加えた形で表され、観測方程式は、時点 t での状態に時点 t での観測誤差を加えた形ですが、ARMAモデルのような特定の一般式をもつわけではなく、モデルの形は扱う時系列データの特性に応じて変化します。

・ **ACFとPACF**…弱定常過程では、 h 次の自己相関係数は γ_h/γ_0 と表せますが、これを h の関数と見たものが自己相関関数（ACF）です。また、 Y_t と Y_{t-h} の h 次の自己相関係数には、その間にある $Y_{t-1}, \dots, Y_{t-h+1}$ の影響が含まれていますが、この影響を取り除いたものが h 次の偏自己相関係数で、これを h の関数と見たものが偏自己相関関数（PACF）です。AR(p)モデル、MA(q)モデル、ARMA(p,q)モデルのACFとPACFは次のような特徴をもちます。

モデル	ACF	PACF
AR(p)	h とともに減衰	$p+1$ 次以降は0
MA(q)	$q+1$ 次以降は0	h とともに減衰
ARMA(p, q)	h とともに減衰	h とともに減衰

なお、（標本）自己相関関数のグラフはコレログラムと呼ばれます。

・ **ダービン・ワトソン検定**…時系列データに回帰モデルをあてはめたときに、残差に自己相関（**系列相関**）が見られる場合があり、そのような系列相関の有無を判定するための検定。誤差項 u_t にAR(1)モデル $u_t = \rho u_{t-1} + U_t$ を仮定し、帰無仮説を $\rho = 0$ とします。検定統計量は、最小2乗法で推定したときの残差を e_t として、次の式で表せます。

$$DW = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2} \doteq 2(1 - \hat{\rho})$$

上の式の ρ ハットは1次の自己相関係数の推定値で、この値が0に近ければDWの値は2に近くなりますから、DWの値が2から離れて0や4に近くなるときに帰無仮説を棄却することになります。

・ **スペクトル密度関数(スペクトラム)**…時系列の変動を様々な周期成分によって表し、その特徴を分析します。

(例1) AR(1)モデル $Y_t = c + \phi Y_{t-1} + U_t$ ($-1 < \phi < 1$) のスペクトル密度関数は次の $f(\lambda)$ になるので、 $\phi > 0$ ならば低周波で大きな値、 $\phi < 0$ ならば高周波で大きな値をとり、 ϕ の絶対値が大きいほど周波数による違いが顕著になります。

$$f(\lambda) = \frac{\sigma^2}{2\pi} \cdot \frac{1}{1 + \phi^2 - 2\phi \cos \lambda}$$

(例2) MA(1)モデル $Y_t = c + U_t + \theta U_{t-1}$ のスペクトル密度関数は次の $f(\lambda)$ になるので、 $\theta > 0$ ならば低周波で大きな値、 $\theta < 0$ ならば高周波で大きな値をとり、 θ の絶対値が大きいほど周波数による違いが顕著になります。

$$f(\lambda) = \frac{\sigma^2}{2\pi} (1 + \theta^2 + 2\theta \cos \lambda)$$

真のスペクトラムを推定するために標本から求められる推定値を与えるのが**ペリオドグラム**です。

第28章 分割表

a個のカテゴリをもつ変数Xとb個のカテゴリをもつ変数Yのab通りのカテゴリの組み合わせについて、カウントされたデータを表にまとめたものがa×b分割表です。このとき、変数を**因子**、各カテゴリを**水準**と呼び、2因子の分割表を2元分割表と言います。因子の数が3、4、…ならば、3元分割表、4元分割表、…と言います。

・ **相対リスク**…例えば、ある疾患の発症率を、喫煙群と非喫煙群で比べる場合、発症率の差ではなく、発症率の比をとることがあり、これを相対リスクと言います。例えば、喫煙群の発症率が0.15、非喫煙群の発症率が0.03ならば、相対リスクは、 $0.15 \div 0.03 = 5$

・ **前向き研究**…研究開始以降に被験者の状態の変化を記録する研究。

・ **後向き研究**…研究開始以前のデータをもとに行う研究。

・ **コホート研究**…特定の集団(コホート)を追跡し、処置とアウトカム(病気など)の関連を調べる研究。

・ **ケースコントロール研究**…特定のアウトカムをもつ被験者とまたない被験者を比較し、過去のリスク要因を調べる研究。

・ **オッズ**…失敗の確率に対する成功の確率の比。例えば、ある疾患から5年以内に回復する確率が0.8ならば、回復しない確率は0.2なので、オッズは、 $0.8 \div 0.2 = 4$

・ **オッズ比**…オッズの比。例えば、疾患Aから5年以内に回復するオッズが6、疾患Bから5年以内に回復するオッズが2ならば、オッズ比は、 $6 \div 2 = 3$

ここで、次の2元分割表を考えます。ある手術を受けた患者が退院までにかかった日数が10日以上かどうかを年齢別に集計したものです。

表 1

	10日未満	10日以上	合計
65歳未満	5	1	6
65歳以上	4	8	12
合計	9	9	18

・ **標本オッズ**…分割表の度数から求められる母オッズの推定値。例えば、上の表 1 で、年齢別に10日未満で退院した人数を10日以上で退院した人数でわった値が標本オッズであり、65歳未満なら、 $5 \div 1 = 5$ 、65歳以上なら、 $4 \div 8 = 0.5$ となります。

・ **標本オッズ比**…標本オッズの比であり、母オッズ比の推定値。例えば、上の表 1 で標本オッズ比は、 $5 \div 0.5 = 10$ となります。また、標本オッズ比の対数の標準誤差はサンプルサイズが大きければ簡単な式で近似できます。サンプルサイズが小さすぎますが、あえて表 1 の度数でその計算方法を示すと、次のようになります。

$$\sqrt{\frac{1}{5} + \frac{1}{1} + \frac{1}{4} + \frac{1}{8}} \approx 1.255$$

・ **フィッシャーの正確検定**…2元分割表で、2つの変数が独立であるかどうかをP値を直接計算することによって検定する手法。次の表 2 は、表 1 と同じ設定で、年齢と退院までの日数が独立だとしたときの2元分割表です。

表 2

	10日未満	10日以上	合計
65歳未満	3	3	6
65歳以上	6	6	12
合計	9	9	18

表 2 で、年齢ごとの標本オッズを計算すると、65歳未満も65歳以上も 1 なので、標本オッズ比は 1 となります。このように、独立ならば標本オッズはほぼ同じ値になると考えられるので、標本オッズ比が 1 に近ければ独立である可能性が高く、1 から離れた値ならば独立ではない可能性が高くなります。「年齢と退院までの日数が独立 = オッズ比が 1」という帰無仮説を仮定し、「65歳未満のほうが10日未満の退院が多い = オッズ比が 1 より大きい」を対立仮説とすると、実際に観測された表 1 以上に極端な結果となる場合として、次の表 3 が考えられます。

表 3

	10日未満	10日以上	合計
65歳未満	6	0	6
65歳以上	3	9	12
合計	9	9	18

各行の合計と各列の合計を固定した上で、65歳未満で10日以内に退院した人数は帰無仮説のもとで超幾何分布にしたがうので、独立なのに偶然に表1の度数になる確率と偶然に表3の度数になる確率は次のように計算できます。

$$\frac{{}_6C_5 \times {}_{12}C_4}{{}_{18}C_9} + \frac{{}_6C_6 \times {}_{12}C_3}{{}_{18}C_9} = \frac{29}{442}$$

片側P値は約0.0656なので、有意水準を5%とすれば有意ではありません。つまり、年齢と退院までの日数が独立なのに、度数がたまたま表1のようになったという可能性を否定できないことになります。

・ **独立性の検定**…フィッシャーの正確検定と同じように、2元分割表の2つの変数が独立であるかどうかを検定する手法として、分割表の度数が十分に大きい場合にカイ2乗分布を用いる手法があります。a×b分割表において、全体の度数の合計をn、i行目j列目のセルの度数を n_{ij} 、i行目の度数の合計を $n_{i.}$ 、j列目の度数の合計を $n_{.j}$ と表すと、検定統計量は次の式で計算できます。

$$\sum_{i=1}^a \sum_{j=1}^b \frac{\left(n_{ij} - \frac{n_{i.}n_{.j}}{n} \right)^2}{\frac{n_{i.}n_{.j}}{n}}$$

nが大きいとき、この検定統計量は、「2つの変数が独立」という帰無仮説のもとで近似的に自由度(a-1)(b-1)のカイ2乗分布にしたがうことを利用して検定します。

特に、2×2分割表では、 n_{11} 、 n_{12} 、 n_{21} 、 n_{22} をそれぞれa、b、c、dとすると、上の検定統計量は次の式で表せます。

$$\frac{(a+b+c+d)(ad-bc)^2}{(a+b)(c+d)(a+c)(b+d)}$$

この2×2分割表における検定統計量に第12章で紹介したイエーツの補正を施すと、 $a+b+c+d=n$ として、次の式になります。

$$\frac{n(|ad - bc| - 0.5n)^2}{(a+b)(c+d)(a+c)(b+d)}$$

なお、分割表のすべての度数を r 倍すると、カイ2乗統計量も r 倍になります。分割表の行と列の数が変わらなければ自由度は変化しないので、独立性の検定はサンプルサイズを増やすだけで有意になりやすくなります。そこで、分割表のすべての度数を r 倍しても変化しない指標として、次のようなクラメールの連関係数 V を用いることがあります。

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

ただし、上の式で χ^2 はカイ2乗統計量、 n はサンプルサイズ、 k は分割表の行の数と列の数のうちの大きくないほうの数を表しています。クラメールの連関係数 V は0以上1以下の値をとり、1に近いほど2元分割表の2つの変数に関連があることを示唆します。

・ **逸脱度**…特定の統計モデルの分割表のデータへのあてはまりを判断するための統計量。 $a \times b$ 分割表において、フルモデルのもとでの尤度といくつかのパラメータを0とおいたモデルのもとでの尤度の比を λ 、 i 行 j 列の観測度数を x_{ij} 、モデルのもとでの期待度数を m_{ij} として、逸脱度は次の式で表せます。

$$2 \log \lambda = 2 \sum_{i=1}^a \sum_{j=1}^b x_{ij} \log \frac{x_{ij}}{m_{ij}}$$

サンプルサイズ n が十分に大きいとき、この統計量は帰無仮説のもとで近似的にカイ2乗分布にしたがい、逸脱度の自由度は、帰無仮説のもとでの自由に値を決められるパラメータ数と対立仮説のもとでの自由に値を決められるパラメータ数の差になります。

・ **対数線形モデル**…分割表の因子間の独立性や条件付き独立性を解析するために使われるモデル。例えば、3元分割表におけるフルモデルは、3因子 $A_i B_j C_k$ に属する同時確率を p_{ijk} として、次の式の右辺のように、主効果項 $\alpha_i, \beta_j, \gamma_k$ 、交互作用項 $(\alpha\beta)_{ij}, (\alpha\gamma)_{ik}, (\beta\gamma)_{jk}, (\alpha\beta\gamma)_{ijk}$ を用いて表せます。

$$\log p_{ijk} = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk}$$

ただし、 $a \times b \times c$ 分割表ならば、 $i = 1, \dots, a, j = 1, \dots, b, k = 1, \dots, c$ であり、次の制約を課します。

$$\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = \sum_{k=1}^c \gamma_k = 0$$

$$\sum_{i=1}^a (\alpha\beta)_{ij} = \sum_{j=1}^b (\alpha\beta)_{ij} = 0 \quad (\alpha\gamma)_{ik} \text{ や } (\beta\gamma)_{jk} \text{ も同様}$$


$$\sum_{i=1}^a (\alpha\beta\gamma)_{ijk} = \sum_{j=1}^b (\alpha\beta\gamma)_{ijk} = \sum_{k=1}^c (\alpha\beta\gamma)_{ijk} = 0$$

交互作用項がある場合、それに含まれる低次の交互作用項と主効果項をすべて含むものを**階層的対数線形モデル**と言います。また、主効果項からはじめて、より高次の交互作用項をたどることで、極大項が見つけれられます。これを**生成集合**と言います。

3 因子の階層的対数線形モデルのうち、フルモデル以外は大きく分けて次の3通りに分類できます。

	記号	生成集合
完全独立モデル	$A \perp\!\!\!\perp B \perp\!\!\!\perp C$	A/B/C
周辺独立モデル	$A \perp\!\!\!\perp (B, C)$	A/BC
条件付き独立モデル	$A \perp\!\!\!\perp B C$	AC/BC

・**無向独立グラフ**…因子を頂点に対応させて、モデルに2因子交互作用が含まれている2頂点の間に辺をひいたグラフ。例えば、3元分割表におけるフルモデルに対応する無向独立グラフは次の図のようになります。



・**グラフィカルモデル**…与えられた無向独立グラフのクリーク（極大な完全部分グラフをなす頂点集合）が生成集合となる階層的対数線形モデル。無向独立グラフに対して、ただ1つ定まります。

・**分解可能モデル**…対応する無向独立グラフが長さ4以上の弦のない閉路を持たないグラフィカルモデル。このモデルのもとでは、分割表の周辺度数を使って、特定の水準組み合わせの同時確率や期待度数が計算できます。

第29章 不完全データの統計処理

欠測（データの一部が観測されない）の例として、次のような場合などが考えられます。

・**打ち切り**…あらかじめ期間が決められている製品の寿命検査のように、ある値以上（または以下）であるこ

とはわかるが、その値自体は得られないタイプの欠測。

・ **トランケーション**…特定の幅の値しか観測できず、この幅に入っていないデータの個数もわからないタイプの欠測。

欠測メカニズムは、大きく分けて次の3つに分類されます。

MCAR	すべての欠測は完全にランダムに生じる
MAR	欠測は完全にランダムではないが、観測されている変量によって説明できる
MNAR	欠測は観測されている変量だけでは完全には説明できず、観測されていない変量の影響を受ける

欠測に対する主な対応として、次のCC解析、単一代入法、多重代入法があります。

・ **CC(complete case)解析**…少なくとも1つの変量に欠測が生じた個体を除いた解析。サンプルサイズが小さくなるため、推定精度や検出力が下がり、MCAR以外の場合にはバイアスが生じます。

・ **単一代入法**…欠測値に適切な値を埋め込み、擬似的な完全データを作成する方法。代表的なものは次の通り。

平均値代入	観測データの平均値を使う。分散を過小評価することになり、MCAR以外の場合は平均にも偏りが生じる
回帰代入	観測データから求めた回帰モデルによる予測値を使う。MNAR以外ならば平均に偏りは生じないが、分散は過小評価となる
Hot Deck法	同じデータセット内で類似のデータを使う。適切なデータを探すのに手間がかかる

・ **多重代入法**…欠測値に適切な値を埋め込んだ複数組の擬似的な完全データを作成し、独立に推定値を計算し、最後にそれらの結果を統合する手法。不確実性をつくり出し、単一代入法で起こりがちな誤差の過小評価を補正します。

・ **1変量正規分布における推測**… $X \sim N(\mu, \sigma^2)$ であり、標準正規分布の確率密度関数を $\phi(x)$ 、累積分布関数を $\Phi(x)$ 、 $a = (c - \mu)/\sigma$ として、 $X \geq c$ のもとでの X の条件付き期待値は、次のように表せます。

$$E[X|c \leq X] = \mu + \frac{\phi(a)}{1 - \Phi(a)}\sigma$$

c 以上の値が観測されない打ち切りのケースで、母平均 μ が未知、母分散 σ^2 が既知であるとき、上の条件付き期待値を用いて、母平均 μ の最尤推定値を求める手順は、サンプルサイズを n 、観測されたデータのサイズを m ($m < n$) として、次の①～④です。

- ① $\mu^{(0)}$ を観測されたサイズ m のデータの平均とする
- ② $t = 0, 1, 2, \dots$ に対し、 $\mu^{(t)}$ をもとに次の式で $a^{(t)}$ を計算

$$a^{(t)} = \frac{c - \mu^{(t)}}{\sigma}$$

- ③ $a^{(t)}, \mu^{(t)}$ をもとに $\mu^{(t+1)}$ を次の式で計算

$$\mu^{(t+1)} = \frac{1}{n} \left[\sum_{i=1}^m x_i + (n - m) \left(\mu^{(t)} + \frac{\varphi(a^{(t)})}{1 - \Phi(a^{(t)})} \sigma \right) \right]$$

- ④ $\mu^{(t)}$ が収束するまで②と③をくり返す

同じ設定でトランケーションの場合、母平均 μ の最尤推定値は次の①～④の手順で求めます。

- ① $\mu^{(0)}$ を観測されたサイズ m のデータの平均とする
- ② $t = 0, 1, 2, \dots$ に対し、 $\mu^{(t)}$ をもとに次の式で $a^{(t)}$ を計算

$$a^{(t)} = \frac{c - \mu^{(t)}}{\sigma}$$

- ③ $a^{(t)}$ をもとに次の式で $\mu^{(t+1)}$ を計算

$$\mu^{(t+1)} = \bar{x} + \frac{\varphi(a^{(t)})}{\Phi(a^{(t)})} \sigma$$

- ④ $\mu^{(t)}$ が収束するまで②と③をくり返す

・ **2変量正規分布における推測**… $(X, Y)^T$ が次の2変量正規分布にしたがうものとします。

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix} \right]$$

欠測は Y のみに生じて、観測されたデータを $(x_1, y_1), \dots, (x_m, y_m), x_{m+1}, \dots, x_n$ ($m < n$) とし、欠測メカニズムがMARだとするとき、パラメータの推定値は次の手順で求めます。

- ① μ_X, σ_X^2 の最尤推定値をサイズ n のデータを使って、次の式で計算

$$\hat{\mu}_X = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}_X^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_X)^2$$

② サイズmのデータを使って、 $\bar{x}$, S_X^2 , $\bar{y}$, S_Y^2 , S_{XY} を次の式で計算

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \quad S_X^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2$$

$$\bar{y} = \frac{1}{m} \sum_{i=1}^m y_i, \quad S_Y^2 = \frac{1}{m} \sum_{i=1}^m (y_i - \bar{y})^2$$

$$S_{XY} = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})(y_i - \bar{y})$$

③ ②で求めた統計量をもとに、Xを与えたもとでのYの条件付き分布を $N(\alpha + \beta x, \tau^2)$ と表したときの α , β , τ^2 を計算

④ α , β , τ^2 を使って、次の式で μ_Y , σ_Y^2 , σ_{XY} の最尤推定値を計算

$$\hat{\mu}_Y = \alpha + \beta \hat{\mu}_X$$

$$\hat{\sigma}_Y^2 = \tau^2 + \beta^2 \hat{\sigma}_X^2$$

$$\hat{\sigma}_{XY} = \beta \hat{\sigma}_X^2$$

なお、MCARの場合には、単純に観測されている $(x_1, y_1), \dots, (x_m, y_m)$ のみを用いてMARの②のように計算するだけでよく、 $x_{m+1}, \dots, x_n$ から $y = \alpha + \beta x$ によって求めた y の値を使うこともXとYに相関がある場合には効果的です。

第30章 モデル選択

- ・ **AIC (赤池情報量規準)** …… $2 \times (\text{最大対数尤度}) + 2 \times (\text{推定するパラメータ数})$
- ・ **BIC (バイズ情報量規準)** …… $2 \times (\text{最大対数尤度}) + \log(n) \times (\text{推定するパラメータ数})$

どちらの情報量規準も、候補となる統計モデルの中から、相対的に数値が小さいものを最適なモデルとして選びます。

例えば、説明変数がp個の次の重回帰モデルを考え、サンプルサイズをnとし、誤差項が独立に同一の正規分布にしたがうことを仮定します。

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon$$

上の重回帰モデルに対して、誤差分散の最尤推定量を σ^2 ハット2乗として、AICは次のように表せます。

$$n \log(2\pi\hat{\sigma}^2) + n + 2(p + 2)$$

ここで、推定するパラメータ数は、説明変数の数+切片+誤差分散= $p+2$ であることに注意します。上の重回帰モデルに対するBICは、AICの第3項の先頭の2を $\log(n)$ でおきかえて、次のようになります。

$$n \log(2\pi\hat{\sigma}^2) + n + (p + 2) \log n$$

$\log(n) > 2$ を満たすサンプルサイズである場合がほとんどなので、BICのほうがAICよりモデルのパラメータ数に対する罰則が強く、よりパラメータ数の少ないモデルを選ぶ傾向があります。また、BICにはモデル選択の一致性があり、候補となる統計モデルの中に真のモデルがあるとき、 $n \rightarrow \infty$ で真のモデルを選ぶ確率が1に収束します。

・ **交差検証法（クロスバリデーション）**…データを訓練用とテスト用に分け、訓練用データによるパラメータの推定とテスト用データによる予測誤差の検証をくり返し、予測誤差が最小となるモデルを見つけ出す方法。

・ **Leave-one-out法**…サンプルサイズを n として、次の手順でモデルを選択する交差検証法。

- ① i 番目のデータを取り除き、それ以外の $n-1$ 個を訓練用としてモデルを推定する
- ② 推定したモデルを用いて、 i 番目のデータに対する予測誤差を求める
- ③ すべての i ($i=1, 2, \dots, n$) についての予測誤差の平均によってモデルを評価する

・ **k分割交差検証法**…データをほぼ同じサイズの k 個のグループに分割して、そのうちの1個のグループをテスト用、それ以外の $k-1$ 個のグループを訓練用とし、予測誤差を k 回求めることをくり返す交差検証法。 $k=n$ の場合がLeave-one-out法。

第31章 ベイズ法

ベイズ法では、確率分布のパラメータ自体が確率分布にしたがうことを仮定し、このパラメータについて、データを得る前の分布を得られたデータの情報を反映した分布に更新する仕組みがベイズ法です。

・ **共役事前分布**…事前分布と事後分布が同じタイプの確率分布になるような事前分布。次の表の3種類は覚えておきましょう。

事前分布	標本分布	事後分布
ベータ分布	二項分布	ベータ分布
ガンマ分布	ポアソン分布	ガンマ分布
正規分布	正規分布 (平均未知・母分散既知)	正規分布

・ **ベータ二項モデル**…標本分布が $Y|\theta \sim \text{Bin}(n, \theta)$ のとき、 θ の事前分布としてベータ分布 $\text{Be}(a, b)$ を採用するモデル。 n 回の試行のうち成功が y 回だとすると、事後分布は $\text{Be}(a+y, b+n-y)$ に更新されます。

・ **ガンマポアソンモデル**…標本分布が $Y_1, \dots, Y_n|\theta \sim \text{Po}(\theta)$ のとき、 θ の事前分布としてガンマ分布 $\text{Ga}(a, 1/b)$ を採用するモデル。実現値を $y_1, \dots, y_n$ とすると、事後分布は次のように更新されます。

$$\text{Ga} \left(a + \sum_{i=1}^n y_i, \frac{1}{b + n} \right)$$

・ **正規-正規モデル**…標本分布が $Y_1, \dots, Y_n|\theta \sim N(\theta, \sigma^2)$ のとき、 θ の事前分布として正規分布 $N(\mu_0, \sigma_0^2)$ を採用するモデル。実現値を $y_1, \dots, y_n$ とすると、事後分布は次のように更新されます。

$$N \left(\frac{n\sigma_0^2}{n\sigma_0^2 + \sigma^2} \bar{y} + \frac{\sigma^2}{n\sigma_0^2 + \sigma^2} \mu_0, \frac{\sigma_0^2 \sigma^2}{n\sigma_0^2 + \sigma^2} \right)$$


・ **ベイズ推定量**…事後分布の期待値。ガンマ分布 $\text{Ga}(a, b)$ の期待値は ab 、ベータ分布 $\text{Be}(a, b)$ の期待値は $a/(a+b)$

・ **MAP推定量**…事後分布のモード。ガンマ分布 $\text{Ga}(a, b)$ のモードは $a > 1$ のとき $(a-1)b$ 、ベータ分布 $\text{Be}(a, b)$ のモードは $a > 1, b > 1$ のとき $(a-1)/(a+b-2)$

・ **ベイズ予測分布**…事後分布を用いて、新たなデータを予測する確率分布。

・ **100(1- α)%信用区間**…母数の事後分布の積分値が $1-\alpha$ になるような区間。

(例) 95%最大事後密度(HPD)区間は、次の図の色のついた部分の面積が0.95であるような $[L(\mathbf{x}), U(\mathbf{x})]$



・ **MCMC法**…事前分布が共役事前分布以外の際には事後分布の計算が困難になることが多いため、その代わりに事後分布からの多数の独立なサンプルを得ることで事後分布を近似する手法。パラメータベクトルを $\theta = (\theta_1, \theta_2, \dots, \theta_p)$ とし、 $\theta^{(0)} \rightarrow \theta^{(1)} \rightarrow \dots$ のように、あるルールでパラメータの更新をくり返すと、十分な回数の更新後には事後分布 $n(\theta|\mathbf{x})$ からのサンプルを得ることができます。MCMC法の代表的なものには、次のメトロポリス法、メトロポリス・ヘイスティングス法、ギブスサンプリングなどがあります。

・**メトロポリス法**…次の①～④の手順で事後分布 $\pi(\boldsymbol{\theta}|\mathbf{x})$ からのサンプルを得る手法。

① 初期値 $\boldsymbol{\theta}^{(0)}$ を決め、 $t = 0$ として②へ進む

② $\boldsymbol{\theta}'$ を $\boldsymbol{\theta}' = \boldsymbol{\theta}^{(t)} + \mathbf{u}$ ($\mathbf{u}$ の各成分は独立に正規分布などの対称な分布にしたがう) によって発生させる

③ $v \sim U(0, 1)$ を発生させ、次の r を計算する。 $r \geq 1$ のとき $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}'$ として採用し、 $r < 1$ のとき、 $r \geq v$ ならば $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}'$ 、 $r < v$ ならば $\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)}$ とする

$$r = \frac{\pi(\boldsymbol{\theta}'|\mathbf{x})}{\pi(\boldsymbol{\theta}^{(t)}|\mathbf{x})}$$

④ t を $t+1$ でおきかえ、十分な数のサンプルが得られるまで②と③をくり返す

・**メトロポリス・ヘイスティングス法**…メトロポリス法の手順②で $\boldsymbol{\theta}'$ を非対称な確率分布 $q(\boldsymbol{\theta}|\boldsymbol{\theta}^{(t)})$ を用いて発生させ、手順③の r を次の式に取り替えた手法。

$$r = \frac{\pi(\boldsymbol{\theta}'|\mathbf{x})q(\boldsymbol{\theta}^{(t)}|\boldsymbol{\theta}')}{\pi(\boldsymbol{\theta}^{(t)}|\mathbf{x})q(\boldsymbol{\theta}'|\boldsymbol{\theta}^{(t)})}$$

・**ギブスサンプリング**… n 変量でかまいませんが、ここでは2変量の例を挙げます。 (X, Y) の同時分布 $f(x, y)$ からの抽出は難しいものの、条件付き分布 $f(x|y)$ 、 $f(y|x)$ からの抽出は可能であるものとして、次の①～④の手順で行います。

① 初期値 $(x^{(0)}, y^{(0)})$ を決める

② $(x^{(j)}, y^{(j)})$ が与えられたとき、 $y^{(j+1)}$ を次のように得る

$$y^{(j+1)} \sim f(y|x^{(j)})$$

③ $y^{(j+1)}$ から次のように $x^{(j+1)}$ を得る

$$x^{(j+1)} \sim f(x|y^{(j+1)})$$

④ ②と③をくり返す

第32章 シミュレーション

・**擬似乱数**…再現不可能な本来の乱数に対し、計算機によって生成される乱数のように、一定の条件のもとで再現できてしまう乱数。

・**逆関数法**…特定の確率分布にしたがう乱数を、その確率分布の累積分布関数の逆関数を使って得る方法。一様分布 $U(0, 1)$ にしたがう乱数を u 、確率変数 X の累積分布関数を $F_X(x)$ として、 $x = F_X^{-1}(u)$ とすれば X の確率分布にしたがう乱数を得ることができます。

・ **採択・棄却法**…特定の確率分布にしたがう乱数を、その確率分布より乱数を発生させやすい確率分布を使って得る方法。確率密度関数 $f(x)$ をもつ分布にしたがう乱数を得たいとき、 $f(x)$ と同じ定義域を持つ関数 $g(x)$ とある定数 R について、すべての x に対して、 $f(x) \leq R \cdot g(x)$ が成り立つとします。ここで、確率密度関数 $g(x)$ をもつ分布にしたがう乱数は容易に得られるものとします。このとき、次の①②の手順で確率密度関数 $f(x)$ をもつ分布にしたがう乱数を得ることができます。

- ① $y \sim g(x)$, $u \sim U(0, 1)$ を独立に生成する
- ② 次の不等式が成り立てば y を出力し、そうでなければ①に戻る

$$u \leq \frac{f(y)}{R \cdot g(y)}$$

乱数を得る効率を上げるには、 R をできるだけ小さくとったほうが良いです。

・ **モンテカルロ法**…正方形領域 $(0, 1) \times (0, 1)$ 内の図形 A の面積 S の近似値を乱数を使って求めるには、一様分布 $U(0, 1)$ にしたがう乱数 (u, v) を n 組発生させて、そのうち A 内に入ったものの個数が X 組ならば、 $S \doteq X/n$ と推定できます。 $X \sim \text{Bin}(n, S)$ であることから、 $V[X] = nS(1-S)$ です。

・ **モンテカルロ積分**…積分を直接的に求めることが難しいとき、乱数を発生させて近似的に積分値を求める方法。 $X \sim U(0, 1)$ のとき、期待値の定義から、次の式が成り立ちます。

$$E[g(X)] = \int_0^1 g(x) \cdot 1 dx$$

無作為標本を $X_1, \dots, X_n \sim U(0, 1)$ として、 n が十分に大きければ、大数の法則により $g(X_1), \dots, g(X_n)$ の平均は $E[g(X)]$ に近づくので、上の式の右辺の積分の近似値を求めることができます。より一般に、 $X \sim U(a, b)$ のとき、期待値の定義から、次の式が成り立ちます。

$$E[g(X)] = \int_a^b g(x) \cdot \frac{1}{b-a} dx$$

よって、 $g(x)$ の $[a, b]$ 上での積分の近似値を求めるには、 $X_1, \dots, X_n \sim U(a, b)$ として、 $g(X_1), \dots, g(X_n)$ の平均を計算し、 $(b-a)$ をかけます。さらに一般に、 $[a, b]$ 上で定義された確率密度関数 $f(x)$ をもつ分布からの乱数が容易に得られるならば、 $X_1, \dots, X_n \sim f(x)$ として、 $g(X_1), \dots, g(X_n)$ の平均を計算すれば、次の積分の近似値を求めることができます。

$$E[g(X)] = \int_a^b g(x) f(x) dx$$

この積分値を θ とおき、次の推定量の精度について考えます。

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n g(X_i)$$

この推定量の分散は、 $V[g(X)] = \sigma^2$ として、次のようになります。

$$V[\hat{\theta}] = \frac{1}{n^2} \sum_{i=1}^n V[g(X_i)] = \frac{\sigma^2}{n}$$

$\sigma^2 = E\{g(X) - \theta\}^2$ なので、次のような σ^2 の推定量を考えます。

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \{g(X_i) - \hat{\theta}\}^2$$

よって、 θ ハットの標準誤差は次のように表せます。

$$\frac{1}{n} \left(\sum_{i=1}^n \{g(X_i) - \hat{\theta}\}^2 \right)^{\frac{1}{2}}$$

モンテカルロ積分の精度を向上させる方法にはいくつかあり、そのうちの主部の分離と負の相関の利用の2つについて、次の積分値 I の推定量を求める手順は下のようになります。

$$I = \int_a^b f(x) dx$$

【主部の分離による手順】

- ① $f(x)$ を近似し、積分しやすい関数 $h(x)$ をテーラー展開などを利用して決める
- ② $g(x) = f(x) - h(x) + \mu$ とおく。ここで、 μ は次の式で定める

$$\mu = \frac{1}{b-a} \int_a^b h(x) dx$$

- ③ 無作為標本を $X_1, \dots, X_n \sim U(a, b)$ として、 I の推定量を次のようにおく

$$\hat{I} = \frac{b-a}{n} \sum_{i=1}^n g(X_i)$$

【負の相関を利用する場合の手順】

① 次のように $g(x)$ を定める

$$g(x) = \frac{f(x) + f(a+b-x)}{2}$$

② 無作為標本を $X_1, \dots, X_m \sim U(a, b)$ として、 I の推定量を次のようにおく

$$\hat{I} = \frac{b-a}{m} \sum_{i=1}^m g(X_i)$$

・ **経験分布関数**…分布関数が $F(x)$ である確率分布からの無作為標本を $X_1, \dots, X_n$ とすると、サイズ n の標本のうち x 以下であるものの個数を n でわった値を x の関数とみたもののこと。経験分布関数 $F_n(x)$ は分布関数 $F(x)$ に確率収束します。

・ **ジャックナイフ法**…母集団分布のパラメータを θ とし、無作為標本 $X_1, \dots, X_n$ から構成した θ の推定量を θ ハットとします。 $j = 1, 2, \dots, n$ とし、 X_j を除いたサイズ $n-1$ の標本によって θ ハットと同じように構成した推定量 $\theta_{(j)}$ ハットの平均を次のようにおきます。

$$\bar{\hat{\theta}}_{(\cdot)} = \frac{1}{n} \sum_{j=1}^n \hat{\theta}_{(j)}$$

このとき、 θ ハットの標準誤差のジャックナイフ推定量は次のように表せます。

$$\sqrt{\frac{n-1}{n} \sum_{j=1}^n (\hat{\theta}_{(j)} - \bar{\hat{\theta}}_{(\cdot)})^2}$$

・ **ブートストラップ法**…互いに独立に同一の確率分布 F にしたがう確率変数 $X_1, \dots, X_n$ の実現値を $x_1, \dots, x_n$ とし、 F に関するパラメータ θ を推定量 θ ハットによって推定することを考えます。 $\{x_1, \dots, x_n\}$ から復元抽出によって得られたサイズ n の標本を $\mathbf{x}^* = \{x_1^*, \dots, x_n^*\}$ とすることを B 回繰り返し、次のような B 個の θ の推定値を求めます。

$$\{\hat{\theta}^*(i) : i = 1, \dots, B\}$$

また、上のB個の θ の推定値の平均を次のようにおきます。

$$\hat{\theta}^*(\cdot) = \frac{1}{B} \sum_{i=1}^B \hat{\theta}^*(i)$$

このとき、推定量のバイアスと分散を次のように推定します。

$$b(\hat{F}) \approx \frac{1}{B} \sum_{i=1}^B \hat{\theta}^*(i) - \hat{\theta}$$

$$\sigma^2(\hat{F}) \approx \frac{1}{B-1} \sum_{i=1}^B \{\hat{\theta}^*(i) - \hat{\theta}^*(\cdot)\}^2$$