

統計検定準1級section1~5

- 統計検定準1級section1~5
 - 1 事象と確率
 - 1.1 ベイズの定理
 - 1.1.1 何が嬉しいのか：恒等式の書き換えが持つ「因果の逆転」の魔力
 - 1.1.2 結論：何が凄すぎるのか？
 - 2 確率分布と母関数
 - 2.1 繰り返しの法則
 - 何これ：神の視点の平均を「条件ごとの平均の平均」で求める
 - 何が嬉しいのか？
 - 2.2 確率母関数
 - 何これ：確率分布を「多項式の係数」として閉じ込めた圧縮ファイル（ZIP）
 - 何が嬉しいのか？：面倒な「和の計算」が「微分の作業」に大化けする
 - 2.3 モーメント母関数
 - 何これ：確率分布の情報を「マクローリン展開の係数」として保存する汎用ZIPファイル
 - 何が嬉しいのか？：分布の「指紋」であり、微分の威力がさらに上がる
 - 3 分布の特性値
 - 3.1 変動係数
 - 何これ：スケール（単位や大きさ）が全く違うもの同士の「相対的なブレ」を公平に比べる指標
 - 何が嬉しいのか？
 - 3.2 歪度（わいど / Skewness）
 - 何これ：分布が「どっちに尻尾（裾）を引いているか」を表す非対称性の指標
 - 覚え方のコツ
 - 3.3 尖度（せんど / Kurtosis）
 - 何これ：正規分布と比べて「極端な外れ値が出やすいか（ファットテールか）」を測る指標
 - 何が嬉しいのか？
 - 3.4 共分散
 - 何これ：2つの変数が「どれくらい連動して動くか」を表す相互作用（クロスターム）
 - 何が嬉しいのか？
 - 3.5 相関係数
 - 何これ：共分散を「単位を持たないキレイなスケール（-1から1）」に規格化したもの
 - 3.6 偏相関関係（偏相関係数）
 - 何これ：共通の「黒幕」の影響を差し引いた、純粋な1対1の関係性
 - 公式の覚え方
 - 3.7 様々な平均
 - 何これ：データの「性質」に合わせて、適切な「平らにならす方法」を使い分けるツール
 - 3.7.1 加重平均（Weighted Average）
 - 3.7.2 幾何平均（Geometric Mean）
 - 3.7.3 調和平均（Harmonic Mean）
 - 3.8 行列表現
 - 確率変数ベクトルと平均ベクトル
 - 分散共分散行列（理論値）
 - 標本分散共分散行列（データから計算）
 - 相関行列
 - 何これ：多次元の「ゆらぎの形状」を記述する慣性テンソル
 - 何が嬉しいのか？：線形代数を使って「データの固有状態」を抽出できる
 - 4 変数変換
 - 4.1 $Y = g(X)$ の変換
 - 何これ：確率という「粉」の総量（面積=1）を保つための「連続の式（質量保存則）」
 - 何が嬉しいのか？
 - 4.2 $Z = X + Y$ の変換
 - 何これ：波の「畳み込み（コンボリューション）」
 - 何が嬉しいのか？
 - 4.3 Box-Cox変換
 - 何これ：歪んだ世界を「正規分布（ユークリッド空間）」に無理やり平坦化する魔法のレンズ
 - 何が嬉しいのか？

- 5 離散型分布

- 5.1 離散一様分布
 - 何これ：すべての選択肢が完全に平等な、もっともピュアな「サイコロ」の分布
- 5.2 ベルヌーイ分布
 - 何これ：すべての離散型分布の「原子」（1回きりの丁半バクチ）
 - 何が嬉しいのか？
- 5.3 二項分布
 - 何これ：ベルヌーイ分布の「コピペ&足し算」
 - 何が嬉しいのか？（再生性の意味）
- 5.4 超幾何分布
 - 何これ：くじを「戻さない（非復元）」せいで、引くたびに確率が変化するリアルな二項分布
 - 何が嬉しいのか？
- 5.5 Poisson（ポアソン）分布
 - 何これ：無限回くじを引けるが、当たる確率がほぼゼロの世界（レア事象の分布）
 - 何が嬉しいのか？
- 5.6 幾何分布
 - 何これ：「SSRが出るまでガチャを引き続ける」ときの、爆死回数の分布
- 5.7 負の二項分布
 - 何これ：幾何分布の「コピペ&足し算」（目的のアイテムを r 個集めるまでの道のり）
- 5.8 多項分布
 - 何これ：コイン（2面）の世界から、サイコロ（多面）の世界への拡張

1 事象と確率

1.1 ベイズの定理

$$\begin{aligned} p(A|B) &= \frac{p(B|A)p(A)}{p(B)} \\ &= \frac{p(B|A)p(A)}{p(B|A)p(A) + p(B|A^c)p(A^c)} \end{aligned}$$

1.1.1 何が嬉しいのか：恒等式の書き換えが持つ「因果の逆転」の魔力

数式単体を見れば、条件付き確率の定義から導かれる単なる「当たり前の恒等式」に過ぎません。数式としての難易度も非常に単純です。

しかし、この定理がデータサイエンスや統計学において「革命」と呼ばれるほど特別視される理由は、**左辺と右辺の文字に、実務上とんでもなく都合の良い意味（役割）を割り当てたから**です。

通常、確率は**「原因（理論・パラメータ）→ 結果（データ）」の順方向で考えます。しかし、現実の科学やデータ分析で私たちが直面するのは**常にその逆**、「結果（データ）→ 原因（理論・パラメータ）」という逆方向の推論です。ベイズの定理は、この逆問題を解くための唯一のツールとなります。

記号の A と B を、以下のように書き換えてみます。

- $A \rightarrow \theta$ （私たちが本当に知りたい **未知のパラメータ、理論、仮説**）
- $B \rightarrow D$ （手元にある **既知の実験データ、観測結果**）

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$

各項にこの意味を割り当てると、この数式の真の嬉しさが見えてきます。

- $p(\theta)$ 【事前分布】
データを得る前の、その理論やパラメータに対する「事前の確信度（仮説）」。
- $p(D|\theta)$ 【尤度（ゆうど）】
理論 θ が正しいと仮定したとき、そのデータ D が観測される確率。順方向の確率であるため、数理モデルやシミュレーションから**直接計算が可能**。
- $p(\theta|D)$ 【事後分布】
実験データ D を目撃した後に、理論 θ が正しいと言える「修正された確信度」。私たちが本当に知りたい**データから原因を逆算する**という究極の目的そのもの。

1.1.2 結論：何が凄すぎるのか？

1. 逆問題を順問題に変える：

「データ D から未知のパラメータ θ を直接当てる（逆問題）」のは一般に超難問ですが、ベイズの定理を使えば、簡単に計算できる「パラメータ θ のときにどんなデータが出るか（順問題 = 尤度）」の掛け算にすり替えることができます。

2. 自動的な学習（アップデート）システム：

データ D が新しく得られるたびに、左辺の「事後分布」を次のステップの「事前分布」に代入して再計算することで、理論をどんどん洗練（学習）させていくサイクルを数式1行で表現しています。

数式自体の当たり前さと、用途の強力さ（逆問題を解くチート性）のギャップこそが、ベイズの定理の最大の価値です。

2 確率分布と母関数

2.1 繰り返しの法則

$$E[E[X|Y]] = E[X]$$

何これ：神の視点の平均を「条件ごとの平均の平均」で求める

物理の言葉で言えば、これは**「全配置にわたるアンサンブル平均を、部分系ごとに粗視化（Coarse-graining）して二段階で計算する手続き」**です。「全確率の公式」の期待値バージョンに過ぎません。

数式の内側から順に解釈すると、意味がはっきり分かります。

- $E[X|Y]$ 【内側の期待値】：条件付き期待値

「変数 Y の値が固定された」という条件下での、 X の平均値です。これは Y の値によって変化するため、 Y の関数になります。

- $E[\cdot]$ 【外側の期待値】： Y についての平均

内側で計算した「条件ごとの平均」に対して、さらに「その条件が発生する確率」の重みをつけて、すべての Y にわたって平均をとります。



Tip

- 💡 具体例：東大生の平均身長を求める

全校生徒を全員一列に並べて平均身長（ $E[X]$ ）を直接計算するのは大変です。

そこで、まずは学部（ Y ）ごとに平均身長を計算します。これが内側の $E[X|Y]$ です（理学部の平均、工学部の平均...）。

次に、その「各学部の平均身長」を、各学部の人数比率で重み付けして足し合わせます。これが外側の $E[\cdot]$ です。結果として、全体の平均身長 $E[X]$ と完全に一致します。

何が嬉しいのか？

全体の平均 $E[X]$ を直接計算するのが難しいとき、**「まず特定の条件 Y でグループ分けして、そのグループ内の平均（内側）を出し、最後にそれをグループの構成比で足し合わせる（外側）」**という二段階のステップを踏めば、複雑な同時確率分布を扱わずに済むため、計算が劇的に楽になります。ベイズ統計などでも頻出する変形テクニックです。

2.2 確率母関数

離散型確率変数 X の確率関数を $p(X)$ とすると、1に十分に近いすべての s に対して、次の級数が収束するときの $G_X(s)$ のこと

$$G_X(s) = E[s^X] = \sum_{k=0}^{\infty} s^k p(k)$$

何これ：確率分布を「多項式の係数」として閉じ込めた圧縮ファイル（ZIP）

物理でいう分配関数（Partition Function）の離散版です。あるいは、信号処理や数学での「Z変換」や「テイラー展開」そのものです。

数式の意味をそのままバラしてみると、ただの形式的な多項式（べき級数）であることが分かります。

$$G_X(s) = p(0)s^0 + p(1)s^1 + p(2)s^2 + p(3)s^3 + \dots$$

ここで導入されている文字 s は、ただの「引数（ダミーの変数）」であり、実用的な意味は何もありません。重要なのは、 s^k の前にくっついている係数が、「 $X = k$ になる確率 $p(k)$ 」そのものになっているという点です。つまり、バラバラに存在していた確率のリストを、多項式という「1つの関数の箱」にパッキング（ZIP圧縮）したものが確率母関数です。

Note

 例え話：仕切り付きの収納ボックス

確率 $p(0), p(1), p(2) \dots$ をそのまま足してしまうと、全部混ざってただの「1」になってしまいます（全確率の和は1だから）。

そこで、 $s^0, s^1, s^2 \dots$ という**「絶対に混ざらない仕切り（タグ）」**をそれぞれにくっつけてから足し合わせることで、各々の確率の値を独立したまま1つの関数 $G_X(s)$ の中に安全に保管しているイメージです。

何が嬉しいのか？：面倒な「和の計算」が「微分の作業」に大化けする

 Important **ここがチート！微分すると中身が飛び出してくる**

確率母関数 $G_X(s)$ を s で1回微分してから $s = 1$ を代入すると、魔法のように期待値 $E[X]$ が出てきます。

$$G'_X(s) = p(1) + 2p(2)s + 3p(3)s^2 + \dots$$

$s = 1$ を代入：

$$G'_X(1) = \sum k p(k) = E[X]$$

1. 微分するだけで期待値や分散が手に入る：

離散確率の面倒な無限級数の和の計算が、「関数を微分して1を代入するだけ」の機械的作業に一変します（2回微分すれば分散もすぐ作れます）。

2. 確率変数の足し算（和の分布）が「掛け算」になる：

独立な2つの確率変数 X と Y の和 $X + Y$ の確率分布を真面目に計算しようとすると、面倒な畳み込み（コンボリューション）が必要になります。しかし、母関数の世界では $G_{X+Y}(s) = G_X(s)G_Y(s)$ となり、**「母関数同士の掛け算」**にするだけで計算が完了します。分配関数で独立な系の全分配関数が各系の積になると全く同じ原理です。

2.3 モーメント母関数

0に十分に近いすべての t に対して、次の期待値が存在するときの $M_X(t)$ のこと

$$M_X(t) = G_X(e^t) = E[e^{tX}] = \sum_{k=0}^{\infty} e^{tk} p(k)$$

何これ：確率分布の情報を「マクローリン展開の係数」として保存する汎用ZIPファイル

先ほどの「確率母関数（2.2）」の進化版です。物理や工学でいうところの**ラプラス変換**（あるいは統計力学の分配関数 $Z(\beta)$ において $\beta = -t$ と置いたもの）と全く同じ操作をしています。

確率母関数は s^X を使いましたが、こちらは e^{tX} を使います。なぜわざわざネイピア数 e を使うのか？それは、 e^{tX} をマクローリン展開（テイラー展開）すると、以下のように綺麗な多項式にバラけるからです。

$$e^{tX} = 1 + tX + \frac{t^2}{2!}X^2 + \frac{t^3}{3!}X^3 + \dots$$

この両辺の期待値（平均）をとると、こうなります。

$$M_X(t) = E[e^{tX}] = 1 + tE[X] + \frac{t^2}{2!}E[X^2] + \frac{t^3}{3!}E[X^3] + \dots$$

つまり、 t のべき乗の係数として、 X のすべての「モーメント $(E[X], E[X^2], E[X^3] \dots)$ 」が規則正しく格納されている状態になります。

 Note **確率母関数との違い**

確率母関数 $G_X(s)$ は基本的に「離散型（サイコロの目など）」にしか使えないという弱点がありました。しかし、モーメント母関数 $M_X(t)$ は総和 $\sum$ を積分 $\int$ に変えることで「連続型（身長や温度など）」の分布にも使える**完全上位互換の汎用圧縮ファイル**になります。

何が嬉しいのか？：分布の「指紋」であり、微分の威力がさらに上がる

 Important **ここがチート！微分して「0」を入れるとモーメントが飛び出す**

確率母関数では微分して「1」を入れましたが、モーメント母関数の場合は微分して $t = 0$ を代入します。

$M_X(t)$ を t で1回微分して $t = 0$ を入れると、期待値 $E[X]$ が出ます。

2回微分して $t = 0$ を入れると、2次のモーメント $E[X^2]$ が出ます。これを使えば、面倒な積分の計算をせずとも分散 $V(X) = E[X^2] - (E[X])^2$ が一瞬で計算できます。

1. どんな分布でも機械的な微分で平均と分散が出せる：

正規分布、ポアソン分布、ガンマ分布など、どんなに複雑な確率密度関数でも、一度 $M_X(t)$ さえ求めてしまえば、あとは「微分して0を入れる」という脳死の作業だけで平均や分散が手に入ります。

2. 和の分布が「掛け算」になる（確率母関数と同じ）：

独立な確率変数 X と Y の和のモーメント母関数は、それぞれの母関数の積 $M_{X+Y}(t) = M_X(t)M_Y(t)$ になります。

3. 分布の「指紋」として使える（一意性）：

「モーメント母関数が完全に一致するなら、元の確率分布も絶対に同じである」という強力な定理があります。準1級の第7章で出てくる「中心極限定理（たくさんの変数を足すと正規分布に近づく定理）」なども、真正面から確率を計算するのではなく、この「モーメント母関数の形が正規分布のそれに近づいていくか」を確認することで証明されます。

3 分布の特性値

3.1 変動係数

非負の確率変数 X のばらつきが期待値に対してどれくらいかを示す指標

$$\frac{\sqrt{V(X)}}{E[X]}$$

何これ：スケール（単位や大きさ）が全く違うもの同士の「相対的なブレ」を公平に比べる指標

物理や工学でいうところの「**相対誤差**」や、「 **S/N 比（シグナル・ノイズ比）の逆数**」に相当するものです。分子の $\sqrt{V(X)}$ は標準偏差（ばらつきの絶対量）を表します。

Tip

💡 例え話：アリの測定誤差とゾウの測定誤差

「アリの体長（平均 1cm）」と「ゾウの体長（平均 300cm）」を測ったとき、どちらも標準偏差（ばらつき）が 0.5cm だったとします。ばらつきの「絶対量」は同じですが、アリにとっての 0.5cm は致命的な大誤差（元のサイズの半分）なのに対し、ゾウにとっての 0.5cm は誤差の範囲（ほとんど無視できる）ですよね。

つまり、標準偏差をそのまま比べるのは不公平なのです。だから、**標準偏差を期待値（平均サイズ）で割り算**することで、「平均値の何倍くらいブレるのか」という相対的な指標に直しています。

何が嬉しいのか？

「単位が違うもの（例：体重と身長）」や「平均値のスケールが桁違いのもの（例：大企業の年収のばらつきと、ベンチャー企業の年収のばらつき）」を、同じ土俵で比較できるようになります。

3.2 歪度（わいど / Skewness）

確率変数 X の期待値を μ 、分散を σ^2 とするとき、次のように X を標準化した確率変数の 3 乗の期待値。

$$\frac{E[(x - \mu)^3]}{\sigma^3}$$

分布が、右に長い裾を持つときには正の値、左に長い裾を持つときには負の値をとりやすく、左右対称ならば 0 になります。

何これ：分布が「どっちに尻尾（裾）を引いているか」を表す非対称性の指標

物理の言葉で言えば、**「重心（平均 μ ）まわりの3次のモーメント」**です。

Note

📌 物理的解釈：なぜ「3乗」するのか？

分散は $(x - \mu)^2$ と「2乗」するため、平均より大きくても小さくても、必ずプラスの値になってしまい「左右のどっちにブレたか」の情報が

消滅してしまいます。

しかし、「3乗」であればマイナスの符号がそのまま残ります。

- 平均よりバカでかい値（右側の外れ値）があると、プラスの方向に大きく引っ張られる → **歪度は正（右裾が長い）**
- 平均よりめっちゃくちゃ小さい値（左側の外れ値）があると、マイナスの方向に大きく引っ張られる → **歪度は負（左裾が長い）**

覚え方のコツ

「右に長い裾=右に歪んでいる」という言葉のニュアンスに引っ張られないでください。試験では**「グラフの裾（しっぽ）が伸びている方向が、歪度の符号（プラスかマイナスか）になる」**と直感的に覚えておくと迷いません。年収の分布など、少数の大金持ちが平均を押し上げているデータは「右裾が長い（歪度>0）」になります。

3.3 尖度（せんど / Kurtosis）

確率変数 X の期待値を μ 、分散を σ^2 とすると、次のように X を標準化した確率変数の4乗の期待値。

$$\frac{E[(x - \mu)^4]}{\sigma^4}$$

確率密度関数のグラフに山が1つあり、その山が尖っているほど尖度は大きな値をとる傾向があります。この期待値を正規分布で計算すると3になるので、上の式から3をひいた値が正か負かによって分布の形状を正規分布と比べることがあります。

何これ：正規分布と比べて「極端な外れ値が出やすいか（ファットテールか）」を測る指標

物理の言葉で言えば、**「重心まわりの4次のモーメント」**です。

🔥 Important

🔥 ここがポイント：なぜ「4乗」するのか？（外れ値への超絶ペナルティ）

$(x - \mu)^4$ という式は、平均 μ の近くでは非常に小さな値になりますが、平均から少しでも離れると、4乗の効果で爆発的に巨大な値になります。

つまり、尖度という指標は「中心付近の山の形」よりも、**「平均から遥か遠く離れた外れ値（尻尾の先っぽ）がどれくらい存在するか」**に強烈に反応するセンサーなのです。

何が嬉しいのか？

「尖度」という名前のせいで「山の頂上が尖っているかどうか」の指標だと誤解されがちですが、本質は**「裾の重さ（極端なリスクの起こりやすさ）」**の評価です。

- **尖度が大きい（正規分布の「3」より大きい）：**

正規分布よりも「平均から遠く離れた極端な外れ値」が頻発する分布です（これをファットテールと呼びます）。確率の総和は1なので、裾に確率を奪われた分を取り返すために、結果として「中心の山が高く尖る」ことになります。金融商品の暴落リスクの評価などで非常に重要視されます。

- **「-3」をする理由：**

統計学の王様である「正規分布」の尖度を計算するとピッタリ「3」になります。そこで、正規分布を基準の「0」として扱うために、公式の最後に「-3」をして調整する流儀（超過尖度と呼びます）がよく使われます。

3.4 共分散

$$\begin{aligned} Cov[X, Y] &= E[XY] - E[X]E[Y] \\ Cov[aX + b, cY + d] &= acCov[X, Y] \\ V[X \pm Y] &= V[X] + V[Y] \pm 2Cov[X, Y] \end{aligned}$$

何これ：2つの変数が「どれくらい連動して動くか」を表す相互作用（クロスターム）

物理の言葉で言えば、**2つの物理量の「内積」や「結合エネルギー」**に相当する概念です。 X が平均より大きいとき、 Y も平均より大きければプラス、小さければマイナスになります。

🔥 Tip

💡 公式の物理的解釈

- $Cov[X, Y] = E[XY] - E[X]E[Y]$
これは定義式 $E[(X - E[X])(Y - E[Y])]$ を展開したものです。力学における「平行軸の定理」のように、実際の計算を劇的に楽にするための実用公式として使われます。
- $V[X \pm Y] = V[X] + V[Y] \pm 2Cov[X, Y]$
これ、物理の**波の干渉**や、**ベクトルの長さの2乗公式 ($|\vec{A} \pm \vec{B}|^2 = |\vec{A}|^2 + |\vec{B}|^2 \pm 2\vec{A} \cdot \vec{B}$) **と全く同じ形をしていますよね。2つの変数を足したときの全体のばらつき（分散）は、ただ足し算するだけではなく、2つが連動する成分（干渉項＝共分散）を考慮しなければならない、ということです。

何が嬉しいのか？

複数の変数が組み合わさった複雑なシステムの分散を計算する際の、基本的な構成要素（ビルディングブロック）になります。

3.5 相関係数

（※ご提示いただいた数式は分母が $V[Y]$ になっていますが、正しくは全体にルートがかかる $\sqrt{V[X]V[Y]}$ 、または $\sqrt{V[X]}\sqrt{V[Y]}$ です。ここでは修正して解説します！）

$$\rho[X, Y] = \frac{Cov[X, Y]}{\sqrt{V[X]}\sqrt{V[Y]}}$$

何これ：共分散を「単位を持たないキレイなスケール（-1から1）」に規格化したもの

共分散の弱点は「値の大きさ自体には意味がない（単位に依存してしまう）」ことです。そこで、共分散をそれぞれの標準偏差（ $\sqrt{V}$ ）で割り算することで、**「スケールに依存しない純粋な連動の強さ」**を抽出しています。

Note

物理的・幾何学的解釈：データ空間における「なす角」

データ点を多次元空間のベクトル $\vec{X}$ と $\vec{Y}$ とみなしたとき、この数式は**「内積を、それぞれのベクトルの長さで割っている」**ことになります。

つまり、相関係数 ρ とは「**2つのベクトルのなす角 θ の $\cos \theta$** 」そのものです。

- $\rho = 1$ ($\cos \theta = 1$) : 全く同じ方向を向いている（完全な正の相関）
- $\rho = 0$ ($\cos \theta = 0$) : 直交している（無相関）
- $\rho = -1$ ($\cos \theta = -1$) : 真逆を向いている（完全な負の相関）

3.6 偏相関関係（偏相関係数）

Z が、 X と Y の両方に相関があるとき、 X と Y の間に直接的な相関がなくても Z を介して相関が発生します（**擬似相関**）。偏相関係数は、 Z の影響を除いた場合の X と Y の相関係数で、次の式で計算できます。

$$\rho[X, Y|Z] = \frac{\rho[X, Y] - \rho[X, Z]\rho[Y, Z]}{\sqrt{(1 - \rho[X, Z]^2)(1 - \rho[Y, Z]^2)}}$$

何これ：共通の「黒幕」の影響を差し引いた、純粋な1対1の関係性

物理で言えば、「背景場（バックグラウンド）」や「外部からの共通の駆動力」の影響をプロジェクション（射影）して取り除き、系どうしの**真の相互作用**だけを見る操作です。

Important

🔥 例え話：アイスクリームと水難事故（擬似相関の古典的例）

- X : アイスクリームの売上
- Y : 水難事故の件数

この2つを計算すると、強い正の相関（ $\rho[X, Y] > 0$ ）が出ます。「アイスが売れるほど、人が溺れる」という謎の結論です。しかし、ここには**「気温（ Z ）」という黒幕**があります。気温が高いからアイスが売れるし、気温が高いから海に行って溺れる人が増えるだ

けです。

先ほどの数式を使って「気温（ Z ）」の影響を数学的に排除すると、 $\rho[X, Y|Z]$ はほぼ 0 になります。これが偏相関係数の威力です。

公式の覚え方

式自体は複雑に見えますが、分子の形 $\rho[X, Y] - \rho[X, Z]\rho[Y, Z]$ に注目してください。

「 X と Y の表面上の相関」から、「 Z を経由した相関ルート（ $X \rightarrow Z \rightarrow Y$ ）」を引き算しているだけです。グラフィカルモデル（第25章）や重回帰分析（第16章）で非常に重要な役割を果たします。

3.7 様々な平均

$$\begin{cases} \frac{\sum_i w_i x_i}{\sum_i w_i} & \text{(加重平均)} \\ \sqrt[n]{\prod_i x_i} & \text{(幾何平均)} \\ \left(\frac{1}{n} \sum_i \frac{1}{x_i} \right)^{-1} & \text{(調和平均)} \end{cases}$$

※幾何平均の数式（ルートの書き方など）は、一般的な数学の表記 $\sqrt[n]{\prod}$ に少し修正しています。

何これ：データの「性質」に合わせて、適切な「平らにならす方法」を使い分けるツール

私たちが普段「平均」と呼んでいるのは「算術平均（全部足して個数で割る）」ですが、データが持っている物理的な意味によっては、算術平均を使うと論理が破綻するケースがあります。それぞれ「どういう状況で使うべきか」という明確な役割があります。

3.7.1 加重平均（Weighted Average）

物理の言葉で言えば、完全に**重心（Center of Mass）**の計算です。

- **何をしているか：** すべてのデータが平等ではなく、それぞれのデータに「重み（重要度や質量） w_i 」がついている場合の平均です（ただし $\sum w_i = 1$ と規格化されている前提です）。
- **何が嬉しいのか：**
物理で「複数の質点系の重心位置」を求めるとき、単に座標を足して個数で割るのではなく、質量の大きな点の座標を強く反映させますよね。それと全く同じです。
 - 例：テストの平均点を出すとき、100点満点の数学と、50点満点の小テストを「1対1」で足して割るのは不公平です。配点（重み）を考慮して平均化する際に使います。

3.7.2 幾何平均（Geometric Mean）

物理の言葉で言えば、**「 n 次元空間の超直方体を、同じ体積を持つ超立方体に変換したときの1辺の長さ」**です。

Note

物理的・幾何学的解釈

$x_1, x_2, \dots, x_n$ を全部掛け合わせる（ $\prod x_i$ ）ということは、各データを「辺の長さ」とした n 次元直方体の「体積」を求めていることになります。

その体積に対して n 乗根（ $\sqrt[n]{\cdot}$ ）をとるということは、「もし全ての辺が同じ長さだったとしたら、その長さはいくらか？」と計算し直している（直方体を正方形に均している）わけです。

- **いつ使うべきか：足し算ではなく「掛け算」で増えていくデータ**
 - 例：投資の利回りや、バクテリアの増殖率など「前年比 x 倍」といった**比率・成長率**の平均を出したいとき。
 - なぜ算術平均ではダメなのか：1年目に株価が2倍（2.0）、2年目に半分（0.5）になったとします。最終的な資産は元通り（ $2.0 \times 0.5 = 1.0$ ）なので、平均成長率は「1.0 倍」であるべきです。しかし算術平均をすると $(2.0 + 0.5)/2 = 1.25$ 倍となり、謎の利益が出たことになってしまい論理が破綻します。幾何平均なら $\sqrt{2.0 \times 0.5} = 1.0$ と正しく計算できます。

3.7.3 調和平均（Harmonic Mean）

物理の言葉で言えば、**「並列回路の合成抵抗」**そのものです。

Tip

💡 例え話：行きと帰りの「平均速度」

行きは時速 60km (x_1)、帰りは時速 40km (x_2) で同じ道のりを往復しました。平均時速は？

算術平均で $(60 + 40)/2 = 50\text{km}$ と答えると**不正解**です。なぜなら、遅い時速 40km で走っている時間の方が長いので、全体の平均速度は 50 より遅くなるはずだからです。

これを調和平均で計算すると $\left(\frac{1/60+1/40}{2}\right)^{-1} = 48\text{km}$ となり、正しい平均時速が求まります。

• いつ使うべきか：「～あたり」といった単位（速度、密度、効率など）の平均

距離（分子）が固定されていて、速度（分母）が変わるようなデータの平均をとるとき、速度をそのまま足し算することは物理的に意味を持ちません。一度「逆数（＝一定距離を進むのにかかる時間）」にひっくり返してから算術平均をとり、最後にもう一度逆数に戻して速度の単位に復元する。これが調和平均の正体です。

3.8 行列表現

確率変数ベクトルと平均ベクトル

- **確率変数ベクトル**：複数の確率変数 $x_1, \dots, x_p$ を縦に並べて 1 つのベクトルにまとめたものです。

$$x = (x_1, \dots, x_p)^T$$

- **平均ベクトル（期待値ベクトル）**：それぞれの期待値を並べたベクトルです。物理でいう**「多粒子系の重心座標」**に相当します。

$$E[x] = (E[x_1], \dots, E[x_p])^T$$

- **線形変換の性質**： A を $r \times p$ の定数行列、 b を r 次元の定数ベクトルとしたとき、期待値の線形性から以下が成り立ちます。

$$E[Ax + b] = AE[x] + b$$

分散共分散行列（理論値）

p 次元確率変数ベクトル x に対して、各成分のばらつきと相互の関係を記述する $p \times p$ の行列です。半正定値対称行列となります。

$$\Sigma = V[x] = E[(x - E[x])(x - E[x])^T]$$

- **線形変換の性質**： $V[Ax + b] = AV[x]A^T$ となり、行列 A が両側から挟まる形になります（テンソルの座標変換公式 $g'_{\mu\nu} = \frac{\partial x^\alpha}{\partial x'^\mu} \frac{\partial x^\beta}{\partial x'^\nu} g_{\alpha\beta}$ と同形式です）。

標本分散共分散行列（データから計算）

p 変数のサイズ n の実標本データに対して、不偏分散・不偏共分散を成分に持つ行列 $S = (S_{ij})$ です。

Important

📄 不偏分散共分散の定義式

i 番目の変数と j 番目の変数の共分散成分 S_{ij} は以下の式で計算されます。

$$S_{ij} = \frac{1}{n-1} \sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)$$

ここで x_{ki} は「 k 番目のサンプルの i 番目の変数の値」を表します。分母が $n-1$ になっているのは、自由度を調整して「偏り」をなくするため（不偏性）です。

相関行列

各成分を相関係数 $\rho[x_i, x_j]$ とした行列です。対角成分は全て 1 になります。

- 標本相関行列：

実データから計算された相関係数を成分に持つ行列です。

何これ：多次元の「ゆらぎの形状」を記述する慣性テンソル

物理系の方にとって、分散共分散行列は力学における**「慣性テンソル（Inertia Tensor）」**そのものです。

Note

物理的・幾何学的解釈

対角成分は「各軸方向のモーメント（分散）」、非対角成分は「軸間の歪み（共分散）」を表します。

データが多次元空間に作る「雲（楕円体）」の形状を完全に記述しており、**非対角成分がゼロでない = データの主軸が座標軸に対して傾いている**ことを意味します。

何が嬉しいのか？：線形代数を使って「データの固有状態」を抽出できる

確率変数をベクトルや行列で記述することで、第22章以降の「多変量解析」において、固有値問題などの線形代数の手法がそのまま炸裂します。

Tip

🔥 ここがチート！主成分分析（PCA）の正体

分散共分散行列 S は「対称行列」なので、必ず直交行列を使って対角化できます。

これを物理に翻訳すると、**「慣性主軸を求める（対角化する）」ことで、データ間の相関を消し去り、最も情報のゆらぎが大きい方向（主成分）を特定する**という作業になります。

剛体の回転において、最も回転させやすい（またはにくい）軸を探すのと、数学的に全く同じ操作でデータの特徴抽出ができるのです。

4 変数変換

4.1 $Y = g(X)$ の変換

$f_X(x) \mapsto f_Y(y)$ が目標

$$\begin{aligned} f_Y(y) &= f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right| \\ &= f_X(g^{-1}(y)) \left| \frac{1}{g'(g^{-1}(y))} \right| \end{aligned}$$

何これ：確率という「粉」の総量（面積=1）を保つための「連続の式（質量保存則）」

物理の流体力学などで出てくる**「連続の式（ $\rho_1 V_1 = \rho_2 V_2$ ）」**と全く同じ考え方です。

Note

物理的解釈：なぜ絶対値の微分（ヤコビアン）が掛かっているのか？

確率密度関数 $f(x)$ は、単なる「値」ではなく「密度（濃さ）」です。

もし変数変換 $Y = 2X$ を行っただとします。これは空間を「2倍に引き伸ばす」操作です。空間が2倍に広がったのに、粉（確率）の濃さがそのままだったら、全確率の合計が2倍に増えて宇宙が崩壊してしまいます。

だから、空間を引き伸ばした分だけ、密度は薄めないとはいけません。この**「空間の伸び縮み率（体積変化率）」を補正する係数が、右辺にくっついている微分の絶対値（ヤコビアン）の正体**です。

何が嬉しいのか？

手元にあるデータ X に、何かしらの関数 g を噛ませて Y という新しい指標を作ったとき（例：半径 X の分布から、面積 $Y = \pi X^2$ の分布を知りたいとき）、その新しい指標 Y がどんな確率分布に従うかを、元の分布 f_X から正確に逆算して求めることができます。

4.2 $Z = X + Y$ の変換

$Z = X + Y$, $T = Y$ の変換を考えると、 $f_X(x)f_Y(y) \mapsto f_Z(z)$ が目標なので、

$$\left| \begin{array}{cc} \frac{\partial x}{\partial z} & \frac{\partial x}{\partial t} \\ \frac{\partial y}{\partial z} & \frac{\partial y}{\partial t} \end{array} \right| f_Z(z) dz dt = f_X(x) f_Y(y) dx dy$$

なので、

$$\begin{aligned} f_Z(z) &= f_X(x) f_Y(y) \\ &= \int_{-\infty}^{\infty} f_X(z-t) f_Y(t) dt \end{aligned}$$

(※補足：チートシートの2行目 $f_Z(z) = f_X(x) f_Y(y)$ は、厳密には同時確率密度関数 $f_{Z,T}(z,t) = f_X(z-t) f_Y(t) \times |J|$ のことですね！そこから邪魔な変数 T を積分して消去（周辺化）した結果が3行目になります。）

何これ：波の「畳み込み（コンボリューション）」

物理や信号処理で頻出する**「畳み込み積分」**そのものです。

Tip

💡 直感的なイメージ：サイコロを2つ振って「和が z 」になる確率

例えば「2つのサイコロの目の和が5になる確率」を求めるとき、どう計算しますか？

「(1,4), (2,3), (3,2), (4,1)」のパターンを全部足しますよね。

これを連続関数でやっているのが上の積分式です。

- t : 1つ目の変数（サイコロの目）
- $z-t$: 和を z にするために、2つ目の変数が**「絶対に取らなければならない値」**

つまり、 z という結果を作るための「すべての組み合わせの確率の掛け算」を、直線 $x+y=z$ に沿ってダーツと積分して足し合わせているだけです。

何が嬉しいのか？

独立な2つのノイズ源（例：測定器の熱雑音 X と、環境の電磁ノイズ Y ）が同時に乗ってきたとき、最終的に観測されるノイズ Z がどんな分布の形になるのかを計算できます。

4.3 Box-Cox変換

非対称であるなど、正規分布からずれている非負のデータ x を正規分布に近づける次の変換のこと。

$$x \mapsto \begin{cases} \frac{x^\lambda - 1}{\lambda} & (\text{for } \lambda \neq 0) \\ \log(x) & (\text{for } \lambda = 0) \end{cases}$$

λ の値を変化させることでべき乗変換や対数変換など、様々な変換が可能であり、その中で変換後のデータが正規分布に近づくものを選択します。

何これ：歪んだ世界を「正規分布（ユークリッド空間）」に無理やり平坦化する魔法のレンズ

物理で言えば、**「現象のスケール（次元）に合わせて、観測する目盛りをリニアから対数などに切り替える作業の自動化」**です。

Important

🔥 ここが美しい！なぜ $\lambda = 0$ で突然 $\log$ が出てくるのか？

数式をパッと見ると、「 λ が0以外の時はべき乗なのに、なんで $\lambda = 0$ のときだけ突然 $\log$ （対数）になるの？ 繋がりがなくない？」と不思議に思いませんか？

実はこれ、上の式 $\frac{x^\lambda - 1}{\lambda}$ において、 $\lambda \rightarrow 0$ の極限をとり、ロピタルの定理（分母と分子を λ で微分）を適用すると、見事に $\log(x)$ に一

致するのです。
つまり、この2つの式は全く別物ではなく、1つの滑らかな数式の「連続した家族」になっています。

何が嬉しいのか？

統計学や機械学習の手法（t検定、回帰分析など）は、基本的に**「データが正規分布（左右対称の綺麗なベルカーブ）に従っていること」**を前提として作られています。

しかし、現実のデータ（年収、待ち時間、地震のエネルギーなど）は右に裾を引いた歪んだ分布ばかりです。

Box-Cox変換は、パラメータ λ のツマミをグリグリと回すだけで、

- $\lambda = 1$ （何もしない）
- $\lambda = 0.5$ （ルートをとる）
- $\lambda = 0$ （対数をとる：地震のマグニチュードや音のデシベルと同じ）
- $\lambda = -1$ （逆数をとる：速度を「ペース」に変換するようなもの）

というあらゆる変換をシームレスに試し、一番データが正規分布に近くなる「最適なツマミの位置（ λ ）」をコンピュータに見つけさせることができる、超強力な前処理ツールです。

5 離散型分布

5.1 離散一様分布

$$p(X = x_i) = \frac{1}{n} \quad (\text{for } i \in \{1, 2, \dots, n\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = \frac{n+1}{2} \\ V[X] = \frac{n^2-1}{12} \\ G(s) = E[s^X] = \frac{s(1-s^n)}{n(1-s)} \end{cases}$$

何これ：すべての選択肢が完全に平等な、もっともピュアな「サイコロ」の分布

物理の言葉で言えば、すべての状態が等確率で発現する**「ミクロカノニカルアンサンブル（等確率の原理）」**そのものです。偏りが一切ない、完全に公平な状態を表します。

Note

特性値の数学的トリック

- 平均 $\frac{n+1}{2}$ ：1から n までの数字を綺麗に並べたときの、ど真ん中の重心位置です。
- 分散の分母にある「12」という謎の数字：これは綺麗な連続空間の一様分布の分散 $\frac{(b-a)^2}{12}$ につながる重要な数字です。自然数の2乗の和の公式 $\sum k^2 = \frac{1}{6}n(n+1)(2n+1)$ を展開して整理していく過程で、この「12」が必然的に浮かび上がってきます。
- 確率母関数 $G(s)$ ：数式を展開すると $\frac{1}{n}(s^1 + s^2 + \dots + s^n)$ となります。これは初項 $\frac{s}{n}$ 、公比 s 、項数 n の等比数列の和の公式そのものです。

5.2 ベルヌーイ分布

コイン投げのように、結果が2通り（一方を成功、他方を失敗と呼ぶ）の試行をベルヌーイ試行と言い、ベルヌーイ試行を1回行ったときの成功回数がしたがう確率分布。ベルヌーイ試行の成功確率を p として、ベルヌーイ分布を $Bin(1, p)$ と表します。

$$p(X = x) = p^x(1-p)^{1-x} \quad (\text{for } x \in \{0, 1\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = p \\ V[X] = p(1-p) \\ G(s) = E[s^X] = ps + 1 - p \end{cases}$$

何これ：すべての離散型分布の「原子」（1回きりの丁半バクチ）

物理の量子力学でいう**「スピン1/2の系（アップかダウンか）」や、情報理論の「1ビット（0か1か）」**に相当する、これ以上分解できない最小単位の分布です。

Tip

💡 数式のハック：なぜ $p^x(1-p)^{1-x}$ なんて回りくどい書き方をするのか？

プログラミングにおける「if文（条件分岐）」を、数式1行でスマートに表現するためのチートテクニックです。

- 成功 ($x = 1$) のとき： $p^1 \times (1-p)^0 = p$ となり、成功確率だけが残る。
- 失敗 ($x = 0$) のとき： $p^0 \times (1-p)^1 = 1-p$ となり、失敗確率だけが残る。

x に0か1を代入するだけで、自動的に確率が切り替わるシステムになっています。

何が嬉しいのか？

一見単純ですが、分散 $V[X] = p(1-p)$ の性質が非常に面白いです。この値は $p = 0.5$ （五分五分）のときに最大値 0.25 になります。確率が $p = 0.9$ （ほぼ成功する）や $p = 0.1$ （ほぼ失敗する）のように偏っているときは、「結果が予想しやすい」ため、ばらつき（物理でいうエントロピー）は小さくなります。完全に予測不可能でカオスなときほど、分散が最大になるという直感と一致します。

5.3 二項分布

成功確率 p の独立なベルヌーイ試行を n 回行ったときの成功回数がしたがう確率分布で、 $Bin(n, p)$ と表します。確率関数は次の通りです。

$$p(X = x) = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \quad (\text{for } x \in \{0, 1, \dots, n\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = np \\ V[X] = np(1-p) \\ G(s) = E[s^X] = (ps + 1 - p)^n \end{cases}$$

二項分布には再生性があり、 $X_1 \sim Bin(n_1, p)$, $X_2 \sim Bin(n_2, p)$ が独立であるとき、 $X_1 + X_2 \sim Bin(n_1 + n_2, p)$ が成り立ちます。

何これ：ベルヌーイ分布の「コピペ&足し算」

先ほどのベルヌーイ分布を、独立に n 回繰り返して全部足し合わせたものです。

Important

💡 ここがチート！特性値はすべて「 n 倍」するだけ

独立な確率変数を足し算するとき、**「平均も分散も、そのまま足し算していい」**という強力な性質（2.1や3.4の応用）がありました。

そのため、1回あたりの平均が p 、分散が $p(1-p)$ なら、 n 回合わせた二項分布の平均は np 、分散は $np(1-p)$ と、ただの n 倍で一瞬で導出できます。

確率母関数 $G(s)$ も、「和の分布は母関数の積」というルール通り、ベルヌーイの式 $(ps + 1 - p)$ を単純に n 乗するだけで完成します。

何が嬉しいのか？（再生性の意味）

「再生性」とは、**「同じ確率のガチャなら、別々に引いて後から合算しても、最初からまとめて引いても同じ分布になる」**という性質です。「午前中に10回ガチャを引く ($Bin(10, p)$)」のと「午後に20回ガチャを引く ($Bin(20, p)$)」のを合計したデータは、完全に「1日に30回ガチャを引く ($Bin(30, p)$)」という1つの二項分布として綺麗にマージして扱えます。

5.4 超幾何分布

N 本のくじの中に M 本の当たりがあり、 n 本のくじを非復元抽出するとき、ひいた当たりの本数がしたがう確率分布で、 $HG(N, M, n)$ と表します。

$$p(X = x) = \frac{{}_M C_x \cdot {}_{N-M} C_{n-x}}{{}_N C_n} \quad (\text{for } x \in [\max\{0, n - (N - M)\}, \min\{n, M\}])$$

この時、以下のようになっている

$$\begin{cases} E[X] = \frac{nM}{N} \\ V[X] = \frac{nM}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1} \end{cases}$$

n と M/N を一定にしたまま、 $N \rightarrow \infty$ とすると、二項分布 $Bin(n, M/N)$ に収束します。

何これ：くじを「戻さない（非復元）」せいで、引くたびに確率が変化するリアルな二項分布

二項分布との決定的な違いは、**「引いたくじを箱に戻さない」という点です。1人目が当たりを引くと、2人目の当たる確率は下がります。つまり、試行同士が独立ではなく、お互いに影響を与え合う（相関がある）**状態の分布です。

Important

🔥 ここに注目！分散の後ろにくっっている不気味な係数の正体

超幾何分布の平均は $\frac{nM}{N}$ であり、これは当たり確率を $p = \frac{M}{N}$ とおけば、二項分布の平均 np と全く同じです。

しかし、分散の式をよく見ると、二項分布の分散 $np(1-p)$ の後ろに、 $\frac{N-n}{N-1}$ という見慣れない係数が掛け算されています。これを統計学では**「有限母集団修正」**と呼びます。この係数が、非復元抽出の「お互いに影響し合う性質」を完璧に制御しています。

- もし $n = 1$ （1回しか引かない）なら：

$\frac{N-1}{N-1} = 1$ となり、二項分布の分散と完全に一致します（1回だけなら戻すも戻さないもないため）。

- もし $n = N$ （箱の中身をすべて引ききる）なら：

分子が $N - N = 0$ になるため、**分散（ばらつき）はゼロになります**。当たり前ですよ。箱の中身を全部引いたら、手元にある当たりの本数は「絶対に M 本」であり、一切のゆらぎが発生しないからです。

何が嬉しいのか？

もし箱の中にある総くじ数 N が無限に大きい（ $N \rightarrow \infty$ ）とすると、この有限母集団修正の項は $\lim_{N \rightarrow \infty} \frac{N-n}{N-1} = 1$ となり、消滅します。

つまり、「琵琶湖の水からコップ1杯の水をすくい取る」ような巨大な対象（無限母集団）からデータをサンプリングするときは、いちいち戻さなくても、計算が簡単な二項分布（復元抽出）として扱って良いという強力な保証（近似）を与えてくれます。

5.5 Poisson（ポアソン）分布

$\lambda > 0$ を平均発生率とすると、特定の時間（空間）内に事象が x 回発生する確率のモデル化に用いられる確率分布で、 $Po(\lambda)$ と表します。

$$p(X = x) = \frac{\lambda^x e^{-\lambda}}{x!} \quad (\text{for } x \in \{0, 1, 2, \dots\})$$

この時、以下のようになっている

$$\begin{cases} E[X] = \lambda \\ V[X] = \lambda \\ G(s) = E[s^X] = e^{(s-1)\lambda} \end{cases}$$

ポアソン分布には再生性があり、 $X_1 \sim Po(\lambda_1)$, $X_2 \sim Po(\lambda_2)$ が独立であるとき、 $X_1 + X_2 \sim Po(\lambda_1 + \lambda_2)$ が成り立ちます。

二項分布 $Bin(n, p)$ で、 $np = \lambda, n \rightarrow \infty$ とすると、 $Po(\lambda)$ に分布収束します。（少数の法則）

何これ：無限回クジを引けるが、当たる確率がほぼゼロの世界（レア事象の分布）

物理で言えば、**「放射性物質の崩壊」や「単位面積に降り注ぐ雨粒の数」**などを記述する分布です。

 Note 直感的なイメージ：二項分布の極限

「少数の法則」とあるように、ポアソン分布は二項分布の親戚です。

例えば、「1年（365日）で交通事故に遭う回数」を考えます。これは $n = 365$ 、 $p = (\text{1日の事故発生率})$ の二項分布です。

さらに細かく「1時間単位」「1秒単位」と区切っていくと、 n は無限大 (∞) に近づき、 p は限りなくゼロ (0) に近づきます。しかし、1年間の「平均事故回数 ($np = \lambda$)」は一定です。

このように、**「いつ起きるか全く予測できないが、平均すると一定期間に λ 回起きる」**という現象を見事に数式化したのがポアソン分布です。

何が嬉しいのか？

二項分布の計算には「試行回数 n 」と「確率 p 」の2つの情報が必要ですが、ポアソン分布は**「平均発生回数 λ 」というたった1つのパラメータだけで完全に形が決まる**という超お手軽仕様になっています。しかも「**平均=分散= λ** 」となるため、計算が劇的に楽になります。

5.6 幾何分布

独立な成功確率 p のベルヌーイ試行をくり返すとき、はじめての成功が起きるまでの失敗の回数 X がしたがう分布で、 $Geo(p)$ と表します。

$$p(X = x) = p(1 - p)^x \quad (\text{for } x \in \{0, 1, 2, \dots\})$$

この時、以下のようにになっている

$$\begin{cases} E[X] = \frac{1-p}{p} \\ V[X] = \frac{1-p}{p^2} \\ G(s) = E[s^X] = \frac{p}{1 - (1-p)s} \end{cases}$$

幾何分布については、どんな0以上の整数 m, n に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$p(X \geq m + n | X \geq m) = p(X \geq n)$$

[Image of geometric distribution mass function]

何これ：「SSRが出るまでガチャを引き続ける」ときの、爆死回数の分布

「いつか必ず成功するけど、それまでに何回失敗するかな？」をモデル化したものです。

 Important ここがポイント：残酷な「無記憶性 (Memoryless Property)」

無記憶性の数式を言葉に翻訳すると、こうなります。

「すでに m 回連続でガチャを外している ($X \geq m$) という条件下で、さらに追加で n 回外す確率は、最初から n 回外す確率と全く同じである」

つまり、「これまで99回外したから、そろそろ当たるだろう」という人間の期待を数学は冷酷に打ち砕きます。サイコロやガチャは過去の失敗を一切記憶していません。いついかなる時も、確率は常にリセットされて一定なのです（連続型分布における「指数分布」も全く同じ性質を持ちます）。

5.7 負の二項分布

成功確率 p のベルヌーイ試行をくり返すとき、 r 回目の成功が起きるまでの失敗の回数がしたがう分布で、 $NB(r, p)$ と表します。 $r = 1$ のときには幾何分布に一致します。

$$p(X = x) = {}_{r+x-1}C_x p^r (1 - p)^x \quad (x \in \{0, 1, 2, \dots\})$$

この時、以下のようになっている

(※ご提示の分散の式は分子に p が余分に入っていたので、 $r(1-p)/p^2$ にそっと修正しておきますね！)

$$\begin{cases} E[X] = \frac{r(1-p)}{p} \\ V[X] = \frac{r(1-p)}{p^2} \\ G(s) = E[s^X] = \left(\frac{p}{1-(1-p)s} \right)^r \end{cases}$$

負の二項分布には**再生性**がある

何これ：幾何分布の「コピペ&足し算」(目的のアイテムを r 個集めるまでの道のり)

幾何分布が「1回成功するまで」なら、負の二項分布は「 r 回成功するまで」の分布です。

Tip

💡 特性値のチート導出

「 r 回成功するまでの失敗回数」は、「1回成功するまでの失敗回数(幾何分布)」を r 回独立に繰り返して足し合わせたものと全く同じです。だから、**平均も、分散も、幾何分布の公式を単純に「 r 倍」するだけで完成します**。確率母関数 $G(s)$ も、幾何分布の母関数を「 r 乗」するだけです。再生性(同じ分布同士を足すと、パラメータが足される性質)があるのもこのためです。

5.8 多項分布

ベルヌーイ試行は結果が2通りですが、より一般的に結果が k 通りで、それぞれが起こる確率が $p_1, p_2, \dots, p_k$ ($p_1 + p_2 + \dots + p_k = 1$) で一定の場合を多項試行と呼ぶことにします。独立な多項試行を n 回行ったとき、 k 通りの結果が起きる回数がしたがう確率分布が多項分布で、 $M(n; p_1, p_2, \dots, p_k)$ と表します。 $k = 2$ のときには二項分布に一致します。

$$p(X_1 = x_1, \dots, X_k = x_k) = \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k} \quad (\text{for } x_1 + \dots + x_k = n)$$

$(X_1, \dots, X_k) \sim M(n; p_1, \dots, p_k)$ のとき、 $X_i \sim \text{Bin}(n, p_i)$ であり、 X_i と X_j ($i \neq j$) の共分散と相関係数は次の通りです。

(※相関係数もルートが分母にまで掛かる形に整理して修正しています！)

$$\begin{cases} \text{Cov}(X_i, X_j) = -np_i p_j \\ \rho(X_i, X_j) = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}} \end{cases}$$

何これ：コイン(2面)の世界から、サイコロ(多面)の世界への拡張

二項分布を「他次元ベクトル」に拡張したものです。「アンケートでA党、B党、C党にそれぞれ何票入るか」といったデータを扱うときの基本になります。

Note

📌 物理的解釈：なぜ共分散と相関係数が「マイナス」になるのか？

共分散の式にマイナスがついているのが最大のポイントです。

多項分布は「全体の試行回数 n が固定されている(保存則がある)」という制約の中で動いています。

つまり、**「項目 i の回数(例：サイコロの1の目)がたくさん出た」ということは、必然的に「他の項目 j の回数(例：サイコロの2の目)はその分だけ減る」**というゼロサムゲームになっているのです。誰かが得をすれば誰かが損をするため、変数同士の関係(相関)は必ずマイナスになります。

https://toketarou.com/quasi_1_cheatsheet/#toc4