

統計検定準1級section6

- 統計検定準1級section6
 - 6 連続型分布と標本分布
 - 6.1 連続一様分布
 - 何これ：どこを切っても「金太郎飴」のような、完全に平坦な確率の海
 - 6.2 正規分布
 - 何これ：統計学における「絶対王者」。自然界のノイズが行き着く究極の姿
 - 6.3 指数分布
 - 何これ：「いつ起きるか分からない突発イベント」を待ち続ける時間の分布
 - 6.4 ガンマ分布
 - 何これ：指数分布の「コピペ&足し算」（目的のイベントが a 回起こるまでの待ち時間）
 - 6.5 ベータ分布
 - 何これ：「確率」そのものの確率分布（コインの歪み具合を推理する）
 - 6.6 対数正規分布
 - 何これ：「掛け算」で増えていく現象（乗法過程）がたどり着く姿
 - 6.7 多変量正規分布
 - 何これ：多次元空間に浮かぶ、傾いた「ラグビーボール型の雲」
 - 6.8 混合正規分布
 - 何これ：異なる背景を持つ集団がごちゃ混ぜになった、ふたつの「山」を持つ分布
 - 6.8.1 パラメータ推定（EMアルゴリズム）
 - 何が嬉しいのか？：「卵が先か鶏が先か」を交互に解く機械学習の超絶テクニック
 - 6.9 カイ二乗分布
 - 何これ：ランダムな矢印（ベクトル）の「長さの2乗」の分布
 - 6.9.1 非心カイ二乗分布
 - 何これ：「的の中心（原点）」から狙いがズレているときの散らばりの分布
 - 6.10 t分布
 - 何これ：データ数が少なくて「真のばらつき」が分からないときの、実戦向けの正規分布

https://toketarou.com/quasi_1_cheatsheet/

6 連続型分布と標本分布

6.1 連続一様分布

区間 $[a, b]$ で一定の確率密度をもつ確率分布で、 $a < b$ として、 $U(a, b)$ と表します。

$$f(x) = \begin{cases} 0 & (x \notin [a, b]) \\ \frac{1}{b-a} & (x \in [a, b]) \end{cases}$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{a+b}{2} \\ V[X] = \frac{(b-a)^2}{12} \\ M(t) = E[e^{tX}] = \frac{e^{bt} - e^{at}}{(b-a)t} \end{cases}$$

何これ：どこを切っても「金太郎飴」のような、完全に平坦な確率の海

離散一様分布（サイコロ）の連続空間バージョンです。ルーレットの針が止まる角度（0 から 360 度）のように、どの値も全く同じ確率で出現する状態を表します。

Note

物理的・幾何学的解釈

- 分散の「12」という数字**：前章の離散一様分布でも登場しましたが、連続空間の場合、分散は積分 $\int x^2 dx = \frac{1}{3}x^3$ から計算されます。この積分の「3」と、幅を計算する際の操作などが組み合わさり、必然的に分母に「12」が現れます。慣性モーメントの計算で、棒の重心周りの回転の式が $\frac{1}{12}ML^2$ になるのと同じ数学的構造です！

6.2 正規分布

偶然誤差に見られるように、平均 μ を中心とする対称な確率分布で、 $\sigma > 0$ として、 $N(\mu, \sigma^2)$ と表します。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

特に、 $\mu = 0, \sigma^2 = 1$ の場合を**標準正規分布**と言います。
この時次が成り立つ。

$$\begin{cases} E[X] = \mu \\ V[X] = \sigma^2 \\ M(t) = E[e^{tX}] = \exp\left(\mu t + \frac{1}{2}\sigma^2 t^2\right) \end{cases}$$

正規分布には再生性があり、 $X_1 \sim N(\mu_1, \sigma_1^2)$, $X_2 \sim N(\mu_2, \sigma_2^2)$ が独立であるとき、 $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ が成り立ちます。
より一般的に、 $aX_1 + bX_2 \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2)$ も成り立ちます。

[Image of normal distribution curve with standard deviations]

何これ：統計学における「絶対王者」。自然界のノイズが行き着く究極の姿

物理系の方にとっては**「マクスウェル＝ボルツマン分布」の速度成分や、量子力学の「ガウス波束（基底状態の波動関数）」**そのものです。

Important

🔥 何が嬉しいのか？：中心極限定理の主役

コイン投げだろうが、サイコロだろうが、ポアソン分布だろうが、**「独立な確率変数を大量に足し合わせると、元の分布の形に関係なく、最終的に必ずこの正規分布の形になる」**という宇宙の法則（中心極限定理）があります。

ランダムウォーク（ブラウン運動）を無限に繰り返した粒子の存在確率も正規分布になりますし、熱雑音も正規分布です。「細かい無数の要因が足し合わさってできた結果」はすべてコレに従うため、統計学の基準として圧倒的に多用されます。

6.3 指数分布

機械が故障するまでの時間などを表すのにも使われる確率分布で、 $\lambda > 0$ として、 $Exp(\lambda)$ と表します。

$$f(x) = \lambda e^{-\lambda x}$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{1}{\lambda} \\ V[X] = \frac{1}{\lambda^2} \\ M(t) = E[e^{tX}] = \frac{\lambda}{\lambda - t} \end{cases}$$

指数分布については、どんな正の数 a, b に対しても次の式が成り立ちます。これを**無記憶性**と言います。

$$p(X \geq a + b | X \geq a) = p(X \geq b)$$

何これ：「いつ起きるか分からない突発イベント」を待ち続ける時間の分布

前章の「幾何分布（ガチャが当たるまでの回数）」の連続時間バージョンです。物理では**「放射性同位体が崩壊するまでの時間」**の分布と全く同じ式です（半減期の計算でおなじみですね）。

Tip

💡 ポアソン分布との密接な関係

ポアソン分布と指数分布は表裏一体です。

- **ポアソン分布**：1時間に平均 λ 台のバスが来る確率。
- **指数分布**：そのバスが「次に来るまでの待ち時間（間隔）」の確率。

ここにも**無記憶性**があります。「もう30分も待ってるんだから、そろそろ来るだろう」という人間の期待は通用しません。いまこの瞬間からさらに b 分待つ確率は、最初から b 分待つ確率と同じです。放射性原子が「俺はもう1億年崩壊せずに我慢したから、そろそろ崩壊しようかな」と思わないのと同じです。

6.4 ガンマ分布

$x > 0$ で定義される確率分布で、 $a > 0, b > 0$ として、 $Ga(a, b)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\Gamma(a)b^a} x^{a-1} e^{-\frac{x}{b}} \quad (x \geq 0)$$

a を**形状母数**、 b を**尺度母数**と言い、上の式の $\Gamma(a)$ はガンマ関数です。 $a = 1$ のときには、指数分布 $Exp(1/b)$ に一致します。この時が成り立つ。

$$\begin{cases} E[X] = ab \\ V[X] = ab^2 \\ M(t) = E[e^{tX}] = (1 - bt)^{-a} \end{cases}$$

ガンマ分布には再生性があり、 $X_1 \sim Ga(a_1, b)$ 、 $X_2 \sim Ga(a_2, b)$ が独立であるとき、 $X_1 + X_2 \sim Ga(a_1 + a_2, b)$ が成り立ちます。

何これ：指数分布の「コピペ&足し算」（目的のイベントが a 回起こるまでの待ち時間）

幾何分布に対する「負の二項分布」の関係と同じです。指数分布が「1回目」のイベントが起きるまでの時間なら、ガンマ分布は「 a 回目」のイベントが起きるまでの時間の分布です。

Note

📌 数式のハック

- 形状母数 a が整数の場合、ガンマ分布は**「互いに独立な a 個の指数分布 $Exp(1/b)$ を足し合わせたもの（アーラン分布）」**になります。
- だから、平均は単に指数分布の平均 b （※ $\lambda = 1/b$ の場合）を a 倍した ab になり、分散も a 倍の ab^2 になります。再生性があるのも、単なる「足し算の拡張」だからです。

6.5 ベータ分布

$0 < x < 1$ で定義される確率分布で、 $a > 0, b > 0$ として、 $Be(a, b)$ と表します。

$$f(x) = \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} \quad (0 \leq x \leq 1)$$

この時次が成り立つ。

$$\begin{cases} E[X] = \frac{a}{a+b} \\ V[X] = \frac{ab}{(a+b)^2(a+b+1)} \end{cases}$$

何これ：「確率」そのものの確率分布（コインの歪み具合を推理する）

X の範囲が $[0, 1]$ （つまり 0% から 100%）に限定されているのが最大の特徴です。これは**「確率（ p ）」がどんな値を取りそうか」を表現するための分布**です。

Tip

💡 何が嬉しいのか？：ベイズ統計の親友（共役事前分布）

未知のコインを投げて「表が $a-1$ 回、裏が $b-1$ 回」出たとき、「このコインの本当の『表が出る確率 X 』はどれくらいだろうか？」と推理（ベイズ推定）した結果が、そのままベータ分布の形になります。

式の中に $x^{a-1}(1-x)^{b-1}$ とあるように、これは**二項分布の $p^x(1-p)^{n-x}$ の p を主役（変数）にすり替えたもの**です。

6.6 対数正規分布

$Y \sim N(\mu, \sigma^2)$ のとき、 $X = e^Y$ がしたがう確率分布で、 $\Lambda(\mu, \sigma^2)$ と表します。確率密度関数は次の通りです。

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2x}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right) \quad (\text{for } x \geq 0)$$

この時次が成り立つ。

$$\begin{cases} E[X] = \exp\left(\mu + \frac{1}{2}\sigma^2\right) \\ V[X] = \exp(2\mu + \sigma^2)(\exp(\sigma^2) - 1) \end{cases}$$

何これ：「掛け算」で増えていく現象（乗法過程）がたどり着く姿

正規分布が「細かい要因の足し算」で生まれるなら、対数正規分布は「細かい要因の掛け算」で生まれます。

Important

🔥 物理的・現実的解釈

- **なぜ対数をとるのか？**： $\log X = Y$ ですから、「掛け算（ $X = A \times B \times C \dots$ ）」の世界を対数によって「足し算（ $\log X = \log A + \log B + \log C \dots$ ）」の世界に変換しています。足し算の世界（ Y ）なら、中心極限定理が発動して正規分布 $N(\mu, \sigma^2)$ になりますよね。それを元の世界（ X ）に戻したのが対数正規分布です。
- **実例**：株価の変動、年収の分布、岩石を砕いたときの破片の大きさ（砕くたびに体積が「何分の一」となるという掛け算）など、右に長く裾を引く非対称なデータの多くがこの分布に従います。

6.7 多変量正規分布

$\mathbf{x} = (x_1, \dots, x_k)^T$ ，その平均ベクトルを $\boldsymbol{\mu} = (\mu_1, \dots, \mu_k)^T$ ，分散共分散行列を Σ とする k 変量正規分布を $N(\boldsymbol{\mu}, \Sigma)$ と表します。同時確率密度関数は次の通りです。

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k |\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

2変量の場合には次のように表せます。

$$f(\mathbf{x}) = \frac{1}{2\pi\sqrt{|\Sigma|}} \exp\left[-\frac{1}{2}\begin{pmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{pmatrix} \Sigma^{-1} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}\right]$$

また、 X_1 と X_2 の相関係数を ρ として、 $(X_1, X_2)^T$ が次の2変量正規分布にしたがうとき、 $X_1 \sim N(\mu_1, \sigma_1^2)$ 、 $X_2 \sim N(\mu_2, \sigma_2^2)$ が成り立ちます。

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N \left[\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right]$$

このとき、 $aX_1 + bX_2$ は次の正規分布にしたがいます。

$$aX_1 + bX_2 \sim N[a\mu_1 + b\mu_2, a^2\sigma_1^2 + 2ab\rho\sigma_1\sigma_2 + b^2\sigma_2^2]$$

$X_1 = x_1$ が与えられたときの X_2 の条件付き分布は次の期待値、分散をもつ正規分布です。

$$E[X_2 | X_1 = x_1] = \mu_2 + \frac{\rho\sigma_1\sigma_2}{\sigma_1^2}(x_1 - \mu_1)$$

$$V[X_2 | X_1 = x_1] = \sigma_2^2(1 - \rho^2)$$

何これ：多次元空間に浮かぶ、傾いた「ラグビーボール型の雲」

1次元のベルカーブ（山）を、多次元空間に拡張したものです。上から等高線を見ると、データは綺麗な楕円の形に広がっています。

Note

幾何学的解釈と予測への応用

- **行列の正体**：指数関数の中身にある $(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ は、幾何学的には**「マハラノビス距離の2乗」**を表しています。分散が大きく傾いている方向を自動的に補正し、公平に距離を測る「計量テンソル」の役割を果たします。
- **何が嬉しいのか？**：条件付き期待値の式は、まさに X_1 から X_2 を当てる**「回帰直線」**の式です。条件付き分散 $V[X_2 | X_1 = x_1] = \sigma_2^2(1 - \rho^2)$ を見ると、相関 ρ がある情報を知ることによって、予測のブレが元の分散より確実に小さく（鋭く）なることがわかります。

6.8 混合正規分布

複数の正規分布を合成してできる確率分布。例えば、 $N(0, 1)$ の確率密度関数を $\phi_1(x)$ 、 $N(4, 1)$ の確率密度関数を $\phi_2(x)$ として、 $f(x) = 0.3\phi_1(x) + 0.7\phi_2(x)$ は2成分混合正規分布の確率密度関数である。これが一般にすると以下のようになる。

$$f(x) = \sum_{j=1}^k \pi_j \phi_j(x) \quad \left(\text{where } \sum_{j=1}^k \pi_j = 1 \right)$$

【例題】大学入試における合格確率

ある大学の入試では60点以上の得点が合格である。

受験者のうち、文系と理系の生徒の割合は 2 : 1 であり、それぞれの得点分布は以下に従うとする。

- 文系の得点： $N(55, 6^2)$
- 理系の得点： $N(65, 8^2)$

ランダムに選んだ1人の受験生の得点を X 、標準正規分布の確率密度関数を $\phi(x)$ としたとき、その受験生が合格 ($X \geq 60$) である確率は次のように求められる。

$$P(X \geq 60) = \frac{2}{3}P\left(Z \geq \frac{60 - 55}{6}\right) + \frac{1}{3}P\left(Z \geq \frac{60 - 65}{8}\right)$$

何これ：異なる背景を持つ集団がごちゃ混ぜになった、ふたつの「山」を持つ分布

これまでの確率分布は山が1つ（単峰性）でしたが、現実の世界は「文系と理系」「男性と女性」のように、**性質の違う複数のグループが混ざり合って、山が2つ以上できている**ことがよくあります。これを数学的に表現したのが混合正規分布です。

6.8.1 パラメータ推定（EMアルゴリズム）

手元にある観測データ $x_1, x_2, \dots, x_n$ から、混合分布を構成する各分布のパラメータ（平均・分散・混合比）を推定する。
ここでは2成分混合正規分布の確率密度関数を以下のように定義する。

$$f(x) = \pi\phi_1(x) + (1 - \pi)\phi_2(x)$$

パラメータ $\theta = (\mu_1, \sigma_1^2, \mu_2, \sigma_2^2, \pi)$ が未知のとき、**EMアルゴリズム**を用いて次の手順で推定を行う。

① 初期値の設定

パラメータの初期値 $\theta^{(0)}$ を決定する。

② 【Eステップ】負担率の計算

現在のパラメータ $\theta^{(k)}$ を用いて、各観測値 x_i がグループ1 (ϕ_1) から得られた確率（負担率 γ_i ）を求める。

$$\gamma_i^{(k+1)} = \frac{\pi^{(k)}\phi_1(x_i | \mu_1^{(k)}, \sigma_1^{2(k)})}{\pi^{(k)}\phi_1(x_i | \mu_1^{(k)}, \sigma_1^{2(k)}) + (1 - \pi^{(k)})\phi_2(x_i | \mu_2^{(k)}, \sigma_2^{2(k)})}$$

③ 【Mステップ】パラメータの更新

②で求めた $\gamma_i^{(k+1)}$ を各データがグループ1に属する重みとして扱い、パラメータの $k + 1$ 回目の更新値を次の式で求める。

$$\begin{aligned}\mu_1^{(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} x_i}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\ \sigma_1^{2(k+1)} &= \frac{\sum_{i=1}^n \gamma_i^{(k+1)} (x_i - \mu_1^{(k+1)})^2}{\sum_{i=1}^n \gamma_i^{(k+1)}} \\ \pi^{(k+1)} &= \frac{1}{n} \sum_{i=1}^n \gamma_i^{(k+1)}\end{aligned}$$

（※ グループ2のパラメータ μ_2, σ_2^2 についても、重みを $(1 - \gamma_i^{(k+1)})$ に置き換えて同様に更新する）

④ 収束判定

パラメータの更新による変化量が十分に小さくなるまで、②（Eステップ）と③（Mステップ）を収束するまで繰り返す。

何が嬉しいのか？：「卵が先か鶏が先か」を交互に解く機械学習の超絶テクニック

データにラベル（「この点は文系」「これは理系」）がなくても、「文系の山」と「理系の山」を自動で分離するためのアルゴリズムです。

- **Eステップ**：いま仮置きしている山から見て、各データが「どちらの山から生まれたっばさ」があるかを確率（負担率）で割り振る。
- **Mステップ**：その割り振られた確率を「重み」として使い、各山の位置（平均・分散）を計算し直す。
これを繰り返すと、水と油が自然に分離するようにコンピュータが隠れたグループの境界線を見つけ出してくれます。

6.9 カイ二乗分布

n を自然数として、 $Ga(n/2, 2)$ を自由度 n のカイ二乗分布と言って、 $\chi^2(n)$ と表します。

1. $Z \sim N(0, 1)$ のとき、 $Z^2 \sim \chi^2(1)$ であり、 Z_i がそれぞれ独立であるならば、 $\sum_{i=1}^n Z_i^2 \sim \chi^2(n)$ です。
2. ガンマ分布の再生性から、 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$ で、 X と Y が独立ならば、 $X + Y \sim \chi^2(m + n)$ です。
3. $X \sim \chi^2(n)$ のとき、 $E[X] = n$, $V[X] = 2n$ です。モーメント母関数はガンマ分布のモーメント母関数から導けるので略。

何これ：ランダムな矢印（ベクトル）の「長さの2乗」の分布

物理の熱力学において、**「空間を飛び回る気体分子の運動エネルギーの分布」**そのものです。



💡 物理的・幾何学的イメージ

各座標軸方向の速度 Z_1, Z_2, Z_3 がそれぞれ独立な標準正規分布に従っているとき、原点からの「距離の2乗」は $Z_1^2 + Z_2^2 + Z_3^2$ になります。これが**自由度3のカイ二乗分布**です。自由度 n は「独立に動ける次元の数」であり、次元が増えれば増えるほど、距離の2乗の平均値も n に比例して大きくなります。

6.9.1 非心カイ二乗分布

Z_i が独立に標準正規分布に従い、 $\lambda = \sum_{i=1}^n \mu_i^2 \geq 0$ のとき、 $\sum_{i=1}^n (Z_i + \mu_i)^2 \sim \chi^2(n, \lambda)$ であり、この分布を**非心カイ二乗分布**と言います。これも再生性があり、 $X_i \sim \chi^2(n_i, \lambda_i)$ のとき、以下のように書ける。

$$\sum_{i=1}^n X_i \sim \chi^2\left(\sum_{i=1}^n n_i, \sum_{i=1}^n \lambda_i\right)$$

何これ：「**的の中心（原点）**」から狙いがズレているときの**散らばりの分布**

最初から中心が μ_i だけズレている（偏りがある）状態での、原点からの距離の2乗を測定しています。物理で言えば、全体として一定の速度（風）で移動している容器の中の、分子の運動エネルギー分布を測るようなものです。

6.10 t分布

$Z \sim N(0, 1)$, $Y \sim \chi^2(n)$ で Z と Y が独立のとき、次の T がしたがう確率分布を自由度 n のt分布と言って、 $t(n)$ と表します。

$$T \equiv \frac{Z}{\sqrt{Y/n}} \sim t(n)$$

$t(1)$ はコーシー分布に一致し、 $n \rightarrow \infty$ で $t(n)$ は標準正規分布に分布収束します。また、 $X \sim t(n)$ ならば、 $n > 1$ のとき $E[X] = 0$ で、 $n > 2$ のとき $V[X] = n/(n-2)$ です。

上の T の式で、 $Z \sim N(\lambda, 1)$ のとき、 T がしたがう確率分布を自由度 n 、非心度 λ の**非心t分布**と言います。

何これ：データ数が少なくて「**真のばらつき**」が分からないときの、**実戦向けの正規分布**

形は標準正規分布にそっくりですが、正規分布よりも**「裾が厚い（両端の確率が高い）」**のが特徴です。

Important

数式の構造を見破る：なぜ裾が厚くなるのか？

分子 Z はデータのズレを表しますが、分母 $\sqrt{Y/n}$ は「手元の少ないデータから見積もった、ばらつきの不確かさ」を表します。データ数が少ないと、分母のばらつき見積もり自体がたまたま小さくなってしまいう「ゆらぎ」が発生します。分母がランダムに変動するせいで、定数で割る時よりも**「確率的にとんでもない大外れの値」が出やすくなります**。これがt分布の裾が厚くなる理由です。データが増えれば分母のゆらぎは消え、完璧な標準正規分布に収束します。